

Chapter 1. 공간 데이터 과학과 GeoAI: 무엇을, 어느 축에서, 어느 층까지

공간 자료를 앞에 둔 분석자는 세 가지를 먼저 정한다. 이 분석을 무엇이라 부를 것인가, 답이 어느 분석 축에서 나오는가, 어느 층까지 갈 것인가. 이 장은 그 세 판정을 여섯 개의 질문으로 나누어 순서대로 다룬다. 각 질문에서 무엇을 입력으로 받아 어떤 기준으로 판정하고 어떤 기록을 남기는지 정리하고, 마지막 절에서 그 기록을 채우는 명세표를 제시한다.

홍수 대응을 예로 들면 판정의 필요성이 분명해진다. 위성영상에서 침수 픽셀을 분류하면 분류 정확도가 나온다. 그러나 예산을 배정하는 쪽이 필요로 하는 값은 정확도가 아니라 행정동별 침수 건물 수, 차단된 도로 구간, 고립 위험 생활권, 복구 우선순위다. 두 값은 자료 형식도 다르고 단위도 다르다. 픽셀 단위 판독에서 행정동 단위 우선순위로 옮겨 가려면 어떤 공간 단위를 쓸지, 무엇을 가중치로 삼을지를 먼저 정해야 한다. 상권 분석도 같은 구조다. 유동인구를 지도에 올리는 작업과 어느 지역에 어떤 업종을 열어야 수익이 나는지 판단하는 작업 사이에는 몇 단계의 변환이 놓여 있다.

판정을 생각하면 실무에서 비용이 발생한다. 명칭을 잘못 붙이면 예산 계정과 심사 기준이 어긋난다. 공간 데이터를 입력으로 썼다는 사실만으로 "GeoAI 사업"이라 부르면, 심사 단계에서 근거를 대지 못한다. 분석 축을 혼동하면 영상 판독 성능을 높이는 데 자원을 쓰고도 정책 산출물을 만들지 못한다. 층을 과하게 잡으면 전통 GIS로 답이 나오는 문제에 학습 모델을 얹어 비용과 불투명성만 늘린다. 세 판정은 방법 선택보다 앞서는 결정이며, 뒤에 오는 모든 선택의 근거가 된다.

이 장의 배열은 판정 순서를 따른다. 1.1은 공간 데이터 과학의 성립 과정과 여섯 질문의 전체 흐름을 제시한다. 1.2는 첫 질문인 자료 형식을 다루고, 1.3과 1.4는 명칭 판정을, 1.5는 분석 축 판정을, 1.6은 층 판정을, 1.7은 적용 맥락 판정을 다룬다. 1.8은 이 책의 구성과 읽는 순서를, 1.9는 여섯 질문의 답을 기록하는 명세표를 제시한다.

이 장이 다루는 것은 계산 절차가 아니라 판정 절차다. 좌표계 변환과 전처리는 제2장, 공간 자기상관과 MAUP의 정식 계산은 제4장, 딥러닝 모델의 구조는 제5장 이후가 맡는다. 이 장은 그 방법들을 언제 어떤 이름으로 어느 단위에서 쓰는지를 정하는 자리다. 여기서 세운 용어와 판정 기준은 이후 14개 장과 종장에서 반복해 쓰인다.

핵심 용어

이 장에서 처음 등장하는 용어를 먼저 정리한다. 각 용어는 본문에서 다시 정의하고 사례와 연결한다.

표 1.1 이 장의 핵심 용어

용어	뜻	등장 절
GIS (지리정보시스템)	공간 데이터의 수집·저장·관리·분석·시각화를 통합하는 체계	1.1
GIScience (지리정보과학)	GIS 기술이 제기하는 근본 질문(공간 표현, 불확실성, 스케일, 공간 추론)을 다루는 학문	1.1
공간 데이터 과학 (spatial data science)	위치·거리·인접성·공간 의존성을 분석 방법과 도구에 명시적으로 반영하는 데이터 과학의 하위 분야	1.1
공간 자기상관 (spatial autocorrelation)	가까운 위치의 관측값이 먼 위치의 관측값보다 서로 닮는 경향	1.1
벡터 데이터	점·선·면의 기하 객체로 공간 현상을 이산적으로 표현하는 형식	1.2
래스터 데이터	격자 픽셀에 관측값을 담아 연속 현상을 표현하는 형식	1.2
포인트 클라우드	3차원 좌표 (x, y, z)의 집합으로 지형과 구조물을 표현하는 자료	1.2
GeoAI (Geospatial AI)	공간 구조를 모델에 명시적으로 반영해 공간 패턴을 학습·예측하고 그 산출물을 공간적 결정으로 연결하는 분야	1.3
공간 이질성 (spatial heterogeneity)	같은 요인이더라도 지역에 따라 작동 방식과 강도가 달라지는 성질	1.3
파운데이션 모델 (foundation model)	대규모 자료로 사전학습한 범용 모델을 특정 과업에 미세조정하는 방식	1.3
지리공간 분석 (geospatial analytics)	공간 데이터를 다루는 모든 분석 활동을 포괄하는 가장 넓은 범주	1.4
원격탐사 (remote sensing)	접촉하지 않고 센서로 지표를 관측·해석하는 기술	1.4
공간 명시성 (spatial explicitness)	공간 구조가 모델 안으로 들어가 예측에 실제로 기여하는 성질	1.4
위치 인텔리전스 (location intelligence)	위치 데이터로 비즈니스 의사결정을 지원하는 용도 범주	1.4
영상·래스터 축	위성·항공·드론영상에서 무엇이 어디에 있고 무엇이 변했는지 판독하는 분석 축	1.5
공간단위 축	행정구역·격자·필지·건물·도로망 단위로 속성·관계·변화를 모델링하는 분석 축	1.5
MAUP (가변적 공간단위 문제)	집계 경계와 격자 크기를 바꾸면 분석 결과와 순위가 달라지는 현상	1.5
생태학적 오류 (ecological fallacy)	집계 단위에서 관찰한 관계를 개인 수준의 관계로 옮겨 해석하는 오류	1.5

용어	뜻	등장 절
3층 모델	공간 데이터 과학(1층) → 공간 명시적 AI(2층) → 정책·비즈니스 의사결정(3층)으로 구성된 본서의 관점	1.6

1.1 공간 데이터 과학의 성립과 과제 위치 판정

과제 위치 판정의 여섯 질문

새 과제를 받으면 방법을 고르기 전에 그 과제가 어디에 놓이는지 확인한다. 확인 항목은 여섯 개이며 순서가 있다. 앞 질문의 답이 뒤 질문의 입력이 되므로 순서를 바꾸면 뒤 판정의 근거가 사라진다. 자료 형식을 확정하지 않은 채 분석 축을 정하면 어떤 집계가 필요한지 알 수 없고, 분석 축을 정하지 않은 채 모델을 고르면 산출물의 단위가 결정과 맞지 않는다.

- [1] 이 자료는 어떤 형식인가 → 벡터·래스터·포인트 클라우드, 해상도·좌표계
↓
- [2] 이것을 GeoAI라 부를 수 있는가 → 공간 명시성 + 학습 기반, 두 조건 판정
↓
- [3] 어느 분석 축에서 답이 나오는가 → 영상·래스터 축 / 공간단위 축, 집계 다섯 단계
↓
- [4] 어느 층에서 끝나는가 → 1층 GIS / 2층 공간 명시적 AI / 3층 의사결정
↓
- [5] 산출물이 어느 결정으로 가는가 → 공공(예산·형평) / 비즈니스(투자·수익)
↓
- [6] 이 책의 어느 장을 읽는가 → Part 구성과 읽는 순서

그림 1.1 과제 위치 판정의 여섯 질문

각 질문의 입력·판정 기준·산출물을 표로 정리하면 다음과 같다. 이 표는 과제를 시작할 때 확인 목록으로 쓰고, 1.9의 명세표를 채울 때 각 행의 근거로 쓴다.

표 1.2 여섯 질문의 입력·판정 기준·산출물

질문	입력	판정 기준	산출물	대응 절
1 자료 형식	파일 목록, 센서 사양	기하 객체인가 격자인가 3차원 점군인가. 해상도·좌표계가 목적에 맞는가	자료 명세(형식·해상도· 좌표계·재방문 주기)	1.2
2 명칭	입력변수 목록, 모델, 적합 절차	공간 명시성과 학습 기반이 함께 성립하는가	명칭 판정과 근거 수치	1.3– 1.4
3 분석 축	분석 질문, 결정의 단위	답이 픽셀 판독에서 나오는가 공간단위 표에서 나오는가	축 결정, 집계 단위와 가중치	1.5
4 층	기준선 성능, 모델 구조	판정 5조건을 몇 번째까지 충족하는가	도달 층(1층·2층·3층)	1.6
5 결정 맥락	산출물 사용처	예산·형평 결정인가 투자·수익 결정인가	비용함수와 검증 기준	1.7
6 읽을 장	앞 다섯 답	어느 Part의 방법이 필요한가	읽는 순서	1.8

공간 데이터 과학의 정의와 범위

공간 데이터 과학(spatial data science)은 공간 데이터의 고유한 성질 — 위치, 거리, 인접성, 공간 의존성 — 을 분석 방법과 소프트웨어에 명시적으로 반영하는 데이터 과학의 하위 분야다. 일반 데이터 과학은 관측값이 서로 독립이라고 가정하는 경우가 많다. 공간 데이터에서는 가까운 관측값끼리 닮는 경향이 있어 이 가정이 성립하지 않는다. 공간 데이터 과학은 이 성질을 예외가 아니라 분석의 전제로 두고, 관측 위치와 관측 간 거리를 버리지 않는 방법을 체계화한다. 데이터 과학이 "무엇이 일어나는가"를 다룬다면, 공간 데이터 과학은 "어디에서, 왜 거기에서 일어나는가"를 다룬다.

세 갈래의 합류

공간 데이터 과학은 따로 발전한 세 학문 갈래가 2010년대에 합류한 결과다. 각 갈래가 무엇을 가져왔는지 구분해 두면, 이후 장에서 어떤 방법이 어느 전통에서 나왔는지 추적할 수 있다.

표 1.3 공간 데이터 과학을 이루는 세 갈래

갈래	핵심 인물	기여	이 책에서
지리 전통	Goodchild (1992)	GIS를 도구에서 과학(GIScience)으로 격상. 공간 데이터를 어떻게 표현·관리·시각화할지에 관한 이론적 토대	Part I, Ch1-3
통계 전통	Tobler (1970), Anselin (1988)	공간 자기상관과 공간 계량경제학. "가까운 것이 먼 것보다 더 관련되어 있다"는 지리학 제1법칙	Part I, Ch4
데이터 과학 전통	2010년대 이후	대규모 자료에서 패턴을 학습하는 머신러닝·딥러닝, 재현 가능한 코드 작업 흐름, 클라우드 컴퓨팅	Part II, Ch5-7

지리 전통은 공간 데이터를 어떻게 표현하고 관리할 것인지를 정립했다. 좌표계, 투영법, 벡터와 래스터 같은 자료 모델, 버퍼·오버레이·공간 조인 같은 연산이 여기에 속한다. 통계 전통은 공간 데이터에 특별한 성질이 있음을 밝혔다. Tobler(1970)의 지리학 제1법칙 — "모든 것은 다른 모든 것과 관련되어 있지만, 가까운 것이 먼 것보다 더 관련되어 있다" — 이 출발점이고, Anselin(1988)의 공간 계량경제학이 이를 회귀 모형 안으로 옮겼다. Moran's I, 크리깅, 공간 회귀가 이 전통의 도구다. 데이터 과학 전통은 대규모 이질적 자료에서 예측과 패턴 발견을 자동화하는 도구를 가져왔다. 세 갈래가 합쳐지면서 각각의 제약이 줄었다. GIS만으로는 어려웠던 예측과 패턴 학습이 가능해졌고, 통계만으로는 감당하기 어려웠던 대규모·다차원 자료를 처리할 수 있게 되었으며, 데이터 과학만으로는 놓치던 공간 구조를 분석에 반영할 수 있게 되었다.

지리 전통과 GIS

지리정보시스템(Geographic Information System, GIS)은 공간적으로 참조된 데이터를 수집·저장·관리·분석·시각화하는 통합 체계다(Longley et al., 2015). GIS는 단일 소프트웨어가 아니라 하드웨어·소프트웨어·데이터·인적 자원·방법론이 결합된 체계이며, 공간적 결정을 지원하기 위해 설계되었다. Goodchild(1992)가 제안한 **지리정보과학**(GIScience)은 GIS 기술이 제기하는 근본 질문 — 공간을 어떻게 표현할 것인가, 불확실성을 어떻게 다룰 것인가, 스케일이 결과를 어떻게 바꾸는가 — 을 다루는 학문이다. GeoAI는 같은 질문을 학습 알고리즘으로 다시 푸는 흐름에 해당한다.

표 1.4 GIS의 다섯 구성요소

구성요소	역할	대표 예시
하드웨어	자료 입력·처리·출력 인프라	센서, 서버, GPU 클러스터
소프트웨어	공간 데이터 처리·분석 도구	ArcGIS Pro, QGIS, PostGIS
데이터	공간 정보와 속성 정보의 결합	벡터, 래스터, 포인트 클라우드
인적 자원	해석과 결정	GIS 분석가, 개발자, 도메인 전문가
방법론	분석 절차와 규칙	공간 질의, 오버레이, 공간 통계

GIS 작업은 네 단계로 진행된다. 첫째, 위성 센서·공공 데이터 포털·클라우드소싱에서 자료를 수집한다. 둘째, 좌표계를 통일하고 결측을 처리하고 품질을 검증한다. 셋째, 공간 질의·거리와 인접 관계 분석·네트워크 분석·공간 통계로 분석한다. 넷째, 지도·대시보드·보고서로 결과를 공유한다. 좌표계를 잘못 고르면 면적과 서비스 반경이 어긋나고 그 오차가 정책 판단까지 옮겨 간다. 이 문제의 원리와 대응은 제2장에서 다룬다.




그림 1.2 GIS 작업 흐름

GIS 분석의 목적은 네 가지로 나뉜다. **기술 분석**(descriptive)은 현황과 공간 분포를 요약한다. **설명 분석**(diagnostic)은 원인과 관계에 관한 가설을 탐색한다. 인과 주장에는 별도의 식별전략이 필요하며, 이는 1.7절에서 예고하고 제8장에서 방법론으로 다룬다. **예측 분석**(predictive)은 향후 변화나 위험을 추정하고, **처방 분석**(prescriptive)은 제약 조건 아래에서 최적 대안을 도출한다. GeoAI를 쓰면 예측과 처방 영역에서 자동화할 수 있는 범위가 넓어진다.

공간 분석의 기원은 1854년 John Snow가 런던의 콜레라 발생 위치와 수도 펌프의 공간적 관계를 지도에 표시해 원인을 규명한 사례로 거슬러 올라간다. 이 사례는 공간 데이터가 처음으로 정책 결정 — 오염된 펌프의 폐쇄 — 으로 이어진 기록이기도 하다. 이후의 전환점을 정리하면 다음과 같다.

표 1.5 GIS 발전의 주요 이정표

시기	사건	의의
1854	John Snow, 런던 콜레라 지도	공간 분석의 시초, 공간 근거 기반 정책
1962–68	Roger Tomlinson, CGIS 개발	최초의 운용 가능한 GIS
1970	Waldo Tobler, 지리학 제1법칙	공간 자기상관의 이론적 기초
1972	NASA, Landsat-1 발사	최초의 지구 관측 위성 프로그램
1992	Goodchild, GIScience 개념 정립	GIS를 도구에서 과학으로 격상
2008	Landsat 자료 무료 공개	원격탐사 연구의 접근 문턱 하락
2015	Sentinel-2A 발사 (EU Copernicus)	10m 해상도, 5일 주기 무료 영상
2020	Janowicz et al., GeoAI 체계화	GeoAI의 학술적 정의

한국에서는 1990년대 이후 국가 GIS 사업으로 기본 공간정보의 디지털화와 표준화가 진행되었다. 현재 국가공간정보포털, 브이월드(V-World), 국토정보플랫폼이 운영되고 있으며, 이 공간정보 기반이 Part III에서 다루는 국내 정책 분석의 자료 토대가 된다.

공간 자기상관

문제 상황. 행정동 400개를 단위로 폭염 취약성을 회귀분석한다고 하자. 인접한 행정동은 기온·건물 밀도·녹지 비율이 서로 닮는다. 한 동의 값을 알면 옆 동의 값을 상당 부분 예측할 수 있다. 관측 400개를 서로 독립인 400개의 정보로 취급하면 자료의 실제 정보량보다 많은 정보를 가정하게 된다.

작동 원리. 최소제곱 회귀의 표준오차는 오차항이 서로 독립이라는 가정 위에서 계산한다. 오차가 공간적으로 상관되면 표준오차 공식의 분모에 들어가는 유효 표본 수가 명목 표본 수보다 작아진다. 계산 절차는 세 단계로 나뉜다. 첫째, 이웃 관계를 정의한다. 둘째, 각 관측의 오차와 이웃 오차의 상관을 측정한다. 셋째, 그 상관을 표준오차에 반영한다. 독립 가정 회귀는 셋째 단계를 건너뛰는 것이다.

정식 개념. 이 현상을 **공간 자기상관**(spatial autocorrelation)이라 부르며, 정도를 측정하는 표준 지표가 Moran's I다. 값이 0에 가까우면 공간적으로 무작위이고, 양수가 크면 비슷한 값끼리 모여 있으며, 음수면 서로 다른 값이 번갈아 배치된다. Moran's I의 정식 계산과 유의성 검정은 제4장에서 다룬다. 이 절에서 필요한 것은 계산식이 아니라 이 성질이 추론 결과를 어떻게 바꾸는지다.

작은 계산 예. 예를 들어 관측 400개의 오차가 이웃 사이에서 상관계수 0.6으로 닮는다면, 유효 표본 수가 명목의 절반 수준인 200개로 줄어든다. 표준오차는 표본 수의 제곱근에 반비례하므로 $\sqrt{2}$ 배, 곧 약 1.41배 커져야 한다. 독립 가정 회귀가 보고한 $t = 2.10$ 은 보정 후 $2.10 / 1.41 = 1.49$ 가 되어 통상적인 유의 기준을 넘지 못한다. 계수 추정치는 그대로인데 "유의하다"는 결론만 사라진다.

적용 조건과 한계. 공간 자기상관 점검은 공간 단위를 행으로 삼는 모든 분석에 적용한다. 점검 대상은 원변수가 아니라 모형 잔차다. 원변수에 자기상관이 있어도 설명변수가 그 구조를 흡수했다면 잔차에는 남지 않는다. 잔차에 자기상관이 남으면 아직 놓지 않은 공간 구조가 있다는 뜻이므로, 변수를 추가하거나 공간 모형으로 바꾼다.

이 책이 확장하는 범위

기존 공간 데이터 과학 교과서는 공간 데이터 표현, 공간 통계, 공간 회귀까지를 다룬다. Pebesma & Bivand(2023)는 R 환경에서, Rey, Arribas-Bel & Wolf(2023)는 Python 환경에서 같은 범위를 다루지만, 딥러닝과 의사결정은 두 책의 범위 밖이다. 이 책은 그 토대 위에 두 가지를 더한다. 첫째, 딥러닝으로 공간 구조를 모델 내부에서 직접 학습하는 GeoAI를 Part II에서 다룬다. 둘째, 분석 결과를 정책·비즈니스 의사결정으로 전환하는 방법을 Part III·IV에서 다룬다. 1.6절에서 제시하는 3층 모델이 이 확장의 골격이다.

GeoAI의 계보는 두 흐름의 교차로 정리된다. 한쪽은 인공지능의 계보로, AI가 ML을 포함하고 ML이 DL을 포함한다. 다른 쪽은 공간 분석의 계보로, 지리공간 분석이 가장 넓은 범주이고 그 안에 GIS·원격탐사·공간 통계가 있으며, 이를 데이터 과학의 방법과 결합한 것이 공간 데이터 과학이다. GeoAI는 공간 데이터 과학 안에서 AI·ML·DL을 써서 공간 구조를 모델에 명시적으로 반영하는 부분이며, 이 관계가 이 책의 Part 구성과 직접 대응한다.

flowchart LR

subgraph AI_계보["AI 계보"]

AI["인공지능"] --> ML["머신러닝\nRF, XGBoost"]

ML --> DL["딥러닝\nCNN, U-Net, LLM"]

end

subgraph 공간_계보["공간 분석 계보"]

GA["지리공간 분석"] --> GIS["GIS\n좌표계, 버퍼, 오버레이"]

GA --> RS["원격탐사\n위성영상 취득·전처리"]

GA --> SS["공간 통계\nMoran's I, 크리깅"]

GA --> SDS["공간 데이터 과학"]

end

ML -->|"Part I Ch4"| GEOAI["GeoAI\n공간 구조 + AI"]

DL -->|"Part II Ch5-7"| GEOAI

SDS --> GEOAI

GEOAI -->|"Part III·IV"| DEC["정책·비즈니스\n의사결정"]

그림 1.3 두 계보에서 본서의 Part 구성으로. ML이 공간 데이터에 결합되면 Part I(Ch4)의 공간 머신러닝이 되고, DL이 결합되면 Part II(Ch5-7)의 GeoAI가 된다.

1.2 공간 데이터의 표현 형식

여섯 질문의 첫 항목은 자료 형식이다. 형식이 정해지면 쓸 수 있는 연산, 다룰 수 있는 도구, 뒤에서 필요한 집계 방식이 함께 결정된다. 공간 데이터는 표현 방식에 따라 벡터·래스터·포인트 클라우드로 나뉜다. 세 형식은 서로 보완적이며, 하나의 과제에서 둘 이상을 함께 쓰는 경우가 흔하다. 좌표계와 전처리의 상세 원리는 제2장에서 다루므로, 이 절에서는 형식의 차이와 그 차이가 분석 설계에 미치는 영향에 집중한다.

벡터 데이터

벡터 데이터는 점(Point), 선(LineString), 면(Polygon)의 기하 객체로 공간 현상을 이산적으로 표현한다. 행정경계, 도로망, 건물처럼 경계가 명확한 대상에 적합하며, 기하 정보와 속성 테이블이 결합된 형태로 저장된다. 이 책의 공간단위 분석 — 행정구역, 격자, 필지, 건물, 도로망 — 은 대부분 벡터 형식을 기반으로 한다. 대표 연산은 객체 주변에 일정 거리의 영역을 만드는 **버퍼(buffer)**, 두 레이어의 교집합·합집합을 계산하는 **오버레이(overlay)**, 공간 관계로 두 자료를 결합하는 **공간 조인(spatial join)**, 최단 경로와 서비스 영역을 계산하는 **네트워크 분석**이다. 실무에서는 GeoPandas로 자료를 처리하고 PostGIS로 대용량 공간 질의를 처리한다.

주요 포맷은 세 가지다. **Shapefile**은 가장 오래된 형식으로 2GB 크기 제한과 필드명 10자 제한이 있다. **GeoPackage**는 SQLite 기반의 단일 파일 형식이고, **GeoJSON**은 웹 친화적인 JSON 구조다.

주의. Shapefile은 2GB 상한과 필드명 10자 제한을 넘으면 필드명이 잘리거나 저장이 중단된다. 잘린 필드명은 오류로 보고되지 않고 그대로 후속 분석에 실린다. 신규 자료는 GeoPackage 또는 GeoJSON으로 만든다. 기존 Shapefile을 받으면 필드명이 잘렸는지 원본 메타데이터와 대조한 뒤 분석에 넣는다.

형식에 따라 파일 하나가 아니라 여러 구성 파일로 흩어지기도 한다. 각 데이터 유형의 대표 포맷과 확장자를 표 1.6에 정리한다.

표 1.6 주요 공간 데이터 포맷과 확장자

유형	포맷	확장자(구성 파일)	저장 구조	특징·제약
벡터	Shapefile	.shp (기하) · .shx (공간 인덱스) · .dbf (속성) + .prj (좌표계) · .cpg (인코딩)	파일 묶음	구성 파일마다 2GB 제한, 필드명 10자 제한
벡터	GeoPackage	.gpkg	SQLite 단일 파일	OGC 표준, 좌표계·인덱스 내장, 2GB 제한 없음
벡터	GeoJSON	.geojson	JSON 텍스트	웹·API 친화적, 좌표계가 WGS84로 고정(RFC 7946)
래스터	GeoTIFF	.tif	TIFF + 지오참조 메타데이터	좌표계·변환 정보를 파일 안에 저장
래스터	COG	.tif (GeoTIFF와 호환)	타일 기반 GeoTIFF	Range Request로 필요한 구간만 전송받음
포인트 클라우드	LAS/LAZ	.las / .laz	점군 이진 포맷	LAZ는 압축형

래스터 데이터

래스터 데이터는 격자 기반의 연속 공간 표현으로, 픽셀 단위 관측값을 저장하며 위성영상, 항공사진, 고도 모델처럼 연속적 현상에 적합하다. 핵심 속성은 세 가지다. **해상도**는 픽셀 하나가 나타내는 실제 면적이고 (Sentinel-2는 10m), **밴드 수**는 동시에 기록하는 파장대의 개수이며(Sentinel-2는 13개), **좌표계**는 픽셀 위치를 지구 표면에 대응시키는 기준이다. 래스터 파일은 크기가 크다. Sentinel-2의 단일 타일(100km × 100km)은 전체 밴드를 합치면 1GB를 넘는다. **COG**(Cloud Optimized GeoTIFF) 같은 타일 기반 포맷을 쓰면

파일 전체를 내려받지 않고 필요한 구간만 요청할 수 있다. 서버에 특정 바이트 구간만 보내 달라고 요청하는 HTTP 기능(Range Request)을 이용하는 방식이며, 1GB 영상에서 관심 지역에 해당하는 조각만 받는다. 실무 도구는 Rasterio와 GDAL이다.

NDVI 계산. 다중분광 영상은 청색·녹색·적색·근적외선(NIR)을 동시에 기록한다. 여기서 계산하는 대표적 파생 지표가 식생 지수 NDVI다.

$$NDVI = (NIR - Red) / (NIR + Red)$$

각 항의 뜻은 다음과 같다. NIR은 근적외선 반사율이고 Red는 적색 반사율이며, 두 값 모두 0과 1 사이다. 분자 (NIR - Red)는 두 파장대의 반사 차이를 측정하고, 분모 (NIR + Red)는 그 차이를 전체 밝기로 나누어 조명 조건의 영향을 줄인다. 나뭇샘이 들어가므로 같은 지표면이라도 태양 고도나 그림자로 밝기가 달라질 때 값이 크게 흔들리지 않는다. 결과는 -1에서 1 사이에 놓인다. 식물의 엽록소는 적색을 흡수하고 근적외선을 강하게 반사하므로, 잎이 많을수록 분자가 커진다.

예를 들어 세 지표면의 반사율이 다음과 같다고 하자. 활엽수림에서 NIR = 0.45, Red = 0.05이면 $NDVI = (0.45 - 0.05) / (0.45 + 0.05) = 0.40 / 0.50 = 0.80$ 이다. 나지에서 NIR = 0.25, Red = 0.20이면 $NDVI = 0.05 / 0.45 = 0.11$ 이다. 수면에서 NIR = 0.02, Red = 0.05이면 $NDVI = -0.03 / 0.07 = -0.43$ 이다. 값이 0.6을 넘으면 식생이 우세하고, 0.1 부근이면 식생이 거의 없으며, 음수면 물이나 눈에 해당한다. 같은 계산을 시점별로 반복하면 식생의 계절 변화와 개발에 따른 감소를 추적할 수 있다.

주의. 지리좌표계(EPSG:4326)에서 면적과 거리를 그대로 계산하면 도(degree) 단위의 값이 나온다. 코드는 정상 종료하고 숫자도 그럴듯한 크기로 나오므로 오류를 알아채기 어렵다. 실제로 EPSG:4326 자료에서 면적을 계산하면 `UserWarning: Geometry is in a geographic CRS. Results from 'area' are likely incorrect.` 경고가 출력된다(`lecture_practice/chapter1/results/1-1-geoai-tools-preview.log`). 면적·거리 계산 전에 등면적 또는 등거리 투영으로 변환하고, 계산 결과의 단위를 한 줄로 적어 확인한다.

포인트 클라우드

포인트 클라우드는 3차원 좌표 (x, y, z)의 집합으로 지형과 구조물을 표현한다. **라이다**(LiDAR) 센서 기반 자료가 대표적이며, 도시 3D 모델링, 산림 구조 분석, 자율주행 인식에 쓰인다. LAS/LAZ 형식이 표준이고 Python에서는 laspy와 PDAL로 처리한다. 딥러닝에서는 PointNet(Qi et al., 2017) 계열 모델이 점군을 직접 입력으로 받아 3D 분류와 세그멘테이션을 처리한다.

해상도와 재방문 주기의 상충

문제 상황. 도시 열섬을 분석한다고 하자. 블록 단위로 어느 구역이 더운지 보려면 격자가 촘촘해야 하고, 폭염 기간에 온도가 며칠 사이에 어떻게 오르내리는지 보려면 관측 간격이 짧아야 한다. 두 조건을 동시에 만족하는 무료 위성 자료는 흔하지 않다. 센서 설계에서 공간 해상도와 재방문 주기가 서로 맞물려 있기 때문이다.

작동 원리. 위성은 정해진 궤도를 돌면서 일정 폭의 띠를 촬영한다. 촬영 폭을 좁히고 픽셀을 잘게 쪼개면 공간 해상도가 올라가는 대신 같은 지점으로 돌아오는 데 걸리는 날짜가 길어진다. 반대로 촬영 폭을 넓히면 매일 같은 지점을 볼 수 있지만 픽셀이 커진다.

수치로 본 상충. 1km × 1km 구역을 덮는 데 필요한 격자 수를 집계하면 차이가 분명해진다. 10m 격자는 한 번에 1,000 / 10 = 100칸이므로 100 × 100 = 10,000개다. 30m 격자는 한 번에 1,000 / 30 ≈ 33.3칸이므로 약 1,111개다. 격자 수가 9배 차이 나며, 이 차이가 곧 블록 내부의 편차를 볼 수 있는지를 결정한다. 관측 횟수는 반대 방향으로 움직인다. 한 달을 30일로 두면 재방문 주기 5일인 자료는 최대 6회, 16일인 자료는 최대 1.9회를 관측한다. 구름으로 절반이 가려지면 각각 3회와 1회 미만으로 줄어, 16일 주기 자료로는 2주짜리 폭염 사건 안에서 변화를 추적할 관측이 사실상 한 장뿐이다.

열적외 자료에서의 상충. 지표면 온도를 측정하는 열적외 밴드에서 이 상충이 더 크다. Landsat의 열적외 자료는 30m 격자로 제공되지만 재방문 주기가 16일이고, MODIS는 하루 한두 번 관측하지만 격자가 1km다. MODIS 픽셀 하나가 Landsat 30m 격자 약 1,111개에 해당하므로, MODIS로는 블록 사이의 온도 차이를 구분할 수 없다. 폭염 2주 동안 Landsat이 최대 1회를 관측할 때 MODIS는 14회를 관측한다. 따라서 블록 단위 열섬 지도는 Landsat 계열로 만들고, 폭염 사건의 시간 변화는 MODIS 계열로 보되 두 산출물을 같은 표에 섞지 않는다.

표 1.7 주요 위성 센서의 해상도와 재방문 주기

센서	공간 해상도	재방문 주기	밴드 수	비용
Landsat 8/9	30m (Pan 15m)	16일 (동시 운용 시 8일)	11	무료
Sentinel-2	10–60m	5일	13	무료
PlanetScope	3m	매일	8	유료
WorldView-3	0.31m	1–4일	29	유료
항공 LiDAR	0.5–1m	주문형	—	유료

세 형식의 특성을 나란히 놓으면 선택 기준이 정리된다.

표 1.8 공간 데이터 유형 비교

기준	벡터	래스터	포인트 클라우드
표현 대상	경계가 명확한 객체	연속 현상	3D 구조
주요 연산	공간 질의, 네트워크 분석	필터링, 지표 계산	분류, 표면 생성
강점	해석과 수정이 쉬움	연속성 표현, 다중 밴드	정밀한 3차원 표현
제약	연속 현상에 부적합	대용량, 해상도 의존	처리 비용이 큼
대표 도구	GeoPandas, PostGIS	Rasterio, GDAL	laspy, PDAL
대표 포맷	GeoJSON, GeoPackage	GeoTIFF, COG	LAS, LAZ

벡터와 래스터 사이의 변환은 실무에서 자주 발생한다. 벡터 행정경계를 래스터로 바꾸어 영역 통계를 계산하거나, 래스터 분류 결과를 벡터 폴리곤으로 바꾸어 보고서용 지도를 만드는 경우다. 변환 시 지정하는 해상도와 격자 정렬 기준이 결과를 바꾸므로, 어떤 값을 썼는지 산출물과 함께 기록한다. 이 기록이 없으면 같은 자료로 다시 계산해도 값이 재현되지 않는다.

1.3 GeoAI의 정의와 성립 조건

자료 형식을 확정하면 두 번째 질문으로 넘어간다. 이 분석을 GeoAI라 부를 수 있는가. 이 절은 GeoAI의 정의와 성립 조건을 정리하고, 다음 절에서 그 정의를 판정 절차로 옮긴다. 공간 데이터 과학은 GeoAI의 상위 범주이며, 이 책의 Part II(Ch5-7)가 그 범위를 다룬다.

정의

GeoAI(Geospatial Artificial Intelligence)는 지리공간 데이터와 인공지능 기술을 결합해 공간 현상의 패턴을 학습하고 예측·분류·탐지를 수행하는 접근이다. 전통 GIS가 규칙 기반 분석과 공간 통계에 집중했다면, GeoAI는 대규모 자료에서 특징을 자동으로 학습하고 비선형 관계를 모델링한다. 여기에 한 가지 조건이 붙는다. 공간 데이터를 입력으로 썼다는 사실만으로는 GeoAI가 아니다. GeoAI의 요건은 공간 구조 — 공간 자기상관, 공간 이질성, 인접 관계 — 를 모델에 명시적으로 반영하고 그 산출물을 공간적 결정으로 연결하는 데 있다. 여기서 **공간 이질성**(spatial heterogeneity)은 같은 요인이라도 지역에 따라 작동 방식과 강도가 달라지는 성질을 말한다. 지하철역과의 거리가 집값에 미치는 영향은 서울 도심과 지방 중소도시에서 크기도 방향도 같지 않다. 전처리만 GIS로 하고 모델링은 일반 머신러닝으로 처리하는 방식은 GeoAI가 아니라 'GIS + ML'이다.

Janowicz et al.(2020)은 GeoAI를 공간 데이터 과학의 하위 분야로 규정하면서 **공간 명시적 모델**(spatially explicit models)을 핵심 원칙으로 제시했고, 질의응답(question answering)과 소셜 센싱(social sensing)을 주요 연구 주제로 함께 논의했다. 공간 명시적 모델은 이 책이 2층에서 요구하는 조건으로, 모델이 공간 구조를 명시적으로 반영해야 한다는 원칙이다. Li(2020)는 GeoAI를 "데이터 집약적 GIScience를 위한 새로운 공간 분석 프레임워크"로 정의하고 세 기둥 — 지리공간 빅데이터, 머신러닝·딥러닝, 고성능 컴퓨팅 — 을 제시했다. 두 정의를 합치면 GeoAI가 성립하려면 분석할 대량의 공간 자료, 패턴을 학습할 알고리즘, 이를 처리할 계산 자원이 모두 갖추어져야 하고, 그 위에 공간 구조를 모델에 넣는 설계가 더해져야 한다.

GeoAI가 수행하는 과업은 입력 자료와 출력 형태로 나뉜다. 각 과업이 1.5절의 두 분석 축 가운데 어디에 속하는지를 함께 적으면, 자기 과제에 필요한 과업이 영상 판독 쪽인지 공간단위 모델링 쪽인지 미리 판단할 수 있다.

표 1.9 GeoAI 주요 과업 유형

과업	입력 자료	대표 모델	출력	분석 축
영상 분류	다중분광 영상	CNN, ViT	토지피복 클래스	영상·래스터
객체 탐지	항공·위성영상	YOLO 계열	경계 상자	영상·래스터
시맨틱 세그멘테이션	위성영상	U-Net, SAM	픽셀 단위 라벨	영상·래스터
변화 탐지	시계열 영상	Siamese, ChangeFormer	변화 지도	영상·래스터
시공간 예측	센서·격자 시계열	LSTM, GNN	미래 예측값	공간단위
공간 명시적 취약성 예측	공간단위 피처(격자·행정동)	공간회귀, 공간 명시 ML	위험·취약 점수	공간단위

이 책의 중심은 공간단위 축이며, 두 축의 구분과 축 사이의 이동은 1.5절에서 다룬다.

성립 조건: 데이터·알고리즘·컴퓨팅

GeoAI는 세 조건이 동시에 갖추어지면서 성립했다. 세 조건 중 하나라도 충족되지 않으면 같은 방법을 쓸 수 없으므로, 자기 과제에서 세 조건이 어느 수준인지 확인하는 것이 도입 판단의 출발점이 된다.

첫째, 지리공간 자료의 규모다. 2023년 기준 지구 관측 자료의 규모를 표 1.10에 정리한다. 활성 위성 수와 누적 자료량이 이 수준이 되면 사람이 영상을 한 장씩 판독하는 방식으로는 처리할 수 없다. 자동 판독은 선택이 아니라 처리 가능 여부의 문제가 된다.

표 1.10 주요 지구 관측 자료 현황 (2023년 기준)

자료 출처	주요 수치	비고
Landsat 아카이브	1,000만 장 이상	1972년부터 50년 이상 연속 관측
Sentinel 제품	1억 개 이상(온라인)	Copernicus 프로그램
활성 EO 위성	약 1,190대	Wilkinson et al. (2023)
전체 EO 자료	약 807PB	연간 약 100PB 증가 (Wilkinson et al., 2023)

둘째, 딥러닝 알고리즘의 성숙이다. 2012년 AlexNet이 CNN을 영상 분류의 표준으로 만들었고, 2015년 U-Net이 시맨틱 세그멘테이션의 구조를 정립했으며, 2017년 Transformer가 시퀀스 모델링의 기준을 바꾸었다. 2023년 이후에는 파운데이션 모델이 이 분야로 확산되고 있다.

셋째, **계산 인프라의 확산**이다. GPU 기반 가속 컴퓨팅과 클라우드 서비스가 보급되면서 대규모 모델의 학습과 추론을 개별 연구자도 수행할 수 있게 되었다. Google Earth Engine 같은 클라우드 플랫폼에서는 페타바이트급 아카이브를 내려받지 않고 원격으로 처리한다.




그림 1.4 GeoAI의 세 기둥

파운데이션 모델

2023년 이후 GeoAI에서는 **파운데이션 모델**(foundation model) 방식이 확산되고 있다. 대규모 지구 관측 자료로 사전학습(pre-training)한 모델을 특정 과업에 미세조정(fine-tuning)하는 접근이며, 라벨이 적은 조건에서도 일정 수준의 성능을 얻는다.

표 1.11 주요 지리공간 파운데이션 모델

모델	개발 기관	특징	공개 시점
Prithvi-EO-2.0	IBM/NASA	HLS 기반, 300M/600M 규모, 다중 시계열	2024.12
AlphaEarth Foundations	Google DeepMind	연간 위성 임베딩, 다중 센서 통합	2025
Clay v1	Clay Foundation	다중 센서 통합, 오픈소스	2024
SatMAE	Stanford	위성영상 특화 MAE	2022.12

표에 실린 모델은 지리공간 자료로 사전학습한 지리공간 전용 모델이다. Meta의 SAM(Segment Anything Model, 2023)은 범용 비전 파운데이션 모델로 위성영상 세그멘테이션에 응용되지만 지리공간 전용 모델은 아니며, 제6장에서 별도로 다룬다. IBM/ESA의 TerraMind(2025) 같은 다중모달 모델도 계속 공개되고 있다. 파운데이션 모델을 GeoAI의 한 분야로 정리한 논의는 Li et al.(2024)에 있으며, 모델의 원리와 활용은 제6장에서 다룬다.

규칙 기반과 학습 기반의 차이

전통 GIS와 GeoAI의 차이는 특징을 누가 정의하는가에 있다. 건물 추출을 예로 들면 차이가 분명해진다. 규칙 기반 접근에서는 분석자가 지붕의 색상 범위, 형태의 직각성, 최소 면적을 수치로 정의하고 그 조건에 맞는 영역을 추출한다. 조건을 명시적으로 적으므로 왜 그 결과가 나왔는지 추적할 수 있지만, 지역마다 지붕 재질과 색이 달라지면 조건을 다시 정해야 한다. 학습 기반 접근에서는 라벨이 붙은 영상으로 모델을 학습시켜 건물 외관 패턴을 모델이 직접 잡아낸다. Microsoft는 이 방식으로 전 세계 약 14억 개의 건물을 자동 추출했다(Global ML Building Footprints, 2025년 갱신 기준). 같은 문제를 두 방식으로 풀어 입력·자료 규모·설명 방식을 나란히 비교한 표는 1.6절의 표 1.18에 있다.

실무에서 두 접근은 대립 관계가 아니다. GIS 규칙 기반 분석으로 관심 영역을 좁힌 뒤 GeoAI 모델로 세밀하게 분류하는 결합 방식이 일반적이다. 이 책의 3층 모델도 같은 구조로, 전통 GIS(1층)를 대체하지 않고 그 위에 공간 명시적 AI(2층)를 쌓는다. GIS의 공간 질의와 전처리 역량이 모델 입력의 품질을 결정하므로, 두 역량 중 하나만 갖춘 상태로는 어느 쪽 결과도 신뢰하기 어렵다.

응용 분야와 정량적 성과

GeoAI는 여러 도메인에서 공간 패턴의 자동 추출과 예측에 쓰인다. 분야별 대표 시스템과 정량적 성과를 표 1.12에 정리한다. 기상 예측, 홍수 예보, 건물 추출 세 분야는 이미 전 지구 규모의 운영 단계에 들어갔고, 나머지 분야는 국가 또는 지역 단위 운영에 머문다.

표 1.12 GeoAI 응용 분야별 정량적 성과

분야	시스템·모델	핵심 성과	출처
기상 예측	GraphCast	10일 예보 90% 우위, 계산 1분 미만	Lam et al. (2023)
홍수 예보	Google Flood Hub	80개국 이상, 약 4.6억 명 조기경보	Nearing et al. (2024)
건물 추출	MS Building Footprints	약 14억 건물 자동 추출(2025 갱신)	Microsoft (2025)
영상 분류	Wide ResNet-50	EuroSAT 전체 정확도 99.17%	Naushad et al. (2021)
산불 탐지	ALERTCalifornia AI	911 신고 이전 선제 탐지(운영)	UC San Diego (2023)
농업	USDA Cropland Data Layer	전국 작물유형 연간 분류 운영화	USDA NASS

표 1.12의 사례는 대부분 해외 시스템이다. 국내에도 산림청 산사태정보시스템, 지방자치단체 침수예측, 경찰 범죄위험도 예측(Pre-CAS) 같은 운영 사례가 있으나, 해외 성과 수치를 국내에 그대로 옮길 수는 없다. 자료의 밀도, 행정 단위의 크기, 제도적 절차가 다르기 때문이다. Part III의 정책 적용 장은 이런 해외 성과를 국내 공공 자료와 제도 환경에 맞추어 적용하는 방법을 사례별로 다룬다.

1.4 명칭의 판정: 세 축과 두 조건

GeoAI의 정의를 세웠으면 다음은 그 정의를 자기 과제에 적용하는 절차다. 이 절은 공간 데이터를 다루는 이름들이 서로 어떤 관계인지 정리하고, 어떤 분석을 GeoAI라 부를 수 있는지를 판정 절차로 옮긴다. 판정 결과는 1.9의 명세표 두 번째 행에 기록하며, 그 기록이 1.6의 층 판정에서 다시 입력으로 쓰인다.

명칭 혼동의 비용

명칭이 어긋나면 실무에서 세 가지 형태로 비용이 나타난다. 첫째, 제안서가 심사에서 근거를 대지 못한다. "GeoAI 기반 상권 분석 시스템"이라는 이름으로 제출된 산출물이 지점별 매출을 색으로 칠하고 반경 500m 원을 그린 대시보드인 경우가 있다. 유용한 도구이지만 학습하는 모델이 없으므로 AI 사업의 평가 지표를 적용할 수 없다. 둘째, 논문 심사에서 "GIS로 전처리한 뒤 일반 머신러닝을 돌린 것"이라는 의견을 받는다. 저자는 위성영상을 입력으로 썼고 랜덤 포레스트를 적합했으므로 GeoAI라고 판단했지만, 심사자는 공간 구조가 모델 안에 들어갔는지를 물었다. 셋째, 같은 회의에서 도시계획 부서는 "공간 분석"을 현황 진단으로 이해하고 마케팅 부서는 매장 입지 선정으로 이해한 채 논의가 진행되어 서로 다른 결론을 갖고 나온다.

세 경우의 공통 구조는 같은 낱말이 다른 대상을 가리키고 있다는 사실을 확인하지 않은 것이다. 명칭은 예산 계정을 정하고, 심사 기준을 정하고, 누가 그 업무를 맡을지를 정한다. "AI 사업"으로 분류되면 다른 예산 계정과 다른 평가 지표가 붙고, 성과 보고에서 요구하는 증빙 자료도 달라진다. 따라서 이 절의 목적은 낱말의 옳고 그름을 가리는 것이 아니라, 하나의 분석을 앞에 두고 그것이 무엇인지 스스로 판정할 기준을 세우는 데 있다.

여덟 이름과 세 축

공간 데이터를 다루는 이름은 여덟 개가 흔히 함께 쓰인다. 이 이름들이 서로 경쟁하는 것처럼 보이는 이유는 서로 다른 축을 기준으로 붙은 이름을 한 줄에 세워 놓았기 때문이다. 축을 분리하면 관계가 단순해진다. 분야 축은 무엇을 연구하고 수행하는 영역인지로 정의된다. 방법 축은 어떤 기법으로 다루는지로 정의된다. 용도 축은 무엇을 위해 쓰는지로 정의된다.

- **분야 축**: 지리공간 분석, GIS, GIScience, 원격탐사, 공간 통계, 공간 데이터 과학
- **방법 축**: GeoAI
- **용도 축**: 위치 인텔리전스, 비즈니스 인텔리전스




그림 1.5 공간 데이터를 다루는 여덟 이름과 세 축

측이 다르면 배타적이지 않다. 하나의 분석이 세 축에서 각각 다른 이름을 동시에 갖는 것이 정상이며, 이 성질은 이 절 뒤쪽에서 사례로 확인한다.

표 1.13 공간 데이터를 다루는 주요 용어와 그 축

용어	축	무엇을 가리키는가	주로 쓰는 쪽	본서에서
지리공간 분석 (geospatial analytics)	분야(가장 넓은)	공간 데이터를 다루는 모든 분석 활동	학계·산업 공통	1~2층 전체를 포괄하는 상위 범주
GIS (지리정보시스템)	분야(시스템)	공간 데이터를 수집·저장·분석·시각화하는 통합 체계	실무·행정	1층의 기반 (1.1)
GIScience (지리정보과학)	분야(과학)	GIS 기술이 제기하는 근본 질문을 다루는 학문 (Goodchild, 1992)	학계	GeoAI가 같은 질문을 학습 알고리즘으로 다시 푸는 관계 (1.1)
원격탐사 (remote sensing)	분야(자료 획득)	접촉하지 않고 센서로 지표를 관측·해석하는 기술	학계·위성 산업	영상 축의 입력을 만드는 상류 공정 (Ch2·Ch5·Ch6)
공간 통계 (spatial statistics)	분야(방법론)	공간 자기상관·이질성을 다루는 통계 이론	학계	1층의 방법이자 2층이 계승하는 개념 토대 (Ch4·Ch8)
공간 데이터 과학 (spatial data science)	분야(최근)	데이터 과학의 방법을 공간 데이터에 적용하는 흐름	학계	GeoAI의 상위 범주 (1.3)
위치 인텔리전스 (location intelligence)	용도 (비즈니스)	위치 데이터로 비즈니스 의사결정을 지원 (Dresner Advisory Services, 2019)	산업	Part IV의 중심 (Ch14·Ch15)
GeoAI	방법 (AI)	공간 데이터에 AI를 적용하되 공간 구조를 모델에 명시적으로 반영	학계·산업	본서의 방법 중심축 (2층·3층)

표에서 위치 인텔리전스만 용도로 정의된다. 나머지 일곱은 무엇을 다루는가 또는 어떻게 다루는가로 정의되는데, 위치 인텔리전스는 무엇을 위해 쓰는가로 정의된다. 그래서 위치 인텔리전스는 전통 GIS로도 최신 GeoAI로도 실현된다. 지도 위에 매출을 색칠하는 작업도 위치 인텔리전스이고, 흡인 모형으로 자기잠식을 계산하는 작업도 위치 인텔리전스다. 자주 함께 언급되는 **비즈니스 인텔리전스**(business intelligence, BI)는 기업 내부 자료를 집계해 보고서와 대시보드로 만드는 도구와 절차를 가리킨다. 이 책은 BI와 위치 인텔리전스를 구분해 쓴다. BI라는 말이 특정 제품군을 강하게 연상시켜 이 책이 다루는 예측·인과추론·최적화까지 포괄하기 어렵기 때문이다.

세 개념의 포함과 겹침

여덟 용어 가운데 이 책의 구조를 이해하는 데 필요한 것은 셋이다. 지리공간 분석, 위치 인텔리전스, GeoAI다. 세 개념은 서로 다른 기준으로 잘라 낸 범주이므로 포함 관계와 겹침 관계가 함께 나타난다.

가장 넓은 범주가 지리공간 분석이며, 공간을 다루는 모든 분석이 여기에 들어간다. GeoAI는 그 가운데 AI를 쓰는 부분을 잘라 낸 범주이고, 위치 인텔리전스는 비즈니스 의사결정에 쓰는 부분을 잘라 낸 범주다. 자르는 기준이 다르므로 두 범주는 포함 관계가 아니라 부분적으로 겹치는 관계에 놓인다. 겹치는 자리가 비즈니스 GeoAI이며, Part IV(제14·15장)가 그 자리를 맡는다. 겹치지 않는 두 자리도 각각 이름이 있다. GeoAI 안이면서 위치 인텔리전스 밖인 영역이 공공정책 GeoAI(Ch8~13)이고, 위치 인텔리전스 안이면서 GeoAI 밖인 영역이 지도 시각화와 상권 통계 같은 비AI 비즈니스 분석이다.

flowchart TB

```
GA["지리공간 분석 - 공간을 다루는 모든 분석"]
GA --> SDS["공간 데이터 과학의 토대\n1층 · Part I · Ch1~4"]
GA --> GEOAI["GeoAI - 공간 명시적 딥러닝\n2층 · Part II · Ch5~7"]
GEOAI --> PUB["공공정책 의사결정\n3층 · Part III · Ch8~13"]
GEOAI --> BIZ["비즈니스 의사결정\n3층 · Part IV · Ch14~15"]
LI(["위치 인텔리전스 - 비즈니스 용도로 자른 단면"]) -.-> BIZ
LI -.-> SDS
```

그림 1.6 세 개념과 본서 각 장의 대응. 위치 인텔리전스는 계층이 아니라 용도로 자른 단면이므로 점선으로 표시했다.

두 조건: 공간 명시성과 학습 기반

어떤 분석이 GeoAI인지는 두 조건으로 판정한다. 첫째는 **공간 명시성**(spatial explicitness)으로, 공간 구조가 모델 안으로 들어가 예측에 실제로 기여하는 성질이다. 둘째는 **학습 기반**으로, 모형의 형태를 분석자가 지정하지 않고 자료에서 적합하는 성질이다. 두 조건을 함께 충족해야 GeoAI이며, 하나만 충족하면 다른 이름을 붙인다. 크리깅(Kriging)은 지도 위에 드문드문 떨어져 있는 실제 측정값들을 바탕으로, 측정하지 않은 나머지 주변 지역의 값을 확률과 통계 기법을 사용해 정확하게 예측(보간)하는 공간 통계 방법이다. 이 방법은 공간 자기상관을 정면으로 모형화하므로 첫째 조건은 충족하지만 학습 기반이 아니어서 1층의 공간 통계로 분류한다. 좌표를 제거한 표에 랜덤 포레스트를 적합한 분석은 둘째 조건은 충족하지만 공간 구조가 모델에 없어 'GIS + ML'로 기술한다.

공간 구조가 모델 안으로 들어가는 경로는 세 가지이며, 어느 경로를 썼는지에 따라 판정의 근거가 달라진다.

표 1.14 공간 구조가 모델에 들어가는 세 경로

경로	내용	판정 기여
공간 시차 피쳐	이웃 값의 가중평균, 상대 높이, 거리·밀도·접근성 변수를 입력 열로 추가	단독으로 공간 명시성을 성립시킨다
이웃 정보를 쓰는 모델 구조	합성곱이 인접 픽셀을 함께 보는 CNN, 인접 노드를 집계하는 GNN, 공간 시차항을 둔 공간회귀	단독으로 공간 명시성을 성립시킨다
공간 블록 교차검증	가까운 관측이 학습과 평가에 함께 들어가지 않도록 공간 덩어리로 분할	단독으로는 성립시키지 못한다. 검증 설계이지 모델 구조가 아니다

첫째 경로는 입력 자료를 바꾸는 방식이다. 표고(해발 고도)의 공간 시차나 하천까지의 거리처럼 이웃 관계에서 계산한 값을 열로 만들어 넣는다. 둘째 경로는 모델 구조를 바꾸는 방식이다. 합성곱 필터는 한 픽셀의 값을 이웃 픽셀과 함께 계산하므로 공간 관계가 연산 안에 들어 있고, 그래프 신경망은 인접 노드의 표현을 집계한다. 셋째 경로는 검증 설계를 바꾸는 방식이며, 성능 추정이 부풀려지지 않게 하지만 모델이 공간을 쓰게 만들지는 않는다. 따라서 셋째만 적용한 분석은 공간 명시적이라고 판정하지 않는다. 검증만 공간적으로 하고 입력과 구조에는 공간 정보가 없는 모델은 여전히 좌표 없는 표를 학습한 모델이다.

두 조건의 판정 절차

공간 명시성은 선언으로 확인되지 않는다. 확인 절차는 같은 모델을 두 조건에서 적합해 성능을 비교하는 것이며, 다섯 단계로 진행한다.

- 1. 기준 모형 적합.** 전체 피쳐로 모델을 학습하고, 공간 블록 교차검증으로 성능을 측정한다. 블록 분할은 이 단계에서 고정하고 이후 바꾸지 않는다.
- 2. 공간 정보 제거.** 좌표, 이웃 값에서 계산한 공간 시차 변수, 인접 단위의 속성을 입력에서 뺀다. 어떤 열을 뺐는지 목록으로 남긴다.
- 3. 동일 조건 재학습.** 같은 알고리즘, 같은 하이퍼파라미터 탐색 절차, 같은 블록 분할로 다시 학습한다. 알고리즘이나 분할을 함께 바꾸면 성능 차이의 원인을 특정할 수 없다.
- 4. 성능 비교.** 두 모형의 블록 교차검증 성능을 같은 지표로 나란히 적는다. 표본이 작으면 분할 반복으로 표준편차를 함께 낸다.
- 5. 판정.** 차이가 표준편차 범위 안에 들어가면 공간 정보가 예측에 기여하지 않은 것이므로 공간 명시적이라고 부르지 않는다.

이 절차가 결론을 내지 못하는 조건이 하나 있다. 남은 피쳐가 공간 정보와 강하게 상관되어 공간 구조가 간접적으로 들어가는 경우다. 표고, 하천거리, 불투수면 비율은 좌표를 빼도 위치 정보를 상당 부분 담고 있으므로, 좌표를 제거했다는 사실이 공간 구조를 제거했다는 뜻이 되지 않는다. 이때는 제거 대상을 좌표가 아니라 이웃 관계에서 계산한 변수와 이웃을 참조하는 모델 구조로 정의하고, 두 모형이 같은 원변수 집합을 쓰되 이웃 참조 여부만 다르게 만든다. 그래도 차이가 작으면 그 자료에서 이웃 정보의 기여가 작다는 결론이 되며, 이 결론 자체를 근거 수치로 기록한다.

주의. 공간 데이터를 입력으로 썼다는 사실만으로 GeoAI라 부르면 심사와 예산 심의에서 근거를 대지 못한다. 이 오판은 오류 메시지 없이 지나가고 성능표에도 나타나지 않는다. 공간 정보를 제거한 자료로 같은 모델을 다시 학습해 성능을 비교하고, 차이가 없으면 'GIS + ML'로 기술한다. 비교에 쓴 제거 목록과 두 성능값을 보고서에 함께 실는다.

본서의 방법 중심축

이 책은 GeoAI를 방법 중심축으로 둔다. 지리공간 분석의 전통 방법인 GIS, 공간 통계, 원격탐사는 1층 기반으로 포함하고, 위치 인텔리전스는 Part IV에서 집중해 다룬다. Part IV는 두 장으로 나뉜다. 제14장은 배후 수요를 추정하고 입지를 점수화하는 문제를 다루고, 제15장은 그 결정이 실제로 효과가 있었는지를 식별하는 문제를 다룬다. 공공에서 제8장이 인과추론의 허브를 맡는 것과 같은 자리를 비즈니스에서는 제15장이 맡는다. Part IV 밖에서도 제2장부터 제13장까지 각 장이 비즈니스 분석 예제를 하나씩 담아, 공공과 비즈니스의 공유 부분과 차이 부분을 코드와 실행 결과로 함께 제시한다.

세 개념을 구분하는 실익은 두 가지다. 첫째, GeoAI가 아닌 분석을 GeoAI라 부르는 혼동을 줄인다. 전통 GIS로 충분한 문제에 학습 모델을 얹으면 비용과 불투명성이 늘고, 반대로 공간 구조를 실제로 반영한 모델을 만들어 놓고 그 사실을 설명하지 못하면 방법의 정당성을 잃는다. 둘째, 같은 파이프라인이 공공정책과 비즈니스에서 쓰일 때 어느 지점부터 의사결정 논리가 달라지는지 확인하게 한다. 공간단위 설계, 피쳐 구성, 모델 학습, 공간 교차검증까지의 기술 파이프라인은 공유되지만 산출물이 향하는 방향과 검증 기준은 다르다. 이 공유와 차이의 구조는 1.6의 3층 모델과 1.7에서 구체화한다.

1.5 분석 축의 판정: 영상·래스터와 공간단위

명칭을 판정하면 세 번째 질문으로 넘어간다. 답이 어느 분석 축에서 나오는가다. 이 책은 GeoAI를 두 개의 분석 축으로 정리한다. 이 구분은 분류를 위한 것이 아니라 기술 결과를 어떤 형태의 판단으로 옮길지를 결정하는 틀이다. 축을 잘못 잡으면 영상 판독 성능을 높이는 데 자원을 쓰고도 결정에 쓸 산출물을 만들지 못한다.

두 축의 정의

첫째는 **영상·래스터 축**이다. 위성영상, 항공사진, 드론영상, SAR, 열적외 자료에서 무엇이 어디에 있는지, 무엇이 변했는지, 피해 범위가 어디까지인지를 판독한다. 토지피복 분류, 객체 탐지, 세그멘테이션, 변화 탐지가 여기에 속하며, 산출물은 픽셀 단위 라벨과 그 라벨을 모은 지도다. 둘째는 **공간단위 축**이다. 행정구역, 격자, 필지, 건물, 도로망, 서비스 권역처럼 공간을 분석 단위로 나누고 각 단위의 속성·관계·시간 변화를 모델링한다. 어느 지역이 취약한가, 어디에 자원을 배분해야 하는가, 정책 효과가 어디에서 나타났는가가 이 축의 질문이며, 산출물은 단위별 예측표와 우선순위표다.

표 1.15 GeoAI의 두 분석 축

분석 축	주요 단위	대표 질문	산출물	본서 내 위치
공간단위 축	행정구역, 격자, 필지, 건물, 도로망, 서비스 권역	어느 지역이 취약한가, 어디에 자원을 배분하는가, 정책 효과는 어디에서 나타났는가	단위별 예측표, 우선순위표, 배분안	Ch4, Ch7, Ch8~13의 중심
영상·래스터 축	위성영상, 항공사진, 드론영상, SAR, 열적외 영상	무엇이 어디에 있는가, 무엇이 변했는가, 피해 범위는 어디인가	픽셀 라벨, 분류 지도, 변화 지도	Ch2, Ch3, Ch5, Ch6 및 응용 장의 입력 자료

두 축은 모두 필요하지만 이 책의 중심은 공간단위 축에 둔다. 영상 분석은 자료 획득과 판독의 기술로 다루되, 도시·환경·민원행정·재난안전·치안·복지·보건·지역정책의 최종 판단이 대체로 구역·격자·행정경계·네트워크 권역·필지·건물 단위에서 이루어지기 때문이다. 모델 정확도, IoU, F1 점수는 중간 산출물이며 최종 산출물은 공간단위별 판단표와 그 해석이다. 두 축을 구분하지 않으면 중간 산출물의 개선을 최종 성과로 보고하게 된다.

영상 축에서 공간단위 축으로: 집계의 다섯 단계

영상 판독 결과를 정책 구역 산출물로 옮기는 과정은 다섯 단계로 나뉜다. 각 단계는 앞 단계의 산출물을 입력으로 받으므로 순서를 바꾸면 뒤 단계에서 근거가 사라진다. 침수 탐지를 예로 각 단계의 산출물이 어떤 형태인지 함께 적으면 다음과 같다.

표 1.16 집계 다섯 단계의 입력·계산·산출물

단계	입력	주요 계산	산출물	침수 탐지의 예
1 분석 단위 설정	정책 질문, 집행 주체	현상 단위와 집행 단위를 각각 정하고 집계 가중치를 지정	단위 정의서, 가중치 ω_i	현상 단위 10m 격자, 집행 단위 행정동, 가중치 건물 수
2 원자료 결합	영상 판독 결과, 행정자료, POI(Point of Interest, 관심지점), 도로망	좌표계 통일 후 공간 조인으로 단위에 연결	단위별 원자료 테이블	침수 픽셀 마스크를 건물 폴리곤에 중첩
3 공간 피쳐 구성	단위별 원자료	거리·밀도·접근성·인접성·노출· 변화량 변수 계산	피쳐 행렬 X	건물별 침수 여부, 저지대 여부, 대피소까지 거리
4 모델링과 검증	X, 관측 라벨	공간 자기상관 점검, 공간 블록 교차검증(spatial block cross-validation), 누수 점검	성능표, 잔차 진단	건물별 침수 확률과 블록 교차검증 성능
5 정책 산출물 작성	단위별 예측값	집행 단위로 집계하고 순위를 매김	지도, 순위표, 배분 근거	행정동별 침수 건물 수· 비율, 복구 우선순위표

1단계에서 현상이 발생하는 단위와 정책이 집행되는 단위를 구분한다. 침수는 격자와 구역에서 발생하지만 복구 예산은 행정동에 배정된다. 처음부터 행정동을 분석 단위로 삼으면 동 내부의 저지대와 고지대가 평균에 섞여 신호가 사라지고, 반대로 격자 예측만 제시하면 예산을 어느 기관에 배정할지 결정할 수 없다. 4단계에서 점검하는 두 항목은 성능과 직결된다. 자료 누수는 평가에 쓸 정보가 학습 과정에 미리 섞여 들어가 성능이 부풀려지는 문제이고, 공간 교차검증은 가까운 지역이 학습용과 평가용에 함께 들어가지 않도록 나누어 검증하는 방법이다. 5단계에서 집계 가중치를 표 제목이나 각주에 적지 않으면 그 값이 무엇을 평균한 결과인지 해석할 수 없다.

주의. 학습 자료가 특정 지역에 몰려 있으면 집계 결과가 그 지역 밖에서 신뢰를 잃는다. 수위계가 도심에만 있는 자료로 학습한 모형은 관측이 없는 외곽에서 오차가 커지지만, 전체 성능표에는 도심 표본의 비중이 커서 이 열화가 드러나지 않는다. 학습 표본의 지역 분포를 표로 남기고, 표본이 희박한 구역은 예측값에 표시를 붙여 별도로 보고한다.

집계 단위가 결과를 바꾸는 문제

집계 단위를 바꾸면 같은 관측에서 다른 순위가 나온다. 이 현상을 **MAUP**(Modifiable Areal Unit Problem, 가변적 공간단위 문제)라 부르며, Openshaw(1984)가 체계적으로 정리했다. 규모 효과와 구획 효과 두 갈래가 있는데, 규모 효과는 격자 크기를 바꿀 때, 구획 효과는 같은 크기의 격자를 다른 위치에 정렬할 때 나타난다.

규모 효과를 계산으로 확인한다. 예를 들어 두 지역의 침수 건물이 다음과 같이 분포한다고 하자. A 지역은 1km² 안에 침수 건물 120채가 250m × 250m 한 구획에 몰려 있고 나머지 구획에는 없다. B 지역은 1km² 안에 침수 건물 150채가 전역에 고르게 퍼져 있다. 500m 격자로 집계하면 A는 120채가 든 격자 하나와 0채인 격자 셋이 되어 최댓값이 120이고, B는 네 격자에 각각 약 38채가 들어가 최댓값이 38이다. 500m 격자의 최댓값으로 순위를 매기면 A가 1위다. 같은 자료를 1km 격자로 집계하면 A는 120, B는 150이 되어 B가 1위다.

표 1.17 격자 크기에 따른 집계 결과와 순위

지역	침수 건물 수	500m 격자 최댓값	500m 기준 순위	1km 격자 합계	1km 기준 순위
A (집중형)	120	120	1	120	2
B (분산형)	150	38	2	150	1

두 순위 가운데 하나만 옳은 것이 아니다. 500m 기준은 피해가 가장 심한 지점을 측정하고, 1km 기준은 구역 전체의 피해 규모를 측정한다. 펌프와 임시 배수 설비를 어디에 놓을지 정하는 결정에는 집중 지점을 측정하는 500m 기준이 맞고, 복구 예산을 구역별로 나누는 결정에는 총량을 측정하는 1km 기준이 맞다. 따라서 집계 단위는 자료의 성질이 아니라 결정의 성질에서 정해지며, 그 근거를 문서로 남겨야 다른 단위로 계산한 결과와 섞이지 않는다. MAUP의 정식 진단과 민감도 분석은 제4장에서 다룬다.

주의. 집계 단위를 정하지 않은 채 모델 성능부터 올리면 앞선 개선이 결론에 반영되지 않는다. 단위가 바뀌면 상위 순위가 바뀌므로 성능 비교의 기준 자체가 이동한다. 분석 단위와 집계 가중치를 먼저 확정해 문서로 남기고, 단위를 바꿔야 하면 성능 비교를 처음부터 다시 수행한다.

집계 단위의 관계를 개인에게 옮기는 오류

집계 결과를 해석할 때 나타나는 두 번째 문제는 **생태학적 오류**(ecological fallacy)다. 집계 단위에서 관찰한 관계를 개인 수준의 관계로 옮겨 해석하는 오류이며, 집계 자료만으로는 개인 수준의 관계를 복원할 수 없다는 사실에서 생긴다.

수치로 확인한다. 예를 들어 행정동 X는 인구 1,000명 가운데 고령자가 300명이고 보행 사고가 20건이며, 행정동 Y는 인구 1,000명 가운데 고령자가 100명이고 보행 사고가 10건이라고 하자. 동 단위로 보면 고령자 비율이 30%인 X에서 사고가 20건, 10%인 Y에서 10건이므로 고령자 비율이 높은 동에서 사고가 두 배다. 그러나 사고의 연령 구성을 열어 보면 X에서는 고령자 6건과 비고령자 14건, Y에서는 고령자 1건과 비고령자 9건이다. 개인 기준 사고율은 X에서 고령자 6/300 = 2.0%, 비고령자 14/700 = 2.0%로 같고, Y에서 고령자 1/100 = 1.0%, 비고령자 9/900 = 1.0%로 같다. 동 안에서는 연령이 사고율을 구분하지 않고, 차이는 동 사이에 있다.

이 자료에서 "고령자가 사고를 많이 낸다"는 해석은 성립하지 않는다. 성립하는 해석은 "고령자 비율이 높은 동의 보행 환경이 나쁘다"이며, 두 해석은 대응 방안이 다르다. 앞의 해석은 고령자를 대상으로 한 교육과 규제로 이어지고, 뒤의 해석은 보도 폭·신호 주기·차량 통행량 같은 환경 개선으로 이어진다. 집계 단위

계수를 개인 해석으로 옮기지 않으려면 산출물에 분석 단위를 명시하고, 개인 수준 주장이 필요하다면 개인 단위 자료로 다시 분석한다. 생태학적 오류의 진단 절차는 제4장에서 다룬다.

1.6 층의 판정: 3층 모델과 AI 도입의 정당화

분석 축을 정하면 네 번째 질문으로 넘어간다. 이 과제가 어느 층에서 끝나는가다. 이 책은 GeoAI를 영상 분석으로 환원하지 않기 위해 3층 모델을 쓴다. 3층 모델은 책 전체의 골격이며, 전통 GIS 분석에 머무르면서 GeoAI라 부르는 오판과 반대로 전통 GIS로 충분한 문제에 학습 모델을 엮는 오판을 함께 막는 장치다.

3층 모델의 구조

1층은 공간 데이터 과학의 토대다. 공간 데이터, 좌표계, 공간 통계, 공간 피처 설계, 공간 머신러닝이 여기에 속하며 Part I(Ch1~4)이 담당한다. 2층은 공간 명시적 딥러닝이다. 원시 자료에서 공간 구조를 모델이 직접 학습하며 Part II(Ch5~7)가 담당한다. 3층은 의사결정이다. 공공에서는 인과평가·형평성 감사·자원 배분으로, 비즈니스에서는 입지 점수·투자 판단·자기잠식 검토로 나뉘며 Part III·IV가 담당한다. 아래 층이 위 층의 입력을 만들므로 층은 대체 관계가 아니라 적층 관계다.

flowchart TB

```
L1["1층 - 공간 데이터 과학의 토대\n공간데이터, 좌표계, 공간 통계\n공간 피처 설계, 공간 ML\n(RF·XGBoost)\nPart I · Ch1-4"]
L2["2층 - GeoAI: 공간 명시적 딥러닝\n원시 자료에서 공간 구조를 직접 학습\nCNN·U-Net·FM·SAM·LLM\nPart II · Ch5-7"]
L3["3층 - 의사결정"]
L3P["공공: 인과평가, 형평성 감사\n우선순위, 자원 배분, 책임성\nPart III · Ch8-13"]
L3B["비즈니스: 입지 점수, 수익성\n경쟁 분석, 자기잠식 검토\nPart IV · Ch14-15"]
L1 --> L2 --> L3
L3 --> L3P
L3 --> L3B
```

그림 1.7 본서의 3층 모델: 공간 데이터 과학 → GeoAI → 의사결정

1층과 2층의 경계

1층과 2층을 구분하는 기준은 피처를 누가 만드는가다. 같은 문제를 두 방식으로 푸는 사례를 나란히 놓으면 경계가 분명해진다. 행정동별 폭염 취약성 예측을 예로 든다.

1층 방식에서는 분석자가 입력 변수를 설계한다. 녹지 비율, 불투수면 비율, 65세 이상 인구 비율, 최근 여름 평균 지표면 온도, 인접 동 지표면 온도의 공간 시차, 무더위쉼터까지의 평균 거리를 각각 계산해 스무 개 안팎의 열로 만들고 그래디언트 부스팅에 투입한다. 어떤 변수를 왜 넣었는지가 문서로 남고, 변수별 기여도를 해석할 수 있으며, 표 형태의 자료 수천 행으로 학습이 끝난다. 2층 방식에서는 같은 행정동에 대해 열적외 시계열 타일과 고해상도 토지피복 영상을 그대로 합성곱 신경망에 넣는다. 필터가 학습되면서 표현이 만들어지므로 어떤 변수가 생성되었는지 사람이 미리 정의하지 않는다. 대신 학습에 필요한 자료 규모가 커지고 계산 자원이 늘며, 산출물의 근거를 설명하려면 별도의 해석 절차가 필요하다.

표 1.18 같은 문제의 1층 방식과 2층 방식

항목	1층 방식	2층 방식
예측 대상	행정동별 폭염 취약성 점수	동일
검증 설계	공간 블록 교차검증	동일
최종 산출물	행정동 우선순위표	동일
입력	분석자가 계산한 20개 안팎의 변수	열적외 시계열 타일과 토지피복 영상
피처 설계 주체	분석자	모델
필요 자료 규모	표 자료 수천 행	영상 수만 장 규모
설명 방식	변수 기여도로 직접 해석	별도 해석 절차 필요
계산 자원	CPU로 수 분	GPU로 수 시간

같은 것과 다른 것을 구분하는 이유는 두 방식의 선택이 성능만으로 결정되지 않기 때문이다. 예측 대상, 검증 설계, 최종 산출물이 같으므로 두 방식의 성능은 같은 기준으로 비교할 수 있다. 그러나 자료 규모가 부족하거나 산출물의 근거를 행정 절차에서 설명해야 하는 경우에는 성능이 조금 낮아도 1층 방식이 적합하다. 3층에서 달라지는 것은 산출물이 향하는 방향, 비용함수, 검증 기준이며, 이 세 가지는 1.7에서 다룬다.

GeoAI 판정의 다섯 조건

어떤 분석을 GeoAI라 부르고 어느 층까지 도달했다고 말하려면 다섯 조건을 순서대로 확인한다. 이 확인으로 통과 여부만이 아니라 어디에서 멈추었는지도 알 수 있다.

표 1.19 GeoAI 판정 5조건과 미충족 시의 도달 층

순서	조건	확인 방법	미충족이면
1	전통 GIS·공간통계로 답이 나오지 않는다	규칙 기반 또는 공간통계 기준선을 먼저 만들어 성능과 비용을 비교	1층에서 종료. GIS 기반 진단으로 기술한다
2	AI가 필요한 이유를 적을 수 있다	고차원 영상, 비정형 텍스트, 시공간 비선형 확산, 대규모 반복 예측 가운데 해당 항목을 한 줄로 기술	1층에서 종료
3	모델이 공간 구조를 반영한다	1.4의 세 경로 가운데 첫째 또는 둘째를 충족하는지 확인하고, 판정 절차로 성능 차이를 측정	'GIS + ML'로 기술한다. 2층이 아니다
4	산출물이 실제 결정을 바꾼다	우선순위·위험등급·자원 배분·입지 점수·투자 판단 가운데 어디로 가는지 기술	2층에서 종료. 기술 검증 단계로 기술한다
5	설명·편향·개인정보·감사 체계가 있다	산출 근거 기록, 집단별 오차 점검, 개인정보 처리 근거, 감사 로그와 책임 주체를 확인	3층 진입 보류. 조건을 갖춘 뒤 배치한다

세 번째 조건에서 멈추는 사례가 가장 많다. 위성영상을 입력으로 쓰고 앙상블 모델을 적합했으나 이웃 관계가 모델에 들어가지 않은 경우이며, 이때는 1.4의 판정 절차로 측정한 성능 차이를 근거로 명칭을 정정한다. 다섯 번째 조건은 성능과 무관하게 3층 진입을 막는 조건이다. 딥러닝 모델은 산출 근거를 직접 읽기 어려우므로, 예산 배분이나 규제 판단처럼 근거를 제시해야 하는 결정에서는 설명 절차를 함께 설계한다. 도시 분석에서 공간 명시적 모델의 설명 가능성을 다루는 방법은 Liu et al.(2024)에 정리되어 있으며, 이 책에서는 각 응용 장의 감사 항목으로 나누어 다룬다.

주의. 전통 GIS로 답이 나오는 문제에 딥러닝부터 적용하면 계산 비용과 불투명성이 늘고 기준선이 없어 개선 여부를 말할 수 없다. 이 오판은 성능표에 나타나지 않는다. 비교 대상이 없기 때문이다. 규칙 기반이나 전통 머신러닝으로 기준선을 먼저 만들고, AI를 쓰는 이유를 한 줄로 적을 수 없으면 쓰지 않는다.

층 도달의 조건: 분야별 적용 성숙도

같은 판정 절차를 적용해도 분야에 따라 도달 가능한 층이 다르다. 자료의 축적, 라벨의 품질, 제도적 절차가 분야마다 다르기 때문이다. 재난 매핑처럼 GIS 기반에서 자연스럽게 확장되어 이미 행정에 정착한 영역이 있는 반면, GeoAI 산출물을 국내 정책의 인과적 평가에 결합하는 응용은 아직 초기 단계다. 인과추론 자체가 미성숙하다는 뜻이 아니다. 준실험 설계는 이미 정책평가의 표준이며, 초기인 것은 위성·AI 산출물을 인과 변수로 안정적으로 결합하는 국내 적용이다.

표 1.20 분야별 적용 성숙도와 도달 가능한 층

성숙도	적용 영역	조건	현재 도달 층
높음	재난 매핑, 산사태·침수 위험지도, 인프라 관리	관측 자료와 라벨이 축적되어 있고 행정 절차가 정해져 있다	3층 운영
중간	환경정의·형평성 분석, 도시계획, 취약지역 매핑	자료는 있으나 결정 규칙과 감사 절차가 정비 중이다	2층 도달, 3층 진행 중
초기	GeoAI 산출물을 결합한 인과적 정책 평가, 예측적 정책 설계	식별 전략과 산출물의 결합 방법이 확립되지 않았다	2층 도달, 3층은 사례별 검증 필요

이 표는 어느 분야가 우수한지를 측정하는 표가 아니라, 자기 과제가 어느 조건을 갖추었는지 확인하는 표다. 성숙도가 초기인 영역에서 3층 산출물을 곧바로 제시하면 근거가 부족한 결정을 내리게 되고, 성숙도가 높은 영역에서 2층에 머무르면 이미 가능한 결정 지원을 하지 않는 것이 된다. 판정 결과는 1.9의 명세표에 도달 층과 그 근거로 기록한다.

1.7 적용 맥락의 판정: 공공정책과 비즈니스

층을 판정하면 다섯 번째 질문으로 넘어간다. 산출물이 어느 결정으로 가는가다. 같은 파이프라인이 공공정책에서 쓰일 때와 비즈니스에서 쓰일 때 기술 단계는 대부분 공유되지만 비용함수와 검증 기준은 달라진다. 이 절은 달라지는 지점을 지정한다.

정책 전 주기에서의 역할

GIS는 오래전부터 정책 도구로 제도화되었다. 1854년 콜레라 지도가 펌프 폐쇄로 이어졌듯이 공간 데이터는 본래 의사결정을 지원하기 위해 만들어졌고, 한국에서도 국가공간정보 사업, 도시계획정보시스템, 재해위험지구 관리에서 GIS가 행정 절차에 편입되어 왔다. GeoAI를 쓰면 사람이 규칙으로 처리하기 어려운 자료 — 고차원 위성영상, 비정형 민원 텍스트, 시공간 비선형 확산, 대규모 반복 예측 — 를 처리 대상에 넣을 수 있다. 적용 지점은 정책 주기의 네 단계 전체다.

- **분석 단계:** 어느 지역이 취약한지, 어떤 패턴이 나타나는지를 자료로 진단한다. 산출물은 취약지역 지도와 진단표다.
- **설계 단계:** 자원을 어디에 우선 배분할지 근거를 만든다. 산출물은 우선순위표와 배분안이다.
- **집행 단계:** 실시간 위험 예측으로 대응을 지원한다. 산출물은 침수·산불 조기경보와 대응 지침이다.
- **평가 단계:** 시행된 정책이 실제로 효과가 있었는지 식별한다. 산출물은 효과 추정치와 그 신뢰구간이다.

네 단계 가운데 평가 단계에서 오판이 가장 자주 나온다. 예측 모델의 출력을 그대로 정책효과로 해석하는 경우이며, 측정오차와 평균수축 같은 편의를 보정하지 않으면 효과가 실제보다 크거나 작게 나온다. 두 영역 모두 분석은 예측에서 인과로 올라가는 사다리를 밟는다. 먼저 현황을 기술하고, 다음으로 위험과 취약을 예측해 우선순위를 매기며, 마지막으로 정책이 실제로 효과가 있었는지를 식별한다. 상관과 예측은 인과가

아니며, 정책이 지역·시점에 따라 다르게 적용된 상황 — 자연실험, 규제 경계선 양쪽의 불연속, 시차를 둔 단계적 도입, 정책이 적용되지 않은 통제구역 — 같은 식별 근거가 있을 때에만 인과 주장으로 올라설 수 있다. 이 규율의 방법론 허브가 제8장이다.

국내 정책 적용 영역

이 책의 정책 적용 장(Ch8~13)은 국내 중앙정부·지방정부의 실제 정책 문제를 기본 사례로 삼는다. 각 영역이 어느 분석 단위를 쓰는지 함께 적으면, 자기 과제와 가장 가까운 장을 찾을 수 있다.

표 1.21 국내 정책 분석 영역과 GeoAI 적용

정책 축	대표 문제	대표 분석 단위	본서 장
분석·평가 방법론 (허브)	정책효과 인과평가, 형평성 분석	읍면동, 격자	Ch8
환경·기후	탄소중립, 도시열섬, 녹지·보호지역	보호구역, 격자	Ch9
국토·도시·민원	생활SOC 접근성, 대중교통 접근성, 도로파임, 행정수요 예측	생활권, 격자, 도로망	Ch10
재난안전·치안	침수, 산사태, 범죄위험, 대피소 접근성	유역, 순찰격자, 건물	Ch11
사회복지·보건	복지 사각지대, 의료 접근성, 감염병 확산	행정동, 취약계층 분포	Ch12
지역정책	인구감소지역, 지방소멸, 지역활력	시군구, 생활서비스 권역	Ch13

비즈니스 적용 영역

같은 방법론은 위치 자료를 비즈니스 의사결정에 쓰는 영역에서도 작동한다. 이 책은 제2장부터 제13장까지 각 장에 비즈니스 분석 예제를 하나씩 두고, Part IV에서 비즈니스 GeoAI를 독립 장으로 다룬다.

표 1.22 비즈니스 GeoAI 적용 영역

비즈니스 영역	대표 문제	공공 대비 영역	본서 위치
유통·상권	신규 출점 입지 선정, 상권 세분화, 자기잠식 검토	Ch13 지역활력·상권	Ch13 비즈니스 예제, Ch14, Ch15
부동산·개발	개발 가능 부지 탐색, 입지 잠재력 평가	Ch10 도시·생활권	Ch6 비즈니스 예제, Ch14
물류·배달	배송 권역 최적화, 라스트마일 접근성	Ch10 접근성	Ch10 비즈니스 예제
보험	홍수·화재 등급 산정, 기후 리스크 보험료	Ch11 재난안전	Ch11 비즈니스 예제, Ch15
농업	작물 모니터링, 수확량 예측	Ch9 환경·기후	전용 예제 없음 — Ch5의 영상 기반 원격 추정이 방법을 공유
금융·ESG	ESG 공시, 공급망 환경 감시, 대체 데이터	Ch9 환경 정책	Ch9 비즈니스 예제, 토론(대체 데이터와 공간 금융)
에너지	태양광 입지, 전력 수요 예측	Ch9 탄소중립	전용 예제 없음 — Ch6의 부지 탐색과 Ch7의 시공간 수요 예측이 방법을 공유

마지막 열이 "전용 예제 없음"인 두 영역은 별도의 분석 예제를 두지 않는다는 뜻이며, 다루지 않는다는 뜻이 아니다. 그 영역의 핵심 방법이 다른 장의 예제와 겹쳐 따로 반복할 실익이 적기 때문이다. 작물 생육 추정과 건설 진행률 추정은 둘 다 영상에서 상태를 읽어 수치로 바꾸는 같은 골격을 쓴다. 공공 대비 영역 열을 보면 비즈니스 영역 대부분이 Part III의 공공정책 장과 짝을 이룬다. 보험의 홍수 등급 산정과 공공의 침수 위험 매핑은 같은 영상 분석과 공간 피처를 입력으로 쓰지만, 공공은 대피소 배치와 복구 예산으로, 보험은 보험료 산정과 인수 심사로 산출물을 옮긴다.

"공공은 취약지역, 비즈니스는 유망지역"이라는 대비는 편의상의 구분이며 정확한 이분법이 아니다. 기업도 수요는 있으나 공급이 부족한 지역을 찾고, 공공도 수요가 집중된 지역에 자원을 배분한다. 공공이 찾는 사각지대와 비즈니스가 찾는 미충족 시장은 구조적으로 같은 문제이며, 계산 절차의 상당 부분이 겹친다. 이 겹침은 각 장의 비즈니스 분석 예제와 Part IV에서 사례별로 확인한다.

1.8 본서의 구성과 읽는 순서

여섯 번째 질문은 이 책의 어느 장을 읽는가다. 이 절은 전체 구성과 배경별 읽는 순서, 실습 환경을 제시한다.

5 Part / 15장과 종장

이 책은 공간 데이터 과학의 기초부터 GeoAI, 공공정책·비즈니스 의사결정까지를 5개 Part, 15개 장과 종장으로 구성한다. 배열은 공간 데이터 과학(Part I) → GeoAI(Part II) → 의사결정(Part III·IV) 순이며, 1.6의 3층 모델과 직접 대응한다. 각 장의 제목은 그 장이 다루는 절차의 단계를 부제로 드러낸다. Part I은 분석자가 공간 피처를 직접 설계하고 검증하는 방법을 다룬다. 제1장이 개념과 판정 기준을, 제2장이 좌표계와 전처리를, 제3장이 자료 확보와 권한·편향 판정을, 제4장이 공간단위 예측의 표준 절차를 담당한다. Part II는 모델이 원시 자료에서 공간 구조를 학습하는 구간이다. 제5장이 위성영상 딥러닝, 제6장이 세그멘테이션과 변화 탐지, 제7장이 자율 GIS와 시공간 예측을 다룬다. Part III는 국내 공간정책 문제에 이 방법들을 적용하며, 제8장이 인과추정의 허브 역할을 한다. Part IV는 비즈니스 의사결정을 전담하고, 종장은 열다섯 장에서 반복한 규율을 다섯 질문으로 압축한다.

실습 환경

이 책은 Python 기초 문법과 NumPy·Pandas 자료 처리 경험을 전제한다. 공간 데이터 처리 경험이 없는 독자는 Part I을 먼저 읽고 벡터·래스터·포인트 클라우드의 개념을 익힌 뒤 실습에 진입한다. 실습은 프로젝트 루트의 통합 가상환경 하나에서 진행한다. 장별로 환경을 따로 만들지 않고 전 장의 의존성을 루트 `.venv` 하나에 설치해 버전 충돌 없이 재사용한다.

```
python -m venv .venv
.venv\Scripts\activate          # Windows (본서의 기준 환경)
# source .venv/bin/activate     # macOS/Linux
pip install -r lecture_practice/requirements.txt
```

딥러닝 실습(제5장 이후)에서는 GPU 가속이 학습 시간을 줄인다. 이 책의 모든 코드는 NVIDIA CUDA, Apple Silicon MPS, CPU를 자동으로 구분해 실행하므로 GPU가 없는 환경에서도 같은 코드가 CPU에서 동작하며, 감지 함수의 구현은 제5장에서 도입한다. 각 장에서 쓰는 라이브러리는 다음과 같다.

표 1.23 본서의 핵심 Python 라이브러리

라이브러리	용도	주요 등장 장
GeoPandas	벡터 데이터 처리	전 과정
Rasterio	래스터 데이터 처리	2~5장
scikit-learn	머신러닝	4, 5, 8~13장
PyTorch	딥러닝	5~7장
xarray	다차원 배열 처리	3장
Matplotlib	시각화	전 과정

1.9 과제 위치 명세

새 과제를 시작할 때 다음 표를 먼저 채운다. 앞부분 여섯 구획은 1.1의 여섯 질문에 대응하고, 뒷부분은 도입 여건을 기록한다. 채우지 못한 행이 있으면 그 판정의 근거가 아직 없다는 뜻이므로, 해당 절로 돌아가 근거를 만든 뒤 다음 단계로 넘어간다.

표 1.24 과제 위치 명세

질문	항목	기록할 내용
1 자료 형식	자료 유형	벡터·래스터·포인트 클라우드 가운데 무엇을 쓰는가
1	해상도·좌표계	공간 해상도와 좌표계는 무엇이며 목적에 맞는가
1	재방문 주기	시간 변화를 볼 수 있는 관측 간격인가
2 명칭	세 축의 답	분야 축·방법 축·용도 축에서 각각 무엇이라 부르는가
2	공간 명시성 근거	1.4의 세 경로 가운데 무엇을 썼고, 제거 비교의 성능 차이는 얼마인가
2	학습 기반 여부	모형을 자료에서 적합하는가, 분석자가 형태를 지정하는가
3 분석 축	축 결정	답이 영상 판독에서 나오는가 공간단위 표에서 나오는가
3	현상 단위와 집계 단위	각각 무엇이며 어떤 가중치로 집계하는가
3	집계 단위의 근거	왜 이 크기와 경계인가. 다른 단위에서 순위가 어떻게 달라지는가
4 층	도달 층	1층·2층·3층 가운데 어디에서 끝나는가
4	기준선	규칙 기반 또는 전통 머신러닝 기준선의 성능과 비용은 얼마인가
4	AI 도입 사유	고차원 영상·비정형 텍스트·시공간 비선형·대규모 반복 가운데 무엇인가
5 결정 맥락	산출물 사용처	예산 배분·형평 판단인가 투자·출점 판단인가
5	비용함수	어느 오류가 더 비싼가. 재현율 우선인가 정밀도 우선인가
5	검증 기준	공간 교차검증 외에 무엇으로 확인하는가
6 읽을 장	필요한 방법	어느 Part의 방법이 필요한가
여건	데이터	라벨의 양과 품질은 충분한가. 정기 수집·갱신 체계가 있는가
여건	인프라	학습·추론에 필요한 계산 자원과 배포 환경이 확보되었는가
여건	인력	GIS 도메인 지식과 머신러닝 기술을 함께 갖춘 인력과 유지보수 체계가 있는가
여건	예산	자료·클라우드·인건비의 지속 가능한 예산이 확보되었는가
여건	거버넌스·규제	개인정보 처리 근거, 공공데이터 활용 절차, 조달 요건을 충족하는가. 감사 로그와 책임 주체가 정해졌는가
여건	평가	기존 방법 대비 개선 목표를 정확도·속도·비용으로 정의했는가

명세를 채우다 보면 앞선 판정을 되돌려야 하는 경우가 나온다. 여건 항목에서 라벨이 부족하다고 확인되면 4번 질문의 도달 층을 2층에서 1층으로 낮추게 되고, 그러면 2번 질문의 명칭도 함께 바뀐다. 이런 되돌림은 오류가 아니라 명세표가 작동한 결과다. 판정을 문서로 남기지 않으면 같은 과제 안에서 서로 다른 전제를 가진 결정이 병행되고, 그 불일치는 대개 산출물이 나온 뒤에야 드러난다. 명세표는 보고서의 방법 절을 쓸 때 목차의 뼈대로도 쓴다.

참고문헌

- Anselin, L. (1988). *Spatial Econometrics: Methods and Models*. Kluwer Academic Publishers. <https://doi.org/10.1007/978-94-015-7799-1>
- Dresner Advisory Services. (2019). *2019 Location Intelligence Market Study*. <https://dresneradvisory.com/products/2019-location-intelligence-market-study>
- Goodchild, M. F. (1992). Geographical Information Science. *International Journal of Geographical Information Systems*, 6(1), 31–45. <https://doi.org/10.1080/02693799208901893>
- Janowicz, K., Gao, S., McKenzie, G., Hu, Y., & Bhaduri, B. (2020). GeoAI: Spatially explicit artificial intelligence techniques for geographic knowledge discovery and beyond. *International Journal of Geographical Information Science*, 34(4), 625–636. <https://doi.org/10.1080/13658816.2019.1684500>
- Lam, R., Sanchez-Gonzalez, A., Willson, M., Wirnsberger, P., Fortunato, M., Alet, F., et al. (2023). Learning skillful medium-range global weather forecasting. *Science*, 382(6677), 1416–1421. <https://doi.org/10.1126/science.adi2336>
- Li, W. (2020). GeoAI: Where machine learning and big data converge in GIScience. *Journal of Spatial Information Science*, 20, 71–77. <https://doi.org/10.5311/JOSIS.2020.20.658>
- Li, W., Hsu, C.-Y., Wang, S., Kedron, P., & Goodchild, M. F. (2024). GeoAI for science and the science of GeoAI. *Annals of the American Association of Geographers*. <https://doi.org/10.1080/24694452.2024.2394285>
- Liu, P., Zhang, Y., & Biljecki, F. (2024). Explainable spatially explicit geospatial artificial intelligence in urban analytics. *Environment and Planning B: Urban Analytics and City Science*, 51(5), 1104–1123. <https://doi.org/10.1177/23998083231204689>
- Longley, P. A., Goodchild, M. F., Maguire, D. J., & Rhind, D. W. (2015). *Geographic Information Science and Systems* (4th ed.). Wiley.
- Microsoft. (2025). *Global ML Building Footprints*. GitHub Repository. <https://github.com/microsoft/GlobalMLBuildingFootprints>
- Naushad, R., Kaur, T., & Ghaderpour, E. (2021). Deep transfer learning for land use and land cover classification: A comparative study. *Sensors*, 21(23), 8083. <https://doi.org/10.3390/s21238083>

Nearing, G., Cohen, D., Dube, V., Gauch, M., Gilon, O., Harrigan, S., et al. (2024). Global prediction of extreme floods in ungauged watersheds. *Nature*, 625, 80–86. <https://doi.org/10.1038/s41586-024-07145-1>

Openshaw, S. (1984). *The Modifiable Areal Unit Problem*. Geo Books. (CATMOG 38)

Pebesma, E., & Bivand, R. (2023). *Spatial Data Science: With Applications in R*. Chapman and Hall/CRC. <https://doi.org/10.1201/9780429459016>

Qi, C. R., Su, H., Mo, K., & Guibas, L. J. (2017). PointNet: Deep learning on point sets for 3D classification and segmentation. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 652–660. <https://doi.org/10.1109/CVPR.2017.16>

Rey, S. J., Arribas-Bel, D., & Wolf, L. J. (2023). *Geographic Data Science with Python*. Chapman and Hall/CRC. <https://doi.org/10.1201/9780429292507>

Tobler, W. R. (1970). A computer movie simulating urban growth in the Detroit region. *Economic Geography*, 46(sup1), 234–240. <https://doi.org/10.2307/143141>

UC San Diego. (2023). *ALERTCalifornia AI-powered wildfire detection*. <https://alertcalifornia.org>

U.S. Department of Agriculture, National Agricultural Statistics Service (USDA NASS). *CropScape and Cropland Data Layer*. https://www.nass.usda.gov/Research_and_Science/Cropland/SARS1a.php

Wilkinson, R., Mleczko, M. M., Brewin, R. J. W., Gaston, K. J., Mueller, M., Shutler, J. D., et al. (2023). Environmental impacts of earth observation data in the constellation and cloud computing era. *Science of the Total Environment*, 909, 168584. <https://doi.org/10.1016/j.scitotenv.2023.168584>