

7장 자율 GIS와 시공간 예측, 도구를 언제 믿고 언제 사람이 확인할까

1. 이 장의 핵심 질문

1. 언어모델에게 "도서관에서 1km 이내 인구는?"이라고 물으면 답은 나온다. 그 답을 얼마나 믿을 수 있으며, 무엇을 검증해야 하는가
 2. "내일 수요는 90% 확률로 70~130개"라는 구간은 어떻게 만드는가. 그리고 이 오차는 관측을 늘려서 줄일 수 있는 것인가, 아닌 것인가
 3. 구간을 받은 점장은 결국 발주서에 숫자 하나를 적어야 한다. 그 숫자를 정하는 값은 예측 모델 안에 없는데, 어디에서 오는가
- ☐ 세 질문의 공통점은 **도구가 낸 값을 그대로 결정에 쓰지 않는다**는 것임
- 언어모델의 답에는 검증 관문이 붙고, 예측값에는 구간이 붙으며, 구간에는 비용 구조가 붙어야 결정이 됨

2. 도입 사례: 질의 4건 중 3건이 거부된 이유

- ☐ `lecture_practice/chapter7/results/7-1-autonomous-gis-query.log` 의 실제 실행 결과를 먼저 봄
- 레이어 카탈로그는 인구격자·도서관(6개소)·학교(12개소), 좌표계 EPSG:5179
 - 네 개의 질의를 순서대로 넣었을 때 결과는 다음과 같음

질의	처리 결과
"도서관에서 1km 이내 인구는?"	✅ 성공 — 약 73,713명
"지하철역에서 500m 이내 인구는?"	❌ 거부 — 존재하지 않는 레이어 '지하철역'
"위도 37.5 경도 127.0 학교에서 1km 이내 인구는?"	❌ 거부 — 좌표계 불일치(질의 EPSG:4326 vs 데이터 EPSG:5179)
"그 동네 살기 좋은 곳 알려줘"	❌ 거부 — 의도를 파싱할 수 없음(모호한 질의)

- ☐ 요약: 질의 4건 중 성공 1건, 검증 단계가 차단 3건
- 눈여겨볼 것은 성공 1건이 아니라 **거부된 3건이 왜 거부되었는가**임
 - 검증 단계가 없었다면 세 질의 모두 "그럴듯한 숫자"가 나왔을 것임 — 존재하지 않는 레이어에도 숫자를 만들어 낼 수 있고, 좌표계가 다른 좌표를 그대로 계산에 넣어도 프로그램은 멈추지 않음

○ 이 장의 앞부분이 다루는 것이 바로 이 지점임. 검증이 없으면 오류가 오류로 보이지 않음

3. 무엇을 말기고 무엇을 사람이 하는가

3.1 언어모델이 잘하는 것과 못하는 것

- 언어모델에 공간 질문을 던지면 과제 유형에 따라 결과가 크게 갈림
 - "행정동과 법정동의 차이를 설명하라"에는 정확한 답이 나옴
 - 그런데 좌표 계산·위상 관계(인접·포함·교차)·거리와 방향 추론에서는 틀린 답이 확정적인 어조로 나오는 경우가 많음
 - 이 현상을 **환각(hallucination)**이라 함 — 근거 없는 내용을 사실 형태의 문장으로 만들어 내는 것
- 원인은 학습 방식에 있음
 - 언어모델은 텍스트의 다음 단어를 맞히도록 학습함
 - 그래서 반복 등장한 지식과 서술 패턴은 잘 재현함
 - 그러나 좌표는 텍스트에서 규칙성 없이 흩어진 숫자열이라 **그 산술적 의미가 학습되지 않음**

3.2 위임 경계를 표로 정한다

- 그래서 역할을 나눔. 언어모델은 자연어로 의도를 받아 "어떤 계산을 할 것인가"로 옮기는 **인터페이스** 역할만 맡고, 버퍼·교차·좌표 변환 같은 실제 공간 연산은 검증된 GIS 엔진에 맡김

위임 가능	위임 불가
공간 용어·개념의 설명	좌표·거리·면적의 직접 계산
분석 절차의 계획 수립("버퍼 → 교차 → 집계 순서로")	"A동과 B동이 인접한가" 같은 위상 판정
결과 수치를 서술문으로 바꾸기	특정 지역 통계값을 언어모델이 직접 인출하는 것

- 2절의 4건 질의로 이 경계를 확인할 수 있음
 - 1번 질의("도서관에서 1km 이내 인구는?")는 **위임 가능** 영역임 — 반경과 대상을 계획으로 옮기는 일까지가 언어모델의 몫이고, 실제 계산은 GIS 엔진이 함
 - 4번 질의("그 동네 살기 좋은 곳 알려줘")는 **위임 불가** 영역임 — "살기 좋다"는 판단은 집계 도구가 답할 수 있는 질문이 아님. 검증 단계가 이를 "의도를 파싱할 수 없음"으로 거부함
 - 2번·3번 질의는 위임 가능 영역의 질문이지만 **입력 자체가 성립하지 않는 경우**임. 다음 절의 관문이 이 둘을 잡음

3.3 이 장의 실습을 시작하기 전에

- 4절부터 9절까지는 설명과 실습을 나누지 않음 — 각 절 첫머리에 실행할 명령이 나오고 그 아래에 코드와 실제 실행 결과가 이어짐. 순서대로 따라가면 이 장의 모든 수치를 직접 만들게 됨
- 먼저 패키지를 설치함. 이 장은 7-2·7-3이 PyTorch를 쓰므로 공통 설치에 더해 두 번째 명령을 한 번 실행함

```
cd geoai_public # 저장소 루트 - 이 장의 명령은 모두 여기서 실행함
pip install -r lecture_practice/requirements-student.txt
python lecture_practice/setup_torch.py
```

- 이 장에서 실행할 코드는 다섯 개이며 순서가 정해져 있음

순서	실행할 파일	하는 일	절
1	7-0-simdata-prep.py	레이어 카탈로그와 교통량 시계열 생성	4·6절 준비
2	7-1-autonomous-gis-query.py	자연어 공간 질의와 검증 관문	4
3	7-2-spatiotemporal-uncertainty.py	LSTM + MC Dropout 예측구간	6
4	7-0b-demand-simdata.py	점포 6곳 × 품목 2종 × 1,460일 수요 패널 생성	5·7~9절 준비
5	7-3-demand-newsvendor.py	정규화 conformal 구간과 임계비 발주 채점	5·7~9

- 1번이 2·3번의 입력을 만들고 4번이 5번의 입력을 만들 — **준비 코드(1·4번)를 먼저 실행**해야 나머지가 돌아감
- 다섯 코드 모두 인터넷 없이 돌아가고 GPU도 필요 없음
- 3·5번은 실제로 LSTM을 학습시킴. 가속기(CUDA·MPS)를 쓰면 LSTM 커널이 달라져 같은 시드에서도 소수점 아래가 흔들리므로, 코드가 장치를 CPU로 고정해 둬(7-2 는 `DEVICE = torch.device("cpu")` , 7-3 은 `PIN_CPU = True`)
- **7-1 은 외부 언어모델 API를 호출하지 않음** — 실제 시스템은 GPT류 언어모델로 자연어 질의를 해석하지만, 이 실습은 비용과 재현성을 위해 **결정론적 규칙 기반 파서**로 언어모델의 역할을 대신함. 이 실습의 핵심은 파서 자체의 정교함이 아니라, **검증 단계가 없으면 무엇이 잘못되는가**를 눈으로 보이는 것임
- 5·7·8·9절의 표는 전부 **7-3 한 번의 실행**에서 나옴 — 5절에서 한 번 돌려 두면 뒤 절에서 다시 실행할 필요가 없음. 6절만 7-2 의 출력임
- 본문에 인용한 출력은 모두 `lecture_practice/chapter7/results/` 의 실행 로그에서 그대로 가져온 것이며, 어느 파일에서 왔는지를 출력 블록 첫 줄에 적어 두었음 — 화면에 나온 값과 그 파일을 한 줄씩 대조하면 됨

4. 검증 관문: 오류가 오류로 보이게 만들기

4.1 질의 처리 순환과 세 가지 확인

□ 준비 코드와 첫 번째 코드를 실행함. 2절의 표와 이 절의 결과는 전부 이 두 명령의 출력임

```
python lecture_practice/chapter7/code/7-0-simdata-prep.py
python lecture_practice/chapter7/code/7-1-autonomous-gis-query.py
```

```
# 출처: lecture_practice/chapter7/results/7-0-simdata-prep.log
인구격자 400셀 → pop_grid.parquet
도서관 6개소 → libraries.parquet, 학교 12개소 → schools.parquet (좌표계 EPSG:5179)
교통량 시계열 1200시간 → traffic_volume.npy
```

- 준비 코드가 만드는 것은 인구격자 400셀·도서관 6개소·학교 12개소의 가상 도시 카탈로그(EPSG:5179) 와, 6절에서 쓸 교통량 1,200시간 시계열임
- 자연어 질의를 GIS 연산으로 옮기는 시스템의 처리 순서는 다섯 단계임

질문 → 의도 파싱(계획 수립) → [검증 관문] → 도구 호출(GIS 엔진 실행) → 결과

- 7-1-autonomous-gis-query.py 가 이 다섯 단계를 그대로 구현함
- 파싱은 정규식으로 "○○에서 △△m 이내"라는 패턴을 찾아 계획(`buffer_count` , 대상 레이어, 반경)으로 바꾸는 규칙 기반 함수가 맡음
- 검증 관문은 계획을 실행하기 전에 세 가지를 확인함
 1. 파싱이 됐는가 — 안 되면 "의도를 파싱할 수 없음"으로 거부
 2. 참조한 레이어가 카탈로그에 있는가 — 없으면 "존재하지 않는 레이어"로 거부
 3. 질의 좌표계가 데이터 좌표계와 같은가 — 다르면 "좌표계 불일치"로 거부
- 아래는 그 코드에 실제 실행 결과를 주석으로 붙인 것임

```

# 주석에 붙인 출력의 출처: lecture_practice/chapter7/results/7-1-autonomous-gis-query.log
import re

DATA_CRS = "EPSG:5179"          # 데이터 좌표계(한국 미터좌표)

# [1] 의도 파싱 - "∞에서 Δm 이내"를 계획(plan)으로 바꿈
def parse_query(q):
    m = re.search(r"(\S+)?(?:에서|로부터)\s*([\d.]+)\s*(km|m)\s*(?:이내|반경)", q)
    if m and ("인구" in q or "사람" in q):
        layer, val, unit = m.group(1), float(m.group(2)), m.group(3)
        radius_m = val * 1000 if unit == "km" else val
        coord_crs = "EPSG:4326" if re.search(r"위도|경도|lat|lon", q) else DATA_CRS
        return {"op": "buffer_count", "layer": layer, "radius_m": radius_m,
                "coord_crs": coord_crs}
    return {"op": None, "error": "의도를 파싱할 수 없음(모호한 질의)"}

# [2] 검증 관문 - 실행 전에 세 가지를 확인함
def verify(plan, catalog):
    if plan["op"] is None:                                # 확인 1: 파싱 실패
        return False, plan["error"]
    if plan["layer"] not in catalog:                      # 확인 2: 없는 레이어
        avail = ", ".join(catalog.keys())
        return False, f"존재하지 않는 레이어 '{plan['layer']}' (사용가능: {avail})"
    if plan.get("coord_crs") != DATA_CRS:               # 확인 3: 좌표계 불일치
        return False, (f"좌표계 불일치: 질의 좌표 {plan['coord_crs']} vs "
                       f"데이터 {DATA_CRS} - 변환(transform) 없이 실행 불가")
    return True, "검증 통과"

# [3] 통과한 계획만 GIS 연산(버퍼 안 인구 합산)으로 넘김
# 출력: Q: 도서관에서 1km 이내 인구는?
#       계획: buffer_count(layer=도서관, radius=1000m)
#       ✅ 성공: 약 73,713명
#       Q: 지하철역에서 500m 이내 인구는?
#       ❌ 거부: 존재하지 않는 레이어 '지하철역' (사용가능: 인구격자, 도서관, 학교)
#       Q: 위도 37.5 경도 127.0 학교에서 1km 이내 인구는?
#       ❌ 거부: 좌표계 불일치: 질의 좌표 EPSG:4326 vs 데이터 EPSG:5179
#       - 변환(transform) 없이 실행 불가
#       Q: 그 동네 살기 좋은 곳 알려줘

```

✗ 거부: 의도를 파싱할 수 없음(모호한 질의)
[요약] 질의 4건 중 성공 1건, 검증 단계가 차단 3건

□ 화면에 나온 값에서 읽을 것

- 거부된 세 질의가 세 확인에 하나씩 나눠 걸림 — 2번 질의는 두 번째 확인에서, 3번 질의는 세 번째 확인에서, 4번 질의는 첫 번째 확인에서 막힘
- 성공한 1번 질의만 계획이 화면에 함께 찍힘(`buffer_count(layer=도서관, radius=1000m)`) — 거부된 질의는 계획이 실행 단계로 넘어가지 않으므로 숫자가 아예 나오지 않음
- 73,713명은 도서관 6개소 각각의 1km 버퍼 안 인구격자 값을 더한 것임. 버퍼가 겹치는 구역은 중복해서 더해지므로 "1km 안에 사는 사람 수"가 아니라 "도서관별 1km 인구의 합"으로 읽음

4.2 관문을 두 층으로 나눈다

- 관문 하나로는 잡히지 않는 것이 있음. 계획으로 환원되지 않는 정보 — 단위, 부호, 요청의 성격 — 는 계획만 보서는 확인할 수 없음
- 그래서 일반 형태에서는 관문을 두 층으로 나눔. **계획 자체를 검사하는 관문과 원 질의를 함께 놓고 검사하는 관문**임




그림 7.1 질의 처리 순환과 두 층의 검증 관문. 1차 관문은 모델이 만든 계획을 검사하고, 2차 관문은 원 질의를 함께 본다. 계획으로 환원되지 않는 정보(단위·부호·요청의 성격)는 2차 관문에서만 잡힌다.

4.3 검증이 없으면 무엇이 남는가

- 7-1-autonomous-gis-query.log 의 마지막 줄이 이 절의 핵심을 그대로 적어 둠 — "검증(self-verifying) 단계가 없었다면 CRS 오류·없는 레이어가 그대로 '그럴듯한 숫자'로 출력됐을 것이다"
- 이 문장을 3번 질의로 구체화하면 다음과 같음
 1. 위도·경도가 섞인 질의를 검증 없이 그대로 실행함
 2. 시스템은 좌표계가 다르다는 사실을 알아채지 못함
 3. 잘못된 위치를 기준으로 인구를 집계함
 4. 결과값은 숫자로 나오고, 그 숫자가 틀렸다는 사실은 프로그램 어디에도 나타나지 않음

- 이것이 환각이 실무에서 위험한 이유임. 오류가 오류처럼 보이지 않고 **정상 출력의 형태로** 나감

4.4 관문으로 막을 수 없는 실패도 있다

- 언어모델이 "도구를 호출하겠습니다"라고 문장으로만 답하고 실제 호출 형식은 비워 두는 실패를 **형식 미준수**(format violation)라 함
 - 내용은 맞는데 실행 형식이 어긋난 경우임. 실제 언어모델 API를 호출하는 환경에서 관측되는 실패 유형이며, 이 장의 규칙 기반 파서로는 재현되지 않음
- **이 실패는 검증 관문으로 막을 수 없음.** 관문은 계획을 검사하는데, 형식 미준수에서는 검사할 계획 자체가 만들어지지 않음
 - 그래서 별도로 **처리율**(처리되어야 할 정상 질의 가운데 실제로 실행한 비율)을 재야 발견됨. 환각은 "틀린 값이 나오는" 실패이고 형식 미준수는 "아무 값도 안 나오는" 실패라서, 확인하는 지표가 다름

4.5 감사 로그

- 7-1 은 처리한 질의마다 질의문·상태·거부 사유·결과값을 `autonomous_gis_query_log.csv` 에 저장함
 - 이런 기록을 **감사 로그**(audit log)라 함. 특정 수치가 어느 레이어와 어느 환경에서 나왔는지, 어떤 질의가 왜 거부되었는지를 사후에 재구성할 수 있게 하는 자료임
 - 감사 로그가 없으면 "몇 건이 거부됐다"는 집계는 남지만 "**어떤 유형이 반복해서 거부되는가**"는 알 수 없음. 관문 규칙을 어디에 보강해야 할지도 로그 없이는 판단할 수 없음

5. 기준선과 겨루기

- 예측 모델을 도입하기 전에 확인할 것이 하나 있음 — **학습이 필요 없는 규칙보다 나은가**
 - 이 확인 없이 모델을 배포하면 가장 기본적인 질문에 답하지 않은 채 도구를 넣는 셈이 됨
- 수요 패널을 만들고 이 장의 대표 실습을 실행함. **5·7·8·9절의 모든 표가 이 한 번의 실행에서 나옴**

```
python lecture_practice/chapter7/code/7-0b-demand-simdata.py
python lecture_practice/chapter7/code/7-3-demand-newsvendor.py
```

- 준비 코드는 점포 6곳 × 품목 2종 × 1,460일 = 17,520행의 수요 패널을 두 벌 만들 — 잡음 크기가 점포·수요 수준에 따라 달라지는 **본 데이터**와, 평균 수요는 같고 잡음 크기 구조만 없앤 **등분산 대조군**임 (7.3절에서 씀)
- 대표 실습의 출력은 다섯 덩어리로 나뉨 — [1] 본 데이터의 conformal 구간(7절), [2] 등분산 대조군 (7.3절), [3] 세 발주 정책의 손익(8.2절), [4] 임계비 민감도(9절), [5] 비용비 오지정 대 예측 개선(5절·9절)
- `7-3-demand-newsvendor.py` 가 LSTM과 함께 **계절 나이브**(지난주 같은 요일 값을 그대로 쓰는 규칙)를 같은 방식으로 채점함

출처: lecture_practice/chapter7/results/7-3-demand-newsvendor.log [5]

품목	기준_LSTM_참CR	예측열화_계절나이브	비용비오지정_대칭가정	비용비오지정_뒤바뀜	RMSE_LSTM	RMSE_나이브
도시락	45,666,000	16,632,000	1,031,600	55,312,400	23.45	32.22
우산	30,012,000	13,231,500	42,333,000	67,516,500	6.48	8.58

품목	RMSE(LSTM)	RMSE(계절 나이브)
도시락	23.45	32.22
우산	6.48	8.58

□ 화면에 나온 값에서 읽을 것

- 두 품목 모두 LSTM이 나이브 기준선보다 오차가 작음(도시락 23.45 대 32.22, 우산 6.48 대 8.58)
- 같은 출력의 나머지 열은 9절에서 씬 — 금액은 발주 결정까지 내려간 뒤에야 읽을 수 있는 값이므로 여기서는 오른쪽 두 열만 봄
- 비교할 때는 **같은 자료, 같은 분할, 같은 평가**로 나란히 잼. 서로 다른 자료에서 잼 성능을 비교하면 차이의 원인이 모델인지 자료인지 구분할 수 없음. 위 출력의 나이브도 LSTM과 같은 3분할·같은 conformal 절차를 거쳐 채점된 것임
- 7-2-spatiotemporal-uncertainty.py (교통량 예측)는 LSTM 하나만 학습시키므로 이 절의 비교 대상이 아님. RMSE 12.82 는 다음 절에서 불확실성을 분해하는 데 쓰는 값으로 다시 나옴

6. 점추정을 구간으로 바꾼다

6.1 점추정만으로는 왜 부족한가

□ "내일 이 구간 교통량은 95대/시간"이라는 예측을 받았다고 함

- 실제 값이 90~100 사이에 들어온다면 별다른 대응이 필요 없지만, 45~145 사이에 들어온다면 예비 인력이나 완충 자원이 필요함
- **같은 점추정에서 정반대 대응이 나올 수 있음.** 점추정 하나만 전달하면 그 값이 얼마나 빗나갈 수 있는지가 전달되지 않음

6.2 두 성분으로 나누어 재기

□ 예측 오차는 원인이 다른 두 성분으로 나뉨

- **모델 불확실성**(epistemic uncertainty) — 자료가 부족해서 생기는 오차. 관측을 늘리면 줄어듦
- **데이터 잡음**(aleatoric uncertainty) — 현상 자체의 변동에서 오는 오차. 자료를 아무리 늘려도 줄어들지 않음

- **둘을 구분해야 하는 이유는 처방이 갈리기 때문임.** 모델 불확실성이 크면 관측을 늘리는 것이 답이고, 데이터 잡음이 크면 관측을 늘려도 소용없고 완충 자원을 마련하는 것이 답임
- 세 번째 코드를 실행함. 4절에서 준비 코드가 만든 교통량 시계열을 입력으로 받아 두 성분을 각각 잼

```
python lecture_practice/chapter7/code/7-2-spatiotemporal-uncertainty.py
```

- **모델 불확실성은 MC Dropout**(Gal & Ghahramani, 2016)으로 잼. 학습을 마친 신경망에서 드롭아웃 층을 끄지 않고 그대로 둔 채 같은 입력을 50번(`MC_SAMPLES = 50`) 통과시킴. 매번 다른 뉴런 조합이 비활성화되므로 50개의 서로 다른 예측이 나오고, 그 흩어진 정도(표준편차)를 모델 불확실성으로 씀
- **데이터 잡음**은 학습 구간에서 실제값과 예측값의 차이(잔차)를 모아 그 분산을 계산함. 학습을 마친 구간에서도 남는 오차이므로 줄어들지 않는 변동의 추정치로 씀

```

# 주식에 붙인 출력의 출처: lecture_practice/chapter7/results/7-2-spatiotemporal-uncertainty.log
import numpy as np
import torch

# [1] 시간 순서대로 앞 70%만 학습에 씬 - 미래 정보가 학습에 섞이지 않게 함
n_train = int(len(X) * 0.7)
# 출력: 데이터: 1200시간 합성 교통량, 윈도우 24h → 다음 1h 예측
#       학습 823 / 검증 353 (앞 70% 학습, 시계열 누수 차단)
#       학습 완료(에폭 15, 최종 train MSE 0.1693)

# [2] 데이터 잡음 - 학습 구간 잔차의 분산
aleatoric_var = float(np.var(tr_actual - tr_pred))

# [3] 모델 불확실성 - dropout을 켜 채 50번 통과시켜 예측의 흠뻑을 봄
model.train() # * 추론에서도 dropout 유지(MC Dropout 핵심)
samples = np.zeros((MC_SAMPLES, len(Xte)))
with torch.no_grad():
    for s in range(MC_SAMPLES):
        samples[s] = model(Xte_t).squeeze(-1).numpy()
epistemic_var = samples.var(axis=0)

# [4] 두 성분을 결합해 90% 구간을 만듦(정규 근사,  $\pm 1.645\sigma$ )
total_std = np.sqrt(epistemic_var + aleatoric_var)
pred_lo = pred_mean - 1.645 * total_std
pred_hi = pred_mean + 1.645 * total_std
# 출력: [점추정] RMSE = 12.82 대/시간
#       평균 표준편차 epistemic 7.23 / aleatoric 11.69 (epistemic 비중 28%)
#       90% 구간 포함률(coverage) = 91.5% (목표 90%)
#       평균 구간 폭 = 45.18 대/시간

```

□ 자료: 합성 교통량 1,200시간, 과거 24시간을 보고 다음 1시간을 예측함

- 앞 70%를 학습(823개 창), 뒤 30%를 검증(353개 창)에 씬 — 시간 순서대로 나눠 미래 정보가 학습에 섞이지 않게 함
- 15에폭 학습 후 최종(정규화된 값 기준) train MSE 0.1693

6.3 실제 분해 결과

- 위 실행의 결과를 항목별로 정리하면 다음과 같음

항목	값
점추정 RMSE	12.82 대/시간
모델 불확실성(epistemic) 평균 표준편차	7.23
데이터 잡음(aleatoric) 표준편차	11.69
모델 불확실성 비중	28%
90% 구간 포함률	91.5% (목표 90%)
평균 구간 폭	45.18 대/시간

□ 데이터 잡음(11.69)이 모델 불확실성(7.23)보다 큼. 이 자료·이 모델에서는 관측을 늘리는 것보다 변동을 흡수할 완충 자원을 마련하는 쪽이 더 정확한 처방이라는 뜻임

○ 두 성분은 원인이 달라 독립으로 간주하고, 표준편차는 각각을 제곱해 더한 뒤 제곱근을 취해 결합함

전체 $\sigma = \sqrt{(\text{모델 불확실성}^2 + \text{데이터 잡음}^2)}$

□ 이 표의 값을 직접 넣어 확인할 수 있음. $\sqrt{(7.23^2 + 11.69^2)} = \sqrt{(52.27 + 136.66)} = \sqrt{188.93} \approx 13.75$

○ 90% 구간은 좌우로 1.645 σ 씩 확장하므로 폭은 $2 \times 1.645 \times 13.75 \approx 45.24$

○ 실제 로그의 평균 구간 폭 45.18 과 거의 같음. 차이는 모델 불확실성이 관측마다 다른 값을 갖는 데서 오는 반올림 수준의 오차임

○ 이 계산에서 확인할 성질 하나 — 두 값의 차이가 클수록 작은 쪽의 기여는 급격히 줄어듦. 두 성분이 3과 4라면 결합값은 7이 아니라 5이고, 1과 10이라면 10.05로 큰 쪽이 사실상 전체를 결정함

6.4 구간을 만든 뒤에는 포함률을 확인한다

□ 구간을 만들었으면 그 구간이 실제로 목표한 비율만큼 정답을 담는지 확인함. 이 값이 포함률임

○ 위 표의 90% 구간 포함률은 91.5%로 목표 90%에 가까움. 목표보다 크게 낮으면 구간이 좁아 위험을 과소평가한 것이고, 크게 높으면 구간이 넓어 쓸모가 떨어진 것임

○ 같은 실행이 불확실성이 큰 시점을 구간 폭 순서대로 다섯 개 찍음

출처: lecture_practice/chapter7/results/7-2-spatiotemporal-uncertainty.log

[정책 연계] 예측 불확실성이 큰 상위 5개 시점(추가 관측·보수적 대응 대상)

test_idx	pred_mean	interval_width	actual
55	96.8	52.6	105.900002
135	10.3	50.5	9.100000
32	93.4	50.4	115.099998
210	8.6	50.1	40.500000
80	84.1	50.0	90.400002

검증 순번	예측 평균	구간 폭	실제값
55	96.8	52.6	105.9
135	10.3	50.5	9.1
32	93.4	50.4	115.1
210	8.6	50.1	40.5
80	84.1	50.0	90.4

- 표를 읽는 방법은 다음과 같음. "구간 폭" 열이 클수록 모델이 그 시점을 자신 없어 한다는 뜻이고, "실제값"과 "예측 평균"의 차이가 클수록 실제로 많이 빗나간 것임
 - 210번 시점을 보면 구간 폭이 50.1로 넓었고 실제값(40.5)이 예측 평균(8.6)과 크게 벌어짐 — 넓은 구간이 실제로 큰 오차와 함께 나타난 사례임

7. 단위마다 다른 폭 — 정규화 conformal

7.1 하나의 폭으로는 맞지 않는 경우

- 6절의 방식은 자료 전체에 하나의 잡음 구조를 가정함
 - 그런데 점포처럼 분석 단위가 여러이고 단위마다 빗나가는 폭이 다르면, **모든 단위에 같은 폭의 구간을 주는 것이 맞지 않음**
- 7-3-demand-newsvendor.py 가 이 문제에 쓰는 방법이 **정규화 conformal**임. 절차는 네 단계임
 1. **점추정** — 학습 구간으로 LSTM을 학습해 각 관측의 예측값을 얻음
 2. **오차 규모 적합(학습 구간)** — 점포마다 "이 수준의 수요를 예측할 때 평균적으로 얼마나 빗나갔는가"를 학습 구간의 실제 잔차로 회귀함. 이렇게 얻은 값을 $\hat{\sigma}$ 로 씀
 3. **분위 보정(보정 구간)** — 학습에 쓰지 않은 별도의 보정 구간에서 (실제값 - 예측값) / $\hat{\sigma}$ 로 정규화한 잔차를 모음. $\hat{\sigma}$ 로 나누었으므로 점포마다 다른 잡음 규모가 하나의 척도로 정리됨
 4. **분위 산출(시험 구간)** — 목표한 분위(예: 상하 5%씩 남긴 90% 구간)에 해당하는 정규화 잔차를 보정 구간에서 찾고, 그 값에 시험 구간의 $\hat{\sigma}$ 를 다시 곱해 각 관측의 실제 구간으로 되돌림
 - 자료를 **학습 60% / 보정 20% / 시험 20%**로 시간 순서대로 나눔
 - 6절의 방식이 학습과 검증 두 구간만 썼던 것과 다른 지점임 — 분포를 가정하지 않는 대신, **학습에 전혀 쓰지 않은 보정 구간을 따로 떼어 뒀다 함**
- 5절에서 이미 실행한 코드의 출력임. 다시 보려면 같은 명령을 씀

python lecture_practice/chapter7/code/7-3-demand-newsvendor.py

출처: lecture_practice/chapter7/results/7-3-demand-newsvendor.log [1]

[이분산 · 도시락] 창 8,592개 (학습 5,088 / 보정 1,752 / 시험 1,752)

시험 RMSE = 23.45 단위/일

정규화 포함률 89.3% · 평균 폭 69.94 · 폭 변동계수 0.364 · 반폭-실오차 순위상관 +0.343

수요 3분위별 포함률 91.3% / 91.1% / 85.6% (편차 5.7%p)

비정규화(C2) 포함률 88.9% · 평균 폭 72.70 · 폭 변동계수 0.000 · 반폭-실오차 순위상관 정의불가 (상수폭)

수요 3분위별 포함률 96.2% / 89.2% / 81.3% (편차 14.9%p)

[이분산 · 우산] 창 8,592개 (학습 5,088 / 보정 1,752 / 시험 1,752)

시험 RMSE = 6.48 단위/일

정규화 포함률 89.6% · 평균 폭 19.68 · 폭 변동계수 0.473 · 반폭-실오차 순위상관 +0.385

수요 3분위별 포함률 88.5% / 90.1% / 90.1% (편차 1.5%p)

비정규화(C2) 포함률 89.3% · 평균 폭 19.49 · 폭 변동계수 0.000 · 반폭-실오차 순위상관 정의불가 (상수폭)

수요 3분위별 포함률 97.4% / 89.4% / 81.0% (편차 16.4%p)

○ 이 출력에서 정규화 쪽만 뽑아 정리하면 다음과 같음(도시락·우산, 이분산 자료)

품목	시험 창 수	시험 RMSE	90% 구간 포함률	평균 구간 폭	폭 변동계수
도시락	1,752	23.45	89.3%	69.94	0.364
우산	1,752	6.48	89.6%	19.68	0.473

○ 두 품목 모두 포함률이 목표 90%에 가깝게 맞음

○ "폭 변동계수"는 구간 폭이 점포마다 얼마나 달랐는지를 나타냄. 0에 가까우면 모든 점포에 같은 폭을 준 것이고, 클수록 점포별로 다른 폭을 준 것임. 0.364와 0.473은 점포마다 상당히 다른 폭이 주어졌다는 뜻임

7.2 전체 포함률만 보면 문제가 드러나지 않는다

○ 위 출력에서 "수요 3분위별 포함률" 줄만 네 개 뽑아 나란히 놓으면 다음과 같음

품목	방식	수요 3분위별 포함률	편차
도시락	정규화	91.3% / 91.1% / 85.6%	5.7%p
도시락	비정규화(모든 관측에 같은 폭)	96.2% / 89.2% / 81.3%	14.9%p
우산	정규화	88.5% / 90.1% / 90.1%	1.5%p
우산	비정규화	97.4% / 89.4% / 81.0%	16.4%p

- 전체 포함률만 보면 정규화와 비정규화의 차이가 크지 않았음(도시락 89.3% 대 88.9%, 우산 89.6% 대 89.3%)
- 그런데 수요 수준별로 나눠 보면 비정규화 방식은 수요가 적은 날에는 필요 이상으로 넓고(96~97%) 수요가 많은 날에는 목표에 크게 못 미침(81~89%)
 - 정규화 방식은 이 편차가 훨씬 작음(5.7%p·1.5%p 대 14.9%p·16.4%p)
 - 전체 평균만 보고했다면 이 구조적 문제가 드러나지 않았을 것임. 포함률은 조건을 나눠서도 확인함

7.3 이 방법이 언제 이득을 주는지 확인하기

- 같은 실행이 잡음의 크기 구조만 상수로 바꾼 대조 자료(`store_demand_homoskedastic.parquet`)에도 같은 절차를 돌려 [2] 구간에 함께 찍음

```
# 출처: lecture_practice/chapter7/results/7-3-demand-newsvendor.log [2]
[대조군 C1·C2 판정] 정규화의 이득이 정말 이분산에서 오는가

품목   데이터   폭변동계수   반폭_실오차_순위상관   분위편차_정규화   분위편차_비정규화C2
도시락  이분산(본)  0.364           0.343           5.7           14.9
도시락  등분산(C1)  0.032           0.035           3.8           5.1
우산    이분산(본)  0.473           0.385           1.5           16.4
우산    등분산(C1)  0.062           0.070           3.3           2.1

폭변동계수 = 구간 폭이 관측마다 얼마나 달라지는가(등분산이면 0에 가까워야 한다)
분위편차 = 수요 3분위별 조건부 포함률의 최대-최소(%p). 작을수록 고른 구간
```

품목	폭 변동계수(본 자료)	폭 변동계수(등분산 대조군)
도시락	0.364	0.032
우산	0.473	0.062

- 등분산 자료에서는 정규화 절차를 동일하게 적용했는데도 폭이 거의 균일해짐(변동계수가 0에 가까워짐)
- 이는 폭의 차이가 알고리즘이 임의로 만든 것이 아니라 **자료의 이분산**(점포·시간대별로 잡음 크기가 다른 성질)에서 왔다는 근거임

- 잡음 구조가 실제로 다르지 않다면 정규화를 적용해도 결과가 상수 폭과 비슷해짐. 이 대조는 정규화 conformal이 "이분산이 있는 자료에서만 이득을 준다"는 조건을 실측으로 확인한 것임
- 분위편차 열도 같은 방향을 가리킴 — 본 자료에서는 정규화가 편차를 5.7 대 14.9, 1.5 대 16.4로 크게 줄이지만, 등분산 대조군에서는 도시락 3.8 대 5.1로 차이가 작고 우산은 3.3 대 2.1로 오히려 정규화 쪽이 약간 큼. **이득이 없는 자료에 이 절차를 붙이면 계산만 늘고 결과는 나아지지 않음**

8. 구간을 발주량 하나로 바꾼다

8.1 신문팔이 문제와 임계비

- 두 점포가 동일한 수요 예측구간을 받았다고 함. 하나는 도시락 가게이고 하나는 우산 가게임
 - 도시락은 재고가 남으면 당일 폐기되어 원가 전액이 손실임
 - 우산은 재고가 남으면 다음 강우일에 팔리지만, 품질이면 손님이 다른 가게로 감
 - 전자는 남는 손실(잉여 손실)이 크고 후자는 모자란 손실(결품 손실)이 큼. **같은 구간을 받았어도 전자는 구간의 아래쪽에서, 후자는 위쪽에서 발주해야 함**
- 이 판단을 계산으로 옮긴 것이 **신문팔이 문제**(newsvendor problem)임. 결품 1단위의 손실을 C_u , 잉여 1단위의 손실을 C_o 라 하면 최적 발주량은 수요 분포에서 다음 비율에 해당하는 지점임

$$\text{임계비(CR)} = C_u / (C_u + C_o)$$

- 7-3-demand-newsvendor.py 가 쓴 가정값은 실행 첫머리에 그대로 찍힘

```
# 출처: lecture_practice/chapter7/results/7-3-demand-newsvendor.log
[비용 가정값] 전부 가정이며, 결론은 금액이 아니라 임계비의 방향에 둔다
품목   Cu   Co   임계비   설명
도시락 1200 2000 0.3750   Cu=판매 마진, Co=원가+폐기비
우산   15000 1500 0.9091  Cu=마진+기회 상실, Co=재고 유지비
```

품목	C_u (결품 1단위)	C_o (잉여 1단위)	임계비	설명
도시락	1,200	2,000	0.375	C_u =판매 마진, C_o =원가+폐기비
우산	15,000	1,500	0.909	C_u =마진+기회 상실, C_o =재고 유지비

- 도시락의 임계비 0.375는 0.5보다 작음 — 구간의 아래쪽에서 발주하라는 뜻
- 우산의 임계비 0.909는 0.5보다 훨씬 큼 — 구간의 위쪽 끝 가까이에서 발주하라는 뜻
- 두 값은 전부 **가정값**임. 실제 업종의 원가율·폐기율을 확인할 근거가 없어 이 예제를 설명하기 위해 정한 값이며, 어떤 업종의 실제 임계비도 나타내지 않음. 이 계산에서 결론으로 삼는 것은 금액의 절댓값이 아니라 **두 임계비가 0.5의 반대편에 있다는 방향**임

8.2 세 발주 정책의 실현 손익

- 임계비가 정해지면 7절의 conformal 절차가 산출한 분위 함수에서 그 비율에 해당하는 값을 뽑아 발주량으로 씀
 - 실무에서 자주 보이는 다른 두 규칙과 비교해 봄
- **P1 점추정** — 예측값을 그대로 발주함. 이는 결품과 잉여 손실이 같다고 가정한 것과 같음(임계비를 0.5로 고정한 것)
- **P2 구간 상한** — 90% 구간의 상한을 그대로 발주함. 이는 임계비를 신뢰수준의 상한 분위(95%)로 고정한 것과 같음
- **P3 newsvendor** — 8.1의 임계비 분위로 발주함
- 시험 구간(품목당 1,752건)에서 세 정책을 실제 수요로 채점한 결과가 같은 실행의 [3] 구간임

출처: lecture_practice/chapter7/results/7-3-demand-newsvendor.log [3]

도시락 (CR = 0.375, 시험 1,752건)

정책	결품손실	과잉손실	총손실	실현서비스수준	평균발주	P3대비
P1 점추정	21,774,000	24,336,000	46,110,000	44.7%	86.8	444,000
P2 구간 상한(90%)	1,459,200	117,894,000	119,353,200	93.6%	123.1	73,687,200
P3 newsvendor(CR)	28,104,000	17,562,000	45,666,000	34.9%	81.8	0

우산 (CR = 0.909, 시험 1,752건)

정책	결품손실	과잉손실	총손실	실현서비스수준	평균발주	P3대비
P1 점추정	59,850,000	6,390,000	66,240,000	57.6%	17.0	36,228,000
P2 구간 상한(90%)	4,380,000	26,824,500	31,204,500	95.3%	26.9	1,192,500
P3 newsvendor(CR)	7,560,000	22,452,000	30,012,000	92.8%	25.1	0

도시락 (CR = 0.375)

정책	결품손실	과잉손실	총손실	평균발주	실현 서비스 수준
P1 점추정	21,774,000	24,336,000	46,110,000	86.8	44.7%
P2 구간 상한(90%)	1,459,200	117,894,000	119,353,200	123.1	93.6%
P3 newsvendor	28,104,000	17,562,000	45,666,000	81.8	34.9%

우산 (CR = 0.909)

정책	결품손실	과잉손실	총손실	평균발주	실현 서비스 수준
P1 점추정	59,850,000	6,390,000	66,240,000	17.0	57.6%
P2 구간 상한(90%)	4,380,000	26,824,500	31,204,500	26.9	95.3%
P3 newsvendor	7,560,000	22,452,000	30,012,000	25.1	92.8%

- 표를 읽는 순서는 다음과 같음. 먼저 P3(newsvendor)의 총손실을 기준으로 삼고, P1·P2가 그보다 얼마나 큰지를 봄
- 도시락에서는 P2(구간 상한)가 P3보다 훨씬 비쌈 — 총손실이 119,353,200원으로 P3(45,666,000원)의 약 2.6배임
 - 원인은 과잉손실에 있음. 90% 구간의 상한을 매일 발주량으로 쓰면 매일 폐기가 발생함
 - **90% 구간의 신뢰수준과 이 품목의 최적 서비스 수준(임계비 0.375)은 전혀 다른 값인데, 구간 상한 발주는 이 둘을 같다고 착각한 규칙임**
- 우산에서는 P2가 P3와 비슷함 — 95.3%와 92.8%로 총손실 차이가 크지 않음. 우산의 임계비(0.909)가 90% 구간의 상한 분위(95%)와 가깝기 때문임
 - **이 우연한 일치가 함정임.** 우산에서 구간 상한 발주가 잘 맞았다고 해서 같은 규칙을 도시락에 그대로 적용하면 2.6배의 손실을 입음. 임계비가 다르면 최적 발주 지점도 완전히 달라짐
- 세 정책이 실제로 어디에 선을 긋는지 시험 구간 90일치로 확인함

같은 예측, 정반대 발주 — 임계비가 구간의 어느 지점을 고르는가




그림 7.2 점포 S1의 시험 구간 90일. 회색이 실현 수요, 파란 점선이 P1(점추정), 빨간 점선이 P2(구간 상한), 초록 실선이 P3(newsvendor)임. 왼쪽 도시락에서는 초록선이 파란선 아래에 있고, 오른쪽 우산에서는 파란선보다 크게 위로 올라가 빨간선에 근접함. 같은 파이프라인이 낸 두 그림에서 두 선의 상하 관계가 뒤집힌 원인은 임계비뿐임(도시락 0.375, 우산 0.909)

9. 임계비를 조금 틀려도 괜찮은가

- 임계비 Cu·Co는 가정값이므로 실제로는 어느 정도 오차가 있을 수 있음

- 이 오차가 결정에 얼마나 영향을 주는지 확인하려면, 같은 예측을 고정한 채 가정 임계비를 여러 값으로 바꿔 가며 손실을 계산해 보면 됨
- 5절에서 실행한 코드가 이 계산을 [4] 구간에 찍어 둠

출처: lecture_practice/chapter7/results/7-3-demand-newsvendor.log [4]

도시락 (참 CR = 0.375)

가정CR	평균발주	총손실	최적대비초과
0.100	62.6	63,916,400	+18,250,400
0.250	74.7	48,825,600	+3,159,600
0.375	81.8	45,666,000	+0
0.500	88.0	46,697,600	+1,031,600
0.750	102.1	64,122,800	+18,456,800
0.909	117.0	100,978,400	+55,312,400
0.950	123.1	119,353,200	+73,687,200

우산 (참 CR = 0.909)

가정CR	평균발주	총손실	최적대비초과
0.100	9.0	211,434,000	+181,422,000
0.250	12.6	133,045,500	+103,033,500
0.375	14.6	97,528,500	+67,516,500
0.500	16.5	72,345,000	+42,333,000
0.750	20.8	37,879,500	+7,867,500
0.909	25.1	30,012,000	+0
0.950	26.9	31,204,500	+1,192,500

도시락 (참 CR = 0.375)

가정 CR	평균발주	총손실	최적 대비 초과
0.100	62.6	63,916,400	+18,250,400
0.250	74.7	48,825,600	+3,159,600
0.375	81.8	45,666,000	+0
0.500	88.0	46,697,600	+1,031,600
0.750	102.1	64,122,800	+18,456,800
0.909	117.0	100,978,400	+55,312,400

- 참값(0.375) 근처에서는 손실 곡선이 평탄함. 임계비를 0.375 대신 0.5로 잘못 잡아도 초과 손실은 1,031,600원으로 최적값의 2%대에 그침

- 그러나 다른 품목의 임계비(우산의 0.909)를 그대로 가져다 쓰면 초과 손실이 55,312,400원으로 뛰어오름
- 즉 담당자가 확인해야 할 것은 임계비를 소수점 몇 자리까지 정밀하게 잡느냐가 아니라, **그 값이 0.5의 어느 쪽에 얼마나 떨어져 있는가임**
- 같은 판단을 다른 방식으로도 확인할 수 있음. 7-3 은 "임계비를 얼마나 틀려야 예측 모델을 통째로 계절 나이브로 바꾼 것과 같은 손실이 나는가"도 계산해 [5] 구간 끝에 찍음

출처: lecture_practice/chapter7/results/7-3-demand-newsvendor.log [5]

[등가 오차] 계절 나이브로 떨어뜨린 대가와 같은 손실을 내는 CR 오차 폭

품목 참CR 나이브대가 등가CR오차_아래 등가CR오차_위

도시락 0.375 16,632,000 0.270 0.355

우산 0.909 13,231,500 0.214 0.086

(임계비를 이 폭만큼 틀리면 예측 모델을 계절 나이브로 바꾼 것과 같은 손실이 된다)

- 도시락에서 계절 나이브로 예측을 낮추면 손실이 16,632,000원 늘어남. 이만큼의 손실을 임계비를 잘못 잡아서 내려면 참값(0.375)에서 아래로 0.270, 위로 0.355만큼 벌어져야 함
- 우산에서는 나이브 대가가 13,231,500원이고, 이만큼의 손실을 내려면 참값(0.909)에서 아래로 0.214, 위로 0.086만큼 벌어져야 함
- 두 계산이 같은 결론을 가리킴 — **예측을 조금 개선하는 것과 비용을 대략이라도 맞게 잡는 것 중, 이 예제에서는 비용비의 방향을 맞추는 쪽이 더 큰 영향을 줌**

10. 핵심 요약

- **언어모델은 좌표 계산에 쓰지 않음.** 텍스트의 다음 단어를 맞히도록 학습해 좌표의 산술적 의미가 학습되지 않기 때문이며, 의도를 계획으로 옮기는 인터페이스 역할까지만 맡김 (3.1, 3.2)
- **검증 관문은 실행 전에 세 가지를 확인함** — 파싱 가능 여부, 레이어 존재 여부, 좌표계 일치 여부. 실습에서 질의 4건 중 3건이 이 세 확인에 각각 걸림 (4.1)
- **검증이 없으면 오류가 정상 출력의 형태로 나감.** 좌표계가 다른 좌표를 그대로 계산해도 숫자는 나오고, 그 숫자가 틀렸다는 사실은 프로그램 어디에도 나타나지 않음 (4.3)
- **형식 미준수는 관문으로 못 막음.** 검사할 계획 자체가 만들어지지 않으므로 처리율을 따로 재야 발견됨 (4.4)
- **예측 모델은 학습이 필요 없는 규칙과 먼저 겨룸.** 실습에서 LSTM 23.45 대 계절 나이브 32.22 (5절)
- **예측 오차의 두 성분은 처방이 다름.** 모델 불확실성은 관측을 늘려 줄이고 데이터 잡음은 완충 자원으로 흡수하며, 두 성분은 제공해 더한 뒤 제공근을 취해 결합함 (6.2, 6.3)
- **전체 포함률만 보면 구조적 문제가 안 드러남.** 비정규화 방식은 전체로는 88.9%로 멀쩡해 보이지만 수요 3분위별 편차가 14.9%p였음 (6.4, 7.2)
- **단위마다 잡음 규모가 다르면 폭도 달라야 하고, 그 이득은 이분산이 있을 때만 나옴.** 등분산 대조군에서 폭 변동계수가 0.364에서 0.032로 떨어짐 (7.1, 7.3)

- 구간을 수량 하나로 바꾸는 값은 예측 모델 밖에 있음. 임계비 $CR = Cu/(Cu+Co)$ 이며, 도시락 0.375와 우산 0.909가 0.5의 반대편에 놓임 (8.1)
- 구간 상한을 발주량으로 쓰면 안 됨. 신뢰수준과 최적 서비스 수준은 다른 값이고, 도시락에서 이 혼동의 대가가 2.6배 손실이었음. 임계비는 방향이 중요하고 소수점 정밀도는 덜 중요함 (8.2, 9절)

11. 과제

```
python scripts/submit.py 7 --id 학번 --name 이름
```

- 이 명령이 대신 처리하는 작업: 7-0b-demand-simdata.py 실행 → 대표 실습 7-3-demand-newsvendor.py 를 학번 시드로 실행 → 제출용 파일 생성
 - 학번마다 난수가 다르므로 결과 숫자도 사람마다 다름. 이 장의 실습은 난수를 쓰므로 1장과 달리 옆 사람과 값이 달라도 정상임
- 끝나면 submissions/ 폴더에 제출_7장_학번.md 파일이 생김
 - 열어 보면 실행 결과가 이미 붙어 있음
 - 눈여겨볼 곳은 두 품목의 임계비, 그리고 예측값과 실제 발주량의 위아래 관계
- 맨 아래 빈칸 세 개를 채우면 됨
 1. 눈에 띈 숫자 하나를 그대로 옮겨 적고, 왜 눈에 띄었는지 한 문장으로
 2. 그 숫자가 왜 그렇게 나왔는가
 3. 점장에게 "내일 90% 확률로 70~130개"라고만 전하면 무엇이 남는가? 숫자 하나를 정해 준다면 몇 개이고, 그 근거는 무엇인가?
- 3번이 이 과제의 핵심. 1·2번은 로그를 보면 답이 나오지만 3번은 그렇지 않음

- 막혀도 제출함
- 실행이 도중에 실패하면 오류 메시지가 자동으로 담기고, 질문이 "어디서 막혔나"로 바뀜
- 실행 성공 여부로 점수를 매기지 않음