

1장 공간 데이터 과학과 GeoAI, 무엇이 다르고 어떤 결정으로 이어지나

- 이 장에 나오는 국가 수, 좌표계, 분석 결과 수치는 모두 `lecture_practice/chapter1/` 의 코드를 실제로 실행해 얻은 값
- 예시를 위해 지어낸 숫자는 없음

1. 이 장의 핵심 질문

- 이 장은 세 가지 질문에 답함
- **질문 1** — GIS와 GeoAI는 무엇이 같고 무엇이 다른가? 어떤 분석이면 GeoAI라 부를 수 있는가?
- **질문 2** — 지도 위의 분석 결과는 어떻게 "결정"으로 이어지는가?
- **질문 3** — 같은 지도를 놓고 시청은 "어디가 위험한가"를 묻고 편의점 본사는 "어디에 댈까"를 묻음. 두 질문은 어디서 갈라지는가?
- 이 장은 GeoAI를 화려한 최신 기술로 소개하는 장이 아님
- 새 문제를 만났을 때 어떤 도구가 필요한지, 어디까지 가야 하는지 판정하는 눈을 만드는 장
- 이 판정을 건너뛰고 방법부터 고르면, 뒤에서 배우는 위성영상·머신러닝·정책 평가·입지 분석이 모두 따로 노는 지식이 됨

2. 지도가 결정을 바꾼 첫 사례

- 1854년 런던에 콜레라가 번짐. 당시에는 나쁜 공기가 원인이라는 설이 우세했음
- 의사 John Snow가 한 일은 세 단계로 나눌 수 있음
 1. 위치를 찍음 — 사망자가 발생한 집을 지도 위에 점으로 표시
 2. 패턴을 봄 — 브로드 스트리트의 수도 펌프 주변에 점이 몰려 있음을 확인
 3. 행동을 바꿈 — 그 펌프의 손잡이를 제거하도록 요청
- 이 사례가 공간 분석의 출발점으로 꼽히는 이유는 지도가 예뻐서가 아님
- 지도 위의 패턴이 실제 행동(펌프 폐쇄)으로 이어졌기 때문
- 2단계에서 멈추었다면 아무것도 바뀌지 않았음. 점이 몰려 있다는 사실만으로는 사망자가 줄지 않음

- 오늘날의 분석도 같음. 모델이 정확도 95%를 기록해도 그 값이 누군가의 결정을 바꾸지 않으면 1854년의 2단계에 머무는 것
- 이 장 전체가 이 세 단계 — 데이터, 패턴, 결정 — 를 오늘의 도구로 다시 밟는 과정임

3. GIS: 지도 프로그램이 아니라 공간 의사결정 체계

- **지리정보시스템**(Geographic Information System, GIS)은 공간적으로 참조된 데이터를 수집·저장·관리·분석·시각화하는 통합 체계
- QGIS나 ArcGIS 같은 소프트웨어 이름이 아님. 데이터를 모으고, 정리하고, 분석하고, 결과를 공유하는 **전체 흐름**을 가리킴
- 목적이 지도 출력이 아니라 **공간적 결정 지원**이라는 점이 핵심




그림 1.1 GIS 작업 흐름

- 흐름의 어느 한 곳이 부실하면 결과를 믿기 어려워짐
- 소프트웨어가 좋아도 데이터 품질이 나쁘면 결과가 나쁨
- 데이터가 좋아도 해석해서 결정으로 옮길 사람이 없으면 2절의 2단계에서 멈춤
- 좌표계를 잘못 고르면 면적과 거리부터 어긋나고 그 오차가 최종 판단까지 옮겨 감. 이 문제는 2장에서 다룸

4. 공간 데이터의 세 형식

- 공간 데이터는 표현 방식에 따라 세 형식으로 옴. 형식이 정해지면 쓸 수 있는 연산과 모델이 함께 정해지므로, 새 자료를 받으면 형식부터 확인함

4.1 벡터: 경계가 있는 객체

- **벡터 데이터**는 점(Point), 선(LineString), 면(Polygon)의 기하 객체로 공간을 표현함
- 행정경계, 도로망, 건물처럼 **경계가 명확한 대상**에 적합함
- 기하 정보와 속성 테이블(이름·인구·용도 같은 값)이 결합된 형태로 저장됨

- 5절 실습에서 읽는 국가 경계 데이터가 벡터의 전형임. 국가는 경계가 정해진 면이고, 섬이 많은 나라는 여러 면의 묶음이라 `MultiPolygon` 이 됨
- 자주 쓰는 연산 네 가지

연산	무엇을 하는가	쓰는 곳
버퍼(buffer)	객체 주변에 일정 거리의 영역을 만듦	학교 반경 500m 안전구역
오버레이(overlay)	두 레이어의 겹침을 계산	침수구역과 건물의 겹침
공간 조인(spatial join)	공간 관계로 두 자료를 결합	점포 목록을 행정동에 붙이기
네트워크 분석	최단 경로와 도달권을 계산	소방서 5분 도달권

4.2 래스터: 연속 현상을 픽셀로

- 래스터 데이터는 균일한 격자의 각 픽셀에 값을 담아 연속 현상을 표현함
- 기온, 고도, 식생, 위성영상처럼 **경계가 뚜렷하지 않고 이어지는 현상**에 적합함
- 픽셀 하나의 크기(공간 해상도)가 표현할 수 있는 최소 단위를 정함

주의. 해상도가 높으면 작은 것을 볼 수 있지만 자료가 커지고 촬영 주기가 길어짐. 해상도가 낮으면 자주 볼 수 있지만 작은 변화를 놓침. 어느 쪽이 옳은지는 목적이 정함 — 건물 단위 피해 판독에는 고해상도가, 전국 식생 변화 추적에는 잦은 재방문이 더 중요함

4.3 포인트 클라우드: 3차원 점의 집합

- 포인트 클라우드는 3차원 좌표 (x, y, z)의 집합으로 지형과 구조물을 표현함
- 라이다(LiDAR) 센서 자료가 대표적이며, 건물 높이·나무의 수직 구조처럼 벡터·래스터로는 잡히지 않는 것을 봄
- 이 책에서는 벡터와 래스터를 주로 쓰고, 포인트 클라우드는 형식이 존재한다는 것만 알아 두면 됨

5. 실습: 첫 공간 데이터 읽기

- 실습 README(실행 방법 및 기대값): [lecture_practice/chapter1/README.md](https://github.com/geoai-lecture-practice/chapter1/README.md)
- 실습 코드: `lecture_practice/chapter1/code/1-1-geoai-tools-preview.py`
- 결과 로그: `lecture_practice/chapter1/results/1-1-geoai-tools-preview.log`
- 이 교재의 실습은 전부 `lecture_practice/` 폴더에 있음

- **GPU 없이 노트북에서 돌아가도록 가볍게 만든 실습**이며, 본문의 실행 수치는 전부 이 폴더의 결과 로그에서 나옴
- 위 코드를 실행하면 GeoPandas로 Natural Earth 국가 경계 데이터를 읽어 다음이 나옴
- 전체 국가 수: 177
- 좌표계(CRS): EPSG:4326
- 기하 유형: MultiPolygon, Polygon
- 경계 상자: 경도 -180.00 ~ 180.00, 위도 -90.00 ~ 83.65
- 아시아 국가 수: 47
- 데이터 형태: (177, 169) — 국가 177개가 행, 속성이 169열
- 메모리 사용량: 356.4 KB
- 이 숫자들이 중요한 이유는 "멋진 결과"라서가 아님
- GIS 작업은 대개 이런 담백한 확인에서 시작함 — 객체가 몇 개인가, 좌표계는 무엇인가, 기하 유형은 점·선·면 중 무엇인가, 자료가 덮는 범위는 어디까지인가
- 이 네 가지를 확인하지 않으면 4.1절의 어떤 연산을 쓸 수 있는지도 정할 수 없음

6. GeoAI: GIS 위에 학습이 올라간다

6.1 무엇이 다른가

- **GeoAI**는 공간 구조를 모델에 명시적으로 반영해 공간 패턴을 학습·예측하고, 그 산출물을 공간적 결정으로 연결하는 분야
- 핵심은 "공간 데이터에 AI를 썼다"가 아니라 **공간 구조가 모델 안으로 들어갔는가**
- 전통 GIS와의 차이를 대비하면

구분	전통 GIS	GeoAI
규칙	사람이 지정 (경사도 15도 이상 = 위험)	데이터에서 학습
비선형 관계	표현이 어려움	자동으로 포착
다루는 규모	수천~수만 객체	수억 픽셀
해석	규칙이 명시적이라 쉬움	별도 설명 절차가 필요

- 마지막 행이 중요함. GeoAI가 항상 나은 것이 아님
- 규칙이 이미 명확하고 데이터가 적으면 전통 GIS가 더 나옴 (9.3절에서 다시 다룸)

- 규모의 감각을 위한 실제 사례 하나 — Microsoft Global ML Building Footprints는 위성·항공 영상에서 건물 윤곽을 자동 추출해 약 14억 개의 건물 폴리곤을 공개함
- 사람이 하나씩 그렸다면 불가능한 규모. "AI가 공간 데이터를 읽는다"는 말의 구체적인 뜻이 이것임

6.2 판정의 도구: 두 조건

- 어떤 분석이 GeoAI인지는 **두 조건**으로 판정함
- 1. **공간 명시성**(spatial explicitness) — 공간 구조(위치, 이웃 관계)가 모델 안으로 들어가 예측에 실제로 기여하는가
- 2. **학습 기반** — 모형의 형태를 분석자가 지정하지 않고 데이터에서 적합하는가
- **두 조건을 함께 충족해야 GeoAI이며**, 하나만 충족하면 다른 이름을 붙임
- 공간 구조가 모델에 들어가는 대표 경로는 둘. 이웃 값의 평균 같은 **공간 피처를 입력 열로 추가**하거나, CNN처럼 **이웃을 함께 보는 모델 구조**를 쓰는 것

주의. 공간 블록 교차검증(가까운 관측이 학습과 평가에 함께 들어가지 않게 나누는 방법)을 썼다는 것만으로는 GeoAI가 되지 않음. 그것은 "제대로 검증했다"는 뜻이지 "공간을 모델에 넣었다"는 뜻이 아님. 검증 방법은 4장에서 배움

7. 판정 연습: 이건 GeoAI인가

- 두 조건을 네 사례에 적용해 봄. 이 판정은 이 책 전체에서 반복됨
- **사례 A** — 행정동별 인구·소득 표에 랜덤 포레스트를 적합해 취약지수를 예측함. 좌표는 쓰지 않음
 - 학습 기반 ○, 공간 명시성 ✕ → **GIS + ML** (공간 데이터에서 출발했지만 모델은 공간을 모름)
- **사례 B** — 같은 표에 **이웃 행정동의 평균값을 열로 추가**해 다시 적합함
 - 학습 기반 ○, 공간 명시성 ○ → **GeoAI**
- **사례 C** — 위성영상에 U-Net(6장에서 배움)을 적용해 침수 픽셀을 분류함
 - 학습 기반 ○, 공간 명시성 ○(합성곱이 인접 픽셀을 함께 봄) → **GeoAI**
- **사례 D** — 크리깅(관측 지점 사이의 값을 공간 통계로 보간하는 방법)으로 미관측 지점의 기온을 추정함
 - 학습 기반 ✕, 공간 명시성 ○ → **공간 통계** (전통적 방법이며, 그 자체로 유용함)
- A와 B의 차이가 **열 하나뿐**이라는 점이 이 연습의 핵심임
- 판정은 말로 하지 않고 수치로 함. 이웃 평균 열을 넣기 전과 후의 성능을 같은 검증 설계로 비교해, 그 열이 예측에 실제로 기여했는지 확인함
- 성능 차이가 없으면 열만 추가한 것이지 공간을 모델에 넣은 것이 아님

- 이름을 정확히 붙이는 것은 말장난이 아님
- "GeoAI 사업"이라는 이름이 붙으면 다른 예산 계정과 다른 심사 기준이 적용됨. 학습하는 모델이 없는 대시보드에 그 이름을 붙이면 심사에서 근거를 대지 못함

8. 3층 모델: 분석이 결정이 되기까지

- 이 책 전체는 3층 구조를 따라감




그림 1.2 이 책의 3층 모델: 공간 데이터 과학 → GeoAI → 의사결정

- 1층이 없으면 2층은 붕 뜸. 좌표계와 데이터 형식을 모르면 딥러닝 입력부터 잘못 만듦
- 2층이 있어도 3층으로 올라가지 못하면 "멋진 분석 결과"에서 멈춤 — 2절의 John Snow가 2단계에서 멈춘 것과 같은 상태
- **1층과 2층은 공공이든 기업이든 거의 같고, 갈라지는 곳은 3층임** (9절)

8.1 픽셀에서 결정까지: 다섯 단계

- 2층의 분석 결과가 3층의 결정이 되려면 단위를 바꾸는 과정이 필요함
- 침수 판독을 예로 들면 다섯 단계를 거침
 1. 위성영상에서 침수 픽셀을 분류함
 2. 오분류가 예상되는 영역(원래 물이었던 곳, 그림자)을 걸러냄
 3. 침수 픽셀과 건물 폴리곤을 겹쳐 침수 건물을 셈
 4. 건물을 행정동 단위로 집계함
 5. 행정동별 우선순위표를 만들
- 분류 정확도는 1단계의 지표이고, 예산을 배정하는 쪽이 필요로 하는 것은 5단계의 표
- **두 값은 자료 형식도 단위도 다름. 1단계만 잘해서는 결정에 도달하지 못함**

주의. 4단계의 집계 단위를 바꾸면 결과 순위가 달라질 수 있음. 같은 자료를 읍면동으로 묶느냐 시군구로 묶느냐에 따라 어느 지역이 "가장 심각한지"가 바뀜. 그래서 집계 단위는 취향이 아니라 근거를 적어야 하는 결정임. 자세한 원리는 4장에서 다룸

9. 같은 지도, 다른 결정

9.1 홍수 지도 하나를 두 사람이 본다

- 같은 침수 위험 지도를 시청 담당자와 보험사 심사역이 봄
- 시청은 "어디에 배수펌프를 먼저 놓을까"를 묻고, 보험사는 "이 지역 보험료를 얼마로 매길까"를 묻음
- 격자를 나누는 법, 넣는 변수, 검증 방법 — 1층과 2층은 같음. **갈라지는 곳은 3층**

9.2 무엇이 다른가: 오류 비용의 비대칭

구분	공공	비즈니스
목적	위험 저감, 형평	손실 관리, 수익
더 아픈 오류	위험을 놓침 (과소예측)	잘못 투자함 (과대예측)
산출 단위	행정동·생활권	건물·계약
책임	설명 의무, 감사	계약 조건, 규제 준수

- 둘째 행이 핵심임
- 공공에서 위험을 낮게 본 지역이 실제로 침수되면 인명 피해가 남. 기업에서 위험을 낮게 보면 손실이 나지만 다음 계약에서 조정할 수 있음
- 그래서 같은 예측값에도 서로 다른 판정 기준을 씀. 예측 모델이 같아도 결정은 달라지는 것이 정상임

9.3 AI를 쓰지 말아야 할 때

- 세 경우에는 학습 모델을 엮지 않는 편이 나음
- 1. 규칙이 이미 명확할 때 — 경사도 기준으로 정해지는 판정에 모델을 엮으면 불투명성만 늘어남
- 2. 데이터가 적을 때 — 관측이 수십 개인 문제에서 딥러닝은 과적합함
- 3. 근거를 제시해야 하는데 설명 절차가 없을 때 — 예산 배분처럼 이유를 대야 하는 결정에서는 정확도가 높아도 배치하면 안 됨
- "AI를 안 쓴다"는 결론도 정당한 판정 결과임. 7절의 판정을 했는데 전통 GIS로 충분하다면 그것이 답

10. 핵심 요약

- 공간 분석의 가치는 결정에서 나옴. John Snow의 지도가 기억되는 이유는 점의 패턴이 아니라 펌프 폐쇄라는 행동으로 이어졌기 때문. 정확도가 아무리 높아도 결정을 바꾸지 못하면 분석은 2단계에서 멈춘 것 (2절)
- GIS는 지도 프로그램이 아니라 공간 의사결정 체계. 수집 → 전처리 → 분석 → 공유의 전체 흐름이며, 어느 한 곳이 부실하면 결과를 믿기 어려움 (3절, 그림 1.1)
- 공간 데이터는 세 형식으로 옴. 경계가 명확한 대상은 벡터(점·선·면), 이어지는 현상은 래스터(픽셀 격자), 3차원 구조는 포인트 클라우드. 형식이 정해지면 쓸 수 있는 연산과 모델이 함께 정해짐 (4절)
- 새 자료를 받으면 네 가지부터 확인함. 객체 수, 좌표계, 기하 유형, 덮는 범위. 실습에서 확인한 값 — 국가 177개, EPSG:4326, MultiPolygon (5절)

- **GeoAI 판정은 두 조건.** 공간 명시성(공간 구조가 모델 안에 들어가는가)과 학습 기반(모형을 데이터에서 적합하는가)을 함께 충족해야 GeoAI. 하나만 충족하면 GIS + ML(공간 없는 학습) 또는 공간 통계(학습 없는 공간)라 부름. 판정은 말이 아니라 이웃 피처를 넣기 전후의 성능 차이, 즉 수치로 함 (6~7절)
- **이 책은 3층 구조를 따라감.** 1층 공간 데이터 과학의 토대 → 2층 GeoAI → 3층 의사결정. 2층의 픽셀 분류가 3층의 결정이 되려면 걸러내기·겹치기·집계의 다섯 단계를 거쳐야 하며, 집계 단위는 근거를 적어야 하는 결정임 (8절, 그림 1.2)
- **1·2층은 공공과 기업이 공유하고 3층에서 갈라짐.** 갈라지는 핵심은 오류 비용의 비대칭 — 공공은 위험을 놓치는 쪽(과소예측)이, 기업은 잘못 투자하는 쪽(과대예측)이 더 아픔. 같은 예측값에 서로 다른 판정 기준을 쓰는 이유 (9절)
- **AI를 안 쓴다는 결론도 정당한 판정 결과.** 규칙이 이미 명확하거나, 데이터가 적거나, 설명 절차 없이 근거를 제시해야 하는 결정이면 학습 모델을 없지 않는 편이 나옴 (9.3절)

11. 과제

- 이번 장의 과제는 **직접 돌려 보고, 그 결과로 판단하는 것**
- 명령 한 줄이면 제출할 파일이 생성됨

```
python scripts/submit.py 1 --id 학번 --name 이름
```

- 이 명령이 대신 처리하는 작업: 실습 데이터 생성, 대표 실습 `1-1-geoai-tools-preview.py` 실행, 제출용 파일 생성
- 저장소를 내려받아도 데이터 파일은 들어 있지 않으므로 첫 단계가 꼭 필요함. 그래서 처음 돌리는 장은 조금 더 걸림
- 끝나면 `submissions/` 폴더에 `제출_1장_학번.md` 파일이 생김
- 열어 보면 실행 결과가 이미 붙어 있음. **눈여겨볼 곳은 국가 수, 좌표계, 기하 유형, 그리고 마지막에 뜨는 경고**
- 맨 아래 빈칸 세 개를 채우면 됨
 1. 눈에 띈 숫자 하나를 그대로 옮겨 적고, 왜 눈에 띄었는지 한 문장으로
 2. 그 숫자가 왜 그렇게 나왔는가
 3. **이 결과는 컴퓨터가 달라도 똑같이 나와야 한다. 왜 그런가? 만약 달랐다면 무엇을 먼저 의심하겠는가?**
- **3번이 이 과제의 핵심.** 1·2번은 결과를 들여다보면 답이 나오지만 3번은 그렇지 않음
- 과제의 핵심은 숫자 산출이 아니라 그 숫자를 근거로 판단하는 능력
- 채운 파일 **하나만** 올리면 제출이 끝남

- **막혀도 제출함**

- 실행이 도중에 실패하면 오류 메시지가 그 파일에 자동으로 담기고, 질문이 "어디서 막혔나"로 바뀜
- 어디서 왜 막혔는지 적은 제출도 온전한 제출. 실행 성공 여부로 점수를 매기지 않음

- **이 장은 난수를 쓰지 않음**
- 그래서 교재에 적힌 값이 그대로 나와야 정상이고, 옆 사람 결과와도 같음
- 다른 결과가 나왔을 때 차이를 찾는 과정까지 과제에 포함