

4장 공간단위 예측, 단위·피처·검증·해석

- 이 장에 나오는 격자·건물·행정동 수치, Moran's I, 검증 점수, SHAP 값은 모두 `lecture_practice/chapter4/` 의 코드를 실제로 실행해 얻은 값
- 예시를 위해 지어낸 숫자는 없음

1. 이 장의 핵심 질문

- 격자 한 칸, 행정동 하나, 건물 한 채를 표의 한 행으로 만들려면 무엇부터 정해야 할까?
- 위성영상은 원래 표가 아닌데, 어떻게 표로 바꿀까?
- 옆 동네 값을 피처로 넣으면 왜 검증 점수가 갑자기 좋아질까? 그 좋아진 점수를 믿어도 될까?
- "무작위로 나눠서 검증했다"는 문장이 공간 자료에서는 왜 거짓말이 될 수 있을까?
- 예측 순위표에서 1위와 5위의 점수 차이가 4.44점이라면, 이 순서를 그대로 배분 순서로 써도 될까?
- 이 장은 "어느 지역이 취약한가", "어느 지역에 매장이 부족한가"처럼 **공간단위마다 점수를 매기고 줄 세우는 분석**을 다룸
- 순위표를 만드는 절차는 여덟 단계로 고정되어 있고, 단계를 건너뛰면 뒤 단계에서 판단할 근거가 사라짐
- 핵심은 다음 한 문장
- **가까운 곳끼리 값이 닮는 성질을 무시하고 검증하면, 검증 점수는 높게 나오지만 그 점수는 거짓말임**

2. 직관적 비유

- **여덟 단계 절차 = 공장의 조립 라인**
- 앞 공정에서 만든 부품이 없으면 다음 공정을 시작할 수 없음
- 어느 공정에서 불량이 나면 그 이후 모든 제품에 불량이 그대로 전파됨
- 공정 순서를 바꾸면 애초에 조립이 되지 않음
- 대응을 하나씩 짚으면
- 부품 = 앞 단계의 산출물(단위 결정서, 피처 행렬, 진단 결과 등)
- 공정 순서 = 4.1에서 정할 여덟 단계의 순서

- 불량의 전파 = 검증 설계(6단계)를 잘못 정하면 그 뒤에 고르는 하이퍼파라미터가 전부 잘못된 기준에 맞춰 최적화됨
- 한 단계라도 빠고 넘어가면, 뒤 단계는 계산은 되지만 그 결과의 근거가 없음
- 공간 분할 누수(spatial split leakage) = 쌍둥이 문제를 학습과 시험에 나눠 낸 시험
- 반 전체의 실력을 재려는데, 시험 문제 중 절반이 이미 수업 시간에 풀어 본 문제와 숫자만 다른 쌍둥이 문제라고 하자
- 학생은 새로 푼 것이 아니라 이미 본 것을 다시 맞히는 것이므로 점수가 실제 실력보다 높게 나옴
- 공간 자료에서는 가까운 위치의 값이 서로 닮는 성질(공간 자기상관)이 이 쌍둥이 문제 역할을 함
- 검증 격자 바로 옆 격자가 학습에 남아 있으면, 모델은 새 지역을 맞히는 것이 아니라 옆 값을 보고 보간하는 것과 비슷한 일을 함
- 재려는 것은 새 지역으로 일반화하는 능력인데, 실제로 재는 것은 이웃값을 보간하는 능력이 되어 버림
- 이 문제를 어떻게 막는지가 12절의 공간 교차검증

3. 핵심 개념 5가지

1. 표의 한 행이 무엇인지부터 정해야 함

- 포인트, 격자, 행정구역, 필지·건물, 네트워크 권역 가운데 무엇을 한 행으로 둘지가 첫 결정임

2. 위성영상은 원래 표가 아니라 밴드×행×열의 배열임

- 픽셀 단위, 패치 단위, 공간단위(존 통계) 세 경로 중 하나로 표로 바꿔야 머신러닝에 넣을 수 있음

3. 이웃 값을 피쳐로 쓸 수 있지만 목표값 누수를 조심해야 함

- 예측 시점에 실제로 받을 수 없는 값을 피쳐로 넣으면 검증 점수만 높아지고 실전에서는 못 씀

4. 자기상관이 있는 자료를 무작위로 나누면 검증 점수가 부풀려짐

- 그래서 블록·버퍼·군집·그룹 단위로 나누는 공간 교차검증을 씀

5. 성능 차이를 한 번의 계산으로 믿지 않고, 여러 번 반복해 그 차이가 흔들리는 폭을 재야 함

- 이것이 반복 실험이며, 이 장의 세 실제 사례가 서로 다른 판정으로 갈림

4. 실제 자료를 먼저 보기

- 이 장도 정의보다 실제 자료를 먼저 보는 편이 이해가 쉬움
- Microsoft Planetary Computer (Sentinel-2 L2A를 STAC API로 제공) <https://planetarycomputer.microsoft.com/>

- ESA WorldCover 2021 (10m 해상도 실측 토지피복 지도, CC BY 4.0) <https://doi.org/10.5281/zenodo.7254221>
- 소상공인시장진흥공단 상가(상권)정보 <https://www.data.go.kr/data/15083033/fileData.do>
- 서울 열린데이터광장 생활인구(행정동) <https://data.seoul.go.kr/dataList/OA-14991/S/1/datasetView.do>
- 이 장의 실습은 이 네 자료 가운데 앞의 둘을 위성영상 분류에, 뒤의 둘을 카페 기대 공급량 분석에 씀
- 시청·복지부서가 쓰는 취약성 예측은 실제 행정자료 대신 통제된 시뮬레이션을 씀(15절에서 이유를 설명)

실습 안내

- 실습 코드
 - `lecture_practice/chapter4/code/4-0-raster-inspection.py` — 실제 Sentinel-2 GeoTIFF 검사
 - `lecture_practice/chapter4/code/4-0-simdata-prep.py` — 격자 시뮬레이션 자료 생성
 - `lecture_practice/chapter4/code/4-1-spatial-features.py` — 형태·거리·위상 피처
 - `lecture_practice/chapter4/code/4-2-spatial-cv.py` — Moran's I와 공간 교차검증
 - `lecture_practice/chapter4/code/4-3-ensemble-comparison.py` — 랜덤포레스트·XGBoost·LightGBM 비교
 - `lecture_practice/chapter4/code/4-4-spatial-clustering.py` — KMeans·DBSCAN 군집
 - `lecture_practice/chapter4/code/4-5-grid-vulnerability-shap.py` — 격자 취약성 예측과 SHAP
 - `lecture_practice/chapter4/code/4-6-store-location-supply.py` — 카페 기대 공급량(비즈니스 사례)
- 결과 로그: `lecture_practice/chapter4/results/*.log`
- 이 장의 실습은 `lecture_practice/` 에서 진행하며 GPU가 필요 없음
- `docs_practice/` 는 7장부터 쓰는 연구 규모 실습이며, 4장은 두 트랙이 같은 실습 폴더를 공유함

5. 실제 사례로 먼저 보기

- `4-0-raster-inspection.log` 의 실제 실행 결과부터 확인
- 이 GeoTIFF는 밴드 12개, 크기 1,314행 × 1,338열, 좌표계 EPSG:32652, 해상도 10m
- `src.read()` 로 읽으면 배열 형태가 정확히 (12, 1314, 1338) 로 나옴 — 밴드가 앞에, 행·열이 뒤에 오는 순서
- 중심 근처 픽셀 하나(행 657, 열 669)를 열어 보면 이런 값이 나옴

밴드	원시값(DN)	반사율
B02 Blue	403	0.040
B03 Green	441	0.044
B04 Red	264	0.026
B08 NIR	164	0.016
B11 SWIR	94	0.009

- 이 픽셀은 의암호 수면임
- $NDVI = (NIR - Red) / (NIR + Red) = (0.016 - 0.026) / (0.016 + 0.026) = -0.234$
- 물은 근적외선을 거의 흡수하므로 NIR이 Red보다 낮아지고, 그 결과 NDVI가 음수로 나옴
- 영상 전체로 보면 NDVI는 최소 -0.525에서 최대 0.867까지 분포하고, 평균은 0.328이며, 0.4를 넘는 (식생) 픽셀이 전체의 **38.4%**
- 이 하나의 숫자(-0.234)가 8절에서 다룰 "영상을 표로 바꾸는 작업"의 최소 단위임
- 픽셀 하나, 밴드값 몇 개, 계산된 지수 하나 — 이것이 표의 한 행이 될 재료임

6. 공간단위 예측의 여덟 단계

- 앞 단계의 산출물이 뒷 단계의 입력이 되므로, 순서를 지키지 않으면 뒷 단계의 판단 근거가 사라짐
- 검증 설계(6단계)를 정하지 않은 채 모델의 세부 설정을 먼저 고르면(5단계), 그 설정은 부풀려진 점수에 맞춰 고른 것이 되고 나중에 되돌릴 수 없음




그림 4.1 공간단위 예측의 여덟 단계와 단계별 산출물

- 각 단계가 이 장의 어느 절에서 다루어지는지 정리하면 다음과 같음

단계	무엇을 하는가	이 장의 절
1 분석 단위	표의 한 행을 무엇으로 둘지 정함	7절
2 표 변환	영상·벡터·표 자료를 관측치×피쳐 행렬로 바꿈	8절
3 피쳐 설계	이웃 관계·거리·접근성을 열로 만듦	9절
4 공간 진단	타깃이 공간적으로 뭉쳐 있는지 확인함	10절
5 모델 적합	기준모형과 후보모형을 학습함	11절
6 공간 검증	검증을 어떻게 나눌지 정하고 반복 실험함	12절
7 결과 해석	어느 피쳐가 왜 기여했는지 확인함	13절
8 산출물	단위별 예측표와 순위표를 만듦	13절

- 이 절차는 8장 이후의 정책 장과 14장 이후의 비즈니스 장에서 계속 재사용됨
- 취약지역 찾기, 서비스 사각지대 찾기, 위험 우선순위 매기기는 모두 "공간단위에 점수를 매기고 줄 세우는" 같은 구조의 문제임

7. 분석 단위와 집계 규칙 정하기

7.1 표의 한 행을 무엇으로 둘까

- 분석에 들어가는 자료는 결국 표 하나로 정리됨
- 그 표의 한 줄이 격자 한 칸인지, 행정동 하나인지, 건물 한 채인지를 먼저 정해야 함
- 이 결정에 따라 어떤 자료를 모을 수 있는지, 어떤 피처를 만들 수 있는지, 결과를 누구에게 어떤 단위로 전달할지가 모두 달라짐

단위	쓰임	특징
포인트	사건·시설 위치	원자료, 집계 전 단계
격자	취약성·위험 비교	균일 단위, 행정경계와 무관
행정구역	예산·정책 집행	통계 공표·집행 단위
필지·건물	안전·에너지·과세	미시 단위
네트워크 권역	접근성·서비스	이동시간 기반 기능 단위

- **포인트**는 화재 신고 지점, 병원 위치처럼 사건·시설이 발생한 자리 그 자체임. 대부분의 분석은 포인트를 어떤 면 단위로 모으는 데서 시작함
- **격자**는 국토를 같은 크기의 정사각형(예: 500m × 500m)으로 자른 단위임. 모든 칸의 면적이 같아 지역 간 비교에서 면적 차이를 신경 쓰지 않아도 되고, 행정 경계가 바뀌어도 단위 자체는 그대로임
- **행정구역**은 통계가 공표되고 예산이 집행되는 단위임. 분석 결과가 정책으로 이어지려면 결국 이 단위로 번역됨
- **필지·건물**은 자산 하나하나를 판정하는 문제(건물 안전 진단, 에너지 효율 평가)에 씀
- **네트워크 권역**은 도보 15분 안에 닿는 범위처럼 도로망 위의 이동시간으로 정의되는 단위임

7.2 같은 자료, 다른 칸 — MAUP

- 같은 현상이라도 지도를 어떤 크기·모양의 칸으로 잘라 세느냐에 따라 다른 결과가 나옴
- 이 현상을 **수정가능면적단위문제**(Modifiable Areal Unit Problem, MAUP)라 함
- 구체적으로 두 가지 상황으로 나타남
- **크기의 문제**: 고령인구 비율을 500m 격자로 집계하면 고령자가 밀집한 작은 마을이 별도의 칸으로 드러남. 같은 자료를 1km 격자로 합치면 그 마을이 주변의 젊은 인구와 한 칸에 섞이면서 평균이 내려가 취약 지점이 지도에서 사라짐

- **경계의 문제:** 같은 마을이 행정동 경계를 어디에 긋느냐에 따라 취약 동에 속하기도 하고 평균적인 동에 속하기도 함
- MAUP는 없앨 수 있는 오류가 아니라 공간 집계에 원래 따라오는 성질임
- 면적이 있는 단위로 값을 합치는 순간 그 단위 안의 분산은 사라지고, 단위의 크기와 경계가 결과를 좌우하는 요인이 됨
- 그래서 대응은 문제를 없애는 것이 아니라 두 가지로 함
 1. 분석과 보고의 단위를 분리하는 2단계 구조(7.3에서 다룸)
 2. 단위 선택이 결과에 미친 영향을 해석에 명시하는 것

7.3 현상이 일어나는 단위와 정책을 집행하는 단위는 다르다

- 취약성은 격자에서 발생하지만 예산은 행정구역에 배정됨
- 분석 단위를 처음부터 행정구역으로 정하면 구역 내부의 취약 지점과 안정 지점이 평균에 섞여 신호가 사라짐
- 반대로 격자 예측만 제시하면 예산을 어느 기관에 배정할지 결정하기 어려움
- 그래서 **현상 단위에서 예측하고 집행 단위로 집계**하는 두 단계를 둬. 취약성은 500m 격자에서 계산해 패턴을 잡고, 예산 배분을 논의할 때는 읍면동 단위로 다시 모음
- 격자 i의 예측값을 행정구역 a로 집계하는 계산은 **가중평균**임
- 각 격자에 가중치를 주고, (가중치 × 예측값)의 합을 가중치의 합으로 나눔
- 계산 예: 어느 행정구역 안에 격자 3개가 있고, 취약성 예측값이 각각 40, 60, 80이라 하자
 - 모든 격자를 동등하게 두면(가중치 1, 1, 1): 구역 평균 = $(40+60+80)/3 = 60$
 - 인구가 각각 100, 500, 100이면(가중치 100, 500, 100): 구역 평균 = $(40 \times 100 + 60 \times 500 + 80 \times 100) / 700 = 58.6$
 - 두 계산의 답이 다름. 가중치를 명시하지 않은 평균은 무엇을 평균한 값인지 알 수 없음

주의. 순위표는 집계 단위를 바꾸면 순서가 바뀜. 500m 격자에서 상위였던 지점이 1km 격자에서는 주변과 평균되어 순위에서 사라질 수 있음. 순위표의 제목이나 각주에 집계 단위와 가중치를 함께 적어야 함

8. 자료를 표로 바꾸기

8.1 관측치와 피처


- 랜덤 포레스트·XGBoost·LightGBM은 관측치가 행으로, 그 관측치를 설명하는 피처가 열로 놓인 표를 입력받음
- **관측치**는 분석의 대상이고, **피처**는 그 대상을 설명하기 위해 측정하거나 계산한 변수임
- 행정동별 취약성을 예측한다면 한 행이 행정동 하나이고, 열에는 고령인구율·1인가구율·병원까지의 거리·평균 NDVI 같은 값이 들어감
- 건물 단위 분석에서는 한 행이 건물 하나이고, 면적·층수·최근접 소방서 거리가 피처가 됨
- 정형 자료란 파일 형식이 표라는 뜻이 아니라, **분석 대상마다 동일한 열 구조를 갖도록 정리한 형태**라는 뜻임

8.2 위성영상은 원래 표가 아니다

- 위성영상 하나는 **밴드 × 행 × 열** 형태의 3차원 배열임
- 가로·세로의 각 위치가 픽셀이고, 밴드는 같은 위치를 서로 다른 파장으로 관측한 값임
- 5절에서 본 GeoTIFF가 그 예임 — (12, 1314, 1338) 은 밴드 12개, 행 1,314개, 열 1,338개라는 뜻
- 영상의 이웃 관계는 정보를 담고 있음. 산림 픽셀 주변에는 산림 픽셀이 있을 가능성이 높고, 건물은 직선 형태의 경계를 만들며, 도로는 길게 이어지는 패턴을 만들
- 그러나 영상 배열을 단순히 표로 펼치면 어떤 픽셀이 어느 픽셀 옆에 있었는지가 입력 형식에 남지 않음
- 전통적 머신러닝을 영상에 적용하려면 원래 배열을 관측치와 피처로 바꾸는 작업이 필요하고, 이때 무엇을 한 행으로 만들지가 모델 성능과 해석을 좌우함
- 정형 자료 표와 영상 배열의 구조 차이는 다음 그림과 같음

전통적 머신러닝과 영상분석의 데이터 형태

같은 지리정보라도 분석 단위와 배열 구조에 따라 입력 방식이 달라진다



핵심 차이: 정형 데이터는 행과 열의 표이고, 영상 데이터는 공간·밴드·시간 축을 가진 배열이다.

그림 4.2 정형 자료 표, 단일 위성영상 배열, 다중시점 영상 배열의 구조 비교

```
import rasterio

with rasterio.open("data/sentinel2_l2a_12band_clip.tif") as src:
    print(src.count, src.height, src.width) # 12, 1314, 1338
    print(src.crs) # EPSG:32652
    pixel = src.read()[:, 657, 669] # 중심 근처 픽셀의 12개 밴드값
```

전체 코드는 [lecture_practice/chapter4/code/4-0-raster-inspection.py](#) 참고

8.3 세 가지 변환 경로

- 영상을 전통적 머신러닝의 입력으로 바꾸는 경로는 분석 단위에 따라 세 가지로 나뉨

분석 단위	표의 한 행	대표 피쳐	적합한 질문	잃는 것
픽셀	픽셀 하나	밴드값, NDVI, NDWI	이 픽셀은 어떤 토지피복인가	객체의 모양, 넓은 맥락
패치	작은 영상 조각	밴드별 평균·분산, 질감	이 조각은 도시·산림 중 무엇인가	패치 내부의 위치·형태
공간단위	격자·행정구역 하나	존 통계, 면적 비율	어느 지역이 취약하거나 위험한가	단위 내부의 분산 (MAUP)

- **픽셀 단위 변환:** 픽셀 하나가 한 행이 됨. 정답 라벨은 그 픽셀이 산림·경작지·시가지·수역 중 무엇인지가 됨. 이 방식은 분광 특성이 서로 다른 토지피복을 구분하는 데 적합하지만, 모델은 그 픽셀이 주변과 어떤 모양을 이루는지는 알지 못함
- **패치 단위 변환:** 64×64 픽셀 같은 작은 조각이 한 행이 됨. 조각 안의 평균·표준편차·질감을 열로 만들. 넓은 영역의 통계가 들어가므로 값의 변동이 줄지만 위치 정보는 약해짐
- **공간단위 변환:** 격자·행정구역이 한 행이 됨. 경계 안의 픽셀 평균·최댓값·면적 비율을 계산해 영상을 표로 바꿈. 여기에 인구·시설 접근성을 결합하면 취약성·위험을 예측하는 표가 만들어짐
- 픽셀 단위 변환의 결과는 실제 파일에서 확인됨. 아래는 GeoTIFF의 첫 네 픽셀을 표로 바꾼 예임

row	col	B02	B03	B04	B08	B11	NDVI	NDWI
0	0	527	715	979	2,018	2,513	0.347	-0.477
0	1	459	608	770	1,882	2,374	0.419	-0.512
0	2	406	542	679	1,692	2,331	0.427	-0.515
0	3	456	594	798	2,062	2,377	0.442	-0.553

- 같은 변환을 공간단위에 적용하면 표의 모양이 완전히 달라짐. 아래는 격자 시뮬레이션 자료의 첫 네 칸임(4-0-simdata-prep.py)

격자	고령인구율	1인가구율	기초수급율	병원거리(m)	평균 NDVI	취약성
0	0.25	0.30	0.07	1,251	0.271	35.7
1	0.24	0.27	0.07	1,313	0.432	44.6
2	0.28	0.36	0.10	1,508	0.344	60.9
3	0.22	0.35	0.08	710	0.291	53.2

- 두 표를 나란히 두면 차이가 보임. 픽셀 표의 열은 밴드값과 분광지수이고, 격자 표의 열은 사회경제 지표와 영상에서 산출한 평균 NDVI임
- 무엇을 고를지는 다음 순서로 판정함

정답 라벨이 붙는 대상은 무엇인가?

|

└ 위치 하나 → 픽셀 단위 변환

└ 영역 조각 → 패치 단위 변환(좌표를 넣었으면 공간 교차검증 필수)

└ 행정·집행 단위 → 공간단위 변환(존 통계)

그림 4.3 영상 자료의 표 변환 경로 선택

8.4 존 통계

- **존 통계**(zonal statistics)는 벡터 경계 하나를 래스터 위에 얹고, 그 경계 안에 들어오는 픽셀을 모아 통계량을 계산해 표의 한 칸으로 만드는 계산임
- 네 단계로 진행함
 1. 경계 폴리곤과 래스터의 좌표계를 일치시킴
 2. 폴리곤을 래스터 격자에 투영해 어느 픽셀이 그 경계에 속하는지 판정함
 3. 속한 픽셀 집합에서 통계량(평균·최대값·표준편차·면적비율)을 계산함
 4. 계산된 값을 폴리곤 식별자와 함께 표의 한 행에 기록함
- 어떤 통계량을 고르느냐가 곧 피처의 의미를 정함. 평균은 구역의 전반적 수준을, 표준편차는 구역 내부가 균질한지를, 임계값 초과 면적 비율은 구역 안에서 그 조건을 만족하는 부분이 얼마나 되는지를 잴

9. 공간 피처 만들기

9.1 어느 칸이 이웃인가 — 공간가중행렬

- 격자표에 고령인구율 열이 있고 주변 격자의 고령인구율을 새 열로 만들려 한다고 하자
- 이 계산을 하려면 격자 하나마다 어느 칸이 이웃인지가 먼저 정해져야 함
- 이웃을 변으로 맞닿은 네 칸으로 볼지, 대각선을 포함한 여덟 칸으로 볼지, 반경 1km 안의 모든 칸으로 볼지에 따라 같은 자료에서 다른 값이 나옴
- 이 정의를 담은 도구가 **공간가중행렬**(spatial weights matrix) W 임. n 개의 공간단위가 있으면 W 는 $n \times n$ 행렬이고, 이웃이 아니면 0, 이웃이면 양수를 담음

방식	정의	적합한 자료
rook 인접	변을 맞댄 4칸	격자, 정방형 셀
queen 인접	모서리를 포함한 8칸	격자, 대각으로도 이어지는 현상
거리 임계	반경 d 안의 모든 단위	점자료, 관측소망
k -최근접	가장 가까운 k 개	단위 밀도가 고르지 않은 자료
거리 감쇠	거리에 반비례하는 가중치	영향이 거리에 따라 줄어드는 현상

- 행정구역처럼 크기가 제각각인 단위에서는 거리 임계 방식이 문제를 일으킴. 임계값을 작게 잡으면 넓은 농촌 구역이 이웃을 하나도 갖지 못하고, 크게 잡으면 좁은 도심 구역이 수십 개의 이웃을 가짐. k -최근접을 쓰면 모든 단위가 같은 수의 이웃을 갖게 됨

- 이웃을 정한 뒤에는 **행 표준화**를 함 — 각 행의 가중치를 그 행의 합으로 나눠 합이 1이 되게 만듦
- 이유는 이웃 수가 위치마다 다르기 때문임. 격자 내부 칸은 이웃이 넷이지만 모서리 칸은 둘뿐임. 표준화하지 않고 이웃 값을 더하면 이웃이 많은 위치일수록 합이 커지므로, 주변의 조건이 아니라 이웃 개수를 반영하는 열이 만들어짐

```
from libpysal.weights import KNN

w = KNN.from_dataframe(gdf, k=8) # 각 지점의 최근접 8개를 이웃으로
w.transform = "r"                # 행 표준화
```

전체 코드는 `lecture_practice/chapter4/code/4-2-spatial-cv.py` 참고

9.2 도형·거리·이웃에서 열 만들기

- 공간단위 하나에서 뽑을 수 있는 열은 네 갈래로 나뉨(존 통계는 8.4에서 이미 다룸)

갈래	무엇에서 나오는가	대표 열
형태	도형 자체의 모양	면적, 둘레, 조밀도, 종횡비
거리	다른 대상까지 떨어진 정도	최근접 시설 거리, 도심 거리
위상	이웃과의 연결 관계	인접 단위 수, 공간 시차

- **조밀도(compactness)**는 같은 둘레로 얼마나 넓은 면적을 감쌌는지 재는 값임. 원에서 1이 되고 길쭉해질수록 0에 가까워짐
- **종횡비(aspect ratio)**는 외접 사각형의 긴 변을 짧은 변으로 나눈 값임. 1이면 정방형에 가깝고 클수록 길쭉함

```
# 형태 피처: 조밀도(원=1)와 최근접 시설 거리
gdf["compactness"] = 4 * np.pi * gdf.geometry.area / (gdf.geometry.length ** 2)
gdf["dist_to_station"] = gdf.geometry.apply(
    lambda g: stations.geometry.distance(g.centroid).min()
)
```

전체 코드는 `lecture_practice/chapter4/code/4-1-spatial-features.py` 참고

- 이 코드를 시뮬레이션 건물 200채에 실행한 실제 결과
- 조밀도는 0.423에서 0.785 사이 — 정사각형에 가까운 건물부터 길쭉한 건물까지 섞여 있음
- 종횡비는 1.00에서 3.87까지 — 가장 길쭉한 건물은 긴 변이 짧은 변의 약 네 배

- 지하철역까지의 거리는 96m에서 3,415m — 역세권 건물과 도보 접근이 어려운 건물이 같은 건물군에 공존함
- 50m 안의 인접 건물 수는 0에서 2채(평균 0.1채) — 이 시뮬레이션의 건물이 대체로 흩어져 배치되어 있기 때문임. 실제 도심 자료에서는 이 열이 밀집 시가지와 저밀 지역을 가르는 강한 신호가 됨

9.3 공간 시차

- 변수 x 의 **공간 시차**(spatial lag)는 이웃 값의 가중평균임
- 시계열 분석에서 한 시점 전의 값을 시차 변수로 쓰듯이, 공간에서는 옆 칸들의 값을 시차 변수로 씀
- 계산 예: 행정동 i 의 이웃 네 곳의 고령인구율이 0.18, 0.22, 0.31, 0.25이고 행 표준화로 각 이웃에 0.25씩 배정되면
 - 공간 시차 = $0.25 \times 0.18 + 0.25 \times 0.22 + 0.25 \times 0.31 + 0.25 \times 0.25 = \mathbf{0.24}$
 - 이 값은 동 i 를 둘러싼 지역의 고령화 수준임. 동 i 자체의 고령인구율이 0.32라면 주변보다 8%p 높은 국지적 고령 밀집지이고, 0.16이라면 고령화된 지역 안의 상대적으로 젊은 동임
 - 원변수 하나만으로는 두 경우를 구분할 수 없으므로, 원변수와 공간 시차의 차를 별도 열로 만듦(위 예에서는 $0.32 - 0.24 = +0.08$)
- 트리 기반 모델은 두 열의 차를 스스로 만들지 못함. 결정 트리의 분기는 한 열에 대한 임계값 비교이므로, 차이가 의미를 갖는 문제에서는 파생 열을 직접 만들어 넣어야 함
- 다만 공간 시차가 항상 새 정보를 더하지는 않음. 이웃의 값이 이미 표에 있는 다른 열로 대부분 설명되면 시차 열은 중복이 됨(14절의 카페 사례가 이 경우)

9.4 접근성

- 거리 피처를 확장하면 **접근성**(accessibility)이 됨. 시설에 도달하는 용이성을 거리·시간·수용력으로 측정한 값임

방식	묻는 질문	반영하는 조건	한계
최근접 시설	가장 가까운 곳까지 몇 분인가	거리	시설 수·혼잡을 반영하지 않음
누적기회	임계 시간 안에 몇 곳인가	거리, 시설 수	임계값 설정에 민감
중력 모형	거리 감쇠를 반영하면 얼마인가	거리, 시설 수, 감쇠	감쇠 함수 선택 필요
2SFCA	수요·공급까지 고려하면 얼마인가	거리, 수용력, 경쟁 수요	자료·계산 부담이 큼

- **2SFCA**(2단계 유동 권역)의 계산은 이름 그대로 두 단계임

1. 시설 j 를 중심으로 임계 이동시간 안의 수요 인구를 합산하고, 시설의 공급 능력을 그 합으로 나눠 공급률을 구함. 병상 100개인 병원의 30분 권역에 인구 50,000명이 살면 공급률 = $100 / 50,000 = 0.002$
 2. 주민 위치 i 에서 같은 임계 시간 안에 도달할 수 있는 시설을 찾고, 1단계에서 구한 공급률을 모두 더함. 어떤 동의 주민이 30분 안에 병원 A(0.002), 병원 B(0.005), 의원 C(0.001)에 도달할 수 있다면 그 동의 접근성 = $0.002+0.005+0.001 = 0.008$
- 가까운 병원이 있어도 그 병원이 수십만 명을 감당하고 있으면 공급률이 낮아져 접근성이 낮게 나옴

시설의 수용력 자료가 있는가?

|

└ 예 → 시설이 혼잡한가?

|

└ 예 → 2SFCA

|

└ 아니오 → 중력 모형

└ 아니오 → 정책 목표가 임계 시간으로 표현되는가?

└ 예 → 누적기회

└ 아니오 → 최근접 시설

그림 4.4 접근성 지표의 선택

9.5 만든 열을 실제로 쓸 수 있는가 — 목표값 누수

- 만들 수 있는 열이 모두 입력으로 쓸 수 있는 열은 아님
- 판정 기준은 하나임. **예측을 수행하는 시점에 그 값을 실제로 받을 수 있는가**
- 답을 적을 수 없는 열은 검증 성능만 올리고 배치 시점에는 빈칸으로 남음. 이 현상을 **목표값 누수(target leakage)**라 함
- 예측 대상이 올해의 화재 발생 여부인데, 올해 화재 진압에 투입된 인력을 열로 넣으면 이 경우에 해당함
- **목표값 누수**와 2절에서 본 **공간 분할 누수**는 서로 다른 문제임. 목표값 누수는 피처 구성의 문제로, 정답에 가까운 정보가 열에 섞여 들어간 것임. 공간 분할 누수는 검증 설계의 문제로, 열 구성은 정당한데 학습과 검증을 나누는 방식 때문에 인접 표본이 양쪽에 걸친 것임
- 앞의 문제는 열을 빼서 고치고, 뒤의 문제는 분할 방식을 바꿔 고침. 두 진단을 섞으면 열을 빼야 할 자리에서 검증 설계만 바꾸게 됨

주의. 예측 시점에 받을 수 없는 값을 피처로 넣으면 오류 메시지 없이 지나감. 코드는 정상 종료하고 성능은 오히려 올라가며, 기여도 표에서 그 열이 상위로 옴. 피처를 만들 때마다 "이 값을 예측 시점에 어디서 받아 오는가"를 한 줄로 적고, 답을 적을 수 없으면 후보에서 제외함

- 좌표를 피처로 넣는 결정은 별도의 판정이 필요함

- 이 격자가 지도의 왼쪽에 있다는 사실은 취약성과 직접 관련이 없어 보이지만, 좌표를 열로 넣으면 무작위 검증 성능이 올라감
- 그 이유는 다음과 같음. 실제 취약성은 표에 있는 열만으로 결정되지 않고, 오래된 마을 공동체의 결속처럼 표의 어느 열에도 기록되지 않지만 지역에 따라 부드럽게 변하는 효과(**잠재 공간 구조**)가 섞여 있음
- 모델에 좌표가 주어진다면 "좌표가 이 범위인 격자는 타깃이 대체로 높다"는 규칙이 학습됨. 무작위 검증에서는 검증 격자 바로 옆 격자가 학습에 남아 있어 이 보간이 잘 통하지만, 공간 분리 검증에서는 검증 지역 전체가 빠지므로 보간의 근거가 사라지고 상승분도 사라짐

주의. 좌표를 피처에 넣으면 무작위 검증 성능이 올라감. 그 상승분은 관측되지 않은 지역 효과를 위치로 보간해 얻은 것이므로 학습 지역 밖에서는 사라짐. 좌표를 넣었다면 공간 분리 검증 결과를 반드시 함께 확인하고, 피처 기여도에서 좌표가 상위로 오르는지 확인함(11절의 실제 사례에서 이 현상이 그대로 나타남)

10. 공간 구조가 있는지 확인하기

10.1 Moran's I

- **Moran's I**는 전역 공간 자기상관의 표준 지표임(Moran, 1950)
- 값이 양수이면 비슷한 값끼리 이웃해 있다는 뜻이고, 0 근처이면 값의 배열이 위치와 무관하며, 음수이면 높은 값과 낮은 값이 교차 배열되어 있다는 뜻임
- 계산 구조를 작은 예로 따라가면 이해가 쉬움
- 네 칸이 일렬로 놓여 있고 값이 10, 12, 4, 6이며, 좌우로 맞닿은 칸만 이웃이라 하자
- 평균은 8이므로 편차는 +2, +4, -4, -2
- 이웃한 두 칸의 편차를 곱해서 다 더하면(공간 교차곱): $2 \times [(+2)(+4) + (+4)(-4) + (-4)(-2)] = 2 \times (8 - 16 + 8) = 0$
- 편차제곱합은 $4 + 16 + 16 + 4 = 40$
- $\text{Moran's I} = (n / \text{가중치합}) \times (\text{공간 교차곱} / \text{편차제곱합}) = (4/6) \times (0/40) = 0$
- 값이 높은 두 칸과 낮은 두 칸이 나뉘어 붙어 있는데도 전역 지표는 0으로 나옴 — 경계에서 발생하는 음의 곱이 같은 크기의 양의 곱을 상쇄하기 때문임
- **전역 Moran's I가 0에 가깝다고 해서 공간 구조가 없다고 단정할 수 없음**
- 유의성은 순열 검정으로 판정함. 값들의 자리를 무작위로 여러 번(예: 999회) 뒤섞어 같은 I를 다시 계산하면, 자기상관이 없는 상태에서 I가 얼마쯤 나오는지의 분포를 얻음. 관측된 I가 그 분포의 극단에 있으면 우연으로 보기 어렵다고 판정함

- 4-2-spatial-cv.log 의 실제 실행 결과
- 포인트 500개의 타깃에 k=8 이웃과 행 표준화를 적용해 계산하면
 - Moran's I = **0.866**, 기대값 -0.002, z-score **40.84**, p = 0.001
 - 무작위 배치에서 기대되는 값에서 표준오차의 40배 넘게 떨어져 있음 → 이 자료의 값은 위치와 무관하게 배열되어 있지 않음
- 같은 계산을 지점별로 분해한 **국지 지표(LISA)**는 어느 지점이 높은 값끼리 뭉친 자리인지 알려줌
- 같은 실행에서 LISA는 500개 포인트 가운데 고-고 군집(HH) 159개, 저-저 군집(LL) 134개를 유의하게 판별했고, 206개는 유의하지 않았음

주의. Moran's I 값은 이웃을 어떻게 정하느냐에 따라 달라짐. k-최근접의 k, 거리 임계값을 바꾸면 같은 자료에서 다른 값이 나옴. 보고할 때 이웃 정의와 순열 검정 반복 수를 함께 적음

10.2 자기상관이 검증 설계를 정한다

- 자기상관이 강한 자료를 무작위로 학습·검증에 나누면 검증 표본의 바로 옆 표본이 학습에 들어감
- 값이 공간적으로 뭉쳐 있으므로, 모델은 인접 관측을 보간하는 것만으로 검증 표본을 상당 부분 맞힐 수 있음
- 이때 측정되는 것은 새 지역으로 일반화하는 능력이 아니라 인접값을 보간하는 능력임 — 2절의 비유가 가리키던 문제가 여기서 수치로 확인됨
- Ploton 외(2020)는 아프리카 열대림 바이오매스 매핑에서 무작위 교차검증으로 높게 측정되던 모델의 성능이 공간 교차검증에서 급락함을 보고했음. 지도 전체를 채색해 발표된 생태 지도의 상당수가 검증되지 않은 외삽이었다는 지적임
- 검증 설계의 방향은 타깃의 Moran's I로 판정함

Moran's I	공간 자기상관	검증 설계
+0.7 ~ +1.0	강함	공간 분리 검증 필수
+0.3 ~ +0.7	중간	공간 분리 검증 권장, 무작위 검증과 병기
-0.3 ~ +0.3	약함	무작위 검증 사용 가능

- 조건이 하나 붙음. Moran's I가 0.3 미만이어도 자료에 그룹 구조(자치구·시군구 등)가 있으면 그룹 단위로 분리해 검증함. 표본이 소속된 단위가 있고 그 단위 안에서 조건이 공유되면, 좌표상의 자기상관과 무관하게 같은 그룹의 표본이 학습과 검증에 갈라지는 문제가 생김(14절의 카페 사례가 이 경우)

11. 모델을 고르고 학습시키기

11.1 기준모형

- R^2 0.66이라는 숫자만으로는 그 모형이 쓸 만한지 답할 수 없음. 단순 평균을 예측하는 것보다 크게 나은 결과일 수도 있고, 선형회귀로도 얻을 수 있는 결과일 수도 있음
- 그래서 복잡한 모형을 적합하기 전에 비교 대상이 될 **기준모형**(baseline model)을 정함
- 첫째는 전체 평균(회귀에서 $R^2 = 0$ 에 해당하는 지점)이고, 둘째는 해석 가능한 선형회귀임
- 실제 취약성은 변수가 독립적으로 더해지지 않는 경우가 많음. 고령인구율이 높으면서 병원까지 멀 때 취약성이 급증하고, 둘 중 하나만 해당하면 그만큼 오르지 않음. 이 구조를 선형모형에 넣으려면 곱셈항을 직접 넣어야 하는데, 변수를 둘만 곱해도 후보가 늘어남 — 후보 변수가 여덟 개면 2차 상호작용만 28개가 됨
- 이 지점이 트리 앙상블을 쓰는 실질적인 이유임. 다만 앙상블을 쓴 뒤에도 기준모형을 버리지 않고, 같은 검증 설계로 비교해 차이를 기록함. 차이가 폴드 간 변동보다 작으면 단순한 쪽을 채택함

11.2 배경 계열: 랜덤 포레스트

- 결정 트리 하나는 학습자료를 조금만 바꿔도 트리 전체의 모양이 바뀌고 예측이 달라짐. 이 불안정을 줄이는 전략이 **배깅**(bootstrap aggregating)이고, 대표 구현이 **랜덤 포레스트**임(Breiman, 2001)
1. **부트스트랩 표본을 뽑음** — 원자료 n 행에서 중복을 허용해 n 행을 다시 뽑음
 2. **트리를 하나 키움** — 각 분기에서 전체 피처를 다 보지 않고 무작위로 고른 일부에서만 최적 분기를 찾음
 3. **가지치기 없이 깊게 키움**
 4. **1~3단계를 여러 번 반복함** — 트리마다 다른 표본과 다른 피처 후보를 보므로 서로 다른 오차 구조를 가짐
 5. **결합함** — 회귀는 여러 트리 예측의 평균, 분류는 다수결
- 2단계의 피처 무작위 추첨이 이 방법의 핵심임. 부트스트랩만 적용하면 강한 피처 하나가 모든 트리의 최상단 분기를 차지해 트리들이 서로 닮게 되고, 닮은 예측을 평균해도 분산이 줄지 않음
 - 계산 예: 개별 트리의 분산이 1이고, 트리 간 상관이 0.9, 트리 수가 200이면 평균의 분산은 $0.9 + 0.1/200 \approx 0.9005$ 로 거의 줄지 않음. 피처 추첨으로 상관을 0.3까지 낮추면 $0.3 + 0.7/200 \approx 0.3035$ 가 되어 분산이 3분의 1 아래로 내려감
 - **트리 수를 늘리는 것만으로는 이 상관이 만드는 항을 줄일 수 없음** — 그래서 피처를 무작위로 고르는 단계가 필요함

- 적용 조건: 표 형태의 중소 규모 자료에서 별도 특성공학 없이 비선형과 상호작용을 잡아야 할 때 씀. 한계는 두 가지임. 예측값은 학습자료의 앞 값들의 평균이므로 학습 범위를 벗어난 입력에서 외삽하지 못함. 그리고 분기 횟수를 세는 변수 중요도는 범주 수가 많거나 연속형인 변수에 유리하게 치우칠 수 있어, 해석에는 SHAP(13절)처럼 예측 기여를 직접 배분하는 지표를 함께 씀

11.3 부스팅 계열: 경사 부스팅

- 배경이 서로 독립적인 트리를 평균한다면, **경사 부스팅**(gradient boosting)은 얇은 트리를 순차적으로 더해 앞 단계의 오차를 조금씩 줄임(Friedman, 2001)
 1. **초기 예측을 정함** — 전체 평균을 첫 예측으로 둬. 취약성 평균이 45점이면 모든 격자의 첫 예측이 45점
 2. **잔차를 계산함** — 실제값과 현재 예측의 차를 구함. 취약성이 59점인 격자에서는 +14점
 3. **잔차를 예측하는 트리를 적합함** — 원래 타깃이 아니라 잔차를 목표로 학습함
 4. **학습률을 곱해 더함** — 새 트리의 예측에 학습률(예: 0.05)을 곱해 기존 예측에 더함. 위 격자의 예측은 45점에서 $45 + 0.05 \times 14 = 45.7$ 점으로 옮겨감
 5. **2단계로 돌아가 반복함**
- 세 하이퍼파라미터가 이 과정을 통제함. 트리 수(반복 횟수), 학습률(트리 하나의 기여 비중), 트리 깊이(하나의 트리가 표현할 수 있는 상호작용의 차수)
- **XGBoost**(Chen & Guestrin, 2016)와 **LightGBM**(Ke et al., 2017)이 이 절차의 대표 구현임

항목	배깅(랜덤 포레스트)	부스팅(XGBoost·LightGBM)
트리 간 관계	독립적으로 학습해 평균	앞 트리의 잔차를 다음 트리가 보정
줄이는 오차 성분	분산	편향
트리 깊이	깊게(20~30)	얕게(4~8)
설정 민감도	낮음	높음

- 부스팅이 배깅보다 항상 앞서지는 않음. 14절의 실제 사례에서 확인됨

11.4 정답 라벨이 없을 때: 군집

- 정답 없이 비슷한 단위끼리 묶어 구조를 드러내는 비지도학습이 필요한 상황도 있음. 대표 방법이 **KMeans 군집**임(MacQueen, 1967)
 1. 중심 k개를 초기화함
 2. 각 표본을 가장 가까운 중심의 군집에 넣음
 3. 각 군집에 배정된 표본들의 평균으로 중심을 옮김
 4. 배정이 바뀌지 않을 때까지 2~3단계를 반복함

- 군집 수 k는 **실루엣 점수**(silhouette score)로 정함. 표본 i에서 같은 군집까지의 평균 거리 a(i)와 가장 가까운 다른 군집까지의 평균 거리 b(i)를 비교함
- 계산 예: a(i)=1.2, b(i)=2.0이면 실루엣 = $(2.0-1.2)/2.0 = 0.4$. 자기 군집 안에서의 거리가 이웃 군집까지 거리의 60% 수준이라는 뜻이며, 1에 가까울수록 군집이 조밀하고 서로 분리되어 있음

```
from sklearn.preprocessing import StandardScaler
from sklearn.cluster import KMeans

Xs = StandardScaler().fit_transform(X) # 거리 기반이므로 표준화 필수
labels = KMeans(n_clusters=4, n_init=10).fit_predict(Xs) # 초기값 10회 반복
```

전체 코드는 [lecture_practice/chapter4/code/4-4-spatial-clustering.py](#) 참고

- 4-4-spatial-clustering.log 의 실제 실행 결과 — Sentinel-2 픽셀 4,000개에 5개 토지피복 라벨이 있는 자료
- 실루엣 점수는 K=2에서 **0.587**로 가장 높고 K=5에서 **0.365**로 내려감 — 이 자료에서 가장 뚜렷한 갈라짐이 물과 물의 두 덩어리라는 뜻
- 실제 클래스 수인 K=5로 군집화한 뒤 WorldCover 라벨과 대조하면 조정 랜드 지수(ARI) **0.329**, 정규화 상호정보량(NMI) **0.431** — 완전 일치(1.0)에는 못 미치지만 우연 수준(0)보다는 뚜렷이 높음
- **KMeans는 정답이 없어도 자료에 실제로 존재하는 구조를 드러내지만, 분석자가 정한 라벨 체계를 그대로 복원하지는 않음**
- 밀도 기반 군집인 **DBSCAN**은 표본이 촘촘히 모인 곳을 군집으로 묶고 나머지를 노이즈로 분리함(Ester et al., 1996)
- 같은 실행에서 DBSCAN은 픽셀 4,000개 가운데 ****123개(3.1%)****를 노이즈로 분리하고 군집 2개를 찾음
- DBSCAN이 찾은 밀집 지역은 군집화의 산물이지, 통계적으로 유의한 핫스팟이라는 검정 결과는 아님 — 그 검정은 8장에서 LISA와 공간 스캔 통계로 다룸

11.5 모델 선택 가이드

타겟(정답 라벨)이 있는가?

|

└ 아니오 → 군집(KMeans, DBSCAN)

└ 예 → 기준모형(평균, 선형회귀) 적합

└ 상호작용이 필요한가?

└ 아니오 → 선형모형 유지

└ 예 → 트리 앙상블

└ 설정 탐색 예산이 적고 안정성이 필요 → 랜덤 포레스트

└ 성능을 더 끌어올릴 예산이 있음 → 부스팅


그림 4.5 자료 조건과 목적에 따른 모델 선택

12. 공간 교차검증으로 검증하기

12.1 검증 설계 다섯 가지

- 검증 설계는 모형이 실제로 놓일 상황에 맞춤. 같은 도시 안에서 관측이 없는 격자를 메우는 용도라면 블록 단위 분리가, 학습한 적 없는 다른 시군으로 모형을 이전할 계획이라면 지역 전체를 분리하는 설계가 그 상황에 대응함(Roberts et al., 2017)

설계	분할 방법	평가하는 상황
무작위 교차검증	행을 무작위로 분할	공간 구조가 없는 표본
블록 교차검증	좌표를 격자 블록으로 잘라 블록 단위 분할	인접하지 않은 블록의 예측
버퍼 교차검증	검증지 주변 학습표본을 제거	가까운 이웃 없이 예측
군집 교차검증	좌표를 군집으로 묶어 군집 단위 분할	학습하지 않은 권역으로 이전
그룹 교차검증	행정구역 등 소속 단위로 분할	학습하지 않은 행정 단위로 이전



- 오른쪽으로 갈수록 학습과 검증의 공간 분리가 강해지고, 측정되는 성능은 학습하지 않은 지역의 성능에 가까워짐

12.2 블록은 얼마나 크게 자를까

- 기준은 타깃의 공간 자기상관이 사라지는 거리임. 이 거리는 **베리오그램**(semivariogram)으로 추정함
- 베리오그램은 두 지점의 거리에 따라 값의 차이가 얼마나 벌어지는지를 그린 곡선임. 가까운 쌍끼리는 차이가 작고, 거리가 멀어질수록 커지다가 어느 거리부터는 더 멀어져도 커지지 않고 평탄해짐. 이 평탄해지는 거리를 **range**라 함
- 베리오그램이 800m에서 평탄해지면 블록 한 변을 800m보다 크게 잡아야 학습 블록과 검증 블록 사이의 상관이 실질적으로 끊어짐

주의. 공간 분리 검증에서 성능이 거의 떨어지지 않는 결과에는 두 원인이 있음. 블록이 자기상관 도달 거리보다 작아 누수가 남았거나, 타깃이 관측 피쳐로 이미 충분히 설명되어 모델이 위치를 쓸 필요가 없거나임. 블록 크기를 키워 다시 재면 두 원인이 같림. 확인하지 않은 채 누수가 없다고 결론 내리면 안 됨

12.3 구현과 성능지표

```
from sklearn.model_selection import GroupKFold, cross_val_score

# 좌표를 5km 격자로 잘라 블록 식별자 부여
gdf["block_id"] = ((gdf.geometry.x // 5000).astype(int) * 10000
                  + (gdf.geometry.y // 5000).astype(int))

# 같은 블록은 같은 폴드로 - 블록 단위 분리
scores = cross_val_score(model, X, y, scoring="r2",
                          cv=GroupKFold(n_splits=5), groups=gdf["block_id"])
```

전체 코드는 [lecture_practice/chapter4/code/4-2-spatial-cv.py](#) 참고

- 회귀에서는 **R²**를 씀 — 전체 평균을 예측하는 것과 비교해 모델이 설명한 변동의 비율. R²=0이면 평균 예측과 같은 수준, 음수이면 평균 예측보다 나쁨
- 분류에서는 **Macro-F1**을 씀 — 클래스별 정밀도·재현율의 조화평균(F1)을 클래스마다 구한 뒤 단순 평균한 값. 표본이 많은 클래스만 맞혀도 올라가는 정확도와 달리 소수 클래스를 동등하게 취급함
- 두 지표 모두 폴드 평균만 보고하지 않고 **폴드 간 표준편차**를 함께 적음. 4-2-spatial-cv.log 의 포인트 500개 실제 결과가 그 이유를 보여 줌

검증 설계	평균 R ²	폴드 간 표준편차	폴드 최저
무작위 5-폴드	0.869	0.008	—
블록 CV	0.798	0.143	—
군집 CV	0.349	0.271	-0.179

- 분리가 강해질수록 평균이 낮아지고 폴드 간 변동이 커짐. 무작위 검증은 다섯 폴드가 좁은 구간에 모여 있지만, 군집 검증에서는 폴드 하나가 -0.179까지 내려감 — 그 군집에 대해서는 평균 예측보다 못했다는 뜻
- 무작위와 블록의 차(0.071)가 블록 검증의 폴드 간 표준편차(0.143)보다 작다는 점에 주목함. 이런 자리에서는 차이를 해석하기 전에 그 차이가 실행마다 얼마나 달라지는지부터 재야 함

12.4 반복 실험 절차

- 성능 차이를 보고하기 전에 그 차이가 실행 간에 얼마나 흔들리는지 재는 절차를 둠
1. **재려는 값을 지목함** — 무작위 검증과 블록 검증의 차인지, 두 모델의 차인지
 2. **그 값을 만드는 축을 지목함** — 어느 블록이 함께 빠지는지, 자료를 어떻게 생성했는지 등
 3. **주축과 대조군 축을 나누어 반복함** — 축마다 여러 시드로 실행해 결과가 움직인 폭을 따로 기록함
 4. **세 갈래로 판정함**

판정	반복 결과의 모양	쓸 수 있는 서술
방향과 크기를 함께 말할 수 있음	부호가 유지되고, 가장 작은 실행조차 무시할 수 없는 크기	어느 실행에서도 X보다 작지 않았다(하한)
방향만 말할 수 있음	부호는 유지되나 크기가 여러 배로 흩어짐	방향은 재현되고, 크기는 Y를 넘지 않았다(상한)
검출되지 않음	축을 바꾸면 부호가 뒤집힘	이 설계로는 검출되지 않았다

- **차이가 작았다는 서술과 검출되지 않았다는 서술은 다름.** 앞의 것은 크기를 잴다는 뜻이고, 뒤의 것은 이 설계로는 크기를 잴 수 없다는 뜻임
- 세 판정이 실제로 어떻게 갈리는지는 14절의 세 사례에서 확인함

12.5 라벨 셔플 대조군

- 실제 자료에는 참값이 없으므로, 모델이 잡은 것이 구조인지 표본에서 우연히 맞아떨어진 잡음인지 확인해야 함
- 결과변수만 무작위로 섞고 같은 절차를 여러 번 반복하면 피처와 타겟의 관계는 끊기고 표본 크기·모델 복잡도·검증 설계는 그대로 남음. 이 조건에서 나오는 성능이 잡음 수준임

- 4-6-store-location-supply.log 의 실제 결과: 셔플 20회의 R^2 는 **-0.141**(표준편차 0.045, 가장 높은 실행 -0.040)이고, 실제 모델의 R^2 는 0.660 — 이 잡음 수준과 명확히 갈림
- 회귀에서 이 값은 0 근처가 아니라 음수로 나오는 것이 정상임. 관계가 없는 자료를 억지로 맞추면 평균을 예측하는 것보다 나빠지기 때문임

13. 결과를 읽고 해석하기

13.1 단위별 예측표

- 앞의 단계를 거치면 단위마다 예측값이 붙음. 표의 열 구성은 다음 기준으로 정함 — 결정에 필요한 값과 그 값을 검증할 근거를 같은 행에 두고, 나중에 다시 계산하기 어려운 중간값은 남김

열	내용	쓰임
단위 식별자, 좌표	격자 번호나 행정동 코드	지도 결합, 재현
주요 입력 피처	예측에 크게 기여한 상위 열	현장 대조
예측값·순위	모델 산출값, 내림차순 순위	배분 후보 정렬
신뢰 표시	예측을 신뢰하기 어려운 단위의 표시	확정 배분에서 제외
집계 단위	이 단위가 속한 행정구역 코드	7.3의 집행 단위 집계

- 예측표를 순위표로 바꿔 읽을 때는 다음 네 가지를 순서대로 확인함
 1. **단순 기준과 비교함** — 모델 없이 고령인구율 상위 25%만 골랐을 때와 비교해 모델의 기여를 확인함
 2. **순위의 간격을 봄** — 상위 다섯 단위의 값이 촘촘하면 오차 범위 안에 들어가므로 개별 순위가 아니라 상위 그룹으로 묶어 처리함
 3. **임계값 주변을 확인함** — 정책 기준이 상위 20개라면 20위와 21위 근처를 따로 뽑아 봄
 4. **예상과 다른 결과를 그대로 보고함** — 설명할 수 있으면 유지하고, 설명할 수 없으면 입력값을 다시 확인함

13.2 SHAP 기여도

- 변수 중요도는 모델 전체가 어느 열을 자주 썼는지 알려주지만, 특정 격자가 왜 1순위로 올라왔는지는 알려주지 않음
- **SHAP**은 개별 예측 하나를 피처별 기여로 분해함(Lundberg & Lee, 2017)
- 계산의 논리는 협력 게임의 배분에서 옴. 피처들을 예측이라는 공동 작업의 참여자로 두고, 어떤 피처를 추가했을 때 예측이 얼마나 움직이는지를 가능한 모든 참여 순서에 걸쳐 평균해 그 피처의 몫을 정함

- 계산 예: 평균 예측 45점, 고령인구율만 반영하면 52점, 병원 거리만 반영하면 48점, 둘 다 반영하면 59점이라 하자
- 참여 순서 A→B: A의 기여 = 52-45 = 7점. 참여 순서 B→A: A의 기여 = 59-48 = 11점. 두 순서를 평균하면 고령인구율의 SHAP = (7+11)/2 = **9점**
- 같은 방식으로 병원 거리의 SHAP = 5점. 45+9+5 = 59로 예측값이 정확히 복원됨 — 이것이 SHAP의 가법성
- 4-5-grid-vulnerability-shap.log 의 실제 결과(랜덤 포레스트, 취약성 예측)

피쳐	평균 절대 SHAP
고령인구율(elderly)	4.003
병원 거리(dist_hosp)	2.476
좌표 y	2.123
기초수급율(basic)	1.365
대중교통 거리(dist_transit)	1.354
1인가구율(single_hh)	1.035
좌표 x	0.795
평균 NDVI	0.456

- **좌표 y가 세 번째라는 점**이 9.5절에서 예고한 신호가 실제로 나타난 자리임. 취약성과 직접 관련이 없는 위치 변수가 상위로 올라온 것은 모델이 잠재 공간 구조를 좌표로 흡수했다는 뜻임
- 예측 잔차의 Moran's I는 **0.663**(p=0.001)으로 여전히 높음 — 좌표만으로는 그 구조를 다 담지 못했다는 뜻
- 한계는 두 가지임. 첫째, SHAP은 인과가 아니라 모델이 무엇을 보고 판단하는지를 보여줌 — 병원 거리의 SHAP이 크다는 사실에서 병원을 지으면 취약성이 내려간다는 결론이 따라오지 않음. 둘째, 서로 강하게 상관된 두 피쳐가 있으면 기여가 나뉘므로 개별 값의 크기를 곧바로 순위로 읽기 어려움

13.3 잔차의 공간 자기상관

- 성능지표는 오차의 크기만 알려주고 오차가 어디에 몰려 있는지는 알려주지 않음
- 예측 후에는 잔차(실제값-예측값)에 10.1의 Moran's I를 그대로 적용함. 값이 유의하게 양수이면 비슷한 부호의 오차가 이웃끼리 모여 있다는 뜻이고, 모델이 그 지역의 공통 조건을 설명하지 못했다는 신호임

대응	방법	트레이드오프
공간 피쳐 추가	공간 시차, 거리·밀도 열을 보강	계산이 간단하나 좌표 의존과 누수에 주의
공간 명시 모델	지리가중회귀, 공간 랜덤효과	구조를 직접 모형화하나 계산 비용 증가
불확실성 보고	점 예측 대신 범위로 보고	추가 모델링 없이 한계를 결과에 남김

13.4 성능 보고 항목

- 공간 예측 결과를 정책이나 사업 판단에 제출할 때 다음을 함께 보고함. 하나라도 빠지면 학습하지 않은 지역에서의 성능을 판단할 수 없음
 - 무작위 검증과 공간 분리 검증을 나란히 적음
 - 검증 설계와 그 근거(블록 크기 등)를 적음
 - 폴드 간 표준편차와 최저 폴드를 적음
 - 잔차 진단 결과와 대응을 적음
 - 반복 실험의 범위와 판정을 적음

14. 세 사례로 확인하기

- 같은 여덟 단계를 세 가지 실제 자료에 적용하면 판정이 서로 다르게 나뉨. 이 대비가 12.4에서 정의한 세 갈래 판정이 실제로 나타난다는 근거임

14.1 위성영상 픽셀의 토지피복 분류

- 자료: Sentinel-2 L2A 클립에 ESA WorldCover 2021 라벨을 결합한 픽셀 7,500개(5개 클래스, 클래스당 1,500개씩 균형 표집)
- 검증: 픽셀 좌표를 1km 격자로 잘라 블록 196개, 지표는 Macro-F1

모델	무작위 CV	블록 CV
랜덤 포레스트	0.763	0.753
XGBoost	0.772	0.760
LightGBM	0.768	0.755

- 반복 실험: 모델 시드, 블록 배정 시드, 픽셀 표집 시드를 조합해 36회 실행함
- 36회 모두 양수였음(무작위 검증이 항상 더 높음). 그러나 값은 +0.005에서 +0.022까지 네 배 폭으로 흩어짐

- **판정: 방향만 말할 수 있음** — 무작위 검증이 블록 검증보다 높고, 그 차이는 0.022를 넘지 않음
- 공간 블록 홀드아웃 기준 클래스별 F1은 수역 0.973, 산림 0.903, 시가지 0.785, 경작지 0.632, 초지 0.530 — 수역·산림은 분광이 뚜렷해 잘 분류되고, 초지·경작지는 둘 다 식생 기반이라 분광이 비슷한 데다 이 장면이 4월 초여서 경작지 상당수가 파종 전 나지 상태였음

14.2 격자 정책 취약성 예측

- 자료: 20×20 격자 400개(시뮬레이션). 타깃(취약성)에 관측 피쳐로 설명되지 않는 잠재 공간 구조를 통제된 크기로 심어 두었음
- 타깃의 Moran's I = **0.817**($p=0.001$) — 공간 분리 검증이 필수인 구간

모델	무작위 CV	블록 CV	군집 CV
랜덤 포레스트	0.639	0.535	0.373
XGBoost	0.629	0.490	0.183

- 반복 실험: 모델 시드, 분할 시드, 자료 생성 시드를 조합해 24회 실행함
- 24회 모두 음수였고, 낙폭이 가장 작았던 실행조차 -0.165였음
- **판정: 방향과 크기를 함께 말할 수 있음** — 무작위에서 군집으로 갈 때 어느 실행에서도 0.165보다 작게 떨어지지 않았음(하한)
- SHAP 순위에서 좌표 y가 3위(13.2절)로 오른 것, 잔차 Moran's I가 0.663으로 남은 것이 이 결과와 앞뒤가 맞음

14.3 서울 행정동의 카페 기대 공급량 (비즈니스 사례)

- 자료: 서울 415개 행정동. 소상공인시장진흥공단 상가정보(카페 22,739개)와 서울 생활인구를 결합함
- 대상은 매출이 아니라 점포 수임. "카페 40개"는 시장이 진입·폐업을 반복하며 도달한 공급 균형이지, 수요를 직접 켜 값이 아님. 그래서 산출물을 유망도가 아니라 **기대 공급량**이라 부름

구분	검증 설계	R ²
수요·위치 피쳐만	자치구 그룹 CV	0.656
공간 시차 피쳐 추가	자치구 그룹 CV	0.660
공간 시차 피쳐 추가	무작위 5-폴드	0.685
라벨 셔플 대조군	자치구 그룹 CV	-0.141

- 공간 시차의 개선(0.660-0.656=0.003)을 반복 실험(모델 시드 축, 폴드 배정 시드 축)으로 확인하면, 폴드 배정 시드까지 바꿨을 때 -0.001에서 +0.018로 **부호가 뒤집힘**

- 무작위-그룹 검증의 차($0.685-0.660=0.025$)도 같은 방식으로 반복하면 -0.006 에서 $+0.034$ 로 부호가 뒤집힘
- **판정: 두 비교 모두 검출되지 않음** — "개선이 작았다"가 아니라 "이 과제에서는 이 설계로 검출되지 않았다"고 서술함
- 다만 4.9.2와 비교하면 상한이 뚜렷이 낮음(0.034 대 0.165 , 네 배 이상 차이) — 낮 생활인구라는 관측된 변수가 이미 카페 수를 상당 부분 설명하므로 모델이 위치를 쓸 필요가 적기 때문임
- SHAP 상위: 낮 생활인구 18.434, 주야 인구비 12.401, 이웃 동 카페 수 4.486, 도심 거리 1.920 — 위치 변수(도심 거리)가 4위에 그침. 14.2의 격자 취약성에서 좌표가 3위였던 것과 대비됨
- 산출물의 예: 실제-기대 차이(공급 격차)가 큰 동

방향	자치구	행정동	실제	기대	차이
기대보다 적음	서대문구	북아현동	16	176.0	-160.0
기대보다 많음	마포구	서교동	535	238.5	+296.5

- 전체 415개 동의 공급 격차를 지도로 보면 다음과 같음




그림 4.6 행정동별 카페 공급 격차(실제 - 기대). 붉을수록 기대보다 적고 푸를수록 많음. 점 크기는 낮 생활인구임

- 이 표를 읽는 규칙이 중요함 — **잔차는 답이 아니라 확인할 질문의 목록임**. 북아현동의 음의 격차를 출점 기회로 읽기 전에 재개발 구역인지, 상가로 쓸 1층 면적이 적은지를 확인해야 함. 모델은 이런 열을 갖고 있지 않으므로 그 부재를 전부 격차로 계산함

14.4 세 사례를 나란히 놓으면

사례	타깃의 공간 구조	판정
토지피복 분류	분광으로 설명되고 표본이 고르게 분포	방향만 말할 수 있음(상한 +0.022)
격자 취약성	관측되지 않는 잠재 구조를 포함	방향과 크기를 말할 수 있음(하한 0.165)
카페 기대 공급량	관측된 수요 변수로 상당 부분 설명	검출되지 않음(부호가 뒤집힘)

- 공간 분리 검증에서 성능이 얼마나 떨어지는가는 검증 설계가 정하는 것이 아니라 **타깃이 관측 피처로 얼마나 설명되는가**가 정함. 관측 피처로 설명되지 않는 구조가 클수록 모델이 위치를 대리 변수로 쓰고, 그 대리는 학습 지역 밖에서 작동하지 않음

15. 방법 점검표

- 새 공간단위 예측 과제를 시작할 때 아래를 채움. 채우지 못한 행이 있으면 그 단계의 결정 근거가 아직 없다는 뜻임

단계	확인할 내용
1 분석 단위	포인트·격자·행정구역·필지·건물·네트워크 권역 중 무엇인가. 집계 단위와 가중치는
2 표 변환	픽셀·패치·공간단위 중 어느 경로로 표로 바꿨는가
3 피처	공간가중행렬은 어떻게 정의했는가. 좌표를 넣었다면 왜, 각 열을 예측 시점에 어디서 받는가
4 진단	타깃의 Moran's I와 이웃 정의는
5 모델	기준모형과 무엇을 비교했는가. 왜 그 모델을 골랐는가
6 검증	블록·버퍼·군집·그룹 중 무엇이며 크기의 근거는. 폴드 간 표준편차와 반복 실험 판정은
7 해석	잔차 Moran's I는. SHAP으로 확인한 것을 인과로 읽지 않았는가
8 산출물	순위표에 신뢰 표시가 있는가. 이 표가 답하지 못하는 것은 무엇인가

16. 활동 / 토론

- 활동 1 (15분) — 실제 위성영상 픽셀 뜯어보기**
 - `python lecture_practice/chapter4/code/4-0-raster-inspection.py` 를 실행
 - 배열 형태 `(12, 1314, 1338)` 이 무엇을 뜻하는지, 중심 픽셀의 NDVI가 왜 음수(-0.234)로 나오는지 한 문장으로 작성
 - NDVI 0.4 초과 비율(38.4%)이 이 장면의 어떤 성격을 말해 주는지 적음
- 활동 2 (20분) — 공간 자기상관과 검증 사다리 확인하기**
 - `python lecture_practice/chapter4/code/4-2-spatial-cv.py` 를 실행
 - Moran's I가 0.866으로 나온 것을 10.1의 계산 예(값 0)와 비교해 무엇이 다른지 설명
 - 표 12.3의 세 검증(무작위 0.869, 블록 0.798, 군집 0.349)을 다시 확인하고, **군집 CV의 폴드 최저값 (-0.179)이 뜻하는 바를 적음**
- 활동 3 (20분) — 좌표가 SHAP 순위에 오르는 이유 확인하기**

- `python lecture_practice/chapter4/code/4-5-grid-vulnerability-shap.py` 를 실행
- SHAP 순위에서 좌표 y가 3위(2.123)로 오른 이유를 9.5절의 잠재 공간 구조 설명과 연결해 두 문장으로 작성
- 잔차 Moran's I(0.663)가 왜 완전히 0으로 내려가지 않는지 추론
- **활동 4 (20분) — 잔차를 질문으로 읽어 보기**
 - `python lecture_practice/chapter4/code/4-6-store-location-supply.py` 를 실행
 - 북아현동(실제 16, 기대 176.0)을 출점 기회로 볼지 말지, 확인이 더 필요한 질문 두 가지를 적음
 - 서교동(실제 535, 기대 238.5)의 양의 격차를 모델이 왜 못 잡아냈는지 9.3절의 공간 시차 설명과 연결해 작성
- **토론 1:** 공간 자기상관이 있는 자료를 무작위로 나누면 왜 오류 메시지 없이 통과할까? 코드가 잡아주지 못하는 이 문제를 사람이 잡으려면 무엇을 확인해야 할까?
- **토론 2:** 14.3의 카페 사례에서는 공간 시차와 과대추정 모두 "검출되지 않음"으로 판정됐다. 이 판정이 "효과가 없다"는 판정과 어떻게 다른지 말해 보라.
- **토론 3:** SHAP이 보여주는 것은 모델이 무엇을 보고 판단했는가지지 인과가 아니다. 병원 거리의 SHAP이 큰 결과를 "병원을 지으면 취약성이 내려간다"는 정책 제안으로 바로 옮기면 무엇이 위험한가?

17. 체크 질문

1. 공간단위 예측의 여덟 단계에서 6단계(검증)를 정하지 않은 채 5단계(모델 적합)를 먼저 끝내면 어떤 문제가 생기는가?
2. MAUP는 무엇이며, 왜 "고칠 수 있는 오류"가 아니라 "관리해야 하는 성질"인가?
3. 위성영상을 표로 바꾸는 세 경로(픽셀·패치·공간단위)는 각각 무엇을 잃는가?
4. 목표값 누수와 공간 분할 누수는 어떻게 다른가? 각각 어떻게 고치는가?
5. Moran's I가 0에 가까우면 공간 구조가 없다고 단정할 수 있는가? 10.1의 4칸 예로 설명하라.
6. 랜덤 포레스트에서 피처를 무작위로 추가하는 단계가 왜 필요한가? 트리 수를 늘리는 것만으로는 왜 부족한가?
7. 무작위 검증과 군집 검증의 R^2 차이가 폴드 간 표준편차보다 작을 때, 그 차이를 결과로 인용해도 되는가?
8. 반복 실험의 세 갈래 판정(하한/상한/검출되지 않음)은 각각 어떤 문장으로 서술하는가?
9. SHAP 값이 예측값과 같은 단위를 갖는다는 것은 무슨 뜻인가?
10. 14.2와 14.3에서 같은 검증 설계를 썼는데 판정이 같았다. 그 차이를 만든 것은 무엇인가?
11. 표 4.27(공급 격차) 같은 순위표에서 음의 값을 곧바로 "기회"로 읽으면 안 되는 이유는?

18. 과제

```
python scripts/submit.py 4 --id 학번 --name 이름
```

- 실행하면 `submissions/` 폴더에 `제출_4장_학번.md` 가 생성되고, 대표 실습(`4-2-spatial-cv.py`)의 실행 결과가 붙어 있음
- 눈여겨볼 곳은 무작위 교차검증 점수와 공간 블록 교차검증 점수의 차이
- 빈칸 네 개를 채움
- 1. 무작위 교차검증 R^2 와 블록 교차검증 R^2 를 옮겨 적고, 두 값의 차이를 한 문장으로
- 2. 무작위 검증 점수를 그대로 보고서에 실었다면, 그 보고서는 무엇을 잘못 말하게 되는가?
- 3. Moran's I 값과 그 유의성(z, p)을 옮겨 적고, 이 값이 검증 설계에 어떤 뜻인지 적으라
- 4. 14절의 세 사례 중 하나를 골라, 그 사례의 반복 실험 판정(방향과 크기/방향만/검출되지 않음)이 왜 그렇게 나왔는지 자료의 성질로 설명하라
- 2번과 4번이 핵심
- 1.3번은 로그를 읽으면 나오지만 2.4번은 판단이 필요함

- 막혀도 제출함
- 실행이 실패하면 오류 메시지가 파일에 담기고, 질문이 "어디서 막혔나"로 바뀜
- 실행 성공 여부로 점수를 매기지 않음

19. 더 알아보기

- 위성영상을 표로 바꾸는 작업을 더 넓게 보기
 - Microsoft Planetary Computer 데이터 카탈로그(<https://planetarycomputer.microsoft.com/catalog>)에서 Sentinel-2 L2A 외에 어떤 분석 준비 자료가 있는지 살펴보면 8절의 세 변환 경로가 실제 데이터셋 규모에서 어떻게 쓰이는지 감을 잡을 수 있음
- 공간 교차검증을 직접 코드로 확인하기
 - scikit-learn의 GroupKFold 문서(https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GroupKFold.html)를 읽으면 12.3의 코드가 어떤 원리로 그룹을 폴드에 배정하는지 알 수 있음
- SHAP을 더 깊이 알고 싶다면
 - Lundberg의 SHAP 공식 문서(<https://shap.readthedocs.io/>)는 13.2의 계산 예를 다양한 모델·자료에 적용하는 방법을 다룸
- 공간 교차검증이 왜 필요한지 보여주는 원논문

- Ploton, P., et al. (2020). Spatial validation reveals poor predictive performance of large-scale ecological mapping models. *Nature Communications*, 11, 4540. <https://doi.org/10.1038/s41467-020-18321-y>