

6장 영역 추출과 변화 탐지, 마스크에서 결정까지

- 이 장에 나오는 IoU·정밀도·재현율·면적·필지 수는 모두 `lecture_practice/chapter6/` 의 코드를 실제로 실행해 얻은 값
- 예시를 위해 지어낸 숫자는 없음

1. 이 장의 핵심 질문

- 산불이 지나간 자리가 몇 헥타르인지 어떻게 재는가?
- 침수된 지역의 경계를 지도 위에 어떻게 그리는가?
- 도시 안에서 개발할 수 있는 빈 땅을 어떻게 찾아내는가?
- "이 사진에는 산림이 있다"라는 답 하나로는 부족한 이유는 무엇인가? "어디서부터 어디까지가 산림인가"를 알아야 면적을 셀 수 있음
- 픽셀마다 붙인 답(마스크)을 구역별 점검 순서나 후보지 목록 같은 실제 결정으로 어떻게 바꾸는가?
- 마스크에는 항상 오차가 섞여 있는데, 그 오차가 결정을 어떻게 흔들고 얼마나 되돌릴 수 있는가?
- 이 장은 **영상에서 영역을 오려 내고 그 결과를 결정으로 옮기는 절차를 다룬다**
- 5장에서 다룬 영상 분류는 "이 패치는 산림이다"라는 답 하나를 냄
- 이 장의 세그멘테이션은 픽셀마다 답을 붙여 "산림이 몇 헥타르이고 경계가 어디인가"에 답함
- 변화 탐지는 같은 계산을 두 시점에 걸쳐 해서 "무엇이 달라졌는가"에 답함

2. 직관적 비유

- 마스크 만들기 = 사진 위에 셀로판지를 오려 붙이는 작업
- 대응을 하나씩 짚으면
 - 사진 = 입력 영상
 - 셀로판지를 붙일지 말지 정하는 한 칸 = 픽셀 하나에 대한 판정
 - 셀로판지의 색 = 그 픽셀에 붙는 클래스(산림·건물·도로 등)
 - 오려낸 셀로판지 전체의 모양 = 마스크가 그리는 경계
- 변화 탐지 = 같은 사진을 두 시점에 찍고 각각 셀로판지를 오려 붙인 뒤 겹치지 않는 자리만 남기는 작업

- 두 시점의 셀로판지 모양이 같으면 변화 없음, 모양이 다르면 그 자리가 변화로 남음
- 셀로판지 자체(마스크)는 아직 행정이나 사업의 결정 단위가 아님
- "셀로판지가 몇 칸 붙었다"로는 담당 부서도 예산 항목도 정해지지 않음
- 이 장의 후반부는 셀로판지를 오려 낸 조각(객체)으로 바꾸고, 그 조각을 구역별로 모아 결정 문서로 바꾸는 계산을 다룸

3. 핵심 개념 5가지

1. 세그멘테이션은 대상에 따라 답의 층위가 다름

- 픽셀마다 클래스 하나만 붙이면 **시맨틱 세그멘테이션**(semantic segmentation). 개체는 구분하지 않음
- 건물 한 채 한 채를 서로 다른 개체로 나누면 **인스턴스 세그멘테이션**. 셀 수 있는 대상과 셀 수 없는 배경을 한 지도에 함께 담으면 **파놉틱 세그멘테이션**

2. 대상이 몇 픽셀인지가 모델의 성패를 가름

- 폭 12m 주택은 10m 격자에서 1.2픽셀이고 0.5m 항공영상에서 24픽셀임
- 같은 대상이라도 픽셀 크기가 다르면 완전히 다른 과제가 됨

3. 클래스 불균형이 있으면 손실을 그냥 쓰면 안 됨

- 변화 픽셀이 전체의 1%뿐인 자료에서, 모든 픽셀을 배경이라고만 답해도 정확도가 99%로 나옴
- 이 함정을 피하려고 **Focal Loss**나 **Dice 손실** 같은 전용 손실을 씀

4. 마스크는 객체로 바뀌야 결정에 쓸 수 있음

- 서로 맞닿은 픽셀을 하나의 덩어리로 묶는 계산이 **연결요소**(connected component) 라벨링
- 덩어리마다 면적·둘레·최소폭·접도 같은 숫자를 재야 "이 부지가 개발 요건을 채우는가" 같은 질문에 답할 수 있음

5. 마스크의 오차는 방향이 있음

- 경계가 한 겹 깎이는 침식은 항상 면적을 실제보다 작게 만듦. 무작위 오차라면 표본을 늘리면 사라지지만 이 오차는 평균해도 남음
- 방향이 있는 오차는 소수의 현장 실측으로 크기를 재서 되돌릴 수 있음

4. 실제 자료를 먼저 보기

- 이 장도 정의보다 실제 자료·논문을 먼저 보는 편이 이해가 쉬움
- Microsoft US Building Footprints — 대륙 단위로 뽑아낸 건물 윤곽 데이터 <https://github.com/microsoft/USBuildingFootprints>

- Segment Anything(SAM) 논문 — 프롬프트 하나로 임의 객체를 오려 내는 모델 <https://arxiv.org/abs/2304.02643>
- SAM 3 공개 블로그 — 텍스트로 대상을 지정해 전 인스턴스를 한 번에 뽑는 최신 버전 <https://ai.meta.com/blog/segment-anything-model-3/>
- AlphaEarth Foundations 논문 — 마스크 대신 지점마다 숫자 64개로 요약된 임베딩을 내는 모델 <https://arxiv.org/abs/2507.22291>
- Microsoft 저장소를 열어 보면 건물 하나하나가 폴리곤(다각형)으로 저장되어 있는 것이 보임
- 이 폴리곤이 바로 이 장에서 다루는 "마스크를 객체로 바꾼 결과"의 최종 형태임
- SAM 논문의 그림을 보면 사람이 클릭 한 번으로 대상의 경계를 오려 내는 예시가 나옴 — 12절에서 이 모델을 자세히 다룸

실습 안내

- 실습 코드
 - `lecture_practice/chapter6/code/6-1-change-detection-policy.py` — 변화 마스크 채점·거짓 변화 필터링·구역 집계
 - `lecture_practice/chapter6/code/6-2-site-sourcing.py` — 개발 가능 부지 탐색, 객체화·기하 피쳐·편향 보정·절단선 계산
 - 데이터 준비 스크립트(`6-0-simdata-prep.py`, `6-0b-site-simdata-prep.py`)는 시뮬레이션 자료를 만들어 두는 역할이며, 두 실습을 실행하기 전에 한 번 돌려야 함
- 결과 로그: `lecture_practice/chapter6/results/*.log`, `*.csv`, `6-2-site-sourcing-map.png`
- 이 장의 실습은 GPU가 필요 없음
- `lecture_practice/` 는 노트북에서 돌아가도록 가볍게 만든 실습이고, 이 장의 본문 수치는 전부 이 폴더의 결과 로그에서 나옴
- 실제 모델(U-Net·SAM 같은)을 학습하는 대신, **그 모델이 냈을 법한 출력(변화 마스크·부지 마스크)을 미리 만들어 둔 자료에서 불러옴**. 이 장의 계산 대상은 모델 내부가 아니라 마스크를 채점·필터·집계·보정하는 절차임

5. 실제 사례로 먼저 보기

- `6-1-change-detection-policy.log` 의 실제 실행 결과
- 무대: 128×128 래스터, 픽셀 한 번 10m, 픽셀 하나가 0.01헥타르
- 진짜 변화 픽셀 2,001개, 모델이 예측한 변화 픽셀 3,022개

- 필터를 걸기 전과 후를 나란히 놓으면

단계	IoU	정밀도	재현율	Dice
필터 전	0.525	0.572	0.865	0.689
필터 후	0.865	1.000	0.865	0.927

- 필터는 식생지수 차분이 0.25를 넘는 픽셀만 남기고, 연결된 덩어리가 1헥타르(100픽셀) 미만이면 지우는 두 규칙임
- 읽는 법: 정밀도는 "변화라고 판정한 것 중 진짜의 비율", 재현율은 "진짜 변화 중 잡아낸 비율"
- 정밀도만 0.572에서 1.000으로 오르고 재현율은 0.865에서 그대로임
- 필터는 예측 안의 가짜를 지우는 장치라서 정밀도만 올림. 모델이 애초에 놓친 픽셀은 예측에 없으므로 필터로 되살릴 수 없음
- 필터를 거친 마스크를 16개 구역(4×4 격자)에 포개면 15개 구역에서 변화가 잡히고 합계 17.3헥타르가 나옴. 상위 5구역은 다음과 같음

순위	구역	변화 면적(ha)
1	구역 9	2.93
2	구역 10	2.47
3	구역 13	2.30
4	구역 6	1.78
5	구역 15	1.41

- "픽셀 3,022개가 변했다"는 담당 부서를 정하지 못하지만 "구역 9에서 2.93헥타르가 개발되었고 관내 최대"는 점검반의 방문 순서를 정함
- 이 장의 나머지는 이 두 계산 — **채점해서 걸러 내기, 구역별로 모아 순서를 매기기** — 을 어떤 절차로 하는지, 그리고 대상이 픽셀이 아니라 개별 필지일 때는 무엇이 달라지는지를 다룸

6. 영역 추출 분석의 일곱 단계

- 이 장의 계산은 순서가 있음. 앞 단계를 건너뛰면 뒤 단계의 판단 근거가 사라짐
- 무엇을 만들지(1단계) 정하지 않고 모델부터 고르면(3단계), 나중에 개체를 세야 하는 과제에 픽셀만 답하는 모델을 붙이는 실수가 나옴




그림 6.1 영역 추출 분석의 일곱 단계와 단계별 산출물

- 이 표는 새 과제를 시작할 때 작업 목록으로 쓰고, 채우지 못한 칸이 있으면 그 단계의 근거가 아직 없다는 뜻으로 읽음

단계	이 장의 절	무엇이 산출되는가
1 무엇을 만들 것인가	7절	과업 유형, 산출 단위, 라벨 예산
2 입력·정합	8절	정합된 입력, 마스킹 규칙
3 모델 선택	9절	후보 모델과 선택 근거
4 학습·적응	10절	학습된 모델, 손실 구성
5 채점	11절	픽셀 지표표, 객체 지표표
6 객체화	12절	객체 목록, 기하 피쳐표
7 집계·결정	13절	우선순위표 또는 후보표, 절단선

- 14절은 이 절차를 실제 두 사례(구역 점검, 부지 탐색)에 적용해 실행 수치로 확인함
- 15절은 새 과제를 시작할 때 채우는 점검표

7. 무엇을 만들 것인가 정하기

7.1 과업 유형

- 주택가 사진 한 장을 놓고 세 가지 답이 가능함

과업	한 입력에 대한 답	답할 수 있는 질문
시맨틱 세그멘테이션	픽셀마다 클래스 1개	산림이 몇 헥타르이고 경계가 어디인가
인스턴스 세그멘테이션	개체마다 마스크 1개	각 건물의 면적과 형상은 얼마인가
파노믹 세그멘테이션	픽셀당 클래스 + 개체 식별자	개체와 배경을 한 지도에서 같이 다룰 수 있는가
변화 탐지	픽셀당 변화 여부	두 시점 사이 어디가 달라졌는가

- **변화 탐지는 별도 계열이 아니라 두 시점을 입력으로 받는 세그멘테이션임.** 계산의 뼈대는 같고 달라지는 지점이 둘 있음
 1. 두 시점이 같은 좌표 격자에 포개지지 않으면 경계선을 따라 가짜 변화가 생기므로 정합이 0단계가 됨(8절)
 2. 검증 지표의 우선순위가 반대로 놓일 수 있음. 재난 피해 평가에서는 농친 피해가 비용이 크고, 단속 행정에서는 잘못 잡은 변화가 비용이 큼(11절)

7.2 산출 단위를 착수 시점에 정한다

- 픽셀 마스크에서 끝낼지, 개체 목록까지 갈지, 구역 집계까지 갈지를 미리 정함
- 이유: 필요한 라벨 형식과 이후 계산이 완전히 달라지기 때문

산출 단위	필요한 층위	주의할 점
픽셀(면적 합계)	시맨틱만으로 충분	픽셀 크기에서 면적으로 환산
개체(면적·형상)	인스턴스, 또는 시맨틱 + 연결요소	맞닿은 개체가 하나로 묶임
구역(집계표·우선순위)	시맨틱으로 충분	구역 경계를 무엇으로 잡느냐가 순위를 바꿈

- 구역이 조밀하게 붙은 도심에서는 "시맨틱 마스크 + 연결요소"로 개체를 대신하는 방법이 성립하지 않음. 맞닿은 두 건물이 한 덩어리로 묶여 버림

7.3 라벨 하나의 값이 다르다

- 5장의 패치 분류에서 라벨 하나는 "이 패치는 산림"이라는 판정 한 번임
- 세그멘테이션의 라벨 하나는 장면 전체의 정답 지도, 즉 모든 픽셀의 클래스임
- 보통 GIS에서 사람이 건물·산림 경계를 폴리곤으로 그린 뒤 래스터로 굽는 방식이라 작업량이 패치 라벨과 자릿수가 다름
- 이 비용이 뒤 단계를 사실상 결정함: 라벨이 없으면 전용 모델을 후보에서 빼야 하고(9절), 라벨이 수백 장 규모면 적응 깊이가 저랭크 적응 쪽으로 내려감(10절)

- 예산에는 검증용 정답의 몫도 따로 세워 둬. 학습 라벨만 만들고 검증 라벨을 남기지 않으면 11절의 채점 자체가 불가능해짐

7.4 마스크로 답할 수 없는 질문도 있다

- 세그멘테이션이 재는 것은 면적과 형상, 즉 "무엇이 거기 있는가"임. "그것이 얼마의 값을 갖는가"의 정보가 아님
- 예: 위성영상에서 건물 윤곽을 대량으로 뽑을 수 있게 되자 그 면적·형상으로 부동산 가치를 예측하려는 시도가 있었음
- 실제 감정에서 가격을 지배하는 신호는 인근의 최근 실거래가이며, 같은 면적의 건물도 두 블록 떨어지면 값이 갈림. 그 차이는 학군·임차인 구성·권리관계처럼 영상에 기록되지 않는 조건에서 옴
- 그래서 이 장은 영상 피쳐로 가치를 예측하는 예제를 두지 않고, 마스크에서 바로 계산되는 질문(개발 가능한 땅이 어디 남았는가)을 다룸. 이 질문은 14절에서 절단선까지 계산함

8. 입력 자료가 조건을 통과하는지 확인하기

- 모델을 고르기 전에 입력 자료가 세 조건을 통과하는지 먼저 확인함
- 이 확인을 건너뛰면 9절에서 어떤 모델을 골라도 마스크의 경계 오차가 결정을 뒤집는 크기로 남음

8.1 대상이 몇 픽셀인가

- 픽셀 크기 g 와 대상의 대표 폭 w 에서 대상의 픽셀 폭은 w/g 로 계산함
- 폭 12m 주택은 10m 격자에서 1.2픽셀, 0.5m 항공영상에서 24픽셀임. 같은 대상이지만 다른 과제임
- 면적 오차의 하한도 여기서 나옴. 경계 한 겹의 오차가 바꾸는 픽셀 수는 대략 둘레만큼이므로, 정사각형 대상에서 상대 오차는 4/한 변의 길이임
 - 한 변 100m면 4%, 한 변 32m면 12.5%
- 면적을 5% 이내로 재야 한다면 대상의 한 변이 픽셀 크기의 80배 이상이어야 함. 이 계산을 착수 시점에 해 두면 해상도가 부족한 자료로 시작했다가 끝에 가서 면적 오차를 발견하는 일을 피함

픽셀 크기	대상	픽셀 폭	판정
10m	주택 12m	1.2	개별 계측 불가, 구역 집계만 가능
10m	개발 패치 200m	20	구역 면적 집계 사용 가능
1m	필지 34m	34	개별 계측 가능, 면적 편향 보정 필요
0.5m	주택 12m	24	개체 검출 가능, 경계 정밀도 확인 필요

8.2 필요한 밴드를 모델이 받는다

- 광학 영상은 가시광선 외에 근적외선·단파적외선 밴드를 담고, 식생·수체 판별은 이 밴드에서 나옴
- 합성개구레이더(SAR)는 마이크로파를 쏘아 되돌아온 세기를 재므로 구름 아래를 볼 수 있지만 반사 통계가 광학과 다름
- 일반 사진으로 학습한 모델은 RGB 3채널을 전제하므로 근적외선을 그대로 넣을 수 없음. 밴드를 골라 세 개로 합성하거나 입력 층을 바꿔야 함
- SAR의 스펙클(산란체 간섭이 만드는 점 잡음)은 광학 영상의 질감과 통계가 달라, 광학으로 학습한 표현이 그대로 옮겨 가지 않음

8.3 두 시점이 같은 격자에 포개져 있는가

- 위성은 촬영마다 궤도와 자세가 미세하게 달라, 기하보정 후에도 두 시점이 몇 픽셀 어긋날 수 있음
- 어긋난 채 차분하면 건물 가장자리·도로변·하천변을 따라 값이 크게 달라지고 이 픽셀들이 변화로 판정됨. 건물은 그대로인데 지붕 경계가 한 픽셀 밀려 변화로 잡히는 형태임
- 변화 탐지의 0단계는 두 시점을 같은 좌표 격자에 포개는 **시점 정합(co-registration)**이고, 2장에서 다른 좌표계와 정합 품질이 여기서 판정 기준이 됨

주의. 시점 정합 오차는 지표를 정상으로 보이게 함. 두 시점이 한 픽셀 어긋나면 모든 경계를 따라 가짜 변화 띠가 생기는데, 이 띠는 면적이 작아 전체 IoU를 크게 떨어뜨리지 않음. 변화 마스크가 선형 띠 모양으로 나타나는지 육안으로 확인하고, 어긋남이 의심되면 정합을 다시 한 뒤 지표를 읽음.

8.4 거짓 변화를 거르는 규칙

- 정합을 맞춰도 지표가 변하지 않았는데 값이 달라지는 경우가 남음. 구름과 그림자가 지표를 가리면 밝기가 급변하고, 여름 녹음과 겨울 나지는 같은 산림인데 값이 다름. 이런 값 변화를 **거짓 변화(false change)**라 함
- 대응은 순서대로 쌓음. 앞의 규칙이 뒤의 규칙이 다룰 자료를 정리해 주기 때문

순서	대응	제거하는 원인
1	대기보정 영상 사용	대기 상태 차이
2	구름·그림자 마스크	구름과 그림자
3	지수 차분 임계	계절 변동, 관측 잡음
4	최소 면적 필터	점점이 흩어진 오탐

- 5절에서 본 실습은 3·4단계만 적용한 결과였음. 식생지수 차분 임계 0.25는 진짜 개발이 식생지수를 크게 떨어뜨린다는 성질에서, 최소 면적 1헥타르는 개발이 덩어리로 일어난다는 성질에서 나온 값임

9. 마스크를 만들 모델 고르기

- 마스크를 만드는 모델은 네 계열임: 전용 세그멘테이션 구조, 변화 탐지 구조, 프롬프트 모델, EO 파운데이션 모델
- 네 계열은 성능으로 줄 세울 대상이 아님. 각 계열이 전제하는 입력 형식과 라벨 조건이 다르므로 7절의 산출 단위와 라벨 예산, 8절에서 통과한 입력 조건이 후보를 먼저 걸러 냄

9.1 전용 세그멘테이션 구조 — U-Net

- **문제 상황.** 10m 격자 위성영상에서 관내 산림 면적을 헥타르 단위로 집계해야 함. 패치 분류는 패치 한 장에 답 하나만 내므로 패치 안에 산림과 나지가 섞여 있으면 비율을 알 수 없음. 경계가 어느 픽셀인지 모르면 면적을 셀 수 없음
- U-Net(Ronneberger 외, 2015)은 인코더-디코더 두 부분으로 이 문제를 풀
 - 인코더는 해상도를 줄이면서(풀링) 의미를 압축함
 - 디코더는 해상도를 되돌리면서(업샘플) 클래스 지도를 복원함
 - 인코더의 얇은 층 특징을 같은 해상도의 디코더 층에 그대로 이어 붙이는 통로가 **스킵 연결(skip connection)**임

```
# U-Net 뼈대. 주석의 값은 (해상도, 채널)
e1 = conv_block(x)                # (256×256, 64) 얇은 특징, 위치가 정확함
e3 = conv_block(pool(pool(e1)))    # (64×64, 256) 바닥, 의미는 깊고 위치는 흐림
d1 = conv_block(cat(up(e3), e1))   # (256×256, 64) cat이 스킵 연결
out = final_conv(d1)               # (256×256, K) 픽셀별 클래스 확률
```

전체 코드는 U-Net 개념 설명이며 이 장의 실습 코드가 아님. 실제 마스크는 6-0/6-0b 데이터 준비 스크립트가 시뮬레이션으로 만들어 둔 값임

- 스킵 연결이 왜 필요한지는 그것을 끊었을 때 남는 값으로 확인함. 4단계까지 풀링한 뒤 스킵 연결 없이 256×256으로 복원하면, 특징 한 화소가 담당하는 지상 영역이 8×8픽셀임. 10m 격자에서는 80m×80m이고, 이보다 작은 경계는 위치를 특정할 수 없음. 스킵 연결은 이 하한을 얇은 층의 해상도까지 끌어내림
- 인코더·디코더·스킵 연결의 배치를 그림으로 확인함

U-Net: 줄였다가 키우고, 잃어버린 위치는 옆에서 받아 온다

왼쪽 절반이 인코더(해상도를 줄이며 의미를 얻는다), 오른쪽 절반이 디코더(해상도를 키우며 경계를 복원한다)




그림 6.2 U-Net의 구조. 왼쪽 아래로 내려가는 인코더는 pool 을 지날 때마다 해상도가 절반이 되고, 오른쪽 위로 올라가는 디코더는 up 으로 해상도를 되돌림. 아래로 갈수록 상자가 납작하고 두꺼워지는 것은 공간 해상도가 줄고 채널 수가 느는 상태임. 붉은 점선 두 개가 스킵 연결이며, 같은 해상도였던 인코더 특징을 건너편 디코더에 그대로 이어 붙임

- 다른 두 구조도 후보에 오름. DeepLabV3+는 풀링 대신 간격을 벌린 합성곱(아트루스 합성곱)으로 해상도를 유지하면서 여러 크기의 대상을 동시에 봄. Swin Transformer는 영상을 작은 창(윈도우)으로 나눠 그 안에서만 어텐션을 계산해 계산량을 크게 줄이지만, 그만큼 많은 학습 자료를 요구함

구조	다중 스케일 처리	라벨 규모 요구	적합한 장면
U-Net	단일 스케일	수백~수천 장	대상 크기가 고른 장면, 정밀 경계
DeepLabV3+	병렬 팽창률(ASPP)	수천 장	소형·대형 대상이 섞인 장면
Swin Transformer	계층적 윈도우 어텐션	수만 장 이상	주변 맥락이 판정에 필요한 장면

9.2 변화 탐지 구조

- 두 시점을 어느 단계에서 비교하는지로 세 방식이 갈림

구조	비교 지점	라벨 필요	적합한 상황
차분	원시 값	없음(임계값만)	재난 직후처럼 라벨과 시간이 없을 때
Siamese 네트워크	학습된 특징	필요	과거 변화 사례가 축적된 상시 감시
다중시점	시계열 패턴의 단절	필요	계절 주기가 뚜렷한 대상의 상시 감시

- 5절의 실습은 차분 방식과 같은 구조임. 계절이 바뀐 산림과 개발로 사라진 산림을 가르는 기준이 임계값이 아니라 학습된 표현에서 나오게 하려면 Siamese 네트워크(Daudt 외, 2018)로 올라가야 하고, 그러려면 변화 라벨이 있어야 함

9.3 프롬프트 모델 — SAM

- **문제 상황.** 재난 직후 확보한 영상에서 침수 경계를 몇 시간 안에 그려야 하는데, 이번 재난을 학습한 모델도 없고 라벨을 만들 시간도 없음. 전용 구조는 픽셀 라벨을 전제하므로 이 조건에서는 후보가 되지 못함
- SAM(Kirillov 외, 2023)은 점·박스·거친 마스크 같은 프롬프트를 받아 그 대상의 경계를 오려 냄. 1,100만 장 영상에서 만든 11억 개 마스크로 학습됨
- SAM이 학습한 것은 "덩어리의 경계가 어디까지인가"이지 "이 덩어리가 무엇인가"가 아님. 지붕을 한 번 클릭하면 윤곽은 나오지만 "건물"이라는 이름표는 붙지 않음(class-agnostic)
- 이 성격 때문에 자동 운용은 두 형태로 나뉨. 하나는 별도 탐지기가 박스와 클래스를 내고 SAM이 그 박스로 경계를 오리는 분업. 다른 하나는 영상 전체에 점을 격자로 뿌려 나온 마스크를 정리하는 방식
- SAM 2(2024)는 메모리 메커니즘을 더해 첫 시점에 한 번만 프롬프트를 주면 이후 시점에서 같은 대상을 이어서 분할함. 홍수 확산처럼 범위가 시간에 따라 자라는 관측에 씬. SAM 3(2025)는 명사구 텍스트와 예시 영상까지 프롬프트로 받아 하나의 개념에 해당하는 모든 인스턴스를 한 번에 검출·분할·추적함

모델	지원 프롬프트	시계열	지리공간 운용에서 달라지는 점
SAM	점, 박스, 마스크	단일 장면	탐지기 또는 격자 프롬프트로 자동화해야 함
SAM 2	점, 박스, 마스크	시점 간 추적	첫 시점 프롬프트만으로 후속 시점을 이음
SAM 3	시각 프롬프트 + 명사구 텍스트	시점 간 추적	대상을 말로 지정해 전 인스턴스를 한 번에 뽑음

- SAM은 영상 좌표(행·열)에서 작동하므로 결과를 지도에 올리려면 좌표계를 다시 입혀야 함(samgeo , Wu & Osco, 2023). 남는 제약도 있음: 사전학습 자료가 일반 사진이라 대상의 픽셀 수가 그 분포에서 크게 벗어나면 경계를 못 잡고, SAR의 스펙클도 그대로 인식되지 않음

주의. 모델이 통하는지는 센서 종류가 아니라 대상의 픽셀 크기가 정함. 같은 SAM이 0.5m 항공영상의 주택(24픽셀)은 오려 내고 10m 위성영상의 주택(1.2픽셀)은 잡지 못함. 모델을 고르기 전에 8.1의 계산으로 대상이 몇 픽셀인지 먼저 구함.

9.4 EO 파운데이션 모델

- 대규모 위성 관측으로 사전학습한 뒤 여러 하위 과제에 적응시켜 쓰는 모델임. 후보가 계속 늘어나므로 이름을 외우기보다 몇 가지 축으로 비교함: 공개성(가중치를 내려받을 수 있는가), 입력 모달리티, 시계열 지원, 사전학습 해상도

모델	입력 모달리티	사전학습 해상도	공개된 적용 사례
Prithvi-EO-2.0	광학(HLS)	30m	홍수 매핑, 산불 흔적 매핑
AlphaEarth Foundations	광학·SAR·고도·기후 통합	10m	유사 지역 검색, 임베딩 위의 경량 분류기
TerraMind	다중 모달리티	—	모달리티 간 변환(광학↔SAR)

- AlphaEarth(Google DeepMind, 2025)는 산출물의 형태가 다름. 마스크가 아니라 지점 하나를 숫자 64개로 요약한 **임베딩(embedding)**을 냄. 한 해 동안의 광학·SAR·고도·기후 관측이 10m 픽셀마다 64차원 벡터로 압축되고, 성격이 비슷한 땅은 비슷한 벡터를 가짐. 이 벡터를 입력 피처로 써서 소량 라벨로 경량 분류기를 학습시키는 운용이 가능함
- 해상도 배율(사전학습 해상도 ÷ 과제 해상도)이 판정 기준이 됨. HLS 30m로 학습한 모델을 0.5m 항공영상에 쓰면 배율이 60배이고, 모델이 익힌 "이 정도 범위에서 이런 질감이면 산림"이라는 관계가 성립하지 않음. 배율이 한 자릿수 안이면 미세조정으로 흡수할 여지가 있고, 두 자릿수를 넘으면 그 모델을 기준선에서 제외함

9.5 조건을 순서대로 걸러 고른다

- 네 계열과 여러 축을 동시에 비교하지 않음. 조건을 순서대로 걸어 후보를 줄이고, 앞 조건에서 탈락한 모델의 성능은 보지 않음

- [조건 1] 가중치를 자체 서버에서 돌려야 하는가? → 예면 공개 가중치 모델만 남김
- [조건 2] SAR·다중스펙트럼·고도가 입력에 필요한가? → 필요하면 해당 모달리티를 받는 모델만 남김
- [조건 3] 해상도 배율이 10배를 넘는가? → 넘으면 그 모델을 기준선에서 뺌
- [조건 4] 픽셀 라벨이 수백 장 이상 있는가? → 있으면 전용 구조, 없으면 프롬프트 모델 zero-shot
- [조건 5] 두 시점 이상을 함께 봐야 하는가? → 예면 변화 탐지 구조나 다중시간 모델
- [조건 6] 계산·배포 예산 → 10절의 적응 깊이로 넘김

그림 6.3 모델 선택의 조건 순서. 앞의 조건에서 탈락한 모델의 성능은 확인하지 않음

- 세 상황에서 지배하는 조건이 다름. 예산이 제한된 지자체는 조건 1과 6이 지배해 임베딩 위에 경량 분류기만 있는 경로가 남음. 산림 벌채 상시 감시는 조건 5가 지배해 다중시간 입력이 우선함. 장마철 침수 대응은 조건 2가 지배해 SAR를 못 받는 모델은 벤치마크 점수와 무관하게 탈락함

- 조건 4가 파운데이션 모델과 전용 모델의 갈림길임. 클래스가 정해져 있고 라벨이 있으면 그 클래스만 학습한 U-Net이 범용 모델보다 정확하고 가볍고 운영비가 낮음. 범용성은 정밀도와 계산량의 대가를 치른 결과임

10. 학습을 어떻게 시킬 것인가

- 모델을 고른 뒤에는 무엇을 최소화할지(손실), 라벨을 어떻게 확보할지, 사전학습 가중치를 어느 깊이까지 갱신할지를 정함. 세 결정은 묶여 있음. 라벨이 적으면 적응 깊이가 얕아지고, 적응 깊이가 얕으면 손실 설계로 조정할 수 있는 폭도 좁아짐

10.1 클래스 불균형과 손실

- **문제 상황.** 변화 픽셀이 전체의 1% 안팎인 자료에서, 모든 픽셀에 같은 확률 p 를 내놓는 상수 예측기를 생각함. 손실을 최소로 만드는 p 는 계산해 보면 정확히 클래스 비율인 0.01임
- 그런데 판정 임계를 0.5로 두면 $p=0.01$ 짜리 예측은 전 픽셀이 배경으로 잘림. 이 예측기의 정확도는 99%이지만 재현율은 0임. 손실이 제 역할을 했는데도 쓸 수 없는 마스크가 나옴
- **Focal Loss**(Lin 외, 2017)는 이미 잘 맞는 픽셀의 손실 기여를 감쇠시킴. 이미 잘 맞는 배경 픽셀 ($p=0.99$)의 감쇠 계수는 0.0001이고, 판정이 갈리는 픽셀($p=0.5$)의 감쇠 계수는 0.25임. 두 계수의 비가 2,500배이므로 학습 신호의 대부분이 판정이 갈리는 픽셀로 옮겨 감
- **Dice 손실**(Milletari 외, 2016)은 픽셀 하나하나가 아니라 마스크 전체의 겹침을 직접 최적화함. 앞의 상수 예측기가 전 픽셀을 배경으로 내면 교집합이 0이므로 손실이 최댓값이 됨. 교차 엔트로피가 만족했던 예측을 Dice는 최악으로 판정함
- 두 손실을 함께 쓰는 조합이 표준적임. 교차 엔트로피 계열은 픽셀별 확률을 안정적으로 학습시키고 Dice는 겹침이라는 최종 지표 쪽으로 마스크를 끌어당김

손실	클래스 불균형에서의 거동
교차 엔트로피	상수 예측의 최적값이 클래스 비율로 수렴함
Focal Loss	쉬운 픽셀의 기여를 감쇠시킴(γ 로 세기 조절, 보통 2)
Dice 손실	빈 마스크를 최악으로 판정함
Focal + Dice 조합	확률과 겹침을 함께 최적화함

10.2 라벨을 확보하는 네 전략

전략	줄이는 비용	남는 위험
관심 클래스 오버샘플링	필요한 장면 수	학습 분포가 실제와 달라짐
경계 집중 라벨링	인건비 대비 오차 감소량	경계 외 영역 품질 저하
프롬프트 모델 초벌 + 수정	폴리곤 작도 시간	초벌의 체계적 오차가 남음
약지도 라벨	픽셀 라벨 제작 자체	추정 오차가 학습에 섞임

- 네 전략 모두 학습 라벨의 비용을 다름. 검증용 정답은 사람이 직접 만든 표본으로 따로 남김. 초벌 마스크로 학습하고 같은 방식으로 채점하면 초벌의 체계적 오차가 학습과 채점 양쪽에 들어가 성능이 실제보다 높게 나옴

10.3 어디까지 다시 학습시킬 것인가 — LoRA

- 문제 상황.** 6억 파라미터 모델을 지역 자료로 적응시켜야 하는데 GPU 메모리가 11GB이고 과제가 셋 (건물 추출·녹지 변화·침수 매핑)임. 전체를 다시 학습시키면 과제마다 갱신된 가중치 사본이 하나씩 생겨 저장·배포 비용이 커짐
- LoRA**(Low-Rank Adaptation, Hu 외, 2021)는 원본 가중치 W_0 를 고정하고, 갱신량을 작은 행렬 두 개의 곱($B \times A$)으로만 표현함
- 1,024×1,024 크기 층에서 원본 파라미터는 1,048,576개임. 랭크 $r=8$ 로 두면 학습 대상은 16,384개로 원본의 1.56%뿐임. 과제 하나가 남기는 사본은 약 19MB이고 과제 세 개를 합쳐도 60MB 안임. 배포할 때는 공통 W_0 하나에 과제별 작은 파일만 바꿔 끼움
- B 는 0으로 초기화하므로 학습 시작 시점의 출력은 원본과 정확히 같고, 적응은 사전학습 상태에서 출발함

방식	필요한 라벨	저장·배포 비용	판단 기준
Zero-shot	없음	없음	마감이 시간 단위인 과제
LoRA	수백~수천 장	과제당 수십 MB	과제가 여럿이고 사본 수를 줄여야 할 때
전체 파인튜닝	수천 장 이상	과제당 수 GB	자료 갱신이 잦고 라벨·자원이 충분할 때

- 대부분의 공공기관 과제는 zero-shot으로 가능성을 확인한 뒤 라벨이 모이면 LoRA로 올라가는 경로를 따름. 과제마다 라벨·학습·검증·운영을 처음부터 반복하는 방식은 감당할 수 있는 기관이 제한되기 때문임

주의. 사전학습 누수는 벤치마크 점수를 올리고 현장 성능은 올리지 않음. 평가 지역이 모델의 사전학습 자료에 이미 포함되어 있으면 점수가 현장 성능을 과대평가하는데, 오류 메시지가 뜨지 않으므로 그대로 지나감. 사전학습에 없는 지역·시점으로 별도 검증 세트를 만들.

11. 마스크를 채점하기

- 검증은 두 층위로 나눔: 픽셀 단위 채점(마스크가 정답과 얼마나 겹치는가)과 객체 단위 채점(개체를 몇 개 찾았고 각 개체의 면적을 얼마나 정확히 켜는가)
- 어느 층위를 쓸지는 7.2에서 정한 산출 단위가 정함. 구역 면적 집계가 최종 산출물이면 픽셀 단위로 충분하고, 개체 목록이 판단 단위이면 픽셀 지표만으로는 부족함

11.1 픽셀 단위 지표

```
def iou_prf(pred, true):
    inter = np.logical_and(pred, true).sum() # 겹친 픽셀 수
    union = np.logical_or(pred, true).sum() # 둘을 합친 픽셀 수
    iou = inter / union
    prec = inter / pred.sum() # 판정한 것 중 진짜
    rec = inter / true.sum() # 진짜 중 잡아낸 것
    dice = 2 * inter / (pred.sum() + true.sum())
    return iou, prec, rec, dice
```

전체 코드는 [lecture_practice/chapter6/code/6-1-change-detection-policy.py](#) 참고

- 계산 예: 정답과 예측이 각각 100픽셀이고 50픽셀이 겹치면 교집합 50, 합집합 150이므로 **IoU = 50/150 = 0.333**, **Dice = 2×50/200 = 0.5**
- 정답의 절반을 맞췄는데 IoU가 0.5가 아니라 0.33인 이유는 분모(합집합)가 두 마스크의 어긋난 부분을 모두 더하기 때문임. IoU 0.5는 절반을 맞힌 결과가 아니라 상당히 겹친 결과임
- 정밀도와 재현율은 오류의 방향을 가름. 재난 피해 평가에서는 놓친 피해가 구호로 이어지지 않으므로 재현율이 우선하고, 판정이 제재로 이어지는 단속 행정에서는 잘못 잡은 변화가 행정력 낭비를 만들므로 정밀도가 우선함. 판정 임계값이 두 값의 균형을 움직이는 손잡이임

주의. 총량이 맞는 것과 개체별로 맞는 것은 다름. 14절에서 확인하겠지만 예측 마스크의 총 면적이 정답의 1.170배인데 개별 필지의 면적은 중앙값 12.5% 작게 나오는 일이 실제로 일어남. 오탐이 총량을 부풀리고 침식이 개별 개체를 깎으면 두 오차가 상쇄되어 총량 비교로는 아무것도 드러나지 않음.

11.2 객체 단위 채점

- 개체 단위 채점의 첫 작업은 예측 객체와 정답 객체를 대응시키는 **매칭 규칙**을 정하는 것임. 어떤 예측 객체가 정답 객체 면적의 절반 이상을 덮으면 그 둘을 대응으로 봄
- 매칭이 끝나면 네 가지를 셈

지표	낮거나 클 때의 뜻
검출률	낮으면 개체 자체를 놓쳤다는 뜻
오탐 객체 수	크면 목록에 없는 대상이 섞임
과분할·병합	크면 개체 수와 규모가 함께 틀림
면적 상대오차	부호가 한쪽으로 쏠리면 체계적 편향

- 한 정답 객체와 겹치는 예측이 둘 이상이고 어느 것도 정답 면적의 절반을 못 넘기면 **과분할**임. 반대로 예측 하나가 서로 다른 정답 둘 이상을 각각 절반 넘게 덮으면 **병합**임
- 면적 상대오차는 중앙값과 사분위수를 함께 봄. 평균만 보면 큰 오탐 하나가 값을 끌고 감. 부호의 쏠림이 무작위 오차와 체계적 편향을 가르는 기준임: 무작위라면 표본을 늘리면 사라지지만, 경계 침식처럼 항상 면적을 깎는 오차는 평균해도 남음
- 편향의 크기가 왜 개체 크기에 달려 있는지도 계산으로 확인됨. 경계 한 겹의 침식이 지우는 픽셀 수는 대략 둘레만큼이므로, 정사각형 대상의 상대 손실은 4/한 변의 길이임. 같은 침식 깊이라도 작은 객체가 상대적으로 더 많이 깎임

11.3 필터가 올리는 것과 못 올리는 것

- 8.4의 마스킹 규칙과 최소 면적 필터는 예측 안의 가짜를 깎는 장치이므로 **정밀도만 올리고 재현율은 올리지 못함**. 모델이 애초에 놓친 픽셀은 예측 안에 존재하지 않으므로 예측을 깎는 어떤 연산으로도 되살릴 수 없음. 5절의 실습에서 필터가 정밀도만 올리고 재현율은 그대로였던 이유가 이것임
- 재현율을 올리려면 판정 임계를 낮추거나 학습 설정을 바꿔야 함

11.4 원인을 분리하는 대조군

- 성능표 한 줄로는 잔여 오차가 어디서 왔는지 알 수 없음. 마스크에는 경계 침식, 오탐, 과분할이 동시에 들어 있기 때문임
- 원인을 분리하려면 주장하려는 메커니즘 하나만 제거한 조건을 만들어 같은 파이프라인을 다시 돌림

조건	제거하는 오차	확인하는 주장
본 실험	없음	기준
C1	경계 침식	면적 편향이 침식에서 왔는가
C2	오탐	목록에 섞인 헛후보가 오탐에서 왔는가
C3	과분할	개체 수·규모 오차가 과분할에서 왔는가

- 대조군 없이 "침식 때문에 후보를 놓쳤다"고 쓰면 그것은 해석이지 측정이 아님. C1에서 오탐률이 0이 되어야 그 주장이 성립함. 14절이 이 세 대조군의 실측을 담고 있음

11.5 검증에서 흔히 생기는 함정

- **사전학습 누수** — 파운데이션 모델이 평가 지역을 이미 학습했을 수 있음. 확인할 수 없으면 그 사실 자체를 성능표에 적음
- **벤치마크와 현장의 괴리** — 공개 벤치마크의 센서·해상도·계절이 과제 자료와 다르면 점수가 그대로 옮겨 가지 않음
- **검증 자료의 공간 분리** — 학습 패치와 검증 패치가 같은 장면에서 인접해 잘리면 두 자료가 사실상 겹침. 장면 단위나 지역 단위로 분리해야 함
- 세 가지 모두 오류 메시지 없이 지나가며, 확인 여부를 기록으로 남기는 것 외에 자동으로 걸러지는 장치가 없음

12. 마스크를 객체로 바꾸기

- 채점을 통과한 마스크는 아직 픽셀의 집합임. 산출 단위를 객체로 정한 과제에서는 이 집합을 개체 목록으로 바꾸고 개체마다 면적·형상·접도를 재야 결정에 씀

12.1 연결요소 라벨링

- 서로 맞닿은 픽셀을 하나의 덩어리로 묶고 번호를 매기는 계산이 **연결요소**임
- 무엇을 "맞닿았다"고 볼지 두 정의가 있음. 4-이웃은 상하좌우만 이웃으로 세고, 8-이웃은 대각선도 이웃으로 셈. 모서리 하나로만 이어진 두 덩어리는 8-이웃에서 한 개체, 4-이웃에서 두 개체가 됨
- 가늘고 긴 대상이 계단 모양으로 이어지는 도로·하천에서는 8-이웃이 끊김을 줄이고, 개체가 조밀한 도심 건물에서는 4-이웃이 병합을 줄임

12.2 최소 크기 필터

- 라벨링 결과에는 잡음이 만든 작은 덩어리가 다수 섞임. 이를 미리 빼지 않으면 이후 통계가 얼룩의 개수에 지배됨
- 14절의 실습에서 연결요소가 949개 나왔는데 그중 909개가 50m² 미만 얼룩이었음. 개체 수의 96%가 후처리로 걸러지는 잡음이라는 뜻이며, 연결요소의 개수 자체가 대상의 개수를 뜻하지 않음

12.3 기하 피쳐 다섯 가지

피쳐	계산	결정에서의 쓰임
면적 A	픽셀 수 × 픽셀 면적	최소 면적 요건 판정
둘레 P	크랙 둘레(픽셀 사이 경계선 길이)	조밀도 계산, 면적 편향 보정
조밀도	$4\pi A/P^2$ (원=1, 정사각형 ≈ 0.785)	형상 선별의 참고 지표
최소폭	개체에 들어가는 최대 내접원의 지름	최소폭 요건 판정
접도 길이	도로에서 허용오차 안에 있는 경계 픽셀 수	접도 요건 판정

- 계산 예: 40m×25m 직사각형 필지에서 면적 1,000m², 크랙 둘레는 $2\times(40+25)=130\text{m}$, 조밀도는 $4\pi\times 1,000/130^2\approx 0.743$, 최소폭은 짧은 변인 25m
- 면적이 같은 100m×10m 필지는 둘레 220m, 조밀도 0.260, 최소폭 10m. **두 필지는 면적이 같지만 최소폭 15m 요건에서 뒤쪽만 탈락함.** 면적 하나로는 가늘고 긴 자투리땅을 걸러 낼 수 없음

12.4 허용오차는 침식 깊이보다 크게

- 도로에 직접 맞닿은 경계만 접면으로 세면 계산은 정확해 보이지만 결과가 뒤집힘. 경계 침식이 개체 가장자리를 한 겹 깎으면, 도로에 붙어 있던 진짜 개체가 도로에서 물러난 것으로 보임. 침식되지 않은 오탁 덩어리는 원래 자리에 그대로 있어 도로에 붙은 채 남음
- 그래서 도로에서 일정 거리 안을 접면으로 인정하는 허용오차를 두고, 그 크기를 마스크의 침식 깊이보다 크게 잡음. 이것은 임계를 느슨하게 하는 타협이 아니라 오차 구조에 맞춰 판정 규칙을 정의하는 절차임

주의. 14절의 실습에서 허용오차를 0으로 두면 40개 중 37개가 접면 부족으로 탈락하고, 남은 3개 중 진짜 필지는 없음. 침식된 진짜 부지가 도로에서 떨어진 것으로 보이는 사이, 침식되지 않은 오탁만 도로에 붙어 살아남기 때문. 실습에서 쓴 허용오차는 3m임.

12.5 벡터화

- 개체 목록을 GIS에서 쓰려면 래스터 마스크를 폴리곤으로 바꿈. 픽셀 경계를 그대로 따라가면 폴리곤이 계단 모양이 되고 꼭짓점 수가 둘레 픽셀 수만큼 생김
- 경계를 단순화해 꼭짓점을 줄이되, 단순화 허용오차는 픽셀 크기 안에서 정함. 이보다 크게 잡으면 면적이 바뀌어 11.2에서 켄 면적 편향과 섞임

13. 구역별로 모아 결정으로 바꾸기

- 마지막 단계는 객체 목록이나 마스크를 결정 문서로 바꾸는 일임. 결정의 형태는 두 가지임: 위에서부터 자원을 배분하는 **정렬형**, 요건을 만족하는 것만 남기는 **절단형**

13.1 집행 단위 집계

- 픽셀 마스크는 그 자체로 행정·사업의 결정 단위가 아님. "어느 픽셀 몇 개가 변했다"로는 담당 부서도 예산 항목도 정해지지 않음
- 세 가지를 순서대로 정함: 단위 경계(행정구역·보호구역·필지 등), 마스크와 경계를 포갠 단위별 픽셀 수, 픽셀 수를 면적으로 환산
- 단위 경계를 어떻게 잡느냐가 순위를 바꿈. 같은 마스크라도 격자로 나눌 때와 실제 행정경계로 나눌 때 상위 구역이 달라질 수 있음

13.2 정렬형과 절단형은 오차에 다르게 반응함

- 정렬형에서 면적 오차는 순위를 흔듦. 3순위 구역이 5순위로 내려가도 그 구역은 표에 남아 있고 다음 회차에 다시 검토됨
- 절단형에서는 임계 근처의 대상이 목록에서 아예 사라짐. 사라진 대상은 다시 확인되지 않으며, 오탐락이 발생했다는 사실 자체가 산출물에 남지 않음
- 이 차이 때문에 절단형 결정에는 두 계산이 추가로 필요함: 체계적 편향을 되돌리는 보정, 임계 자체를 비용으로 계산하는 절차

13.3 체계적 편향의 보정

- 면적 상대오차의 부호가 쏠린 것을 확인했다면 소수의 대상을 실측해 그 크기를 되돌림. 두 형태를 씀
- **스칼라 보정**: 표본에서 참 면적을 추정 면적으로 나눈 값의 평균 k 를 모든 대상의 추정 면적에 곱함
- **둘레 모형**: 침식이 없애는 픽셀 수가 둘레에 비례한다는 성질을 써서 보정 면적을 $A + \hat{c}P$ 로 두고 $\hat{c}$ 를 표본에서 추정함. 한 겹 침식이면 이론값 $\hat{c} \approx 1$ 임
- 두 보정 모두 전역 계수 하나를 쓰므로 대상마다 다른 침식 깊이를 완전히 되돌리지 못함

주의. 보정 계수는 표본을 어느 모집단에서 뽑았는지에 달려 있음. 14절의 실습에서 같은 방식으로 계산해도 실사 검토 풀 표본은 1.128, 검출된 필지 전수는 1.217, 검출된 모든 객체는 1.453이 나옴. 표본을 늘려도 고쳐지지 않으므로 표본의 추출 모집단을 보고서에 적음.

13.4 절단선을 비용으로 계산한다

- 요건값을 임계로 그대로 쓸 이유는 없음. 후보 하나를 현장 확인하는 비용을 C_v , 요건을 만족하는 대상 하나를 놓치는 비용을 C_m 이라 하면 총비용은

$$T(\tau)/C_v = N(\tau) + (C_m/C_v) \times M(\tau)$$

- $N(\tau)$ 는 임계 τ 에서 남는 후보 수, $M(\tau)$ 는 오탈락 수임. 최적 τ 는 두 비용의 절대값이 아니라 **비 C_m/C_v 에만 의존함**. "놓친 대상 하나가 실사 몇 건 값인가"만 답할 수 있으면 임계를 계산할 수 있다는 뜻
- 요건이 여러 개면 후보는 갈때기를 차례로 통과함. 한 요건을 느슨하게 했을 때 늘어나는 후보 수는 그 요건이 단독으로 자르는 양이 아니라 다른 요건을 통과한 것 중에서 자르는 양임. 갈때기의 어느 칸이 실제로 좁은지 먼저 확인함

13.5 우선순위표와 후보표

결정 형태	표 이름	읽는 순서
정렬형	우선순위표	위에서부터 어디까지 자원을 배분할지 읽음
절단형	후보표	탈락 사유 열을 먼저 읽어 어느 요건이 많이 자르는지 확인함

- 두 표 모두 탈락하거나 순위에서 밀린 대상의 목록을 별도 파일로 남김. 이 목록이 없으면 오탈락을 사후에 셀 수 없음

14. 두 사례로 절차 전체를 확인하기

- 앞의 일곱 단계는 절차로 서술했지만 실제 과제에서는 산출 단위와 결정의 형태에 따라 일부 단계가 달라짐. 실습에 실행 로그가 있는 두 사례로 확인함

14.1 보호구역 변화 점검 — 정렬형

- 5절에서 이미 본 사례임. 광역지자체가 관내 보호구역의 무단 훼손을 점검하는 상황을 시뮬레이션함. 산출 단위가 구역(집행 단위)이고 결정이 정렬형이므로 개체 단위 채점(11.2)은 필요 없음

- 자료: 128×128 래스터, 픽셀 10m(0.01ha), 정답 변화 픽셀 2,001개
- 심어 둔 오차: 계절 잡음, 진짜 변화 경계의 침식, 산발 얼룩 오탐 2%. 결과로 나온 예측 변화는 3,022픽셀로 정답보다 51% 많음
- 필터 전후 지표는 5절의 표와 같음(IoU 0.525→0.865, 정밀도 0.572→1.000, 재현율 0.865에서 고정)
- 필터를 거치지 않은 변화량을 그대로 쓰면 예측 변화의 42.8%가 오탐(1-0.572)이므로, 잡음이 많이 낀 구역이 실제 개발 구역을 제치고 상위에 오를 수 있음. **마스킹 규칙이 정렬형 결정의 신뢰성을 좌우하는 지점임**

14.2 개발 가능 부지 탐색 — 절단형

- 도시 안의 유휴 부지를 찾아 현장 실사 대상을 좁히는 상황을 시뮬레이션함. 산출 단위가 개체(필지)이고 결정이 절단형이므로 12절의 객체화와 11.2의 객체 단위 채점이 모두 필요함
- 자료: 512×512 래스터, 픽셀 1m(1m²), 총 26.2헥타르. 도로 50,005m², 기존 건물 40동 26,877m², 정답인 유휴 부지 32필지 47,294m²(그중 맹지 5필지). 필지 면적은 최소 432m², 중앙값 1,155m², 최대 3,685m²
- 개발 요건(예시로 설정한 사업 요건이며 법정 기준이 아님): 면적 1,000m² 이상, 도로 접면 12m 이상, 최소폭 15m 이상. 이 요건을 모두 채우는 우량 부지는 10필지
- 심어 둔 오차: 32필지 중 8필지는 두 겹 침식, 3필지는 폭 2m 띠로 갈라 과분할, 산발 얼룩과 큰 오탐 덩어리 5개. 예측 마스크 총 면적은 55,313m²로 정답의 1.170배

객체화와 채점

- 연결요소 949개 중 909개가 50m² 미만 얼룩 → 분석 대상 40개
- 필지 검출률 30/32(0.938), 오탐 객체 5개, 과분할 3필지·병합 0객체
- 면적 상대오차 중앙값 -0.125(1사분위 -0.177, 3사분위 -0.112). 부호가 전부 음수라는 점이 이 채점의 결론임. 침식은 항상 면적을 깎으므로 평균해도 남음
- 크기별로도 다름: 큰 절반 -0.112, 작은 절반 -0.136. 작은 필지에서 상대 손실이 큰 것은 12.3의 둘레÷면적 관계와 일치함
- 과분할된 세 필지는 참 면적 2,394~2,511m²인데 가장 큰 조각만 보면 1,026~1,216m²로, 참 면적 대비 0.41~0.51로 규모가 절반 안팎으로 보고됨. 조각 하나만 보고하면 필지 크기를 완전히 잘못 세게 됨

접도 허용오차

- 허용오차 3m로 접도 판정을 하면 40개 중 20개는 면적 미달, 9개는 접도 미달로 걸러짐(12.4의 주의 항목대로 허용오차 0이면 40개 중 37개가 탈락하고 남은 3개 중 진짜는 0개)

필터 깔때기와 오탐락

단계	잔존
얼룩 제외 객체	40
면적 $\geq 1,000\text{m}^2$	20
접도 $\geq 12\text{m}$	9
최소폭 $\geq 15\text{m}$	8

- 최종 후보 8건 중 우량 부지는 5필지뿐. 우량 부지 10필지 중 5필지(필지 19·20·21·22·23)가 목록에 오르지 못했고, 이들은 모두 침식으로 추정 면적이 임계 아래로 내려간 임계 근처 필지군임

면적 편향 보정

- 실사 검토 풀 16건 중 무작위 12건을 실측하고 2건은 부지가 아닌 것으로 판명되어 10건으로 계수를 추정함
- 스칼라 보정 $k = 1.128$, 둘레 모형 $\hat{c} = 0.916$

보정	후보 수	우량 부지 포착	우량 부지 오탈락	헛후보
보정 없음	8	5	5	3
스칼라 보정	11	8	2	3
둘레 모형 보정	11	8	2	3

- 보정이 오탈락을 5건에서 2건으로 줄임. 되돌린 3건은 한 겹 침식으로 임계 바로 아래에 있던 필지이고, 남은 2건은 두 겹 침식이 걸린 필지임. **전역 계수 하나로는 필지마다 다른 침식 깊이를 되돌리지 못함.** 헛후보 3건은 세 조건 모두 동일함. 면적을 보정해도 유희지가 아닌 대상이 유희지가 되지는 않음

대조군

조건	검출 필지	면적오차 중앙값	후보 수	우량 오탈락	헛후보
본 실험(오차 3종)	30	-0.125	8	5	3
C1 침식 제거	30	+0.005	13	0	3
C2 오탈 제거	30	-0.132	5	5	0
C3 과분할 제거	32	-0.121	8	5	3

- C1에서 면적오차가 사실상 사라지고 오탈락이 0이 됨 — 우량 부지를 놓친 원인이 경계 침식이라는 주장이 이 조건에서 성립함. C2에서 헛후보가 0이 됨 — 목록에 섞인 3건은 전부 오탈 덩어리였음. C3에서는 검출 필지가 회복되지만 후보 수·오탈락·헛후보는 바뀌지 않음 — 과분할된 조각 하나가 이미 임계를 넘어 후보 자리를 지켰기 때문임

절단선의 계산


임계 τ	후보 수	오탈락	비고
725m ²	14	0	농침이 실사 3배·10배 비용일 때 최적
875m ²	11	2	면적 편향(-0.125)만큼 낮춘 값
1,000m ²	8	5	요건값 그대로
1,450m ²	7	5	농침 1건 = 실사 1건 비용일 때 최적

- 농침 부지 1건이 실사 1건과 같은 값이면 최적 임계는 요건값보다 높은 1,450m²임. 어차피 농침 대상이라면 방문 횟수를 줄이는 쪽이 총비용을 낮추기 때문. 농침이 실사보다 세 배 비싸면 최적 임계는 725m²로 내려가고 오탈락이 0이 됨. 접도·최소폭이 이미 대부분을 걸러 낸 뒤라 면적 임계를 크게 낮춰도 후보가 폭증하지 않음(8건→14건)

실사 예산 6건일 때 방문 순서

- 면적 큰 순: 적중 4/6건, 확보한 참 면적 10,166m²
- 여유폭 큰 순(세 요건 중 가장 빠듯한 값이 큰 순): 적중 4/6건, 10,166m²
- 정답을 아는 순(참고): 적중 6/6건, 11,413m²
- 두 순서의 성적이 같은 이유는 헛걸음 2건이 모두 오탈 덩어리였고 요건 미달 부지는 0건이었기 때문임. 오탈 덩어리는 크고 넓고 도로에 붙어 있어 **기하 피쳐만으로는 우량 부지와 구별되지 않음**. 오탈을 줄이려면 유휴지와 포장 주차장을 가르는 정보(다중스펙트럼 반사 특성, 시계열 변화)를 모델 입력에 넣어야 하며 후처리로는 해결되지 않음
- 정답과 최종 결과를 지도에서 나란히 확인함

정답: 유휴 부지 32필지 (진한 색 = 요건 충족 10필지)



예측: 최종 후보 11건(파랑), 농침 우량 부지 2건(빨강)




그림 6.4 개발 가능 부지 탐색의 정답과 결과. 왼쪽은 정답으로, 회색이 도로와 기존 건물, 옅은 색이 유휴 부지 32필지, 진한 색이 세 요건을 모두 채우는 우량 부지 10필지임. 오른쪽은 예측 마스크에서 뽑은 최종 후보(파랑)와 우량 부지인데 목록에 오르지 못한 필지(빨강)임. 파란 후보 가운데 왼쪽에 대응하는 유휴 부지가 없는 것이 유휴지로 오인된 오탐 덩어리임

이 사례가 뒷받침하는 것과 뒷받침하지 못하는 것

- 뒷받침하는 것: 면적 임계를 쓰는 후보 선별에서 세그멘테이션의 체계적 면적 편향이 임계 근처 객체를 통째로 탈락시킨다는 것, 소수 실측 표본에 의한 보정이 그 탈락의 일부를 되돌리지만 침식 깊이가 다른 대상은 되돌리지 못한다는 것, 기하 조건의 허용오차가 마스크의 위치 오차보다 작으면 필터가 뒤집힌다는 것
- 뒷받침하지 못하는 것: 실제 도시에서의 검출률과 면적 오차의 크기. 여기 심은 침식 폭·오탐률·과분할 빈도는 설계값이므로 12.5%라는 편향 크기를 다른 자료에 그대로 옮길 수 없음. 옮길 수 있는 것은 절차 자체임 — 편향의 방향과 크기를 소수 실측으로 재고 그 크기만큼 임계를 조정하는 절차
- 이 사례가 판정하는 것은 부지의 물리적 가용성뿐임. 용도지역, 건폐율·용적률, 소유관계, 토양오염 이력 같은 법적·행정적 제약은 다루지 않음. 이 목록은 실사 대상을 좁히는 1차 필터이지 개발 가능 판정이 아님

14.3 긴급 재난 침수 매핑 — 실습 없는 서술 사례

- 대규모 홍수 직후 침수 범위 지도를 몇 시간 안에 만들어야 하는 상황임. 이 장의 실습에는 해당 코드가 없으므로 수치는 제시하지 않고 절차의 어느 단계가 달라지는지만 정리함
- 라벨 예산이 0이고 마감이 시간 단위이므로, 전용 구조는 후보에서 빠지고 프롬프트 모델 zero-shot이 기준선이 됨(9.5의 조건 4)
- 정답 마스크가 없어 채점을 즉시 할 수 없음. 검증은 사후 관측이나 현장 대조로 미루고, 산출물에는 "검증되지 않았다"는 사실을 표기해 넘김
- 결정도 즉시 집행되는 판단(대피·구호 배분)이 받으므로 13.4의 절단선 계산을 그대로 적용하지 못함. 대신 프롬프트가 직접 지정한 영역, 자동 확장으로 얻은 영역, 검증되지 않은 영역을 구분해 표기하고 확인 여부를 열로 남김
- 대응이 끝난 뒤 사람이 검수한 마스크를 학습 라벨로 재활용하면 10.2의 프롬프트 모델 초벌 전략이 되어, 다음 재난에서는 조건 4가 다른 답을 냄. **재난 대응 한 번이 라벨 예산을 만드는 경로가 됨**

15. 새 과제를 시작할 때 채우는 점검표

- 채우지 못한 행이 있으면 그 단계의 결정 근거가 아직 없다는 뜻으로 읽음

단계	항목	확인할 내용
1	산출 단위	픽셀, 개체, 구역 가운데 어디에서 끝나는가
1	라벨 예산	학습 라벨과 검증 라벨을 각각 몇 장, 어떤 방식으로 만드는가
2	픽셀 대비 대상 크기	대상의 픽셀 폭과 그때의 면적 오차 하한은 얼마인가
2	시점 정합	두 시점의 정합 상태를 무엇으로 확인했는가
3	배제 순서	반출·모달리티·해상도 배율·라벨·시계열 조건에서 무엇이 탈락했는가
4	적응 깊이	zero-shot·프롬프트·LoRA·전체 가운데 무엇을 왜 골랐는가
5	픽셀·객체 지표	IoU·정밀도·재현율·검출률·과분할과 판정 임계값
5	대조군	주장하는 메커니즘만 제거한 비교 조건이 있는가
6	허용오차	기하 조건의 허용오차가 마스크의 위치 오차보다 큰가
7	편향 보정	계수를 어떤 표본에서 추정했고 그 표본의 모집단은 무엇인가
7	절단선	요건값과 비용비 기반 임계 가운데 무엇을 썼는가
7	탈락 목록	목록에서 빠진 대상을 어디에 남겼는가

- 정렬형 과제에서는 마스킹 규칙과 집계 단위가 결과를 지배하고, 절단형 과제에서는 객체 단위 채점·허용오차·편향 보정·절단선 계산이 결과를 지배함. 시뮬레이션으로 얻은 값을 실제 지역의 경험값으로 옮겨 쓰지 않음

체크 질문

1. 시맨틱·인스턴스·파노믹 세그멘테이션은 한 입력에 대해 각각 어떤 답을 내는가?
2. 폭 12m 주택이 10m 격자에서 1.2픽셀이라는 계산이 뜻하는 바는 무엇인가?
3. 클래스 불균형이 있는 자료에서 교차 엔트로피만 쓰면 왜 위험한가?
4. 필터를 걸었을 때 정밀도는 오르는데 재현율은 그대로인 이유는 무엇인가?
5. 매칭 규칙에서 "정답 면적의 절반 이상"이라는 기준을 쓰는 이유는 무엇인가?
6. 크랙 둘레와 조밀도는 각각 무엇을 재며, 두 필지의 면적이 같아도 형상 요건에서 갈리는 예는 무엇인가?
7. 접도 판정의 허용오차를 0으로 두면 왜 결과가 뒤집히는가?
8. 스칼라 보정과 둘레 모형 보정은 각각 어떤 계산을 하며, 둘 다 되돌리지 못하는 대상은 무엇인가?
9. 절단선을 요건값이 아니라 Cm/Cv 로 계산한다는 것은 무엇을 뜻하는가?
10. 실습에서 방문 순서를 면적 큰 순으로 해도 여유폭 큰 순으로 해도 성적이 같았던 이유는 무엇인가?
11. 정렬형 결정과 절단형 결정에서 같은 크기의 마스크 오차가 왜 다르게 작용하는가?

과제

```
python scripts/submit.py 6 --id 학번 --name 이름
```

- 실행하면 `submissions/` 폴더에 `제출_6장_학번.md` 가 생성되고 `6-2-site-sourcing.py` 의 실행 결과가 붙어 있음
 - **눈여겨볼 곳은 면적 임계별 후보 수와 오탈락 수**
 - 빈칸 세 개를 채움
1. 개발 요건은 면적 1,000m² 이상이다. 임계를 그대로 1,000m²에 두겠는가, 낮추겠는가? 그 판단을 정하는 것은 무엇인가?
 2. 보정 전후 표에서 오탈락이 5건에서 2건으로 줄었지만 0건이 되지는 않았다. 남은 2건에 공통으로 있는 것은 무엇이며, 왜 보정으로 되돌릴 수 없는가?
 3. **실사 예산이 6건에서 12건으로 늘어난다면, 14.2의 어느 표를 다시 보고 방문 순서를 정하겠는가? 그 표를 고른 이유를 적으라**

- **막혀도 제출함**
- 실행이 실패하면 오류 메시지가 파일에 담기고, 질문이 "어디서 막혔나"로 바뀜
- 실행 성공 여부로 점수를 매기지 않음

- **이 장의 두 실습은 시뮬레이션 자료를 씀**
- `6-0-simdata-prep.py` 와 `6-0b-site-simdata-prep.py` 가 매번 같은 시드로 자료를 만들므로 값이 사람마다 같아야 정상
- `FRONT_TOL` 같은 상수를 바꾸면 당연히 달라짐

더 알아보기

- **건물 윤곽 데이터를 직접 열어 보기**
 - Microsoft US Building Footprints(<https://github.com/microsoft/USBuildingFootprints>)에서 실제 대륙 단위 건물 폴리곤이 어떤 형태로 저장되는지 확인할 수 있음
- **프롬프트로 마스크를 오려 내는 과정 보기**
 - Segment Anything 논문(<https://arxiv.org/abs/2304.02643>)의 그림에서 점 하나로 대상의 경계가 오려지는 예시를 확인할 수 있음
- **최신 파운데이션 모델의 방향 보기**

- SAM 3 공개 블로그(<https://ai.meta.com/blog/segment-anything-model-3/>)는 텍스트로 대상을 지정하는 최신 방식을 소개함
- AlphaEarth Foundations 논문(<https://arxiv.org/abs/2507.22291>)은 마스크 대신 임베딩을 내는 접근을 설명함
- **SAM을 지도 좌표계로 연결하는 도구**
 - `samgeo` 논문(<https://doi.org/10.21105/joss.05663>)은 SAM의 출력을 GeoTIFF·폴리곤으로 바꾸는 절차를 설명함