

9장 환경·기후 정책평가, 위성 관측을 정책 결정으로 바꾸기

- 이 장에 나오는 손실률, 추정치, 표준오차, 컷오프, 비용은 모두 `lecture_practice/chapter9/` 의 코드를 실제로 실행해 얻은 값
- 예시를 위해 지어낸 숫자는 없음(계산 구조를 보이려고 임의로 넣은 값은 문장 안에서 "임의 입력"이라고 밝힘)

1. 이 장의 핵심 질문

1. 보호구역 안의 숲이 덜 훼손된 것은 정책 때문인가, 아니면 원래 덜 훼손될 곳을 골라 지정했기 때문인가
2. 다음 해에 신규 보호구역 100곳을 지정한다면 어디를 골라야 하는가. 평균효과로는 왜 이 질문에 답할 수 없는가
3. 실사 인력이 한 해 30건만 움직일 수 있다면 어디를 점검하는가. 자료도 예측도 그대로인데 대상 수를 움직이는 것은 무엇인가

□ 세 질문의 공통점은 관측이 늘어난다고 답이 저절로 나오지 않는다는 것임

○ 위성이 매일 지구를 관측해도, 그 관측을 지표로 만들고 오차를 진단하고 효과를 추정하고 비용을 세는 단계를 거쳐야 결정이 나옴

○ 한 단계를 건너뛰면 다음 단계의 결과를 믿을 근거가 사라짐. 관측 오차를 점검하지 않고 효과부터 추정하면, 그 추정치가 정책 때문에 움직였는지 분류 오차 때문에 움직였는지 구분할 수 없음

2. 도입 사례: 사후 비교가 참값의 1.6배가 되는 이유

□ 절차를 설명하기 전에, 정책효과를 잘못 재면 무슨 일이 벌어지는지 실제 실행 결과로 먼저 봄

○ `9-1-protected-area-forest-loss.log` 에서 가져온 보호구역 안팎의 평균 연간 산림손실률(%)

집단	사전(2001-2010)	사후(2011-2020)
보호구역 밖	4.781	5.264
보호구역 안	4.298	3.958

□ 이 표를 왼쪽부터 읽지 말고 **위아래부터** 읽음

○ **사전 기간에 이미 안쪽(4.298)이 밖쪽(4.781)보다 낮음.** 정책이 시행되기도 전에 생긴 차이이므로 정책 효과일 수 없음. 보호구역이 원래 압력이 낮은 곳에 지정됐다는 신호임

○ 이 상태에서 "사후 기간 안-밖 차이"만 계산하면 $3.958 - 5.264 = -1.306\%p$ 가 나옴

□ 이 장의 합성 자료에는 참 정책효과가 **-0.80%p**로 심겨 있음. 방금 계산한 -1.306%p는 참값보다 1.6배 넘게 큼

○ **이 격차를 만든 것은 나쁜 모형이 아니라 비교 방식임.** 정책이 없었어도 원래 낮았던 손실률을 정책의 몫으로 잘못 셧기 때문임

○ 결론을 먼저 밝히면, 6절의 이중차분으로 다시 계산한 값은 **-0.822%p**로 참값에 훨씬 가까워짐

3. 무엇을 재는가

3.1 실제 상태, 관측값, 예측값

□ 분석의 첫 작업은 세 값을 구분해 적는 것임

○ y = 정책이 실제로 바꾸려는 환경 상태

○ y^{obs} = 센서·분류·행정 기록을 거쳐 자료에 남은 값

○ $\hat{y}$ = 모델이 공변량으로 계산한 예측값

○ **산림손실은 y 와 y^{obs} 의 거리가 짧음.** 위성 분류가 틀릴 수는 있어도 관측 행위 자체가 별채를 만들지 않기 때문임. 이 오차는 측정오차로 다루고 5절에서 보정함

○ **규제 위반 적발 건수는 거리가 멀.** 단속 자료가 곧 y^{obs} 이므로, 단속을 늘리면 실제 위반율이 그대로여도 y^{obs} 가 늘어남. 이 지표는 y 와 y^{obs} 의 관계 자체를 의심해야 함

○ 이 거리를 짧다·멀다로 미리 적어 두면 뒤 단계에서 어떤 진단이 필요한지 정해짐

3.2 공간 단위와 집계 가중치

□ 환경 현상이 일어나는 단위(픽셀, 격자)와 정책이 집행되는 단위(행정구역, 시설)는 다름

○ 격자 단위로 계산한 값을 행정구역으로 모을 때 **무엇으로 가중평균할지가 결과를 바꿈**

○ 인구가 적은 산간 구역은 면적 가중에서는 상위로 오르고 인구 가중에서는 하위로 내려감

○ "구역 평균 손실률"이라는 말만으로는 무엇을 평균했는지 알 수 없으므로, 표 제목이나 각주에 가중치를 반드시 적음

4. 지표를 만든다

4.1 활동자료 × 배출계수

□ 국가는 산림 부문의 배출·흡수량을 해마다 한 수로 보고해야 하는데, 전국을 현장 조사로 다 세는 것은 예산과 시간 어느 쪽으로도 불가능함

○ 이 문제를 우회하는 방법이 배출량을 두 항의 곱으로 쪼개는 것임

$$E = AD \times EF$$

○ **AD**(활동자료, activity data)는 얼마나 많은 면적이 바뀌었는가이고, 위성으로 전국을 같은 기준으로 잴 수 있음

○ **EF**(배출계수, emission factor)는 그 면적 1헥타르가 품고 있던 탄소량이고, 현장 표본 조사나 LiDAR 기반 모델에서 나옴

○ 아래 계산은 구조를 보이기 위한 **임의 입력**이며 실측치가 아님. $AD = 1,000 \text{ ha}$, $EF = 150 \text{ tC/ha}$ 면 $E = 150,000 \text{ tC} \approx 550,000 \text{ tCO}_2$

4.2 두 오차는 더해지지 않고 곱해진다

□ AD의 오차 10%, EF의 오차 20%를 넣어 봄

○ 두 오차가 곱셈 구조로 결합하므로 최종 오차는 단순히 더한 30%가 아니라 ****제곱합의 제곱근인 22.4%****(두 오차가 서로 독립일 때)

□ 이 계산에서 배우는 것은 **개선 순서**임

○ AD 오차를 10%에서 5%로 줄이면 결합 오차는 1.8%p만 내려감

○ EF 오차를 20%에서 10%로 줄이면 8.3%p 내려감

○ **더 큰 쪽 항을 먼저 개선해야 최종 수치가 움직임**

주의. 활동자료와 배출계수의 오차는 더해지지 않고 곱해짐. 면적을 아무리 정밀하게 재도 배출계수가 30% 틀리면 최종 오차는 30% 근처에 머무름. 어느 항을 먼저 개선할지는 두 상대오차의 크기를 비교해 정함.

4.3 면적으로는 잡히지 않는 손실

□ 나무를 일부만 베어 내 임관이 성글어진 구역은 "산림에서 산림으로" 남으므로 AD로는 잡히지 않지만 **탄소는 실제로 빠져나감**. 이를 **열화**(degradation)라 함

○ 면적 기반 산정은 이 손실을 구조적으로 놓치며, 임관 밀도나 바이오매스 지표를 따로 추적해야 보완됨

5. 지표 오차를 진단한다

5.1 두 방향의 오류

- 4절에서 만든 산림손실률은 위성 변화탐지 모델의 산출물이며 그 자체가 오류를 품음
- 거짓양성(FP): 변화가 없는데 손실로 판정
- 거짓음성(FN): 실제 손실을 놓침
- 두 오류가 정책효과 추정에 미치는 영향은 **오류율이 처치군과 대조군에서 같은지**에 달려 있음
- **비차등 오류**: 오류율이 네 집단(처치·대조, 사전·사후)에서 모두 같으면, 정책효과 추정치는 참값에 $(1 - \text{거짓양성률} - \text{거짓음성률})$ 을 곱한 값이 됨. 방향은 유지되고 크기만 0쪽으로 줄어듦
- **차등 오류**: 보호구역이 산악·오지에 몰려 있어 처치군의 사후 기간에만 그림자 오분류가 늘었다고 하자. 이때는 추정치가 특정 방향으로 밀려남
- 더 위험한 것은 이 상황에서도 전체 정확도 지표가 정상 범위로 나온다는 점임

주의. 변화탐지 오류가 처치군과 대조군에서 같은 비율로 발생하는지 확인하지 않으면, 전체 정확도가 높아도 정책효과 추정치가 편향됨. 처치·대조 각각에서 거짓양성률·거짓음성률을 따로 추정하고, 두 값이 다르면 오류율 가정별 민감도를 함께 보고함.

5.2 참조표본으로 면적을 보정한다

- 오류율을 알려면 지도가 분류한 층별로 표본을 뽑아 실제 상태를 고해상도 영상이나 현장 조사로 판정한 **참조표본**이 필요함
- 아래는 계산 구조를 보이는 **임의 입력**임
 1. 대상 면적 100,000 ha 중 지도가 손실로 분류한 면적이 30,000 ha였음
 2. 참조표본으로 층별 정확도를 확인해 보니 손실 층의 사용자정확도가 0.750, 비손실 층에서 놓친 손실이 10/140이었음
 3. 층별 면적 비율에 그 층의 실제 손실 비율을 곱해 더하면 보정 손실 비율은 0.275
 4. 면적으로는 27,500 ha가 되며, 지도가 그대로 준 30,000 ha보다 **9.1% 작음**
- 이 절차의 요지는 **정확도 수치 하나로 자료 품질을 요약하지 않는 것**임. "정확도 95%"라는 말은 그 5%가 처치·대조 어느 쪽에 몰려 있는지에 따라 결론의 방향까지 바꿀 수 있음
- 6절부터 11절까지는 설명과 실습을 나누지 않음 — 각 절 첫머리에 실행할 명령이 나오고 그 아래에 코드와 실제 실행 결과가 이어짐. 순서대로 따라가면 이 장의 모든 수치를 직접 만들게 됨
- 먼저 패키지를 설치함. 인터넷도 GPU도 필요 없고 노트북에서 끝까지 돌아감

```
cd geoai_public # 저장소 루트 - 이 강의 명령은 모두 여기서 실행함
pip install -r lecture_practice/requirements-student.txt
```

□ 이 장에서 실행할 코드는 네 개이며 순서가 정해져 있음

순서	실행할 파일	하는 일	절
1	9-0-simdata-prep.py	합성 자료 세 벌 생성	—
2	9-1-protected-area-forest-loss.py	정책효과 추정·위험 예측·우선순위표	6·7·10
3	9-2-causal-heterogeneity.py	이질성 추정과 표적화	8
4	9-3-supply-chain-due-diligence.py	컷오프·예산 배분·공급망 사례	9·11

○ 자료 생성과 분석이 분리되어 있으므로 **1번을 먼저 실행해야 함** — 나머지 세 코드는 1번이 만든 파일을 읽고, 2~4번 사이에는 순서 의존이 없음

○ 1번이 만드는 자료는 세 벌이며, 어느 절이 어느 자료를 쓰는지 파일 이름으로 갈림

```
# 출처: lecture_practice/chapter9/results/9-0-simdata-prep.log
산림손실 패널 6000행(300단위×20년, 보호 150) → forest_loss_panel.parquet
참 CATE 격자 1600개(40×40, 보호 692) → cate_grid.parquet
조달 구역 240개(참 위반확률 평균 0.128, 실현 위반 25건) → sourcing_districts.parquet
```

○ **6·7·10절이 쓰는 자료(300단위 20년 패널)와 8절이 쓰는 자료(40×40 격자)는 서로 다른 합성 자료임.** 패널에는 모든 격자에 같은 정책효과가 심겨 있어 이질성을 물을 수 없고, 8절은 이질성을 채점하려고 효과 크기가 격자마다 다르게 심긴 별도 자료를 씀. **두 자료의 수치를 같은 표본의 분해로 읽으면 안 됨**

○ 본문에 인용한 출력은 모두 lecture_practice/chapter9/results/ 의 실행 로그에서 그대로 가져온 것이며, 어느 파일에서 왔는지를 출력 블록 첫 줄에 적어 두었음 — 화면에 나온 값과 그 파일을 한 줄씩 대조하면 됨

6. 정책효과를 추정한다

6.1 이중차분으로 선택 편향을 걷어낸다

□ 먼저 실행함. 2절의 표와 이 절의 추정치, 7절의 위험 예측, 10절의 우선순위표가 모두 이 두 명령의 출력임

```
python lecture_practice/chapter9/code/9-0-simdata-prep.py
python lecture_practice/chapter9/code/9-1-protected-area-forest-loss.py
```

□ 2절에서 본 것처럼 사후 시점의 단순 비교는 선택 편향을 그대로 안고 있음

○ **이중차분**(difference-in-differences, DID)은 두 집단의 **수준**이 아니라 **변화량**을 비교해 시간불변의 집단 차이를 제거함

효과 = (처치군 사후 - 처치군 사전) - (대조군 사후 - 대조군 사전)

□ 2절 표의 값을 넣으면 $(3.958 - 4.298) - (5.264 - 4.781) = -0.340 - 0.483 = -0.823\%p$

○ 사전 기간의 수준 차이 $-0.483\%p$ 가 두 번의 차분 과정에서 상쇄됨. 그 결과 참값 $-0.80\%p$ 에 훨씬 가까운 추정치가 나옴

○ 회귀식으로 쓰면 상호작용 항의 계수가 정책효과가 됨

$$\text{loss}_{it} = \beta_0 + \beta_1 \cdot \text{treated}_i + \beta_2 \cdot \text{post}_t + \delta \cdot (\text{treated}_i \times \text{post}_t) + \varepsilon_{it}$$

```
# 주석에 붙인 출력의 출처: lecture_practice/chapter9/results/9-1-protected-area-forest-loss.log
```

```
import statsmodels.formula.api as smf
```

```
# [1] 사후 시점만 놓고 안-밖을 뺀 값 - 2절이 보여 준 잘못된 비교
```

```
post = df[df["post"] == 1]
```

```
naive = (post[post.treated == 1]["loss"].mean()
        - post[post.treated == 0]["loss"].mean())
```

```
# 출력: naive 추정(사후 안-밖 차이): -1.306 %p ← selection bias로 효과 과대추정
```

```
# [2] 이중차분 - 상호작용 항의 계수가 정책효과이고, 표준오차는 단위별 군집 강건
```

```
res = smf.ols("loss ~ treated + post + treated:post", data=df).fit(
    cov_type="cluster", cov_kwds={"groups": df["unit"]})
```

```
# 출력: === [심화] DID 추정 (전체 표본, n=6000) ===
```

```
# DID 효과(treated:post): -0.822 %p (SE=0.020, p=0.0000)
```

```
# [3] 공통 지지 구간으로 표본을 제한하고 같은 회귀를 다시 돌림
```

```
matched = df[(df.pressure >= low) & (df.pressure <= high)]
```

```
# 출력: 공통 지지 구간 압력 [0.36, 0.84] → 매칭 후 단위 232개
```

```
# === [심화] DID 추정 (매칭(공통지지) 표본, n=4640) ===
```

```
# DID 효과(treated:post): -0.804 %p (SE=0.022, p=0.0000)
```

○ 추정 방법별 정책효과(참 효과 = $-0.80\%p$)

방법	추정 효과(%p)	참값과의 오차	표본
naive(사후 단순 비교)	-1.306	-0.506	n = 3,000
DID(전체 표본)	-0.822	-0.022	n = 6,000
DID(공통 지지 제한)	-0.804	-0.004	n = 4,640

□ 화면에 나온 값에서 읽을 것

○ 새 변수를 넣은 것이 아니라 비교 방식만 바꾼 것인데도 오차가 -0.506%p에서 -0.022%p로 줄어듦

○ 표준오차는 0.020(전체)·0.022(공통 지지 제한)이고 p값은 두 경우 모두 0.0000임

○ p값이 작다는 것과 참값에 가깝다는 것은 다른 말임 — 두 DID 모두 $p = 0.0000$ 이지만 참값과의 거리는 -0.022%p와 -0.004%p로 다섯 배 넘게 차이가 남. 참값을 알고 대조할 수 있는 것은 합성 자료이기 때문이며, 실제 자료에서는 이 대조가 불가능함

주의. 같은 격자를 20년에 걸쳐 관측한 패널에서 일반 표준오차를 쓰면, 표준오차가 실제보다 작게 나와 유의성이 과장됨. 오류 메시지는 나오지 않음. 단위(격자)별 군집 강건 표준오차를 쓰고, 군집 수가 적으면 그 수를 함께 보고함.

6.2 공통 지지 구간

□ 개발 압력이 0.1인 오지와 0.9인 도시 인접지는 시간에 따른 변화 양상도 다를 수 있음

○ 두 집단의 공변량 분포가 겹치는 구간으로 표본을 제한하면 이 위험이 줄어듦. 이 실습 자료에서 그 구간은 압력 [0.36, 0.84]이고, 제한하면 300단위 중 232단위($n = 4,640$)가 남음 — 위 실행의 **공통 지지 구간** 압력 [0.36, 0.84] → 매칭 후 단위 232개 줄에서 그대로 온 값임

○ **대가도 있음.** 표준오차가 0.020에서 0.022로 커졌고, 추정 대상이 "전체 보호구역"에서 "압력 [0.36, 0.84] 구간의 보호구역"으로 좁아짐. 제한 후 표본 수와 공변량 범위는 반드시 함께 적음

6.3 평행추세를 눈으로 먼저 본다




그림 9.1 보호구역 안팎의 연도별 산림 손실률 추세와 정책 발효 시점

- 이중차분이 성립하려면 정책이 없었을 때 두 집단의 추세가 나란히 움직였어야 함. 그림 9.1은 정책 발효 (2011) 이전 두 집단의 추세가 나란히 움직이다가 발효 후 보호구역 안쪽만 꺾이는 형태를 보임
- **시각적 평행성은 필요조건이지 충분조건이 아님.** 사전 기간이 짧으면 서로 다른 추세도 평행해 보일 수 있음
- 보호구역 경계 근처 격자를 제외하고 다시 추정해 결과가 유지되는지, 평균 대신 중앙값으로도 결론이 유지되는지 확인하는 절차가 함께 필요함

7. 보호가 없을 때의 위험을 예측한다

- 이 절의 수치는 6.1에서 실행한 `9-1-protected-area-forest-loss.py`의 뒷부분 출력임. 6절을 건너뛰었다면 여기서 실행함

```
python lecture_practice/chapter9/code/9-1-protected-area-forest-loss.py
```

7.1 학습 표본을 통제구역으로 제한한다

- 6절은 이미 시행한 정책의 평균 효과를 답함. 다음 배분을 정하려면 다른 값이 필요함 — 아직 보호되지 않은 격자 가운데 **보호가 없다면 어디가 크게 훼손될 것인가**
- 이 값은 관측되지 않으므로 공변량에서 학습해야 하며, **학습 표본을 통제구역**(보호되지 않은 격자, 이 자료에서는 150개)으로 **제한해야 함**
- 처치구역의 사후 손실을 그대로 학습하면 "보호가 없을 때의 위험"이 아니라 "보호가 적용된 뒤에 남은 위험"을 배우게 됨

주의. 처치구역의 사후 손실로 위험 모형을 학습하면 예측 대상에 정책효과가 섞임. 성능 지표는 정상으로 나오므로 실행만으로는 발견되지 않음. 학습 표본을 통제구역으로 제한하고, 그 표본이 전체 공변량 분포를 덮는 범위를 함께 적음.

7.2 이웃 값을 넣으면 예측이 좋아진다

- 토양 조건, 임도 접근성, 지역 단속 관행처럼 손실을 좌우하지만 자료로 잡히지 않는 요인이 있음. 이런 요인은 공간적으로 뭉쳐 있는 경우가 많음
- **공간 시차**는 한 격자의 이웃 값들을 가중평균한 값이며, 관측되지 않은 공간 요인의 흔적을 이웃 격자의 사전 손실에서 끌어옴
- 검증도 무작위가 아니라 공간 분할로 함. 이웃 격자는 값이 서로 비슷하므로, 무작위로 나누면 "새 구역으로 일반화하는 능력"이 아니라 *****바로 옆 값을 보간하는 능력*****을 재게 됨. 이 실습은 격자를 좌우로 나누어 학습·검증하는 2겹 공간 블록 교차검증을 씀

```
# 출처: lecture_practice/chapter9/results/9-1-protected-area-forest-loss.log
=== [2층 AI] 공간 명시적 ML 벌채위험 예측 (2겹 공간 블록 CV, 통제구역 학습) ===
공간 피쳐 포함 :  $R^2=0.307$ , RMSE=0.459
공간 피쳐 제외 :  $R^2=-0.080$ , RMSE=0.570
→ 공간 시차(미관측 공간효과) 기여:  $R^2 +0.386$  (공간 ML 정당)
피쳐 중요도(설명가능성): spatial_lag_pre_loss=0.569, habitat_value=0.219, pressure=0.212
```

- 공간 시차를 빼면 R^2 가 -0.080 으로, **검증 표본의 평균을 그대로 찍는 것보다 나쁨**. 넣으면 0.307 로 오름
- 피쳐 중요도에서도 공간 시차(0.569)가 서식지 가치(0.219), 개발 압력(0.212)보다 크게 앞섬. 관측되지 않은 공간 요인이 손실의 상당 부분을 좌우한다는 뜻임
- **이 값은 예측 기여도이지 인과효과가 아님**. "공간 시차가 크므로 이웃 손실이 벌채의 원인"이라고 읽지 않음

7.3 예측구간과 신뢰등급

- 점예측 하나(예: 5.0%p)만으로는 그 값이 얼마나 틀릴 수 있는지 알 수 없음
- **정규화 conformal 예측**은 분포 가정 없이 목표 포함확률을 겨냥하되, 위치마다 예측 난이도가 다르다는 점을 반영한 구간을 만들
- 계산 절차는 다섯 단계임
 1. 통제구역을 보정표본으로 씀
 2. 교차검증에서 나온 절대잔차로 격자별 "예측 난이도"를 별도로 학습함
 3. 실제 오차를 그 난이도로 나눈 정규화 점수를 만들
 4. 보정표본에서 이 점수의 90분위수를 구함
 5. 그 분위수에 난이도를 다시 곱해 격자별 반폭을 만들
- 반폭이 격자마다 달라지는 이유가 여기에 있음. 같은 분위수라도 난이도가 낮은 격자는 반폭이 좁고, 높은 격자는 넓어짐

```
# 출처: lecture_practice/chapter9/results/9-1-protected-area-forest-loss.log
=== [불확실성] 정규화 conformal 예측구간(90%, 00F 근사)과 신뢰등급 ===
통제구역 보정표본 n=150 · 목표 포함확률 0.90 conformal 계열(교육용 00F 근사)
00F 경험적 포함률 = 0.907 (목표 0.90)
구간 반폭(%p): 중앙값 0.511, 범위 [0.125, 1.327]
신뢰등급 분포: 높음 100 · 중간 100 · 낮음 100
```

- 실행 결과 90% 목표에 대한 경험적 포함률은 **0.907**이었고, 구간 반폭은 중앙값 $0.511\%p$, 범위 $[0.125, 1.327]\%p$ 였음. 반폭을 3분위로 나누면 신뢰등급 높음·중간·낮음이 각 100개씩으로 갈림
- **이 값에는 근사가 섞여 있음**. 학습·보정·시험 표본을 세 갈래로 분리하지 않고 같은 잔차를 두 곳에 함께

썼으므로 포함률 0.907은 다소 낙관적임. 실무에서는 세 갈래를 분리한 split conformal을 씀
○ 90% 포함률은 **표본 전체를 겨냥한 값**이며, 특정 격자 하나가 90% 확률로 그 구간 안에 있다는 뜻이 아님. 이 차이를 헛갈리면 개별 격자의 판단에 과도한 확신을 갖게 됨

8. 효과가 어디서 큰가

8.1 평균 하나로 배분을 정할 수 없다

- 6절의 이중차분은 보호구역 정책이 손실률을 평균 0.80%p 낮췄다고 답함
- 이 값으로 "정책을 계속할까"는 답할 수 있지만 "**다음 100곳을 어디로 정할까**"는 답할 수 없음
- 공변량 x 가 주어졌을 때의 처치효과를 **조건부 평균처치효과**(CATE, $\tau(x)$)라 함. 평균처치효과(ATE)는 이 함수를 전체 분포로 평균낸 하나의 수임
- 이질성이 크면 평균은 중심만 보여 주고, 정책적으로 중요한 고효과 지역이 그 안에 묻힘
- 세 번째 코드를 실행함. 8절의 표 세 개와 그림 9.2가 모두 이 한 번의 실행에서 나옴

```
python lecture_practice/chapter9/code/9-2-causal-heterogeneity.py
```

```
# 출처: lecture_practice/chapter9/results/9-2-causal-heterogeneity.log
표본 N = 1600 (40×40 격자), 보호구역(처치) = 692개
참 CATE 범위 = [-1.60, -0.20] %p, 참 ATE = -0.891 %p
공변량: ['pressure', 'enforce', 'habitat', 'elevation', 'slope'] (elevation·slope는 CATE와 무관한 잡음
대조군)
```

- 이 절은 **다른 합성 자료**를 씀(5절 참고). 손실 수준은 개발 압력이 정하고, 보호가 막아 주는 손실의 크기는 **집행역량**이 따로 정하도록 설계됨
- 참 CATE는 $\tau(x) = -(0.20 + 1.40 \times \text{집행역량})$ 으로 심었으며, 격자 1,600개 중 692개가 보호됨. 참 CATE의 범위는 $[-1.60, -0.20]\%p$, 참 ATE는 $-0.891\%p$ 임

8.2 R-러너가 교란을 걷어내는 방식

- 관측 자료에서 보호구역은 무작위로 지정되지 않음. 개발 압력이 낮은 곳이 우선 보호되므로 처치와 결과가 얹혀 있음
- **R-러너**는 결과와 처치를 각각 공변량으로 예측한 뒤 그 예측을 뺀 **잔차**만으로 $\tau(x)$ 를 추정함
 1. 결과의 주변기대 $\hat{m}(x)$ 와 처치의 성향점수 $\hat{e}(x)$ 를 교차적합으로 학습함(자기 자신을 학습한 모형으로 자기를 예측하면 안 됨)
 2. 잔차 $\tilde{Y} = Y - \hat{m}(x)$, $\tilde{D} = D - \hat{e}(x)$ 를 만듦(공변량으로 설명되는 부분을 뺀 나머지)
 3. $\tilde{Y}/\tilde{D}$ 를 목표로, $\tilde{D}^2$ 를 가중치로 하는 가중 회귀로 $\tau(x)$ 를 적합함

```

# 주석에 붙인 출력의 출처: lecture_practice/chapter9/results/9-2-causal-heterogeneity.log
# [1] 누이선스 교차적합 - 자기 자신을 학습한 모형으로 자기를 예측하지 않음
rf_m = RandomForestRegressor(n_estimators=300, min_samples_leaf=5,
                             random_state=42, n_jobs=1).fit(X[tr], y[tr])
m_hat[te] = rf_m.predict(X[te])
rf_e = RandomForestClassifier(n_estimators=300, min_samples_leaf=5,
                              random_state=42, n_jobs=1).fit(X[tr], d[tr])
e_hat[te] = np.clip(rf_e.predict_proba(X[te])[:, 1], 0.02, 0.98) # positivity 절단

# [2] 잔차 - 공변량으로 설명되는 부분을 뺀 나머지
y_res = df["y"].values - m_hat
d_res = df["treated"].values - e_hat

# [3] 유사결과  $\tilde{Y}/\tilde{D}$ 를 목표로,  $\tilde{D}^2$ 를 가중치로 하는 가중 회귀
pseudo = np.where(np.abs(d_res) > 1e-8, y_res / d_res, 0.0)
lo, hi = np.nanpercentile(pseudo, [1, 99])
pseudo = np.clip(pseudo, lo, hi) # 극단값이 소수 앞을 지배하지 않게 원저화
rf = RandomForestRegressor(n_estimators=400, min_samples_leaf=8,
                           random_state=42, n_jobs=1)
rf.fit(X, pseudo, sample_weight=d_res ** 2)
# 출력: [1] CATE 복원: 참  $\tau(x)$  vs 추정  $\hat{\tau}(x)$  (out-of-fold)
# Pearson 상관  $r = 0.744$ , Spearman  $\rho = 0.731$ 

```

□ 한 격자에 숫자를 넣어 봄(계산 흐름을 보이는 임의 입력). $Y = 4.2$, $\hat{m}(x) = 3.8$, $D = 1$, $\hat{e}(x) = 0.62$ 라면 $\tilde{Y} = 0.40$, $\tilde{D} = 0.38$ 이고 유사결과 = $0.40/0.38 = 1.053$, 가중치 = $0.38^2 = 0.144$ 가 됨

○ 개별 격자의 유사결과 하나는 잡음이 크게 섞여 있어 그 자체로 효과를 뜻하지 않음. 가중 회귀가 공변량이 비슷한 격자들의 유사결과를 모아 $\hat{\tau}(x)$ 를 만들

○ 실행 결과 교차적합 $\hat{\tau}$ 와 참 $\tau(x)$ 의 상관은 **Pearson $r = 0.744$, Spearman $\rho = 0.731$** 이었음. 평균 차원에서는 다음과 같음(참값 $\tau = -0.891\%$)

방법	추정 ATE(%p)	참값과의 오차
naive 하위집단 차이	-1.343	-0.452
이중강건(AIPW) ATE	-0.937	-0.047
R-러너 $\hat{\tau}$ 평균	-0.942	-0.052

○ naive 하위집단 차이가 크게 벗어나는 이유는 2절과 같음. 저압력 지역이 우선 보호된 선택 편향임

8.3 이질성이 진짜인지 검정한다

□ $\hat{\tau}$ 의 산포는 진짜 이질성일 수도, 추정 잡음일 수도 있음. 산포가 있다는 사실만으로는 근거가 되지 않으므로 두 검정으로 확인함

○ **GATES**: $\hat{\tau}$ 로 격자를 5분위로 나눈 뒤, 각 분위의 실제 효과를 $\hat{\tau}$ 와 독립인 별도 점수(이중강건 점수)로 채점함(각 분위 $n = 320$)

분위	예측 CATE(%p)	실제 그룹 효과(%p)
1 (효과 큼)	-1.570	-1.338
2	-1.137	-1.049
3	-0.922	-0.791
4	-0.715	-0.758
5 (효과 작음)	-0.368	-0.751

○ 분위가 올라갈수록 실제 효과가 줄어들고, 1분위와 5분위의 차이는 $+0.587\%p(z = 5.52, p = 0.0000)$ 로 잡음으로 설명되는 크기가 아님

□ **BLP**: 이중강건 점수를 중심화한 $\hat{\tau}$ 에 회귀함. 실행 결과 $\beta_1 = +0.519(\text{SE } 0.083, z = 6.28, p = 0.0000)$ 로 0보다 유의하게 커 이질성이 재확인됨

○ 다만 β_1 이 1보다 작다는 사실도 중요함. 예측 CATE의 산포가 실제 효과 산포의 약 두 배라는 뜻임

주의. BLP 보정기울기가 1보다 작으면 예측 CATE의 산포가 실제 효과의 산포보다 큼. 이때 $\hat{\tau}$ 를 지역별 효과의 절대 크기로 인용하면 과장됨. 순위 산정에만 쓰고, 특정 지역의 효과를 수치로 확정하지 않음.

8.4 표적화가 실제로 이득이 되는가

□ 미보호 격자 908곳 중 신규 보호 100곳을 고르는 네 전략을 비교함. 합성 자료라 참 τ 를 알고 있으므로 각 전략이 실제로 막는 총 손실을 채점할 수 있음

배분 전략	실제 총 저감손실(%p 합)	무작위 대비
CATE 표적화($-\hat{\tau}$ 큰 순)	123.12	+43%
사후손실 표적화(관측 손실 큰 순)	83.28	-3%
무작위 배분	86.17	기준
oracle(참 CATE)	135.13	+57%

○ CATE 표적화는 무작위보다 43% 더 막고, 참값을 아는 oracle의 91%까지 도달함

- 손실이 큰 곳을 고르는 전략(83.28)이 무작위(86.17)보다 오히려 낫다는 점이 이 표의 핵심임
- 손실 수준(개발 압력이 정함)과 보호효과(집행역량이 정함)가 서로 다른 변수이므로, 손실이 큰 구역이 곧 보호가 잘 듣는 구역이 아니기 때문임
- "위중도가 높은 곳부터 손댄다"는 관행이 이 조건에서는 성립하지 않음. 두 변수가 같은 방향으로 움직이는 지역에서는 결과가 달라질 수 있으며, 그 여부는 자료로 확인해야 함




그림 9.2 참·추정 CATE 산점도(왼쪽), 공간 지도(가운데), GATES 분위별 효과(오른쪽)

- 이 결론은 두 가정 위에서만 인과로 성립함 — 무교란(처치 배정이 관측 공변량으로 충분히 설명됨)과 positivity(모든 조건에서 보호 확률이 0과 1 사이에 있음)임
- 실제 자료에서는 집행역량처럼 관측되지 않는 요인이 지정과 손실을 동시에 좌우할 수 있고, 그러면 $\hat{\tau}$ 도 편향됨

9. 등급과 컷오프를 정한다

9.1 등급을 예측 대상으로 두면 안 되는 이유

- 앞 절까지의 산출물은 격자별 위험 예측, 구간, 효과 추정치임. 이 값을 행동으로 바꾸려면 "어디까지를 조치 대상으로 볼 것인가"라는 문턱이 필요함
- 흔히 저지르는 실수는 **등급을 목표변수로 두고 지도학습으로 예측하는 것임**
- 등급이 이미 손실을 같은 규칙으로 정의돼 있다면, 그 라벨을 손실률로 다시 예측하고 "손실률이 중요 변수"라고 결론짓는 것은 **넣은 것을 다시 꺼내는 순환논증**임
- 물어야 할 것은 "등급을 어떻게 잘 맞힐까"가 아니라 *****문턱을 어디에 둘 것인가*****이며, 그 답은 자료가 아니라 두 오류의 비용이 정함

9.2 비용비가 문턱을 정한다

- 조달 구역이 240곳이고 현장 실사는 한 해 30건만 가능한 기업을 생각함. 각 구역에는 위반확률 p 가 붙어 있고, 두 방향의 오류가 서로 다른 손해를 낳음
- **놓친 위반**(C_{FN}): 과징금, 계약 파기, 평판 손실
- **불필요한 실사**(C_{FP}): 실사 비용과 그 인력을 다른 구역에 못 쓴 기회비용
- 두 선택의 기대손실이 같아지는 지점이 문턱임

$$p^* = C_{FP} / (C_{FP} + C_{FN})$$

- 실사 1건 비용을 1로 두고($C_{FP} = 1$) 놓친 위반의 손해를 10배로 보면($C_{FN} = 10$), $p^* = 1/(1+10) = 1/11 \approx 0.0909$

- 이 문턱이 판정을 어떻게 가르는지 두 구역으로 확인함
 - $p = 0.05$ 인 구역: 실사 기대손실 0.95, 미실사 기대손실 0.50 → 실사하지 **않음**
 - $p = 0.15$ 인 구역: 실사 0.85, 미실사 1.50 → 실사**함**
- **확률 차이는 0.10에 불과하지만 판정이 같림.** 문턱이 그 사이에 있기 때문임
- 두 비용이 같으면 $p^* = 0.5$, 즉 익숙한 "확률 절반" 규칙이 됨. **확률 0.5가 기본값이 되는 것은 비용이 대칭일 때뿐이며, 환경 규제 맥락에서 이 조건은 거의 성립하지 않음**

9.3 비용비를 바꾸면 문턱이 움직인다

- 네 번째 코드를 실행함. 이 절의 두 표와 그림 9.3, 11절의 규칙 비교표가 모두 이 한 번의 실행에서 나옴

```
python lecture_practice/chapter9/code/9-3-supply-chain-due-diligence.py
```

```
# 주식에 붙인 출력의 출처: lecture_practice/chapter9/results/9-3-supply-chain-due-diligence.log
# [1] 비용 최적 확률 컷오프  $p^* = C_{FP}/(C_{FP}+C_{FN}) = 1 - \text{임계비}$ 
def prob_cutoff(cost_ratio):
    return 1.0 / (1.0 + cost_ratio)

# [2] 기대 총비용 - 실사 1건은 1단위, 놓친 위반 1건은 R단위
def expected_cost(selected, cost_ratio, p=None):
    p = p_true if p is None else p
    sel = np.asarray(selected, dtype=bool)
    return float((1.0 - p[sel]).sum() + p[~sel].sum() * cost_ratio)

# [3] 비용비만 바뀌 가며 컷오프에 걸리는 구역 수를 셈
for R in [1, 3, 5, 10, 20, 50, 100]:
    sel = p_hat > prob_cutoff(R)
# 출력: R=C_FN/C_FP 임계비 확률컷오프p* 실사건수 기대총비용 놓친위반(기대건수)
#           1 0.500 0.5000 7 28.8 26.29
#           10 0.909 0.0909 123 149.5 5.21
#           100 0.990 0.0099 237 208.5 0.02
```

○ 실사 1건 = 1단위, 240구역 기준. 아래 표는 그 출력의 [3단계 비용 곡선] 구간 일곱 행을 그대로 옮긴 것임

R = C _{FN} /C _{FP}	확률 컷오프 p*	실사 건수	기대 총비용	놓친 위반(기대 건수)
1	0.5000	7	28.8	26.29
3	0.2500	32	74.3	18.27
5	0.1667	59	106.0	12.97
10	0.0909	123	149.5	5.21
20	0.0476	168	178.6	1.97
50	0.0196	219	204.1	0.31
100	0.0099	237	208.5	0.02

○ 실사 대상이 7구역에서 237구역으로 움직이는 것은 모형이 바뀐 게 아니라 비용비가 바뀐 결과임

○ R = 10 행의 $p^* = 0.0909$ 는 9.2에서 손으로 계산한 값과 일치함

주의. 이 표에서 기대 총비용 열을 행끼리 비교하면 안 됨. R이 다르면 손실함수 자체가 달라 28.8과

208.5는 같은 자로 잰 값이 아님. 비교는 같은 R 안에서 서로 다른 결정 규칙끼리만 함.

9.4 예산이 부족하면 순위 문제가 된다

- R = 10의 최적 컷오프는 123구역을 지목함. **실사 예산이 한 해 30건뿐이면 이 컷오프는 실행할 수 없음**
- 이때 물음이 "문턱을 어디에 둘까"에서 *****제한된 K건을 누구에게 쓸까*****로 바뀜
- 한 건의 실사가 줄이는 기대비용은 p에 대해 단조증가하므로, 예산이 구속되면 **확률 상위 K건을 고르는 것이 최적임**

실사 건수 K	잔여 기대 총비용	달성한 절감 비율
0	307.8	0%
10	253.8	34.1%
30	205.7	64.5%
60	170.1	87.0%
90	153.5	97.5%
123 (K*)	149.5	100%

- 위 표는 같은 실행의 [4단계 예산 제약] 구간임

□ **절감의 대부분은 앞쪽에서 나옴.** K = 66건에서 이미 달성 가능한 절감의 90%를 얻고, 그 뒤로는 한 건당 절감이 빠르게 줄어듦

- 이 표는 예산 요청서에 그대로 쓸 수 있는 형태임. "실사를 더 해야 한다"가 아니라 *****현재 30건에서 잔여 기대손실이 205.7이고, 60건으로 늘리면 170.1로 내려가 절감의 87%에 이른다*****로 진술할 수 있음




그림 9.3 위험함수와 세 가지 컷오프(왼쪽), 실사 예산에 따른 잔여 기대손실 곡선(오른쪽)

10. 결과를 해석한다

10.1 우선순위표는 위험 → 신뢰 → 집중도 순으로 읽는다

- 앞 절들을 거치면 격자마다 관측 손실률, 위험 예측값, 구간 반폭, 신뢰등급, 순위가 붙음
- 아래 표는 6.1에서 실행한 9-1-protected-area-forest-loss.py 의 [불확실성] ml_risk 기준 행정구역 우선순위 구간임

순위	행정구역	평균 예측위험(%p)	평균 구간반폭(%p)	저신뢰 격자 수	신뢰등급
1	A01	5.629	0.434	4	높음
2	A02	5.293	0.519	7	중간
3	A07	5.256	0.489	8	높음
4	A08	5.168	0.451	1	높음
5	A10	5.141	0.568	8	중간
6	A09	5.115	0.458	6	높음

- 읽는 순서가 있음. 먼저 예측위험으로 후보를 좁히고, 구간 반폭·저신뢰 격자 수로 그 순위를 확정해도 되는지 판정하고, 마지막으로 고위험 격자의 집중도를 봄
- A01은 위험도 1위이면서 저신뢰 격자가 4개뿐이라 곧바로 배분에 쓸 수 있음
- A02와 A10은 위험도가 중상위지만 저신뢰 격자가 각각 7·8개로 많음. 순위를 무시하는 게 아니라, **확정 배분 전에 추가 관측이나 현장 확인으로 불확실성을 줄여야 하는 대상으로 분류함**
- 손실·압력·서식지 가치를 가중합해 사람이 직접 고른 상위 30개와 위험 예측 상위 30개를 비교하면 18개가 겹치고 12곳이 다름. 순위가 바뀌었다는 사실 자체는 영향의 근거일 뿐이므로, 이 격자들이 실제로 우선 후보인지는 손실·압력·보호 여부를 근거로 사람이 마지막으로 판정함

10.2 평균만 보고하면 놓치는 것

- 오염과 환경위험의 노출은 균등하지 않음. 산업단지·항만·간선도로 인접 지역, 녹지가 부족한 고밀 주거지역에서 환경 부담과 사회적 취약성이 겹치는 경우가 많음
- **환경정의**는 이 불균등 분포를 다루며, 평가 단계에서는 같은 추정치를 집단별로 쪼개는 절차로 구현됨
 1. 정책이 바꾸려 한 상태 변수(노출 지표)를 정함
 2. 집단과 집계 가중치를 정함(취약계층 인구 비율로 지역을 나누거나, 노출 지표를 취약계층 인구나 가중평균함)
 3. 전체 평균 변화와 취약지역 평균 변화를 나란히 보고함

○ 전체는 개선됐는데 취약지역이 정제하면 배분을 다시 검토할 근거가 됨. 이 분해를 별도 보고서가 아니라 10.1의 우선순위표에 취약계층 인구 비율 열로 추가하면, 상위 구역이 취약지역과 겹치는지 한눈에 확인됨

10.3 무엇을 확정하고 무엇을 조건부로 읽을 것인가

무엇을	판단	근거
신뢰할 수 있는 것	정책의 평균효과 방향과 크기	DID -0.822(SE 0.020)
신뢰할 수 있는 것	효과가 큰 지역과 작은 지역의 상대 순위	참 CATE 상관 $r = 0.744$, GATES 1-5 차이 $z = 5.52$
조건부로만 읽을 것	개별 격자의 효과 절대 크기	BLP $\beta_1 = 0.519 < 1$ 로 예측 산포가 과대
하지 말아야 할 것	무교란이 깨진 상태에서의 인과 해석	미관측 교란이 남아 있을 수 있음
다음에 필요한 것	실제 공간자료, 성향점수 겹침 진단	실증 분석으로의 확장 조건

- 예측 성능이 좋아졌다고 해서 식별 가정이 면제되지 않으며, 예측과 인과는 서로를 대신하지 않음
- 이 표를 정책 문서에 그대로 붙이면 절대 크기와 상대 순위가 같은 문장 안에서 섞이는 실수를 막을 수 있음

11. 사례 전체: 공급망 산림 리스크 실사

□ 이 절의 수치는 9.3에서 실행한 9-3-supply-chain-due-diligence.py 의 뒷부분 출력임. 9절을 건너뛰었다면 여기서 실행함

```
python lecture_practice/chapter9/code/9-3-supply-chain-due-diligence.py
```

○ 앞 절들의 결정 주체는 정부였음. 이 사례는 결정 주체가 기업으로 바뀜

제도 배경

- EU 산림전용방지법(Regulation (EU) 2023/1115)은 팜유·대두·목재·커피·카카오·소·고무 같은 품목을 EU 시장에 내놓으려는 사업자에게 "이 원료가 산림전용과 무관하다"는 실사를 요구함
 - 적용 시점은 개정으로 연기되어 대·중 사업자는 2026년 12월 30일, 영세·소 사업자는 2027년 6월 30일부터임(2026년 8월 확인)
 - 이 법은 생산국을 저위험·표준위험·고위험으로 나누고 당국의 표본 점검률을 각각 1%-3%-9%로 정함
- 목적함수가 바뀐다

- 공공 사례의 목적이 "같은 예산으로 막는 손실을 최대화"였다면, 여기서는 **기대 총비용을 최소화**함
- 효과 추정과 이질성 분석(6·8절)은 하지 않음. **물음이 인과가 아니라 배분이기 때문임**
- 국내 식품·목재 기업이 표준위험 생산국 4개국의 하위 행정구역 240곳에서 원료를 조달하는 상황을 둠

출처: lecture_practice/chapter9/results/9-3-supply-chain-due-diligence.log [1단계 관측]

분위 p50 p75 p90 p95 p99

손실률% 0.51 0.89 1.58 2.28 4.19

평균 0.780% · 최대 8.761%

손실 면적 상위 10% 구역(24개)이 전체 손실 면적의 39.6%를 차지

- 실행 결과 손실률은 중위 0.51%, 90분위 1.58%, 99분위 4.19%, 최대 8.761%이고, **손실 면적 상위 10% (24곳)가 전체 손실 면적의 39.6%를 차지함**. 손실이 소수 구역에 쏠려 있다는 조건이 "어디를 볼 것인가"를 결정 문제로 만듦
- 위반확률은 추정하지 않고 로지스틱 위험함수로 **선언**함. 규칙으로 정의된 값을 지도학습으로 복원하면 9.1의 순환논증이 위험함수에도 그대로 적용되기 때문임. 이 설정에서 참 위반확률은 평균 0.128, 범위 [0.006, 0.827]이고, 실현 위반은 240구역 중 25건임

제도 점검률을 사내 규칙으로 옮길 때의 대가

- 제도의 1%-3%-9%는 **당국이 감독 자원을 배분한 결과**이지 기업이 스스로 몇 %를 점검해야 하는지를 정한 값이 아님. 그런데 사내 목표율을 정할 때 이 숫자가 기준점으로 옮겨 붙기 쉬움
- 실사 규칙별 기대 총비용($R = 10$, 예산 $K = 30$, 240구역)

실사 규칙	실사 건수	기대 총비용	무실사 대비 절감
무실사	0	307.8	0.0
제도 기본선 3%(표준위험 점검률 전용)	7	272.5	+35.2
제도 기본선 9%(고위험 점검률 전용)	21	233.3	+74.4
무작위 $K = 30$	30	291.6	+16.1
손실률 단일 컷오프($K = 30$)	30	219.8	+88.0
위험순위 상위 $K = 30$	30	205.7	+102.0
전수 실사	240	209.2	+98.5
비용 최적 컷오프($p^* > 0.0909$)	123	149.5	+158.2

- 세 가지를 읽음

1. **제도 점검률을 그대로 옮기면 비용 최적보다 크게 더 씀**. 이 사례의 조달국이 표준위험이므로 옮겨 붙은 값은 3%이고, 그대로 쓰면 7건·272.5로 비용 최적(149.5)보다 123.0단위를 더 씀. 고위험 기준 9%로 올려도 233.3이라 83.8단위, 즉 실사 1건 비용의 84배를 더 씀

2. 같은 예산 30건이라도 무엇으로 순서를 매기느냐가 결과를 가름(위험순위 205.7 대 손실률 단일 컷오프 219.8 대 무작위 291.6)
3. 전수 실사(209.2)가 표적 30건(205.7)보다 오히려 비쌌. 문제없는 구역 약 209곳에서 헛되이 인력을 쓰기 때문이며, "다 보면 안전하다"는 판단이 비용 기준으로는 성립하지 않음

주의. 규제가 제시하는 점검률은 감독 당국의 자원 배분 결과이며 기업의 실사 목표율이 아님. 사내 컷오프는 자사의 C_FN과 C_FP로 다시 계산하고, 제도 점검률은 규제 대응의 하한선으로만 인용함.

가정이 틀렸을 때의 대가

- 위험함수의 손실률 기울기를 $\pm 50\%$ 틀려도 기대 총비용 초과는 1.3~4.2단위(최적값의 1~3%)에 그침
- 반면 **비용비 R을 한 자릿수 틀리면 초과가 9.4~116.0단위로 커짐**
- 최적 컷오프 부근에서는 기대비용 곡선이 평평해서 위험함수 오차는 잘 흡수되지만, 비용비를 잘못 잡으면 컷오프 자체가 다른 자리로 옮겨 가 평평한 구간을 벗어나기 때문임
- 실무 함의는 순서 문제임. 먼저 확보할 것은 더 정교한 위험 모형이 아니라 **C_FN / C_FP**이며, 과징금·계약 파기·대체 조달 비용을 세어 비용비의 자릿수를 확정하는 일이 모형을 정교화하는 일보다 결정에 크게 기여함

대조군으로 확인하기

- 이 절차가 옳게 작동하는지는 **대조군**으로 확인함. 위반이 손실률과 무관하게 발생하는 세계에서는 위험순위로 고른 30건과 무작위 30건의 성적이 같아야 함

출처: lecture_practice/chapter9/results/9-3-supply-chain-due-diligence.log [7단계 대조군]

(a) 신호 0 대조군 - 위반을 300회 다시 뽑아 실현 비용으로 채점

세계	위험순위	무작위	차이(순위-무작위)
신호 있음	208.2	297.3	-89.0 (SD 32.0)
신호 0	297.2	297.2	+0.0 (SD 27.2)

- 실행 결과 그 차이는 **+0.0**(SD 27.2, 300회 재추출)으로 이득이 정확히 사라졌고, 신호가 있는 세계에서는 **-89.0**(SD 32.0)이었음
- 위험순위의 이득이 정렬이라는 절차 자체가 아니라 **손실률·거버넌스라는 신호에서 나온다는 뜻임**
- 공공 분석과 이 사례를 나란히 두면 파이프라인의 앞쪽(위성 산출물에서 지표를 만드는 부분)은 거의 같음. 갈리는 것은 뒤쪽임 — **무엇을 비용으로 세는가, 그리고 누가 그 결과로 무엇을 결정하는가**

12. 핵심 요약

- **관측이 늘어난다고 정책효과가 저절로 드러나지 않음.** 지표를 만들고 오차를 진단하고 효과를 추정하고 비용을 세는 단계를 거쳐야 결정이 나옴 (1절)
- **사후 단순 비교는 선택 편향을 그대로 안음.** 실습에서 -1.306% 로 참값 -0.80% 의 1.6배가 나왔고,

이중차분으로 비교 방식만 바꾸자 -0.822%p가 됨 (2절, 6.1)

○ **실제 상태와 관측값의 거리는 지표마다 다름.** 산림손실은 가깝지만, 단속 적발 건수는 단속을 늘리면 위반율이 그대로여도 늘어남 (3.1)

○ **활동자료와 배출계수의 오차는 더해지지 않고 곱해짐.** 10%와 20%가 결합하면 30%가 아니라 22.4%이고, 큰 항을 먼저 개선해야 최종 수치가 움직임 (4.2)

○ **차등 오류가 비차등 오류보다 위험함.** 처치·대조에서 오류율이 다르면 추정치가 밀리는데 전체 정확도는 정상으로 나옴 (5.1)

○ **위험 모형은 통제구역으로 학습함.** 처치구역 사후 손실로 학습하면 예측 대상에 정책효과가 섞이는데 성능 지표는 정상으로 나옴 (7.1)

○ **평균효과로는 배분을 정할 수 없음.** 손실이 큰 곳을 고르는 전략이 무작위보다 못했음(83.28 대 86.17). 손실 수준과 보호효과가 서로 다른 변수이기 때문임 (8.1, 8.4)

○ **산포가 있다는 사실만으로는 이질성의 근거가 되지 않음.** GATES-BLP로 검정하고, BLP 기울기가 1보다 작으면 $\hat{\tau}$ 를 순위 산정에만 씀 (8.3)

○ **문턱은 자료가 아니라 두 오류의 비용이 정함.** 자료도 예측도 그대로인데 실사 대상이 7건에서 237건까지 움직이며, 움직인 것은 비용비뿐임 (9.2, 9.3)

○ **예산이 구속되면 문턱 문제가 순위 문제로 바뀜.** 제도가 제시하는 점검률은 감독 당국의 자원 배분 결과이지 기업의 목표율이 아니며, 표준위험 점검률 3%를 그대로 쓰면 비용 최적보다 123.0단위, 고위험 9%를 써도 83.8단위를 더 씀 (9.4, 11절)

13. 과제

```
python scripts/submit.py 9 --id 학번 --name 이름
```

□ 실행하면 9-0-simdata-prep.py 로 자료를 먼저 만들고, 9-3-supply-chain-due-diligence.py (공급망 산림 리스크 실사)를 학번 시드로 돌려 submissions/ 폴더에 제출_9장_학번.md 를 생성함

○ **눈여겨볼 곳은 비용비(R)에 따라 달라지는 확률 컷오프와 실사 대상 구역 수**

○ 제출 파일 안의 빈칸 세 개를 채움

1. 로그에서 눈에 띈 숫자 하나를 그대로 옮겨 적고, 왜 눈에 띄었는지 한 문장으로 적음
2. 그 숫자가 왜 그렇게 나왔는지 이 장에서 배운 개념으로 한두 문장 설명함
3. 데이터도 예측도 그대로인데 실사 대상 구역 수가 크게 움직인다. 무엇이 그것을 움직이는가? 당신이 리스크 담당자라면 몇 곳을 검사하겠는가?

○ **3번이 이 과제의 핵심임.** 1·2번은 로그를 보면 답이 나오지만 3번은 판단이 필요함

- **막혀도 제출함**
- 실행이 실패하면 오류 메시지가 파일에 담기고, 질문이 "어디서 막혔나"로 바뀜
- 실행 성공 여부로 점수를 매기지 않음

- 이 장의 실습은 학번을 시드로 씀
- 비용비:실사 건수 등 구체적인 숫자가 이 문서의 표와 정확히 같지 않을 수 있음
- 중요한 것은 방향임 — 비용비 R이 커지면 실사 건수도 늘어나는지 확인