

11장 공간 위험예측, 관측에서 결정까지

- 이 장에 나오는 침수심, 우선순위, 편향 지표, 보험료 배수는 모두 `lecture_practice/chapter11/` 의 코드를 실제로 실행해 얻은 값
- 예시를 위해 지어낸 숫자는 없음

1. 이 장의 핵심 질문

- 침수 대응, 순찰 배치, 보험료 산정은 모두 같은 질문에서 시작함 — "어느 위치가 얼마나 위험한가"
- 세 문제는 입력 자료의 생김새도 비슷하고 쓰는 알고리즘도 겹침
- 그런데 왜 같은 절차를 그대로 옮겨 쓸 수 없을까?
- 모델이 데이터를 정확히 맞히는 것과, 그 데이터가 실제 위험을 정확히 담고 있는 것은 같은 말일까?
- 예측이 다음 순찰이나 다음 보험 가입을 바꾸면, 그 예측은 다음번에도 같은 방식으로 맞을 수 있을까?
- 이 장은 위와 같은 질문에 답하기 위해 **공간 위험예측을 일곱 단계로 나눈 절차**를 다룸
- 각 단계에서 무엇을 입력받아 무엇을 계산하고 어떤 결과물을 남기는지 순서대로 따라감
- 중심 사례는 침수 위험이고, 같은 절차를 예측적 치안과 보험 위험모형에 적용해 **어느 단계가 왜 달라지는지**까지 확인함
- 핵심은 다음 한 문장
- 모델 성능이 좋아 보인다고 해서 그 모델이 실제 위험을 잘 잡아낸다는 뜻은 아님. 데이터에 적힌 값과 실제 값이 같은지부터 확인해야 함

2. 직관적 비유

- **관측 라벨** = 병원 진료기록으로 지역 유병률을 추정하는 일
- 진료기록에는 병원에 온 사람의 진단명만 남음
- 진료소가 멀어서, 돈이 없어서, 증상이 가벼워서 병원에 안 간 사람은 기록에 없음
- 기록이 없다고 그 사람이 건강한 것은 아님
- 대응을 하나씩 짚으면
 - 실제 유병률 = 이 장에서 말하는 실제 위험 y
 - 진료기록 = 관측 라벨 y^{obs}

- 병원 접근성·비용·증상 인지 = y 와 y^{obs} 를 갈라놓는 관측 과정
- 진료기록만으로 학습한 모델은 진료기록을 잘 맞히는 모델이지, 실제 건강 상태를 잘 맞히는 모델이 아닐 수 있음
- 침수에서는 이 간극이 좁고, 치안과 보험에서는 이 간극이 결정을 뒤집을 만큼 넓어짐 — 그 이유를 이 장에서 확인함
- **되먹임 루프 = 마이크를 스피커 쪽으로 돌렸을 때 나는 하울링**
- 마이크가 소리를 잡고, 스피커가 그 소리를 증폭해 내보내고, 마이크가 증폭된 소리를 다시 잡음
- 한 바퀴 돌 때마다 소리가 커지다가 결국 원래 소리와 무관한 굉음만 남음
- 대응을 하나씩 짚으면
 - 마이크가 잡는 소리 = 순찰이 만드는 적발 기록
 - 스피커의 증폭 = 기록을 학습한 모델이 다음 순찰을 그 지역에 더 배정하는 과정
 - 하울링 = 실제 위험과 무관하게 특정 지역만 계속 표적이 되는 상태
- 원래 신호(진짜 범죄율)가 거의 같아도, 초기의 작은 차이가 반복될수록 증폭됨
- 11.9의 예측적 치안 시뮬레이션이 이 구조를 숫자로 보여 줌

3. 핵심 개념 5가지

1. 실제 위험 y 와 관측 라벨 y^{obs} 는 다른 값일 수 있음
 - 모델은 y^{obs} 를 정답으로 학습하지만, 결정에 필요한 값은 y
 - 두 값의 거리가 짧은 자료(침수)와 먼 자료(치안, 보험)를 구분해야 함
2. 공간가중행렬 W 가 "이웃"을 숫자로 정의함
 - 어느 위치가 이웃인지, 이웃에 얼마의 비중을 줄지 $n \times n$ 행렬로 적음
 - 이웃 값의 가중평균이 공간 시차이고, 침수에서는 "주변보다 낮은 저지대"를 표현하는 변수가 됨
3. 목표값 누수는 오류 메시지 없이 성능만 올림
 - 예측 시점에 알 수 없는 값(이웃의 현재 침수심)을 입력에 넣으면 검증 점수가 좋아짐
 - 배치 시점에는 그 값을 받을 곳이 없으므로 실제로는 못 쓰는 모델이 됨
4. 공간 블록 교차검증은 새로운 지역으로 일반화하는 능력을 잴 수 있음
 - 무작위로 행을 나누면 검증지점 바로 옆이 학습자료에 들어가 점수가 부풀려짐
 - 블록 단위로 떼어 내야 "안 본 지역"을 예측하는 실제 상황을 흉내 냄
5. 예측값 하나로는 얼마나 믿을지 알 수 없음
 - 예측구간은 개별 예측이 벗어날 수 있는 범위를 주고
 - 적용가능영역은 학습자료가 다루지 않은 조건을 표시함

- 둘 다 없으면 점예측을 그대로 자원 배분에 쓰게 됨

4. 실제 자료를 먼저 보기

- 이 장의 개념은 실제로 운영 중인 시스템과 공공 자료에서 나온 것들임
- 국내 산림청 산사태정보시스템 — 산사태 위험지도를 국가가 제공 <https://sansatai.forest.go.kr>
- 경찰청 보도자료 — 빅데이터·AI 기반 범죄예방활동(Pre-CAS) 전국 확대(2021) https://www.police.go.kr/user/bbs/BD_selectBbs.do?q_bbsCode=1002&q_bbscttSn=20210429172502138
- ESA Sentinel-1 긴급대응 — SAR로 홍수 범위를 관측하는 실제 절차 https://www.esa.int/Applications/Observing_the_Earth/Copernicus/Sentinel-1/Emergency_response
- USGS Post-Fire Mapping Glossary — 산불 피해 지표(NBR, dNBR) 정의 <https://burnseverity.cr.usgs.gov/glossary>
- Pre-CAS는 실제로 전국에 깔린 시스템이고, 이 장의 11.9.2 시뮬레이션은 이런 시스템이 왜 신중하게 다뤄야 하는지를 보여 주는 반면교사 사례임
- 산사태정보시스템 페이지를 열어 보면 이 장에서 다루는 "정적 취약성지도"와 "실시간 경보"의 구분이 실제 화면에 어떻게 나타나는지 확인할 수 있음

실습 안내

- 실습 코드
 - `lecture_practice/chapter11/code/11-0-simdata-prep.py` — 침수·치안·보험 세 자료를 한 번에 준비
 - `lecture_practice/chapter11/code/11-1-flood-risk-priority.py` — 침수위험 예측과 대응 우선순위
 - `lecture_practice/chapter11/code/11-2-predictive-policing-bias.py` — 예측적 치안의 되먹임 시뮬레이션
 - `lecture_practice/chapter11/code/11-3-insurance-risk-grading.py` — 보험 위험등급과 보험료 차등
- 결과 로그: `lecture_practice/chapter11/results/*.log`
- 이 장의 실습은 GPU가 필요 없음
- 격자 300개(침수), 256개(치안), 건물 500채(보험) 규모라 노트북에서도 몇 초 안에 끝남
- 세 자료는 모두 시뮬레이션 자료이며, 실제 지역이나 실제 시장의 값이 아님. 본문에서 다루는 숫자는 이 시뮬레이션 설계값이 만든 결과일 뿐, 실제 침수 확률이나 실제 보험 시장 통계로 읽으면 안 됨

5. 실제 사례로 먼저 보기

- 11-1-flood-risk-priority.log 의 실제 실행 결과부터 봄
- 격자 300개(20×15)에서 표고 하위 25%인 저지대 격자 75개의 평균 침수심은 **25.1cm**, 나머지 225개는 **10.3cm**
- 표고 하나만으로도 두 집단이 두 배 이상 갈림
- 그런데 표고만으로는 강우와 불투수면이 겹칠 때 침수심이 급증하는 비선형 관계를 놓침
- 이 부족한 부분을 채우려고 공간 시차와 머신러닝이 들어감
- 같은 데이터에서 세 가지 조건으로 성능을 비교하면

조건	검증 방식	R ²
비공간 피쳐	공간 블록 CV	0.781
+공간 시차 피쳐	공간 블록 CV	0.816
+공간 시차 피쳐	랜덤 CV	0.874

- 공간 시차(이웃의 침수심, 상류 흐름의 대리변수)를 추가하면 공간 블록 CV에서 R²가 0.781에서 0.816으로 **+0.034** 올라감
- 같은 피쳐를 랜덤 CV로 검증하면 R²가 0.874로 더 높게 나오는데, 이 차이(+0.058)는 성능 향상이 아니라 **검증 방식이 인접 지점의 정보를 새어 들어오게 만든 결과**
- 두 숫자를 나란히 보면 "공간 시차가 정말 도움이 되는 만큼(+0.034)"과 "검증을 잘못 설계해서 부풀려진 만큼(+0.058)"을 구분할 수 있음
- 어떤 변수가 예측에 크게 기여했는지도 확인함

피쳐	중요도
depth_lag(이웃 침수심)	0.569
elevation(표고)	0.358
imperv(불투수면)	0.040
elev_lag(이웃 표고)	0.013
slope(경사)	0.011
rainfall(강우)	0.007
river_dist(하천거리)	0.001

- 이웃 침수심 하나가 전체 기여도의 절반 이상(0.569)을 차지함

- 침수는 인접한 저지대로 물이 흘러드는 현상이므로, 이웃 값을 아는 것이 다른 변수보다 예측에 크게 도움이 됨
- 다만 이 값을 실제로 예측 시점에 쓸 수 있는지는 별도로 확인해야 함 — 8절에서 이 문제(목표값 누수)를 다룸

6. 공간 위험예측의 일곱 단계

- 공간 위험예측은 다음 순서로 진행함
- 앞 단계를 건너뛰면 뒤 단계의 판단 근거가 사라짐
- 예를 들어 검증 설계(4단계)를 정하지 않은 채 모델을 고르면(3단계), 무엇을 기준으로 그 모델을 골랐는지 답할 수 없음

[1] 예측 대상·공간 단위 정의	→ 대상 정의서, 단위 결정, 집계 규칙
↓	
[2] 공간 피처 설계	→ 공간가중행렬 W , 공간 시차 변수, 가용성 점검표
↓	
[3] 모델 선택	→ 기준모형 + 후보모형, 선택 근거
↓	
[4] 공간 검증	→ 블록 CV 성능, 잔차 진단 결과
↓	
[5] 불확실성 정량화	→ 예측구간, 적용가능영역 표시
↓	
[6] 결과 도출·해석	→ 단위별 예측표, 집계 우선순위표
↓	
[7] 결정 규칙·감사	→ 조치 매트릭스, 감사 지표 정의

그림 11.1 공간 위험예측의 일곱 단계와 단계별 산출물

- 각 단계가 이 장의 어느 절에서 다뤄지는지

단계	이 장의 절
1 예측 대상·단위	7절
2 공간 피쳐 설계	8절
3 모델 선택	9절
4 공간 검증	10절
5 불확실성 정량화	11절
6 결과 도출·해석	12절
7 결정 규칙·감사	13절

- 14절에서 같은 절차를 위성 관측, 치안, 보험의 세 자료에 적용하면서 어느 단계가 달라지는지 확인함

7. 위험 대상과 데이터 라벨을 정한다

7.1 실제 값과 기록된 값을 구분한다

- 분석의 첫 작업은 세 값을 구분해 적는 것
- 실제 위험 또는 피해를 y , 데이터에 기록된 값을 y^{obs} , 모델이 산출한 예측값을 $\hat{y}$ 로 씀
- 모델은 y^{obs} 를 정답으로 학습하지만 의사결정에 필요한 값은 y

사례	실제로 알고 싶은 값	관측 라벨	주요 결정
침수	격자·건물별 침수 여부와 침수심	수위계, 현장조사, SAR 침수 관측	방재시설·대피 자원 배치
치안	시간·지역별 실제 범죄 발생	신고·적발·입건 기록	순찰 배치
보험	건물별 실제 피해확률과 기대손실	가입자의 청구 여부와 청구액	보험료·인수 조건

- 침수에서는 y 와 y^{obs} 의 거리가 짧음
- 수위계가 없는 곳은 관측되지 않고 SAR는 건물 그림자를 오분류할 수 있지만, 이 오차는 측정오차일 뿐 관측 행위 자체가 침수를 만들지는 않음
- 치안과 보험은 거리가 멀
- 순찰을 늘리면 같은 범죄 발생률에서도 적발 기록이 늘고, 보험에 가입하지 않은 건물의 피해는 청구자료에 남지 않음
- 이 거리를 분석 시작 시점에 한 줄로 적어 두면, 나중에 모델을 고르는 기준과 감사 항목이 달라짐

7.2 어느 단위로 예측하고 어느 단위로 모을까

- 위험이 발생하는 단위와 정책이 집행되는 단위는 다름
- 침수는 유역과 격자에서 발생하지만 복구예산은 행정구역에 배정됨
- 분석 단위를 처음부터 행정구역으로 정하면 구역 내부의 저지대와 고지대가 평균에 섞여 신호가 사라짐
- 그래서 **현상이 발생하는 단위에서 예측하고, 정책이 집행되는 단위로 집계하는** 두 단계를 둬
- 격자 i 의 예측값을 행정구역 a 로 모으는 식

$$\hat{y}_a = [\sum_{i \in a} \omega_i \hat{y}_i] / [\sum_{i \in a} \omega_i]$$

- 여기서 ω_i 는 가중치이고, 무엇을 가중치로 쓰느냐에 따라 같은 예측값도 다른 순위표가 됨

가중치 ω_i	계산 결과의 뜻	적합한 결정
면적(모두 동일)	구역의 평균 물리 위험	방재시설 설계, 토지이용 규제
인구	주민 노출을 반영한 위험	대피 계획, 인력 배치
건물 수	피해 대상 건물 기준 위험	복구 인력, 응급 지원
건물가액	기대 피해액 기준 위험	예산 배분, 보험 손실 추정

- 인구가 적은 산업단지는 면적 가중과 건물가액 가중에서 상위로 오르고 인구 가중에서는 하위로 내려감
- 가중치를 밝히지 않은 구역 평균은 "무엇을 평균한 값인지" 알 수 없으므로, 집계 결과를 낼 때 ω_i 를 표 제목이나 각주에 함께 적음

8. 이웃을 정의하고 공간 시차를 만든다

8.1 공간가중행렬

- 어떤 위치가 서로 이웃인지 수치로 정의하는 도구가 **공간가중행렬** $W = [w_{ij}]$
- n 개 공간 단위가 있으면 W 는 $n \times n$ 정방행렬이고, w_{ij} 는 위치 j 가 위치 i 에 주는 가중치
- 자기 자신은 이웃으로 세지 않으므로 대각원소 w_{ii} 는 0

방식	정의	적합한 자료
rook 인접	변을 맞댄 4칸	격자, 정방형 셀
queen 인접	모서리를 포함한 8칸	격자, 대각으로도 확산하는 현상
거리 임계	반경 d 안의 모든 단위	점자료, 관측소망
k-최근접	가장 가까운 k개	단위 밀도가 고르지 않은 자료
거리 감쇠	$w_{ij} = 1/d_{ij}$ 또는 $1/d_{ij}^2$	영향이 거리에 따라 연속으로 줄어드는 현상
유형 연결	하류 방향 연결 격자만	유역, 하천망, 도로망

- 유역 분석에서는 방향이 중요함 — 물은 위에서 아래로만 흐르므로 하류 방향에만 가중치를 주고 반대 방향에는 0을 줌
- 이웃을 정한 뒤에는 **행 표준화**를 적용함(각 행의 합이 1이 되게 나눔)
- 표준화를 안 하면 이웃이 많은 위치일수록 공간 시차 값이 커져서, 주변 조건이 아니라 이웃 개수를 반영하는 변수가 만들어짐

8.2 공간 시차

- 변수 x의 **공간 시차**는 이웃 값의 가중평균

$$x_i^{\text{lag}} = \sum_j w_{ij} x_j$$

- 실습 코드는 4-이웃 평균으로 이 계산을 함

```
def spatial_lag(df, col):
    return _neighbor_mean(df["row"].values, df["col"].values, df[col].values)
```

전체 코드는 [lecture_practice/chapter11/code/11-1-flood-risk-priority.py](#) 참고

- 작은 계산 예 — 중앙 격자의 네 이웃 표고가 12m, 14m, 10m, 8m이면

$$\text{elevation}_i^{\text{lag}} = 0.25 \times 12 + 0.25 \times 14 + 0.25 \times 10 + 0.25 \times 8 = 11\text{m}$$

- 이 값이 중앙 격자 주변의 지형 수준
- 중앙 격자의 표고가 9m라면 주변보다 2m 낮은 저지대이고, 15m라면 주변보다 4m 높은 언덕
- 표고 하나만 입력하면 이 두 경우를 구분할 수 없지만, 공간 시차를 함께 넣으면 상대적 높이를 학습할 수 있음
- 물이 모이는 위치는 절대 표고가 아니라 주변과의 상대 관계로 정해지므로, 침수 예측에서 이 차이는 실질적임

8.3 이 값을 예측 시점에 실제로 쓸 수 있는가

- 공간 시차를 만들 수 있다고 모두 입력변수로 쓸 수 있는 것은 아님
- 판정 기준은 하나 — **예측을 수행하는 시점에 그 값을 실제로 관측할 수 있는가**

피쳐	예측 시점 관측	판정
표고, 경사, 하천거리	사전 측량 자료로 상시 가용	사용
불투수면 비율	최근 토지피복 자료로 가용	사용
강우(예보)	예보 시점에 가용	사용, 실측과 구분해 기록
강우(사후 누적)	재난 종료 후에만 확정	사전 예측에는 제외
표고의 공간 시차	표고가 상시 가용하므로 계산 가능	사용
이웃의 현재 침수심	예측 시점에 관측 불가	제외
이웃의 직전 시점 침수심	실시간 수위계망이 있으면 가용	조건부 사용

- 이웃의 현재 침수심을 입력하면 **목표값 누수**가 생김
- 예측을 하는 이유는 침수심을 모르기 때문인데, 이웃의 침수심은 알고 있다고 가정하는 셈
- 검증 성능은 높게 나오지만 배치 시점에는 그 값을 받을 곳이 없음

- 목표값 누수는 오류 메시지 없이 지나감**
- 코드는 정상 종료하고 성능은 오히려 좋아지며 피쳐 중요도표에서 그 변수가 1위로 올라옴
- 5절에서 본 `depth_lag`의 중요도 0.569도 이 위험을 안고 있는 값 — 실제 배치에서는 실시간 수위계망이 있는 지역에만 조건부로 쓸 수 있음
- 피쳐를 만들 때마다 "이 값을 예측 시점에 어디서 받아 오는가"를 한 줄로 적고, 답할 수 없으면 후보에서 뺌

- 공간 흐름을 반영할 대안은 세 가지
 - 이전 시점의 관측 침수심**을 입력함. 실시간 수위계망이 있는 지역의 단기 예측에 적합
 - 물리적 상류 기여량**을 입력함. 표고에서 유향을 계산해 상류 집수면적과 강우량으로 유입량 대리변수를 만듦. 지형과 강우만 쓰므로 사전 위험지도 작성에 적합
 - 공간자기회귀모형**을 씬. 동시적 공간 시차를 모형 안에 두되 내생성을 처리함. 예측보다 공간 파급효과의 크기를 추정하는 것이 목적일 때 씬

9. 예측 모델을 고른다

9.1 세 계열의 방법

- 침수 위험은 하나의 모델로만 분석하지 않음
- 물리모형, 공간통계모형, 머신러닝은 서로 다른 질문과 자료 조건에 대응함

방법	계산 대상	장점	주요 한계	적합한 상황
수문·수리모형	강우-유출-수위-범람 과정	물리적 해석과 시나리오 분석 가능	지형·관망·경계조건 자료와 계산비용이 큼	설계홍수와 방재시설 검토
공간통계모형	공변량 효과와 잔차의 공간 의존성	계수와 공간효과를 분리해 해석	복잡한 비선형과 고차원 상호작용에 제약	위험요인 추론과 설명
트리 기반 ML	입력변수와 피해 사이의 비선형 함수	비선형·상호작용을 자동으로 포착	외삽과 인과 해석에 취약	충분한 관측 라벨이 있는 예측

- 물리모형을 쓸 수 있는 상황에서 머신러닝이 이를 자동으로 대체하지는 못함
- 머신러닝은 물리모형의 계산비용을 줄이는 대리모형이거나, 관측자료의 반복 패턴을 학습하는 예측모형으로 씀
- "불투수면이 10% 늘면 침수심이 얼마나 늘어나는가"처럼 원인별 계수가 필요하면 공간회귀나 가법모형이 더 적합함
- 트리 기반 모델의 피쳐 중요도는 예측 기여도이지 인과효과의 크기가 아님
- 이 장의 실습은 트리 기반 그래디언트 부스팅 회귀를 씀
- 이유는 둘 — 침수심은 저지대와 고강우가 겹칠 때 급증하는 상호작용 구조이고, 격자 300개 규모의 표 형태 자료에서 트리 앙상블이 별도 특성공학 없이 이 상호작용을 학습하기 때문

9.2 선형 기준모형부터 세운다

- 복잡한 모델을 쓰기 전에 해석 가능한 기준모형을 둬
- 기준모형은 복잡한 모형의 성능이 실제로 그 선을 넘는지 판정하는 잣대가 됨

$$y_i = \beta_0 + \beta_1 \cdot \text{elevation}_i + \beta_2 \cdot \text{slope}_i + \beta_3 \cdot \text{riverdist}_i + \beta_4 \cdot \text{impervious}_i + \beta_5 \cdot \text{rainfall}_i + \varepsilon_i$$

- 이 식은 각 변수가 침수심에 독립적으로 더해진다고 가정함
- 실제 침수는 이렇게 작동하지 않음 — 강우가 적으면 저지대여도 물이 고이지 않고, 강우가 많아도 투수면이 충분하면 일부가 흡수됨
- 저지대이면서 불투수면 비율이 높고 강우가 집중될 때 침수심이 급증함
- 선형모형에서 이 구조를 표현하려면 곱셈항을 직접 넣어야 함

$$y_i = \dots + \beta_6(\text{rainfall}_i \times \text{impervious}_i) + \beta_7(\text{rainfall}_i \times \text{lowland}_i) + \varepsilon_i$$

- 변수를 두 개만 곱해도 항이 늘어남 — 후보 변수가 일곱이면 2차 상호작용만 21개
- 어느 조합이 실제로 필요한지 사전에 알기 어렵다는 점이 선형모형의 한계이고, 트리 양상블을 쓰는 실질적 이유가 여기에 있음

9.3 그라디언트 부스팅이 작동하는 순서

- **그라디언트 부스팅**은 작은 회귀나무를 순차적으로 더해 예측함수를 만듦(Friedman, 2001)
 - 하나의 큰 나무를 키우는 대신, 얇은 나무 수백 개가 각각 앞 단계의 오차를 조금씩 줄임
1. **초기 예측을 정함** — 전체 관측값의 평균을 첫 예측으로 둠
 2. **잔차를 계산함** — 각 격자에서 실제값과 현재 예측의 차를 구함. 저지대 격자에서는 이 값이 양수로 크고 고지대에서는 음수
 3. **잔차를 예측하는 나무를 적합함** — 원래 목표값이 아니라 잔차를 목표로 회귀나무를 학습. "현재 모형이 어느 조건에서 얼마나 틀리는가"를 학습하는 셈
 4. **학습률을 곱해 더함** — 새 나무의 예측에 학습률 η 를 곱해 기존 예측에 더함. η 가 0.05면 나무 하나가 잔차의 5%만 메움
 5. **2단계로 돌아감** — 나무 수 M 에 도달할 때까지 반복

```
m = GradientBoostingRegressor(random_state=42, n_estimators=200,
                               max_depth=3, learning_rate=0.05)

m.fit(X[tr], y[tr])
```

전체 코드는 [lecture_practice/chapter11/code/11-1-flood-risk-priority.py](#) 참고

- 세 하이퍼파라미터가 이 과정을 통제함

장치	작동 방식	설정 기준
낮은 학습률	나무 하나의 기여를 줄여 점진적으로 학습	0.01~0.1, 낮출수록 나무 수를 늘림
나무 수 제한	반복 횟수 상한	검증 성능이 개선을 멈추는 지점
깊이 제한	상호작용 차수 상한	도메인에서 예상되는 조건 결합 수
얇은 최소표본	표본이 적은 분기를 금지	전체 표본의 1~5%
부분표본	나무마다 자료 일부만 사용	0.5~0.8

- 나무 깊이가 1이면 변수 하나만 보고 분기하므로 상호작용을 표현하지 못함
- 깊이가 3이면 "표고가 낮고, 불투수면이 높고, 강우가 많은" 3중 조건까지 하나의 잎에 담을 수 있음
- 이 장의 실습은 나무 200개, 최대 깊이 3, 학습률 0.05를 씀

- 하이퍼파라미터는 시험자료 성능을 보고 고르지 않음
- 시험자료를 반복해서 들여다보며 설정을 조정하면 그 자료는 더 이상 독립적인 시험대상이 아님
- 학습자료 안에서 내부 검증 분할을 만들어 정하고, 시험자료는 최종 한 번만 씀

9.4 무엇을 고를지 순서로 판정하기

물리 과정 자료(지형·관망·경계조건)가 갖춰져 있는가?

```

|
└ 예 → 수문·수리모형으로 기준 결과 확보
    └ 계산이 느려 반복 시나리오가 어려운가? → ML 대리모형 병행
|
└ 아니오 → 분석 목적은 무엇인가?
    |
    └ 요인별 효과 크기 추정 → 공간회귀·가법모형
    |
    └ 위치별 예측값 산출 → 선형 기준모형 적합
        └ 상호작용이 필요한가?
            └ 예 → 트리 앙상블
            └ 아니오 → 선형모형 유지
  
```

그림 11.2 분석 목적과 자료 조건에 따른 모델 선택

- 트리 앙상블을 고른 뒤에도 선형 기준모형을 버리지 않음
- 두 모형을 같은 검증 설계로 비교해 성능 차이를 기록하고, 차이가 작으면 단순한 쪽을 채택함
- 복잡한 모형의 사용 여부는 모델 이름이 아니라 동일 조건 비교 결과로 정함

10. 공간을 나눠 검증한다

10.1 왜 무작위로 나누면 안 되는가

- 공간자료에서는 가까운 관측치끼리 값이 비슷함
- 무작위로 행을 나누면 검증지점 바로 옆의 관측치가 학습자료에 들어감
- 이 방식으로는 새로운 지역으로 일반화하는 능력이 아니라 **인접값을 보간하는 능력**을 잼
- 5절에서 확인한 랜덤 CV의 R^2 0.874가 공간 블록 CV의 R^2 0.816보다 높았던 이유가 이것

검증 설계	분할 방법	평가하는 상황	주의점
무작위 CV	관측행을 무작위 분할	동일 분포의 비공간 표본	공간자료에서는 인접 누수 가능
블록 CV	좌표를 공간 블록으로 분할	인접하지 않은 블록 예측	블록 크기·방향에 민감
버퍼 CV	검증지 주변 학습표본 제거	가까운 이웃 없이 예측	표본 수가 감소
유역·지역외 CV	유역·행정구역 전체 제외	학습하지 않은 지역으로 이전	지역 수가 적으면 분산 증가

- 검증 설계는 모형이 실제로 놓일 상황에 맞춤
- 같은 도시 안에서 관측이 없는 격자를 메우는 용도라면 블록 CV, 학습한 적 없는 다른 시군에 모형을 이전할 계획이라면 지역외 CV가 그 상황에 대응함

```
def spatial_block_folds(df, n_blocks=5):
    block = (df["col"].values / (GRID_COLS / n_blocks)).astype(int)
    block = np.clip(block, 0, n_blocks - 1)
    for b in range(n_blocks):
        test = block == b
        yield ~test, test
```

전체 코드는 [lecture_practice/chapter11/code/11-1-flood-risk-priority.py](#) 참고

- 실습은 열 방향으로 도시를 다섯 블록으로 나눔
- 이 설계로는 동서 방향 일반화를 평가할 수 있지만, 남북 방향으로 나누면 어떻게 되는지는 이 설계만으로 알 수 없음
- 블록 크기의 기준은 공간 자기상관이 사라지는 거리(range)임 — 블록 한 변을 이보다 크게 잡아야 학습 블록과 검증 블록 사이의 상관이 실질적으로 끊어짐

10.2 성능을 세 지표로 읽는다

$$R^2 = 1 - [\sum_i (y_i - \hat{y}_i)^2] / [\sum_i (y_i - \bar{y})^2]$$

- $R^2 = 0$ 이면 검증자료의 평균을 예측하는 것과 같은 수준
- 음수이면 평균 예측보다도 나쁨
- R^2 로는 오차의 실제 크기를 cm 단위로 알 수 없으므로 평균절대오차(MAE)를 함께 봄

$$MAE = (1 / n) \times \sum_i |y_i - \hat{y}_i|$$

- 두 지표는 오차를 다르게 셈 — R^2 는 제곱을 쓰므로 큰 오차 하나가 지표를 크게 끌어내리고, MAE는 모든 오차를 같은 비중으로 더함

- 정책 임계값이 정해져 있다면 세 번째 지표가 필요함 — 침수심 30cm가 통행 제한 기준이라면, 실제 32cm를 28cm로 예측한 오차와 실제 12cm를 8cm로 예측한 오차는 크기가 같아도(4cm) 결정에 미치는 영향이 다름. 앞의 오차는 통행 제한 여부를 뒤집고 뒤의 오차는 아무 결정도 바꾸지 않음

10.3 잔차가 어디에 몰려 있는지 본다

- 성능지표로는 오차의 크기만 알 수 있고 오차가 어디에 몰려 있는지는 알 수 없음
- 예측 후에는 잔차 $e_i = y_i - \hat{y}_i$ 를 지도에 표시함
- 잔차의 뭉침 정도는 Moran I로 수치화함(Moran, 1950)

$I = (n / \text{전체 공간가중치}) \times (\text{공간 잔차곱} / \text{잔차제곱합})$

- 공간 잔차곱은 이웃한 두 격자의 잔차 편차를 곱해 더한 값
- 두 격자가 모두 과소예측(양의 잔차)이면 곱이 양수가 되고, 한쪽은 과소·다른 쪽은 과대이면 음수가 됨
- I가 양수이면 비슷한 부호의 잔차가 이웃끼리 모여 있다는 뜻
- I가 유의하게 양수로 나오면 다음 순서로 대응함
 1. 잔차지도에서 뭉친 위치를 확인하고 그 지역의 공통 조건을 찾음
 2. 그 조건이 배수관망, 토양, 하천 단면처럼 자료로 확보 가능한 요인인지 검토함
 3. 확보 가능하면 피쳐로 추가하고, 불가능하면 공간효과를 명시적으로 모형에 넣는 공간통계모형을 검토함
 4. 어느 쪽도 어려우면 해당 지역을 예측 신뢰도가 낮은 구역으로 표시해 결과에 함께 보고함
- 최종 성능표에는 공간 CV의 R^2 , MAE, 임계값 오분류율, 잔차 Moran I를 함께 둠
- 네 값이 모두 있어야 "오차가 얼마나 크고, 어느 결정을 뒤집으며, 어디에 몰려 있는가"에 답할 수 있음

11. 예측에 불확실성을 붙인다

11.1 정규화 conformal 예측구간

- 점예측 $\hat{y}_i = 30\text{cm}$ 만으로는 모델이 얼마나 틀릴 수 있는지 알 수 없음
- **정규화 conformal 예측**은 분포 가정 없이 예측구간을 만들되, 위치마다 오차 규모가 다를 수 있다는 점을 반영함(Lei et al., 2018; Romano et al., 2019)
 1. 학습에 쓰지 않은 보정자료에서 절대잔차를 계산함 — $r_i = |y_i - \hat{y}_i|$
 2. 입력조건에서 예상되는 오차 규모 $\hat{\sigma}(x_i)$ 를 추정함 — 절대잔차를 목표값으로 두고 같은 입력변수로 회귀모형을 하나 더 적합함
 3. 절대잔차를 σ 로 나눈 정규화 부적합 점수를 만들 — $s_i = |y_i - \hat{y}_i| / \hat{\sigma}(x_i)$
 4. 보정자료에서 s_i 의 $(1 - \alpha)$ 분위수를 구함 — 예측구간은 $[\hat{y}(x) - q(1 - \alpha)\hat{\sigma}(x), \hat{y}(x) + q(1 - \alpha)\hat{\sigma}(x)]$

- 예측 침수심이 30cm, $\hat{\sigma}(x) = 4$, $q(0.9) = 1.5$ 라면 구간 반폭은 $4 \times 1.5 = 6\text{cm}$ 이고 90% 예측구간은 24–36cm
- 같은 모형에서 $\hat{\sigma}(x) = 12$ 인 격자라면 반폭이 18cm로 늘어 12–48cm가 됨
- 두 격자의 점예측은 같아도 결정에 쓸 수 있는 정보량이 다름
- 실습 결과 — 11-1-flood-risk-priority.log

지표	값
90% 예측구간 경험적 포함률(OOF)	0.903(목표 0.90)
구간 반폭 중앙값	3.1cm
구간 반폭 범위	[1.3cm, 18.7cm]

- 목표 포함률 0.90에 실제 0.903으로 거의 맞아떨어짐
- 다만 반폭의 범위가 1.3cm에서 18.7cm까지 벌어져 있음 — 어떤 격자는 예측을 꽤 믿을 수 있고 어떤 격자는 그렇지 않다는 뜻

- σ 를 같은 OOF 잔차로 적합했으므로 이 포함률은 다소 낙관적임
- 엄밀한 실무는 학습·보정·시험을 세 부분으로 나누는 split conformal을 씀
- 자료가 적어 3분할이 어려우면 교차적합 conformal을 쓰고, 그 사실과 함께 포함률을 보고함

11.2 적용가능영역

- 예측구간은 모델이 학습한 범위 안에서 생기는 오차를 다룸
- 새 지점의 입력조건이 학습자료와 크게 다르면 예측구간 자체를 신뢰하기 어려움
- **적용가능영역(AoA)**은 이 외삽 문제를 표시함(Meyer & Pebesma, 2021)

$DI(x)$ = 새 지점 x 와 가장 가까운 학습지점의 가중거리 / 학습자료 내부의 평균거리

- 분자는 새 지점이 학습자료에서 떨어진 거리, 분모는 학습자료 자체가 퍼진 정도
- DI 가 1이면 새 지점이 학습표본들 사이의 평균 간격만큼 떨어져 있다는 뜻이고, 값이 커질수록 학습자료가 다루지 않은 조건임
- 실습 결과 — DI 임계값($Q3 + 1.5 \cdot IQR$) = **0.24**, 적용가능영역 밖 격자 = **9개**
- AoA 판정은 예측값을 지우는 데 쓰지 않고 별도 열로 남김 — 적용범위 밖 격자에도 예측값은 나오지만, 그 값을 근거로 자원을 확정 배분하지 않고 추가 관측 대상으로 분류함
- 불확실성과 AoA를 반영한 행정구역 우선순위(11-1-flood-risk-priority.log)

admin	mean_pred_depth	mean_pi_half	low_conf_cells	aoa_out_cells	priority_rank	confidence
2	23.49	5.46	32	1	1	낮음
3	22.25	3.79	12	2	2	중간
4	11.16	3.27	15	1	3	높음
1	10.87	4.12	18	2	4	낮음
5	8.19	2.96	8	1	5	높음
0	8.00	3.27	15	2	6	높음

- 이 표를 읽는 순서 — 예측값이 가장 높은 admin 2가 순위 1위인데 신뢰등급은 '낮음'
- 예측 침수심이 높다고 곧바로 우선 집행하지 않고, 신뢰가 낮은 곳은 확정 배분 전에 추가 관측이나 현장확인으로 보완함
- 이 판단 기준을 13절의 조치 매트릭스에서 표로 정리함

12. 결과를 표로 만들고 읽는다

12.1 격자 단위 예측표

- 앞의 다섯 단계를 거치면 격자마다 예측값, 예측구간, 적용가능영역 판정이 붙음
- 이 세 값을 하나의 표로 모으는 것이 결과 도출의 첫 작업

열	내용	쓰임
cell, row, col	격자 식별자와 좌표	지도 결합, 재현
elevation, imperv, rainfall	주요 입력변수	예측 근거 확인, 현장 대조
pred	예측 침수심	순위 산정
pi_low, pi_high	예측구간 하한·상한	임계값 판정
pi_half	구간 반폭	신뢰등급 산정
aoa_di, inside_aoa	비유사도지수와 적용범위 판정	외삽 표시
priority_rank	예측값 기준 순위	배분 후보 정렬

- 입력변수 열을 남기는 이유는 현장 확인 때문 — 상위 순위 격자를 실무자가 검토할 때 "표고 1.8m, 불투수면 0.64, 강우 102mm"라는 조건을 함께 보면 예측이 지형 조건과 맞는지 즉시 판단할 수 있음
- 예측값만 있는 표는 검토가 불가능함

- 실습 결과 — 격자 우선순위 상위 5(11-1-flood-risk-priority.log)

cell	row	col	elevation	imperv	rainfall	pred_depth	priority_rank
142	9	7	1.77	0.64	101.84	34.52	1
277	18	7	2.72	0.75	126.23	34.18	2
202	13	7	3.08	0.51	120.76	31.91	3
187	12	7	0.00	0.65	114.38	31.90	4
127	8	7	6.18	0.81	114.14	31.30	5

- 상위 5개의 예측값이 34.52~31.30cm로 촘촘히 몰려 있음
- 이 정도 촘촘한 순위는 모델의 오차 범위 안에 있을 수 있으므로, 1위와 5위를 엄밀히 구분하지 않고 상위 그룹으로 묶어 처리하는 편이 안전함

12.2 행정구역 집계표

- 격자 예측표를 7.2의 가중치로 행정구역에 모음
- 집계표에는 예측값 평균 외에 두 종류의 열을 더함

열	계산	해석
mean_pred	구역 내 격자 예측값의 가중평균	구역 전체의 위험 수준
high_risk_cells	예측값이 전체 상위 25%인 격자 수	구역 안의 집중도
mean_pi_half	구간 반폭의 평균	예측의 평균 정밀도
low_conf_cells	신뢰등급 낮음 격자 수	추가 관측 필요 규모
aoa_out_cells	적용범위 밖 격자 수	외삽 구간의 규모
priority_rank	mean_pred 기준 순위	배분 순서 후보
confidence	mean_pi_half 3분위 구간	순위 확정 가능 여부

- 평균만 보면 구역 안의 편차가 사라짐 — 예측 침수심이 상위 25%인 격자가 그 구역에 몇 개 있는지를 함께 살펴야, 평균이 같은 두 구역이라도 고위험 격자가 많은 구역과 적은 구역을 구분할 수 있음
- 집계 결과는 지도와 표를 함께 냄 — 지도에서 공간 패턴을 읽고, 표에서 순위와 수치를 확정함

12.3 결과를 읽는 네 가지 순서

- 첫째, 단순 기준과 비교함.** 모델을 쓰지 않고 표고만으로 저지대를 고르면 어떤 결과가 나오는지 먼저 계산함. 5절에서 확인했듯 저지대 75개 격자의 평균 침수심은 25.1cm, 나머지는 10.3cm. 모델의 기여는 이 기준선을 넘는 부분에서 나오므로, 기준선 자체를 먼저 수치로 확보함
- 둘째, 순위의 안정성을 봄.** 12.1에서 확인한 상위 5개 격자의 예측값(34.52~31.30cm)처럼 촘촘하면 1위와 5위의 차이는 모델의 오차 범위 안에 있을 수 있음. 이때는 순위를 그대로 배분 순서로 쓰지 않고 상위 그룹으로 묶어 처리함
- 셋째, 임계값 주변을 확인함.** 정책 기준이 30cm라면 예측값이 28~32cm인 격자를 따로 뽑음. 이 격자들은 예측이 조금만 틀려도 조치 대상 여부가 바뀜. 예측구간이 임계값을 걸치는 격자는 현장 확인 대상으로 분류함
- 넷째, 예상과 다른 결과를 그대로 기록함.** 고지대인데 상위 순위에 오른 격자가 있다면 불투수면 비율이나 국지 강우가 원인일 수 있음. 원인을 확인해 설명 가능하면 결과를 유지하고, 설명할 수 없으면 자료 오류를 의심해 입력값을 검토함. 결과를 알고 난 뒤 예상을 수정하거나 사후 해석을 덧붙이지 않고 불일치를 그대로 보고함

13. 결정 규칙을 만들고 감시한다

13.1 조치 매트릭스

- 예측값, 구간 폭, 적용범위 판정은 서로 다른 질문에 대응함
- 예측값은 위험 수준, 구간 폭은 예상 오차의 크기, 적용범위 판정은 그 예측을 신뢰할 근거의 유무
- 세 값의 조합마다 조치가 달라짐

예측 위험	구간 폭	AoA	조치
높음	좁음	안	우선 집행 후보로 확정
높음	넓음	안	순위는 유지하고 현장확인 후 확정
높음	무관	밖	추가 관측과 정밀 조사 우선
낮음	넓음	안	표본 확인 후 낮은 순위 유지 여부 판정
낮음	좁음	안	일반 모니터링

- 11절에서 본 admin 2가 여기 해당함 — 예측 위험은 1순위이지만 신뢰등급이 '낮음'이므로 세 번째 줄에 해당하는 조치(추가 관측·정밀 조사)로 다뤄야 함
- "높음"과 "낮음"의 경계는 정책 임계값이 있으면 그 값을 우선하고, "좁음"과 "넓음"의 경계는 구간 반폭의 3분위를 쓰되 절대 기준(예: 5cm 이상은 무조건 넓음)을 함께 두면 해석이 안정됨

- 예측 위험이 높아도 적용범위 밖이면 집행을 미룸 — 이때 자원을 배분하지 않는 것이 아니라 배분할 자원의 종류를 바꿈. 시설 공사 예산이 아니라 관측 장비와 현장 조사 인력을 먼저 보냄

13.2 감사 항목

- 배치 후에는 예측 성능만 감시하지 않음
- 예측이 만든 자원 배분이 실제 필요와 어긋나는지, 특정 지역이나 집단에 치우치는지를 함께 봄

범주	지표	확인 주기
예측 성능	공간 CV R^2 , MAE, 임계값 오분류율	자료 갱신 시
공간 진단	잔차 Moran I, 잔차지도	자료 갱신 시
적용범위	적용범위 밖 단위 수와 위치 변화	자료 갱신 시
배분 결과	지역별 자원 투입량, 집중도(Gini)	분기
집단 형평	집단별 예측오차, 차별적 영향	분기
되먹임	배분이 다음 관측에 미치는 영향	반기

- 마지막 행이 특히 중요함 — 예측 결과로 자원을 배분하고 그 배분이 다음 시점의 관측자료를 바꾸면, 모형이 자기 결정의 흔적을 학습함
- 침수 예측에서는 이 문제가 약함. 펌프를 배치해도 그 지역의 강우와 지형은 변하지 않음
- 반면 치안과 보험에서는 이 되먹임이 분석의 중심 문제가 됨 — 14절에서 두 사례를 봄
- 집단 형평 지표는 결과지표만으로 부족함. 거짓양성률을 계산하려면 실제 음성 여부를 알아야 하는데, 관측 라벨이 오염된 자료에서는 그 값을 모름. 관측 라벨을 진실로 두고 계산한 지표는 라벨의 편향을 그대로 물려받으므로, 결과지표와 함께 투입량·집중도·관측과정의 변화를 감사 대상에 넣음

14. 같은 절차를 다른 위험에 적용하기

- 앞의 일곱 단계는 침수 예측을 기준으로 설명함
- 같은 절차를 다른 자료에 적용하면 일부 단계가 달라짐 — 어느 단계에 무엇을 추가해야 하는지 세 사례로 확인함

14.1 위성영상으로 관측하기

- 위성영상은 두 가지로 씀 — 위험요인을 예측하는 입력이 되기도 하고, 재난 발생 뒤의 피해를 관측하는 라벨이 되기도 함

- 두 역할을 구분해야 7절의 대상 정의가 어긋나지 않음. 홍수 전 토지피복과 불투수면은 예측 입력이고, 홍수 직후 SAR에서 뽑은 침수범위는 대응지도이자 향후 모형의 검증 라벨
- **SAR**는 위성이 마이크로파를 보내고 지표에서 돌아온 후방산란을 측정하는 능동 센서
- 마이크로파는 구름의 영향을 적게 받고 태양광이 없어도 관측할 수 있어, 폭우와 구름이 동반되는 홍수 시점에 광학영상보다 관측 가능성이 높음(ESA, n.d.)
- 침수 판별의 물리적 근거는 후방산란의 세기 — 잔잔한 수면은 입사한 전파를 위성 반대 방향으로 반사하므로 후방산란이 낮게 나타나는 경우가 많음
- 다만 이 관계는 조건부임. 바람이 강한 수면은 거칠어져 밝아지고, 아스팔트·레이더 그림자·평탄한 나대지도 어둡게 나타남. 어두운 픽셀을 모두 물로 분류하면 안 되고 마스킹이 필요함
- 일반적인 SAR 침수 분석 절차
 1. 홍수 전·후 영상을 같은 좌표와 픽셀 격자로 정합함
 2. 방사보정과 지형보정을 거쳐 후방산란계수 σ^0 를 계산함
 3. 홍수 전후의 후방산란 변화량 또는 분류모형으로 침수 후보를 구함
 4. 영구수역, 급경사, 레이더 그림자처럼 오분류가 예상되는 영역을 마스킹함
 5. 현장 침수경계 또는 독립 영상과 비교해 precision, recall, IoU를 계산함
 6. 픽셀 침수 결과를 건물·격자·행정구역으로 집계함
- 세그멘테이션 모형이 관여하는 곳은 3단계뿐 — 정합·보정·마스킹·검증을 생략하면 픽셀 분류 성능이 높아도 피해지도를 신뢰할 수 없음
- 6단계의 집계 단위는 7.2에서 정한 집행 단위와 맞춤
- 산불과 산사태도 같은 골격을 씀
- 산불 피해는 산불 전후의 정규화 연소비율을 비교해 파악함(USGS, n.d.)

$$NBR = (NIR - SWIR) / (NIR + SWIR)$$

$$dNBR = NBR(\text{산불 전}) - NBR(\text{산불 후})$$

- 건강한 식생은 근적외선 반사가 높고, 연소된 지표는 단파적외선 반사가 상대적으로 높아짐
- dNBR가 크면 연소로 인한 분광 변화가 컸다는 뜻이며, 피해등급 임계값은 센서·식생·지역에 따라 검증해야 하고 하나의 값을 모든 지역에 적용하면 안 됨
- 산사태 분석에서는 표고 자체보다 경사, 곡률, 집수면적, 토양, 지질, 식생과 선행강우를 결합함
- 정적 취약성지도(장기간 잘 변하지 않는 지형·지질 조건)와 실시간 경보모형(최근 강우와 토양수분처럼 시간에 따라 변하는 조건)을 구분함
- 국내 산림청 산사태정보시스템에서 산사태 위험지도를 제공하므로 실제 입력자료와 공공 산출물의 형식을 확인할 수 있음(산림청, n.d.)

14.2 예측적 치안, 되먹임을 시뮬레이션으로 확인하기

- 예측적 치안은 관측 행위가 라벨을 바꾸는 대표 사례
- 국내 경찰청은 범죄·신고·환경자료로 위험을 예측해 순찰을 지원하는 Pre-CAS를 2021년 전국으로 확대함(경찰청, 2021)
- 과거 체포기록과 예측 순찰이 특정 지역을 반복 표적화할 수 있다는 문제는 Lum과 Isaac(2016)이 오클랜드 사례와 시뮬레이션으로 제시함
- 지역 i , 시점 t 의 실제 범죄를 C_{it} , 순찰량을 P_{it} , 기록된 범죄를 R_{it} 로 씀

$R_{it} \sim \text{Detection}(C_{it}, P_{it})$

- 같은 C_{it} 에서도 P_{it} 가 늘면 적발 가능성이 커져 R_{it} 가 늘어남
- 모델이 R_{it} 를 예측하고 그 값에 비례해 다음 순찰을 배정하면

$P_{i,t+1} \propto \hat{R}_{it}$

- 두 식을 연결하면 순찰이 기록을 늘리고, 늘어난 기록이 다음 순찰을 늘리는 순환이 만들어짐
- 2절의 마이크·스피커 비유가 가리키는 구조가 이것임
- 이 순환의 결과를 확인하는 시뮬레이션 — 16×16 격자 256개에서 8라운드 반복
- 두 집단의 실제 범죄율은 평균 8.4건(A)과 8.5건(B)으로 거의 같게 설정하고, 초기 기록만 집단 A 지역에서 크게 만듦

1. 누적 기록 R_{it} 로 위험모형을 학습함
2. 예측값에 비례해 순찰 $P_{i,t+1}$ 을 배정함
3. 순찰량에 따라 적발확률을 바꾸고 새 기록을 만듦
4. 새 기록을 다음 라운드 학습자료에 추가함

$$DI(A) = [P(A) / P(\text{전체})] / [C(A) / C(\text{전체})]$$

- 실습 결과 — 11-2-predictive-policing-bias.log

라운드	기록 기준 R^2	순찰-실제 위험 상관	순찰 Gini	차별적 영향
0	0.823	0.397	0.247	1.370
1	0.924	0.537	0.436	1.574
2	0.972	0.530	0.639	1.793
3	0.988	0.511	0.753	1.893
4	0.994	0.493	0.825	1.943
5	0.998	0.467	0.875	1.971
6	0.998	0.447	0.896	1.990
7	0.999	0.429	0.917	2.001

- 네 열이 서로 다른 방향으로 움직임
- 기록 기준 R^2 는 0.823에서 0.999로 올라감 — 성능표만 보면 모형이 계속 좋아진 것으로 읽힘
- 그러나 순찰과 실제 위험의 상관은 1라운드의 0.537에서 시작해 마지막에 0.429로 떨어짐
- 순찰 Gini는 0.247에서 0.917로 올라 순찰이 소수 지역에 집중되고, 차별적 영향은 1.370에서 2.001로 커짐
- 마지막 라운드에서 집단 A는 실제 위험 비중의 두 배에 해당하는 순찰을 받음. 실제 범죄율은 두 집단이 8.4 대 8.5로 거의 같았는데도 그러함
- 성능지표 하나로 모형을 판정하면 안 되는 이유가 이 표에 그대로 담겨 있음. 13.2의 감사표에서 배분 결과와 집단 형평을 별도 범주로 둔 근거이기도 함
- 되먹임을 끊는 완화 장치

장치	바꾸는 계산 단계	확인할 지표
단속 노출 보정	기록을 순찰량으로 정규화	순찰-독립 위험자료 상관
독립 피해조사	순찰과 무관한 라벨 추가	기록자료와 독립자료의 격차
탐색 순찰	일부 순찰을 예측값과 무관하게 배정	Gini와 미관측지역 정보량
집중 상한	지역별 최대 순찰량 제한	집단별 차별적 영향
독립 감사	지역·집단·시간별 결과 공개	모든 지표의 추이

- 기록을 순찰량으로 나누는 보정만으로는 편향이 모두 사라지지 않음 — 신고 가능성과 범죄 유형별 적발 가능성도 지역과 집단에 따라 다르기 때문
- 독립 피해조사나 표본조사처럼 순찰과 관측 과정이 다른 자료를 함께 쓰는 편이 확실함

전체 코드는 [lecture_practice/chapter11/code/11-2-predictive-policing-bias.py](#) 참고

14.3 보험 위험모형, 가입이 라벨을 지우는 구조

- 보험은 표본 선택이 라벨을 지우는 사례
- 재해보험의 catastrophe model은 위험현상, 노출자산, 취약성을 결합해 손실을 추정함(Grossi & Kunreuther, 2005)

- 건물 i 의 실제 피해확률을 $Y_{i,true}$, 보험 가입 여부를 S_i , 피해를 청구하는 과정을 Q_i 로 씀

$$Y_i^{obs} = Y_{i,true} \times S_i \times Q_i$$

- $S_i = 0$ 이면 실제 피해가 있어도 보험자료에는 라벨이 없음
 - $S_i = 1$ 이어도 자기부담금보다 작은 피해를 청구하지 않으면 $Q_i = 0$ 이 되어 관측값이 0으로 남음
 - 두 경로 모두 실제 피해가 있는 건물을 "피해 없음"으로 기록함
 - 실습 데이터 — 300개 격자에 건물 500채(11-0-simdata-prep.log)
 - 가입률 55.4%, 저소득 비율 28.4%
 - 저소득 가입률 42.3%, 고소득 가입률 60.6%
 - 소액 피해 미신고(가입자 중) 21건(저소득 가입자의 35.0%)
 - 이 값은 교육용 시뮬레이션의 설계값이며 실제 보험시장의 추정치가 아님
 - 성능 차이 하나만으로는 원인을 특정할 수 없음. 가입자 모형과 전체 모형의 차이에는 세 요인이 동시에 들어감
1. 가입 여부가 위험과 관련된 선택편향
 2. 학습표본이 500채에서 277채로 줄어든 표본 크기 효과
 3. 실제 피해 대신 청구기록을 쓰는 라벨 왜곡
- 세 요인을 분리하려면 대조군을 둬

조건	표본	라벨	분리하려는 요인
A	전체 500채	실제 피해확률	기준
B	가입자 277채	청구기록	선택+표본감소+라벨왜곡
C	무작위 277채	청구기록	표본감소+라벨왜곡

- B와 C의 차이가 가입 선택 고유의 몫이고, C와 A의 차이는 표본 감소와 라벨 왜곡의 합
- C는 무작위 추출이므로 20회 반복해 평균과 표준편차를 함께 냄
- 실습 결과 — 세 조건의 성능을 같은 채점 대상(전체 500채의 실제 피해확률)으로 비교함(11-3-insurance-risk-grading.log)

지표	완전 모형(A)	관측 모형(B)	무작위 동일크기 대조군(C)
전체 R ²	0.890	0.669	0.658(SD 0.030, 20회)
저소득 건물 R ²	0.888	0.588	—
위험 과소평가 비율	2.0%	19.2%	—

- 관측 모형 0.669와 대조군 0.658의 차이는 0.011 — 가입 선택만 제거해도 성능이 거의 회복되지 않는다는 뜻
- 완전 모형 0.890과 대조군 0.658의 차이는 0.231로 훨씬 큼 — 이 몫은 표본 감소와 라벨 왜곡에서 옴
- 두 몫을 섞어 "가입자 편중 때문에 성능이 나빠졌다"고 읽으면 틀림
- 라벨 왜곡의 규모는 직접 셀 수 있음 — 소액 피해 미신고는 전체 48건이고, 그중 가입자 21건이 학습자료에 0으로 들어감
- 청구 기록을 목표값으로 두고 가입자 277채 안에서만 채점하면 교차검증 R²가 0.520으로 떨어짐
- 같은 모형을 전체 건물의 실제 피해확률로 채점한 0.669와 값이 다른 이유는 채점 대상이 다르기 때문 — 성능을 보고할 때 채점 대상을 함께 적지 않으면 두 값이 뒤섞임

• 모형 비교에서는 시험대상을 같게 맞춤

- 완전 모형은 교차검증 예측으로 평가하고 관측 모형은 가입자료로 적합한 뒤 전체에 적용하면, 관측 모형의 학습표본 일부가 평가자료에 포함됨
 - 조건을 바꿀 때는 학습자료만 바꾸고 시험자료는 고정함
- 예측값을 4등급으로 나누고 등급별 보험료 배수를 정함 — 등급표에는 위험 지표뿐 아니라 집단 구성 비율을 함께 실음

등급	등급명	건물 수	평균 예측 침수확률	보험료 배수	저소득 비율	미가입 비율
1	최고위험	125	0.404	3.0배	44.8%	54.4%
2	고위험	125	0.222	2.0배	26.4%	40.8%
3	중위험	125	0.145	1.5배	13.6%	48.0%
4	저위험	125	0.073	1.0배	28.8%	35.2%

- 최고위험 등급의 저소득 비율 44.8%는 저위험 등급의 28.8%보다 높음
- 소득변수를 모델에 넣지 않아도 이런 격차가 생김 — 표고, 하천거리, 주택유형이 소득분포와 연관되면 소득을 직접 쓰지 않은 모형에서도 집단별 가격 격차가 생길 수 있음(Prince & Schwarcz, 2020)
- 입력변수 목록만 검사하지 않고 최종 오차와 가격의 집단별 분포를 감사함
- 전체 성능이 비슷해도 특정 집단에서 오차가 한 방향으로 몰릴 수 있음

- 관측 모형과 완전 모형의 등급이 어긋난 건물은 전체의 38.0%. 집단별로 보면 저소득 30.3%, 고소득 41.1%로 고소득 쪽이 높음
- 그러나 방향을 보면 성격이 다름 — 저소득 건물에서는 과소평가 26건, 과대평가 17건으로 실제보다 덜 위험하다고 판정한 경우가 많음
- 위험을 낮게 본 건물은 보험료가 싸지만 재난 시 보장이 부족해짐. 집단별 감사에서 평균 오차만 보고 방향을 보지 않으면 이 차이를 놓침
- 보험료는 위험등급과 불확실성 로딩을 분리해 계산함

보험료_i = 기본보험료 × 위험배수_i × 불확실성로딩_i

- 위험배수가 3.0이고 불확실성 로딩이 1.15이면 최종 배수는 $3.0 \times 1.15 = 3.45$
- 위험배수는 기대손실 수준에 대응하고, 불확실성 로딩은 예측오차가 큰 경우의 안전마진
- 두 값을 모두 예측 위험의 함수로 정하면 위험과 불확실성을 중복 반영하므로, 불확실성은 별도 자료의 잔차에서 추정함
- 실습 결과 — 11절의 정규화 conformal을 적용하면 $\hat{q} = 1.601$, 가입자 기준 포함률 0.906(목표 0.90)
- 구간 반쪽의 중앙값은 0.116이고, 상위 25%를 저신뢰로 분류하는 기준은 0.141
- 저신뢰로 분류된 건물 125채에 보험료 $\times 1.15$ 를 적용함
- 여기서 확인할 값이 하나 있음 — 구간 폭과 예측값의 순위상관은 **0.236**
- 이 값이 1.0에 가까우면 "위험이 높은 건물이 곧 불확실한 건물"이라는 뜻이 되어 불확실성 로딩이 위험배수와 중복됨
- 0.236은 두 값이 상당 부분 독립이라는 뜻이므로 로딩을 별도로 계산할 근거가 됨
- 실제로 저신뢰 건물 가운데 최고위험 등급은 43.2%에 그침 — 나머지 56.8%는 위험이 중간 이하이면서 예측이 불확실한 건물
- 마지막으로 확인할 되먹임 — 진짜 고위험 건물 125채 가운데 70채, 즉 ****56.0%****를 미가입으로 설정함
- 이 건물들은 관측 모형의 학습자료에 들어가지 않으므로 그 지역의 위험이 과소평가됨
- 과소평가된 지역에는 상품이 설계되지 않고, 상품이 없으면 가입이 늘지 않으며, 가입이 없으면 기록이 계속 부족함
- 14.2의 순찰-기록 순환과 같은 구조 — 위험 기반 가격이 특정 저소득 지역에 집중되면 보험 접근성이 낮아지고, 접근성 저하가 다시 자료 공백을 키움

전체 코드는 [lecture_practice/chapter11/code/11-3-insurance-risk-grading.py](https://github.com/lecture_practice/chapter11/code/11-3-insurance-risk-grading.py) 참고

15. 방법 점검표

- 새 위험예측 과제를 시작할 때 아래 표를 먼저 채움

- 채우지 못한 행이 있으면 그 단계의 결정 근거가 아직 없다는 뜻

단계	항목	기록할 내용
1	분석 질문	예측, 피해 관측, 자원 배분, 가격 결정 중 무엇인가
1	실제 대상 y	실제로 알고 싶은 위험·피해 값
1	관측 라벨 y^{obs}	센서·신고·단속·청구 중 어떤 과정으로 기록되는가
1	분석 단위	픽셀·격자·건물·구역·행정구역·도로망
1	집계 규칙	면적·인구·건물·가액 중 어떤 가중치를 쓰는가
2	공간 관계 W	인접·거리·상하류·도로망 중 무엇인가
2	예측 시점	어느 시점의 정보로 어느 시점을 예측하는가
2	입력 가용성	모든 입력이 예측 시점에 실제로 존재하는가
3	기준모형	평균·선형·가법·물리모형 가운데 무엇과 비교하는가
3	후보모형	공간통계·트리 ML·영상모형을 왜 선택하는가
4	검증 설계	블록·버퍼·구역외 검증 가운데 배치 상황과 맞는 것
4	성능지표	R^2 , MAE, 임계값 오분류율, 집단별 오차
4	공간 진단	잔차 Moran I와 잔차지도에서 무엇을 확인하는가
5	불확실성	예측구간을 어떤 독립 보정자료로 계산하는가
5	적용범위	학습자료 밖의 위치를 어떻게 표시하는가
6	산출물	단위별 예측표와 집계표에 어떤 열을 담는가
6	대조군	주장하는 메커니즘만 제거한 비교 조건이 있는가
7	결정 규칙	집행·현장확인·추가 관측·보류의 기준은 무엇인가
7	감사 항목	지역·집단·시간별로 어떤 지표를 반복 점검하는가

- 이 표를 채우면 자연위험과 사회적 위험을 같은 방식으로 처리하는 오류를 줄일 수 있음
- 침수 분석에서는 공간 흐름·공간 검증·센서 오차가 중심이 되고, 치안 분석에서는 실제 위험과 적발 기록의 차이·순찰과 기록의 되먹임이 중심이 되며, 보험 분석에서는 가입 선택·청구 라벨·집단별 가격과 오차가 중심이 됨
- 보고서를 쓸 때는 확정값과 진단값을 구분함 — 교육용 근사를 썼다면 정식 방법과 다른 지점을 계산식 바로 아래에 적고, 시뮬레이션의 설계값은 실제 지역이나 시장의 경험값으로 해석하지 않음

- **활동 1(15분) — 저지대 기준선을 직접 확인하기**

- `python lecture_practice/chapter11/code/11-1-flood-risk-priority.py` 를 실행
- 저지대 75개 격자의 평균 침수심이 25.1cm, 나머지가 10.3cm로 나오는지 확인
- 표고만으로 대응 우선순위를 정하면 놓치는 지역이 무엇인지 피쳐 중요도표(depth_lag 0.569)를 근거로 한 문장으로 설명

- **활동 2(20분) — 랜덤 CV와 블록 CV 차이 재현하기**

- 같은 로그에서 랜덤 CV R^2 0.874와 공간 블록 CV R^2 0.816을 비교
- 두 값의 차이(+0.058)가 왜 "성능 향상"이 아니라 "검증 설계의 문제"인지 목표값 누수 개념으로 설명
- 코드에서 `spatial_block_folds` 의 `n_blocks` 를 3으로 바꿔 다시 실행하고 R^2 가 어떻게 달라지는지 기록

- **활동 3(20분) — 예측적 치안 되먹임 관찰하기**

- `python lecture_practice/chapter11/code/11-2-predictive-policing-bias.py` 를 실행
- 라운드 0과 라운드 7의 표를 나란히 두고, R^2 는 올라가는데 순찰-실제 위험 상관은 왜 내려가는지 표 안의 네 지표로 설명
- 초기 진짜 범죄율이 8.4 대 8.5로 거의 같았다는 점을 다시 확인하고, 차별적 영향이 커진 원인이 진짜 위험 차이가 아니라 무엇인지 적음

- **활동 4(15분) — 대조군으로 원인 분리하기**

- `11-3-insurance-risk-grading.log` 에서 완전 모형 0.890, 관측 모형 0.669, 대조군 0.658 세 값을 옮겨 적음
- 가입 선택의 몫(0.011)과 라벨·표본의 몫(0.231)을 각각 계산하고, 어느 쪽이 성능 저하의 주된 원인인지 판정

- **토론 1:** 관측 라벨과 실제 위험의 거리가 짧은 자료(침수)와 먼 자료(치안, 보험)를 구분하지 않고 같은 절차를 적용하면 어떤 문제가 생길까? 이 장에서 다룬 세 사례 중 어느 것이 가장 위험할까?

- **토론 2:** 예측 위험이 높지만 적용가능영역 밖인 지역(admin 2)에 대해, 자원을 배분하지 않는 대신 "관측 장비를 먼저 보낸다"는 결정은 실무에서 어떤 반발을 부를 수 있을까? 그 반발에 어떻게 답할 수 있을까?

- **토론 3:** 보험 등급표에서 소득변수를 모델에 넣지 않았는데도 최고위험 등급의 저소득 비율(44.8%)이 저위험 등급(28.8%)보다 높았다. 이 결과를 근거로 "이 모델은 소득을 차별하지 않는다"고 주장할 수 있을까?

체크 질문

1. 실제 위험 y 와 관측 라벨 y^{obs} 는 어떻게 다르며, 침수·치안·보험 세 사례에서 이 거리가 각각 얼마나 벌어져 있는가?
2. 공간가중행렬을 만든 뒤 행 표준화를 하는 이유는 무엇인가?
3. 이웃의 현재 침수심을 입력변수로 쓰면 안 되는 이유는 무엇이며, 이 문제를 무엇이라 부르는가?
4. 실습에서 랜덤 CV의 $R^2(0.874)$ 가 공간 블록 CV의 $R^2(0.816)$ 보다 높게 나온 이유는 무엇인가?
5. 그래디언트 부스팅에서 학습률을 낮추면 나무 수를 늘려야 하는 이유는 무엇인가?
6. 정규화 conformal 예측구간에서 $\hat{\sigma}(x)$ 를 별도로 추정하는 이유는 무엇인가?
7. 적용가능영역(AoA) 판정에서 DI가 크다는 것은 무엇을 뜻하며, DI가 큰 격자를 어떻게 처리해야 하는가?
8. 실습에서 admin 2가 예측 위험 1순위이면서도 신뢰등급이 '낮음'으로 나온 이유는 무엇이며, 조치 매트릭스는 이 경우 어떤 조치를 권하는가?
9. 예측적 치안 시뮬레이션에서 R^2 는 계속 올라가는데 순찰-실제 위험 상관은 왜 떨어지는가?
10. 보험 위험모형에서 대조군(C)을 두는 이유는 무엇이며, B와 C의 차이는 무엇을 알려주는가?
11. 구간 폭과 예측값의 순위상관이 0.236으로 나온 것이 보험료 산정 방식(위험배수 $\times$ 불확실성 로딩)에 왜 중요한가?

과제

```
python scripts/submit.py 11 --id 학번 --name 이름
```

- 실행하면 `submissions/` 폴더에 `제출_11장_학번.md`가 생성되고 실행 결과가 붙어 있음
 - **눈여겨볼 곳은 검증 방식별 R^2 비교, 피쳐 중요도, 예측구간·AoA 표, 예측적 치안의 라운드별 지표, 보험 대조군 표**
 - 빈칸 네 개를 채움
1. 랜덤 CV $R^2(0.874)$ 와 공간 블록 CV $R^2(0.816)$ 의 차이(+0.058)가 뜻하는 바를 목표값 누수 개념으로 설명하라
 2. admin 2의 `mean_pred_depth(23.49cm)`와 `confidence('낮음')`를 옮겨 적고, 조치 매트릭스의 어느 줄에 해당하는지 밝히라
 3. 예측적 치안 시뮬레이션에서 라운드 0과 라운드 7의 차별적 영향(1.370 $\rightarrow$ 2.001)을 옮겨 적고, 진짜 범죄율이 거의 같았다는 사실과 이 결과가 어떻게 양립하는지 설명하라
 4. 보험 대조군 표에서 관측 모형(0.669)과 대조군(0.658)의 차이, 완전 모형(0.890)과 대조군의 차이를 각각 계산하고, 어느 요인이 성능 저하의 주된 원인인지 판정하라
- 3번과 4번이 핵심

- 1·2번은 표를 읽으면 나오지만 3·4번은 판단이 필요함

- **막혀도 제출함**

- 실행이 실패하면 오류 메시지가 파일에 담기고, 질문이 "어디서 막혔나"로 바뀜
- 실행 성공 여부로 점수를 매기지 않음

- **이 강의 세 시뮬레이션은 모두 시드가 고정된 교육용 자료를 씀**

- 실제 지역이나 실제 시장의 값이 아니므로, 숫자 자체를 현실의 위험 확률로 인용하지 않음

더 알아보기

- **공간 블록 교차검증의 근거 논문 읽기**

- Roberts et al.(2017), "Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure"(*Ecography*)를 읽으면 10절에서 다룬 블록 CV가 왜 필요한지 통계적으로 확인할 수 있음

- **예측적 치안 문제를 다른 사례로 확인하기**

- Lum & Isaac(2016), "To predict and serve?"(*Significance*)는 이 강의 14.2절 시뮬레이션이 기반한 오클랜드 실제 사례를 다룸

- **적용가능영역 개념을 원논문으로 확인하기**

- Meyer & Pebesma(2021), "Predicting into unknown space?"(*Methods in Ecology and Evolution*)는 11.2절에서 다룬 DI 계산의 정식 정의를 담고 있음

- **국내 산사태 위험지도를 직접 열어 보기**

- 산림청 산사태정보시스템(<https://sansatai.forest.go.kr>)에서 14.1절의 정적 취약성지도가 실제로 어떻게 제공되는지 확인할 수 있음