

12장 복지·보건 수요 분석, 라벨에서 배분까지

- 이 장에 나오는 예측 위험, 접근성, 검정통계량, 처치효과, 입지 선택 결과는 모두 `lecture_practice/chapter12/` 의 코드를 실제로 실행해 얻은 값
- 예시를 위해 지어낸 숫자는 없음(신호 결합의 조건부확률 계산 하나만 예외이며, 그 자리에서 "예시 계산"이라고 표시함)

1. 이 장의 핵심 질문

- 도움이 필요한데 신청하지 않은 가구는 행정 기록 어디에도 없음. 그런데도 "그 가구가 어디에 많은가"를 어떻게 추정할까?
- 병원까지 걸리는 시간과, 병원에 실제로 갈 수 있는 정도는 왜 다른 계산이 필요할까?
- 예측이 불확실한 지역을 만나면 "일단 제외한다"와 "먼저 가서 확인한다" 중 어느 쪽이 맞을까? 답은 분야마다 다름
- 감염이 몰린 자리를 "찾는" 일과 다음 주 발생을 "맞히는" 일은 왜 다른 계산일까?
- 방문상담을 받은 가구가 안 받은 가구보다 위기 점수가 높게 나온다면, 방문상담은 효과가 없는 것일까?
- 예측 점수를 그대로 행정 처분에 연결하면 왜 위험할까?
- 이 장은 위 여섯 질문에 하나씩 답하는 장이 아니라, **여섯 질문이 사실은 한 절차의 서로 다른 단계임을** 보여주는 장
- 복지 사각지대, 의료·돌봄 접근성, 감염병 확산, 개입 효과는 각각 다른 문제처럼 보이지만 전부 "개인 단위 신호를 공간 단위로 모아서, 그 위에서 계산하고, 계산 결과를 자원 배분으로 바꾸는" 같은 아홉 단계를 거침
- 이 장의 핵심 문장은 다음과 같음
- **관측된 기록과 실제 수요는 다른 값이고, 그 차이를 무시한 채 학습한 모형은 성능이 높아도 무엇을 예측한 것인지 알 수 없음**
- 같은 절차의 앞부분(집계·피쳐·접근성)은 민간 사업자의 입지 결정에도 그대로 쓰임
- 공급이 수요를 못 따라가는 지역은 행정에게는 확충 대상이고 사업자에게는 진입 후보임
- 12장 뒷부분에서 서울 동물병원 자료로 이 겹침을 직접 계산해 봄

2. 직관적 비유

- **관측 라벨 = 손전등이 비춘 자리만 찍힌 사진**
- 어두운 방에서 손전등을 들고 사진을 찍으면, 빛이 닿은 물건만 사진에 남고 빛이 안 닿은 물건은 사진에 아예 나타나지 않음
- 방문·상담·조사가 잦았던 지역은 위기가구 기록이 많이 남고, 조사가 뜸했던 지역은 위기가구가 있어도 기록이 남지 않음
- 대응을 하나씩 짚으면
 - 사진에 찍힌 밝은 물건 = 관측 라벨(발굴·신청·수급 기록)
 - 어둠 속에 있지만 안 찍힌 물건 = 실제로 존재하는 위기가구
 - 손전등을 얼마나 오래 어디에 비쳤는가 = 행정의 그 지역을 들여다본 정도(관심의 분포)
- 사진만 보고 "이 방에는 물건이 이만큼밖에 없다"고 결론 내리면 틀림. 사진은 물건의 분포가 아니라 **손전등의 분포**를 절반쯤 담고 있음. 12.7절(이 장 7절)에서 이 어긋남을 진단하는 절차를 다룸
- **2SFCA = 좌석이 한정된 식당들이 배후 동네에 나눠 주는 몫**
- 배달 식당 여러 곳이 있고, 각 식당은 하루에 처리 가능한 주문 수(좌석·조리 용량)가 정해져 있음
- 한 동네가 여러 식당의 배달 권역에 겹쳐 있으면, 그 동네는 여러 식당에서 조금씩 몫을 받을 수 있음
- 대응을 하나씩 짚으면
 - 식당의 하루 처리 용량 = 시설의 용량 S_j (병상 수·의사 수 등)
 - 한 식당이 배달권역 안 모든 동네에 나눠 줄 수 있는 1인분 몫 = 그 식당의 공급비 R_j
 - 한 동네가 여러 식당에서 받는 몫의 합 = 그 동네의 접근성 A_i
- 식당까지 걸리는 시간만 재면 "10분 거리에 식당 하나"와 "10분 거리에 식당 하나, 단 그 식당에 이미 주문이 몰려 있음"을 구분하지 못함. 2SFCA는 이 혼잡까지 계산에 넣음. 9절(이 장 9절)에서 실제 수식과 계산 예를 다룸
- **정규화 conformal 예측구간 = 일기예보에 붙는 오차범위**
- 일기예보는 "내일 강수확률 70%"만 말하지 않고, 예보관이 확신하는 날과 그렇지 않은 날이 있음. 확신이 낮은 예보에는 더 큰 우산을 챙기는 것이 안전함
- 예측 위험이 같은 16%로 나온 두 지역이라도, 한 곳은 오차범위가 좁고 다른 곳은 넓을 수 있음
- 대응을 하나씩 짚으면
 - 강수확률 70% = 점예측 $\hat{y}_i$
 - 예보관의 확신 정도 = 잔차 크기 모형 $\hat{\sigma}(x)$ 가 산출하는 값
 - 실제로 챙길 우산 크기 = 예측구간의 반폭

- 이 구간은 "느낌"이 아니라 과거 예측이 실제로 얼마나 틀렸는지(잔차)를 계산해 만든 값임. 11절(이 장 11절)에서 여섯 단계 계산 절차를 다룸
- **공간 스캔 통계 = 반경을 넓혀 가며 비추는 원형 탐조등**
- 어디에 이상이 몰려 있는지 모를 때, 작은 원부터 큰 원까지 반경을 바꿔 가며 자리를 옮겨 비추고, 그중 "평균보다 훨씬 밝은" 원을 찾음
- 대응을 하나씩 짚으면
 - 탐조등이 비추는 원의 위치와 반경 = 스캔 윈도우
 - 그 원 안이 평균보다 밝은 정도 = 관측 발생과 기대 발생의 차이(로그우도비)
 - 가장 밝았던 원 = 가장 가능성 높은 군집(MLC)
- 탐조등을 어디에 놓을지, 얼마나 크게 켜지 미리 정하지 않고 전부 시도해 본 뒤 가장 두드러진 자리를 고른다는 점이 핵심임. 13절(이 장 13절)에서 실제 계산과 유의성 검정을 다룸

3. 핵심 개념 6가지

1. 관측 라벨과 실제 수요는 다른 값

- 행정 기록(발굴·신청·수급, 진단·신고)은 실제 상태와 행정 행위(방문·검사·배정) 양쪽에 함께 좌우됨
- 이 차이를 진단하지 않고 예측 모형을 학습하면, 성능이 높아도 그 예측값이 실제 수요를 가리키는지 행정 관심을 가리키는지 알 수 없음

2. 접근성은 계산으로 확정되지만, 사각지대·감염병 위험은 예측이 필요

- 이동시간과 2SFCA는 도로망과 시설 위치가 주어지면 답이 하나로 정해지는 결정론적 계산
- 사각지대 위험과 감염병 발생은 미래(또는 관측되지 않은 현재)를 추정해야 하므로 예측 모형이 필요함

3. 저신뢰 예측을 다루는 방식은 분야마다 다름

- 복지에서 저신뢰가 나오는 원인은 대개 위기정보 자체가 적게 수집된 것. 저신뢰 단위를 순위에서 빼면 자료 부족이 다음 회차에도 이어짐
- 그래서 복지 분석은 저신뢰 단위를 배제가 아니라 **현장확인 우선 대상**으로 돌림

4. 예측·탐지·인과는 같은 자료 위에서 다른 질문에 답하는 세 갈래

- 예측은 "다음에 어디가 위험한가", 탐지는 "지금 어디가 비정상적으로 몰렸는가", 인과는 "이미 한 개입이 결과를 바꿨는가"를 물음
- 세 산출물은 수신자와 조치가 다르므로 하나가 다른 하나를 대신하지 않음

5. 예측 점수는 지원에 연결하고 불이익 처분과 분리함

- 예측이 틀렸을 때의 비용이 대칭이 아님. 위기를 놓치면 원래 상태(신청주의의 한계)로 남지만, 위기가 아닌 사람을 잘못 지목해 처분까지 이어지면 예측 체계가 없었으면 없었을 피해가 새로 생김

6. 같은 계산 도구가 공공 배분과 민간 입지 결정에 함께 쓰이되, 목적과 제약이 달라짐

- 2SFCA와 미충족 수요 계산은 행정에게는 확충 우선순위이고 사업자에게는 진입 후보지 진단이지만, 사업자의 계산에는 자기잠식·용량 제약·원가 컷라인이 추가로 들어감

4. 실제 자료를 먼저 보기

- 이 장이 다루는 제도와 자료는 이미 운영되고 있음. 아래 자료를 열어 보면 12장 전체가 왜 이런 절차로 짜여 있는지 감이 잡힘
- 보건복지부 복지 사각지대 발굴시스템 소개 <https://www.mohw.go.kr>
- 질병관리청 감염병포털(신고 자료 제공) <https://dportal.kdca.go.kr>
- 소상공인시장진흥공단 상가(상권)정보(공공데이터포털, 12.10절 동물병원 분석의 원자료) <https://www.data.go.kr/data/15083033/fileData.do>
- 국가법령정보센터(수의사법 제17조, 개설 자격 확인) <https://www.law.go.kr>
- 발굴시스템 페이지에서 확인할 것 — 21개 기관에서 47종의 신호(단전·단수, 요금 체납, 재난적 의료비 등)를 모은다는 설명이 있음. 8절(이 장 8절)에서 이 47종을 네 유형으로 묶어 다룸
- 감염병포털에서 확인할 것 — 신고 자료가 지역·시점별로 쌓인다는 점. 12절(이 장 12절)의 군집 탐지가 이 자료 구조를 그대로 씀
- 상가정보에서 확인할 것 — 업종 소분류로 "동물병원"을 검색하면 실제 운영 중인 병원의 위치가 나옴. 15절(이 장 15절)의 서울 자료가 이 목록을 씀

실습 안내

- 실습 코드
 - `lecture_practice/chapter12/code/12-0-simdata-prep.py` — 사각지대·감염병·DML·SaTScan 합성자료 생성(공개 원천 없음, 실행 전 준비 단계)
 - `lecture_practice/chapter12/code/12-0b-vetcare-data-prep.py` — 서울 동물병원·생활인구 실데이터 준비
 - `lecture_practice/chapter12/code/12-1-welfare-blindspot-priority.py` — 사각지대 위험 예측과 신뢰등급
 - `lecture_practice/chapter12/code/12-2-infectious-spatiotemporal-risk.py` — 감염병 시공간 예측
 - `lecture_practice/chapter12/code/12-3-dml-highdim-confounding.py` — 개입효과 DML 추정
 - `lecture_practice/chapter12/code/12-4-satscan-cluster.py` — 공간 스캔 통계와 순열검정
 - `lecture_practice/chapter12/code/12-5-unmet-demand-siting.py` — 미충족 수요와 제약 하 순차 입지 선택

- 결과 로그: `lecture_practice/chapter12/results/*.log`
- 앞의 네 스크립트(12-1~12-4)는 **합성자료**를 씀. 실제 지역명이 아니라 격자 번호로 표시되고, 신호를 미리 설계해 넣은 자료라서 "방법이 설계한 신호를 회복하는가"를 확인하는 용도임
- 실제 복지 사각지대나 감염병의 크기를 알려 주는 자료가 아님. 이 구분을 놓치면 합성자료의 수치를 실제 정책 결론으로 오해하게 됨
- 12-5(동물병원 입지)만 **국내 공개 실데이터**를 씀. 이 장에서 실제 지명·실제 수치가 등장하는 유일한 절이 15절임
- 이 장의 실습은 GPU가 필요 없음. 일부 계산(공간 블록 교차검증, 999회 순열검정)은 수 분이 걸릴 수 있으므로 여유를 두고 실행함

5. 실제 사례로 먼저 보기

- 절차를 하나씩 따라가기 전에, 다섯 실행 결과의 핵심 값만 먼저 봄. 각 값이 왜 이렇게 나왔는지는 6절부터 순서대로 다룸

표 12-1 다섯 실행의 핵심 결과 미리보기

실행	핵심 결과	읽는 법
사각지대 위험 예측	공간 블록 CV R^2 0.681 $\rightarrow$ 0.737 (+0.056)	이웃 단위의 위기신호·접근성을 더하면 예측이 좋아짐
감염병 시공간 예측	R^2 0.694 $\rightarrow$ 0.776, 이웃 발생 중요도 0.440+0.420 vs 자기 발생 0.074	다음 주 발생은 자기 과거보다 이웃의 최근 발생이 더 크게 좌우함
공간 군집 탐지	심어 둔 21개 단위를 recall 1.00·precision 1.00으로 회복, $p = 0.0010$	스캔 통계가 위치와 크기를 지정하지 않고도 설계된 군집을 정확히 찾음
개입효과 추정	순진 비교 $\hat{\theta}$ -0.579 vs DML $\hat{\theta}$ -1.874 (참값 -2.0)	배정 구조를 다루지 않은 비교는 효과를 3분의 1 이하로 낮춰 봄
동물병원 입지 선택	탐욕적 순차 선택이 미충족 수요 순위표보다 실현 포획 48.5% 많음	"가장 부족한 곳"과 "먼저 여는 것이 나은 곳"은 다른 목록임

- 이 다섯 줄 가운데 가장 눈에 띄는 것은 개입효과 행임. 방법을 바꾸는 것만으로 "효과가 미미한 사업"이 "효과가 확인된 사업"으로 판정이 뒤집힘. 13절에서 이 계산을 처음부터 다시 따라감
- 동물병원 행도 놓치면 안 됨. "부족한 곳에 낸다"와 "이득이 가장 큰 순서로 연다"가 다른 답을 준다는 것이 이 장 뒷부분의 핵심 논지임

6. 아홉 단계의 흐름

- 복지·보건 수요 분석은 아홉 단계로 진행함. 단계는 순서가 있고, 앞 단계를 건너뛰면 뒤 단계의 판단 근거가 사라짐
- 예를 들어 2단계(관측 라벨이 무엇을 기록한 값인지 정의)를 건너뛰고 5단계(예측 모형 학습)로 가면, 성능이 아무리 높아도 그 값이 실제 수요를 가리키는지 행정 관심을 가리키는지 구분할 수 없음




그림 12-1 복지·보건 수요 분석의 아홉 단계와 세 갈래 분기

- 1~4단계는 세 갈래(예측·탐지·인과) 모두가 공유함. 개인 단위 신호를 공간 단위로 모으고, 자기 단위와 이웃 단위 피처를 만들고, 서비스 접근성을 계산하는 일은 어느 갈래로 가든 같음
- 갈리는 것은 5단계부터임. 아래 표는 각 단계가 무엇을 입력받아 무엇을 계산하고 무엇을 내놓는지 정리한 것으로, 과제를 시작할 때 할 일 목록으로 쓰고 보고서를 쓸 때 목차로 씀

표 12-2 단계별 입력·계산·산출물

단계	입력	주요 계산	산출물
1 정책 질문·대상	정책 질문, 자료 목록	질문 유형 분류, 분석 단위 선택	대상 정의서
2 관측 라벨	행정 기록, 관심 프록시	y 와 y^{obs} 의 거리 판정, 편향 진단	라벨 생성 경로표
3 피처 구성	위기정보 47종, 좌표	신호 결합, 공간 시차, 가용성 판정	피처 행렬 X
4 접근성	시설 위치·용량, 인구, 도로망	이동시간, 2SFCA, 미충족 수요	A_i , U_i
5 예측	X , y^{obs} , 좌표	기준모형·후보모형 적합, 공간 블록 CV	예측값 $\hat{y}_i$
6 불확실성	out-of-fold 잔차, X	잔차 크기 모형, 정규화 conformal	구간 반폭, 신뢰등급
7 탐지	단위별 발생·인구, 좌표	윈도우 생성, LLR, 순열검정	MLC, p 값
8 인과	공변량 X , 처치 D , 결과 Y	nuisance 교차적합, 직교화	$\hat{\theta}$, 표준오차
9 해석·처분	예측표, 구간, $\hat{\theta}$	순위 산정, 집행 단위 집계	우선순위표, 조치 매트릭스

- 세 갈래를 나란히 놓으면 왜 하나로 합칠 수 없는지가 드러남

표 12-3 절차의 세 갈래

갈래	단계	묻는 것	연결되는 조치
예측	5·6	다음 시점에 어느 단위가 위험한가	방문 인력 배치, 대비 물량 산정
탐지	7	지금 어디에 발생이 비정상적으로 몰렸는가	역학조사 착수, 현장 확인
인과	8	이미 집행한 개입이 결과를 바꾸었는가	사업 존속·확대·중단 판단

- 7절부터 14절까지가 각 단계에 대응함. 15절은 같은 절차를 다른 자료(고독사, 감염병 조기경보, 동물병원 입지)에 적용하면서 어느 단계가 달라지는지 다룸. 16절은 새 과제를 시작할 때 채우는 점검표임

7. 관측 라벨을 의심하기

7.1 정책 질문의 네 유형

- 복지·보건 정책이 공간 분석을 요구하는 지점은 네 가지로 정리됨. 네 질문은 분석 단위와 자료 갱신 주기가 다르고, 따라서 절차의 어느 단계에 무게를 두는지도 다름

표 12-4 정책 질문의 네 유형

질문 유형	정책 질문	분석 단위	자료 갱신 주기
사각지대	도움이 필요하나 제도 밖에 있는 가구는 어디에 많은가	읍면동·격자	월 1회
접근성	의료·돌봄 서비스에 닿기 어려운 지역은 어디인가	생활권·이동시간	연 1회
위험 집중	감염병·고독사 위험이 높아지는 지역은 어디인가	격자·보건소 권역	일 1회~주 1회
자원 배분	한정된 인력·예산을 어디에 먼저 투입할 것인가	행정구역·권역	예산 주기

- 사각지대는 제도가 신청주의로 작동하는 데서 생기는 문제임. 신청하지 않은 가구는 행정 기록에 존재하지 않으므로, 곤궁을 직접 세는 대신 곤궁의 흔적을 세어 추정함
- 접근성은 제도 안에 있어도 서비스에 물리적으로 닿지 못하는 문제. 소아과가 차로 한 시간인 군 지역의 아동은 수급 자격과 무관하게 진료를 받기 어려움
- 위험 집중은 발생이 특정 시공간에 몰려 규모가 커지는 문제이고, 자원 배분은 앞의 세 진단을 "어디에 먼저"라는 결정으로 바꾸는 문제임
- 갱신 주기 열이 중요한 이유는 이 값이 3단계(피쳐 구성)의 시점 정합을 규정하기 때문임. 월 단위 위기정보와 일 단위 신고 자료를 같은 모형에 넣으면, 예측 시점에 아직 존재하지 않는 값이 섞일 수 있음. **갱신 주기가 가장 긴 자료가 전체 분석의 시간 해상도를 정함**

7.2 세 값을 구분하기

- 이 장에서 가장 중요한 구분은 다음 세 값을 헷갈리지 않는 것
- y_i = 실제 수요 또는 위험(우리가 진짜로 알고 싶은 값)
- y_i^{obs} = 발굴·신청·수급·진단·신고로 거쳐 기록에 남은 값(관측 라벨)
- $\hat{y}_i$ = 모델이 산출한 예측값
- 모델은 y_i^{obs} 를 정답으로 학습하지만, 정책 결정에 필요한 값은 y_i 임. 두 값이 같다고 볼 수 있는 자료에서는 예측 정확도가 곧 유용성이지만, 두 값이 어긋나는 자료에서는 정확도가 높아도 실제 수요를 잘 예측한다고 결론 내릴 수 없음
- 이 장이 다루는 세 라벨은 모두 행정 행위를 거쳐 생성됨

표 12-5 세 라벨의 생성 경로

대상	알고 싶은 값 y	관측 라벨 y^{obs}	라벨을 만드는 행정 행위
복지 사각지대	도움이 필요한데 연결되지 않은 가구 수	발굴·신청·수급 결정 기록	방문·상담·조사 배정
감염병 발생	지역·시점별 실제 감염자 수	진단·신고 기록	검사 시행과 신고 체계
개입효과	개입이 없었다면 나타났을 위기 수준	개입 후 관측한 위기점수	개입 대상 배정

- 세 라벨 모두 실제 상태와 행정 행위를 함께 반영함. 사각지대 라벨은 곤궁의 신호를 실제로 담고 있으므로 버리면 남는 자료가 없고, 관심 편중도 함께 담겨 있으므로 그대로 실재 수요로 읽으면 판단이 틀림
- 대응은 다음과 같음. 라벨을 쓰되 7.3절의 네 절차로 편향을 진단하고, 그 결과를 예측 단계의 해석 범위와 처분 단계의 규칙에 반영함. 감염병 라벨은 검사 편중이 섞이므로 탐지 결과를 확정이 아니라 역학조사의 가설로 씀. 개입효과 라벨은 배정 규칙이 섞이므로 그 규칙을 명시적으로 모형화함(13절)

주의. 발굴·신청·수급 기록은 실제 곤궁과 행정이 들여다본 정도를 함께 반영함. 방문 인력이 자주 가는 지역에서 위기가구가 더 많이 기록되고, 그 기록으로 학습한 모형은 수요가 아니라 관심의 분포를 재현함. 라벨을 쓰되 행정 관심 프록시(과거 방문·상담 건수)와의 상관을 함께 산출하고, 상관이 높으면 예측값을 실재 수요로 읽지 않음.

- 이 어긋남은 되먹임 구조를 만들. 관측 기록이 많은 지역에 다음 회차 방문 인력이 더 배정되고, 그 배정이 다시 기록을 늘림
- 되먹임의 방향은 이 장에서 **누락 쪽으로 열려 있음**. 방문 인력이 닿지 않아 위기정보조차 수집되지 않는 지역은 예측 위험이 낮게 산출되고, 낮은 예측 위험 때문에 다음 회차에도 인력이 배정되지 않음
- 그래서 이 장의 처방은 예측이 낮게 나온 저정보 지역을 순위에서 빼는 것이 아니라 별도의 현장확인 대상으로 돌리는 것임(11.2절의 조치 매트릭스가 이 규칙을 표로 적음)

7.3 라벨 편향을 진단하고 보정하기

- 라벨 편향 진단은 예측(5단계)과 인과(8단계) 앞에서 입력 품질을 판정하는 작업임. 진단하지 않고 학습하면 성능 지표만 남고, 그 성능이 무엇에 대한 성능인지 알 수 없게 됨

표 12-6 라벨 편향의 진단·보정 절차

절차	입력	계산	판정 기준
차등 결측 점검	위기정보 47종의 결측 여부, 인구 구성	결측률을 계층·지역별 교차집계	특정 계층·지역의 결측률이 크게 벗어나면 라벨이 그 집단을 체계적으로 누락
관심 프록시 상관	과거 방문·상담 건수, 라벨, 예측	프록시와 라벨·예측의 상관계수	상관이 높으면 모형이 수요가 아니라 관심 배분을 학습
감사 표본	무작위로 고른 지역의 전수 조사	전수 조사 대비 라벨 누락률	누락률이 지역마다 다르면 라벨을 그대로 비교에 못 씀
준실험 활용	제도 개편·정원 증원 시점·지역	관심이 외생적으로 변한 전후의 발굴 건수 변화	이 효과가 크면 지역 간 라벨 차이의 상당 부분이 관심 차이

- 차등 결측 점검이 가장 먼저 하는 진단임. 위기정보는 행정과 접점이 있어야 생기므로, 디지털 접근이 어려운 고령층이나 무연고 가구가 많은 지역에서 결측이 많음
- 결측이 무작위로 흩어져 있으면 표본 크기만 줄지만, 특정 집단에 몰려 있으면 그 집단은 학습에서 아예 사라짐
- 관심 프록시 상관은 라벨 자체를 의심하는 진단임. 프록시를 통제변수로 넣으면 수요 신호까지 함께 건어낼 위험이 있으므로, 통제 전후의 예측 순위를 함께 보고하고 순위가 크게 바뀌는 단위를 표시함
- 감사 표본과 준실험은 보정의 기준선을 만듦. 표본이 작으면 지역별 누락률보다 전체 누락률의 하한을 얻는 데 쓰는 편이 현실적임. 네 절차 모두 이 장의 실습 자료에는 실행 증거가 없으므로 절차만 다룸

7.4 공간 단위와 집계 가중치

- 개인 단위 수요를 공간 단위로 모으는 이유는 둘임. 개인을 직접 지목하면 개인정보 근거가 좁아지고 낙인 위험이 생기며, 집행 주체가 읍면동·구역 단위로 인력·예산을 배정하므로 개인 점수는 그대로 결정으로 바뀌지 않음
- 집계 단위 선택에는 두 조건이 맞섬. 격자가 작을수록 위험 지점을 정밀하게 쥌지만 한 칸의 인구가 줄어 개인 식별 위험이 커지고, 격자가 클수록 식별 위험은 낮아지지만 구역 안 최악 단위가 평균에 섞여 사라짐
- 집계 가중치는 계산 파라미터가 아니라 정책 판단임

표 12-7 집계 가중치의 선택

가중치	계산 결과의 뜻	적합한 결정
면적(모두 동일)	구역의 평균 위험 수준	시설 배치 계획, 구역 재획정
인구	주민 노출을 반영한 위험	방문 인력 배치, 검사 역량 배분
취약계층 인구	대상 집단 기준 위험	돌봄 서비스 배치, 안부 확인 인력
가구 수	지원 단위 기준 위험	긴급복지 예산, 상담 건수 산정

- 고령 인구 비율이 높고 총인구가 적은 농촌 읍면은 취약계층 가중에서 상위로 오르고 인구 가중에서 하위로 내려감. 가중치를 밝히지 않은 구역 평균은 무엇을 평균한 값인지 알 수 없으므로, 보고할 때 가중치를 표 제목이나 각주에 함께 적음

8. 위기 신호를 결합하기

8.1 위기정보의 구조

- 곤궁은 신청서에 기록되지 않아도 생활의 흔적에는 남음. 전기요금이 여러 달 밀리고, 건강보험료가 체납되고, 의료비가 소득을 넘어서는 가구는 스스로 도움을 청하지 않았어도 위기 상태일 수 있음

- 이 흔적을 여러 기관에서 모아 결합하는 체계가 복지 사각지대 발굴시스템이며, 21개 기관의 47종 위기정보를 다루고 입수 주기가 2개월에서 매월로 단축됨(보건복지부)
- 47종을 성격별로 묶으면 네 유형이 됨

표 12-8 위기정보의 유형과 성격

유형	신호 예	발생 시차	해석상 주의
주거·공과금	단전, 단수, 요금 체납, 임차료 연체	짧다 (1~2개월)	단발 체납은 착오일 수 있어 단독 신호로는 판별력이 낮음
의료·건강	재난적 의료비, 건강보험료 장기 체납	중간 (1~3개월)	의료비 지출은 소득과 무관하게 급증할 수 있어 소득 대비 비율로 봄
금융·부채	채무조정 신청, 서민금융 신청 반려	중간	신청 자체가 접근성을 전제하므로 금융 접점이 없는 가구는 안 잡힘
고용·소득	고용위기 신고, 실업급여 수급 종료	길다	비공식 고용은 기록에 안 남음

- 입수 주기가 2개월에서 매월로 짧아진 변화는 피처의 시점 정합을 바꿈. 2개월 주기에서는 급격히 악화된 가구가 다음 갱신까지 잡히지 않고, 매월 주기에서는 그 지연이 절반으로 줄지만 신호의 잡음이 늘어남. 그래서 연속 체납 개월 수처럼 지속 기간을 세는 피처를 함께 만들어 일시적 변동과 지속적 악화를 분리함

8.2 신호를 결합하면 판별력이 올라가는 계산

- 신호 하나로는 위기가구를 판별하기 어려움. 이유는 신호의 성능이 아니라 **기저율**에 있음
- 전체 가구 가운데 실제 위기가구의 비율이 낮으면, 신호가 위기가구를 잘 잡아도 신호 양성 가구의 대다수는 위기가 아닌 가구가 됨
- 이 관계는 조건부확률로 계산됨. 아래는 예시 계산이며 실측 자료가 아님
- 기저율(전체 가구 중 실제 위기가구 비율) 2%, 신호의 민감도(위기가구가 신호에 걸릴 확률) 60%, 위양성률(위기가 아닌데 신호에 걸릴 확률) 10%를 넣으면
- 신호 양성인 가구 중 실제 위기가구 비율(양성예측도) = $0.02 \times 0.60 \div (0.02 \times 0.60 + 0.98 \times 0.10) = 0.012 \div 0.110 = \mathbf{0.109}$
- 민감도 60%인 신호를 썼는데도 신호 양성 가구 열 곳 가운데 아홉 곳이 위기가 아님
- 두 번째 신호(민감도 50%, 위양성률 8%)를 조건부 독립으로 더하면
- 양성예측도 = $0.02 \times 0.60 \times 0.50 \div (0.02 \times 0.60 \times 0.50 + 0.98 \times 0.10 \times 0.08) = 0.006 \div 0.01384 = \mathbf{0.434}$
- 신호 하나로 0.109였던 값이 두 신호를 겹치자 0.434로 오름. 신호 하나하나는 약해도 겹칠 때 판별력이 커지는 구조가 여기에 있고, 발굴시스템이 개별 신호가 아니라 신호의 결합을 쓰는 이유도 여기에 있음

- 다만 두 신호가 실제로는 독립이 아닐 수 있음. 공과금 체납과 건강보험료 체납은 같은 지불 능력에서 나오므로, 위기가 아닌 가구에서도 한쪽이 밀리면 다른 쪽도 밀릴 확률이 높음
- 두 번째 신호의 위양성률을 8%가 아니라 30%로 두면 양성예측도는 0.169로 떨어짐. 47종을 정제 없이 그대로 모형에 넣으면 이런 중복이 다수 생겨 계수 해석이 불안정해짐. 대응은 같은 생활 영역의 신호를 하나의 집단 지표로 묶어 차원을 줄이는 것

8.3 공간 시차 피처

- 한 읍면동의 사각지대 위험은 그 단위의 자료만으로 정해지지 않음. 복지관·주민센터·방문 인력은 권역 단위로 배치되므로, 이웃 읍면동에 위기가구가 몰려 전달체계가 과부하되면 자기 단위에 배정되는 발굴 여력이 줄어들
- 이웃 값을 하나의 수로 요약한 것이 **공간 시차**임. 단위 i 의 변수 x 에 대한 공간 시차는 이웃 j 들의 값을 가중평균한 값
- 코드로 보면 격자에서 상하좌우 이웃의 값을 평균 내는 계산임

```
def spatial_lag(df, value_col):
    # 4-이웃(상하좌우) 평균 = 공간 시차 피처. 미관측 공간효과의 대리변수
    grid[df["row"], df["col"]] = df[value_col].values
    for r, c in zip(df["row"], df["col"]):
        neigh = [grid[r-1, c], grid[r+1, c], grid[r, c-1], grid[r, c+1]]
```

전체 코드는 [lecture_practice/chapter12/code/12-1-welfare-blindspot-priority.py](#) 참고

- 이웃을 어떻게 정의하는가가 결과를 바꿈. 경계를 맞댄 읍면동을 이웃으로 두는 인접 정의, 중심점 거리로 정하는 거리 정의, 같은 복지관·보건소 권역을 이웃으로 두는 권역 정의가 있고, 이 장의 메커니즘(전달체계 부하 공유)과 가장 가까운 것은 권역 정의임
- 만든 피처가 예측 시점에 실제로 존재하는지는 별도로 확인해야 함

표 12-9 피처 가용성 점검표(발체)

피처	예측 시점 기준 지연	가용성 판정
자기 단위 위기신호 집계	최대 1개월	사용. 직전 입수분만 씀
이웃 단위 위기신호 공간 시차	최대 1개월	사용. 자기 단위와 같은 시점
당해 연도 발굴 건수	사후 집계	제외. 예측 대상과 같은 과정에서 생성됨
상담 후 판정 결과	사후 집계	제외. 방문 이후에만 존재함

주의. 위기정보의 입수 주기와 예측 시점이 어긋나면 예측 시점에 존재하지 않는 값이 피처에 섞임. 오류 메시지는 안 나오고 성능만 좋아짐. 피처마다 "이 값을 예측 시점에 어디서 받아 오는가"를 한 줄로 적고, 답을 못 적으면 후보에서 뺌.

9. 서비스 접근성을 계산하기

9.1 이동시간 기반 접근성

- 의료·돌봄 접근성의 기본 지표는 시설까지의 이동시간임. 직선거리가 아니라 실제 이동이 일어나는 도로망 위에서 켄 시간
- 국내 의료취약지 제도가 이 이동시간을 임계로 씬(보건복지부 고시 제2024-261호)

표 12-10 국내 의료취약지 지정 기준

취약지 유형	기준
응급의료취약지	지역응급의료센터 30분 내 접근 불가 인구 27% 이상, 또는 권역센터 60분 내 접근 불가 27% 이상
소아 취약지	소아과 60분 내 입원 의료이용률 30% 미만이면서 접근 불가 인구 30% 이상

- 이 계산에는 학습 모델을 쓰지 않음. 도로망과 시설 위치가 주어진다면 이동시간은 계산으로 확정되는 값이라(결정론성), 제3자가 같은 자료로 같은 값을 다시 계산할 수 있어야 하고(재현성), "왜 이 지역이 취약지인가"에 한 문장으로 답할 수 있어야 하기(이의제기 가능성) 때문임
- 2절(2장)에서 다룬 도로망 거리·우회비의 계산이 여기서도 그대로 쓰임

9.2 2SFCA로 혼잡까지 반영하기

- 이동시간 하나로는 이용 경쟁을 반영하지 못함. 10분 거리에 병원 하나가 있고 배후 인구 5만 명이 매달린 지역과, 15분 거리에 병원 셋이 있고 배후 인구가 1만 명인 지역은 최근접 지표로는 전자가 낫다고 나오지만 실제 대기는 후자가 짝음
- 이 차이를 지표에 넣는 방법이 **2단계 유동권역법(2SFCA)**임(Luo & Wang, 2003). 두 단계로 나눠 계산함
 1. 시설 j 의 용량 S_j 를 권역 안 배후 수요의 합으로 나눠, 수요 한 단위가 그 시설에서 받을 몫 R_j 를 구함
 2. 단위 i 가 닿는 시설들의 몫 R_j 를 더해 그 단위의 접근성 A_i 를 구함

```
def two_sfca(D, d_dc, capacity, radius):
    inside = d_dc <= radius                # 권역 안인가
    served = inside.T @ D                  # 병원별 권역 안 수요 합
    R = np.where(served > 0, capacity / served, 0.0) # 1단계: 병원별 몫
    return inside @ R                      # 2단계: 동네별 접근성
```

전체 코드는 [lecture_practice/chapter12/code/12-5-unmet-demand-siting.py](#) 참고

- 산출값 A_i 의 단위는 "수요 한 단위가 확보할 수 있는 용량"임. 값이 크면 그 지역 주민 한 명이 확보 가능한 진료 용량이 크다는 뜻이며, 이동시간처럼 분 단위로 읽으면 해석이 어긋남
- 용량 S_j 의 대리변수 선택도 결과를 좌우함. 요양시설은 정원이 명확하지만 의원급 외래는 정원 개념이 없어 진료 건수를 대신 쓰게 되고, 그 대체값이 인구와 대응하지 않으면 해석이 사라짐

9.3 미충족 수요의 정의

- 접근성 A_i 자체는 순위를 주지만 부족분의 크기를 주지 않음. 부족분을 수요 규모로 환산한 값이 **미충족 수요**이며, 기준 접근성 A^* 에 못 미치는 비율을 그 단위의 수요에 곱해 정의함

$$U_i = D_i \times \max(0, 1 - A_i / A^*)$$

- A_i 가 A^* 이상인 단위는 괄호 안이 음수가 되어 0으로 잘리고, A_i 가 A^* 의 절반인 단위는 그 단위 수요의 절반이 미충족으로 계산됨
- A^* 를 수요가중 평균 접근성으로 두면, 시설이 배분한 용량의 총합이 시설 용량의 총합과 같다는 성질에서 $A^* = (\text{시설 수} \times \text{지점 용량}) \div \text{총수요}$ 가 유도됨. 지점 용량을 평균 담당 수요의 κ 배로 두면 $A^* = \kappa$ 로 정리됨. 15절의 서울 자료에서 용량 배수 1.8을 넣었을 때 A^* 가 실제로 1.8000으로 나온 것이 이 관계의 확인임
- 이 성질의 쓸모는 확인 못 한 가정의 영향 범위를 좁히는 데 있음. 수요 규모를 전부 c 배 하면 A_i 는 변하지 않고, 용량 배수를 바꾸면 A_i 와 A^* 가 같은 비율로 움직여 비율 A_i/A^* 는 그대로 유지됨. 즉 확인 못한 사육률·수요 밀도 가정이 접근성 비율에는 영향을 주지 않음
- 다만 이 정의는 총량 부족이 아니라 **분포의 불균형**만 잼. 지역 전체 용량이 절대적으로 모자라도 모든 단위가 똑같이 모자라면 A_i 가 모두 A^* 와 같아져 미충족 수요는 0이 됨
- 접근성 하나로 사각지대 위험이 얼마나 설명되는지는 실행 결과로 확인됨. 합성자료 300개 읍면동에서 의료시설 이동시간 30분을 초과하는 접근성 취약 단위는 15개(5.0%)였고, 이 취약지의 평균 사각지대 위험은 13.56%로 그 외 지역의 10.88%보다 높음. 차이는 2.68%p로 경향은 있지만 크지 않음
- 접근성이라는 한 축으로 설명되지 않는 나머지를 잡으려면 여러 신호를 결합하는 예측 모델이 필요함. 이 판정이 10절(5단계)로 넘어가는 근거가 됨

10. 위험을 예측하고 공간으로 검증하기

10.1 횡단면 위험 예측 — 사각지대

- 첫 형태는 시점 하나의 자료에서 단위별 위험을 예측하는 것임. 입력은 8~9절에서 만든 피처 행렬 X , 정답은 관측 라벨 y^{obs} , 출력은 단위별 예측 위험 $\hat{y}_i$
- 합성자료 300개 읍면동에서 취약계층 구성, 위기신호 집계, 의료 접근성과 각각의 공간 시차를 피처로 그래디언트 부스팅으로 사각지대 위험을 예측함
- 검증 설계를 모델 선택보다 먼저 정해야 함. 이웃한 읍면동은 값이 서로 닮아 있으므로, 검증 자료를 무작위로 나누면 검증 단위의 이웃이 학습 자료에 들어가고 모델이 그 이웃 값을 참고해 검증 단위를 맞힘. 실제 배치 상황보다 성능이 높게 나오는 것
- **공간 블록 교차검증**은 이 경로를 막음. 좌표를 기준으로 자료를 덩어리로 나누고, 한 덩어리를 통째로 검증에 쓰는 동안 그 덩어리는 학습에 넣지 않음

표 12-11 사각지대 위험 예측: 공간 피처의 정보 가치 (공간 블록 CV)

피처 구성	R ²	포함 변수
비공간 피처(자기 단위만)	0.681	자기 단위의 위기정보·접근성·취약계층 구성
+ 공간 시차 피처	0.737	위에 이웃 단위의 위기정보·접근성을 더함
차이	+0.056	공간 시차 피처가 설명하는 몫

- 공간 시차 피처를 더하자 R²가 0.681에서 0.737로 오름. 합성자료에는 이웃 위기·접근성의 파급 구조를 설계해 넣었으므로, 공간 피처가 그 구조를 회복한 결과임
- 이 비교가 확인하는 것은 "파급 구조가 자료에 있을 때 공간 명시적 피처가 그것을 잡는다"까지이며, 실제 복지 사각지대에 그런 파급 구조가 있다는 결론은 아님. 실데이터에서 같은 비교를 해야 그 판정이 나옴
- 피처 중요도는 이웃 접근성(access_lag) 0.527, 65세 이상 비율 0.145, 1인 가구 비율 0.100, 의료 접근성 0.069, 이웃 위기신호 0.062 순임. 다만 상관된 변수 사이에서 트리 기반 중요도가 흔들릴 수 있으므로, 이 순위를 그대로 설명으로 쓰지 않고 별도 진단(순열 중요도)을 함께 봄

주의. 이 자료에서는 랜덤 교차검증의 R²도 0.737로 공간 블록 교차검증과 같게 나왔다. 이 값을 "공간 누수가 없다"는 결론으로 옮기면 안 됨. 공간 상관의 원천이 공간 시차 피처로 이미 모형에 들어가면 잔차에 남는 공간 상관이 약해지고, 그 결과 무작위 분할이 얻는 이득도 사라짐. 두 값의 차이는 성능이 아니라 잔차 구조의 진단 정보로 읽음.

10.2 시공간 위험 예측 — 감염병

- 두 번째 형태는 시간 축이 있는 자료에서 다음 시점의 발생을 예측하는 것임. 감염병이 여기 해당함
- 한 격자의 다음 주 발생은 그 격자의 이번 주 감염자 수에 비례해 늘어나는 데 그치지 않음. 이웃 격자의 감염자가 출퇴근·시장·학교를 오가며 감염압을 더하므로, 이웃에서 유행이 시작되면 자기 격자의 발생이 자기 추세와 무관하게 오름
- 합성자료는 16×16 격자 256단위 × 40주의 **SIRS 모형**(감수성-감염-회복-재감수성 네 상태의 전이)으로 생성함. 마지막 재감수성 전이 때문에 감염이 완전히 사라지지 않고 낮은 수준으로 계속 도는 상태가 유지됨. 총 발생은 40주 동안 14,345건, 피크 주는 1,279건, 8개 보건소 권역으로 집계함
- 피쳐는 시간 시차(같은 격자의 직전 1~3주 발생)와 공간 시차(이웃 격자의 직전 0~1주 발생)의 두 축으로 만들. 검증은 앞 기간으로 학습하고 뒤 기간으로 평가하는 **시간 블록** 설계를 씬. 시점을 무작위로 섞으면 미래 정보가 학습에 들어가므로, 시간 축이 있는 자료에서는 시간 순서를 지키는 분할이 최소 조건임

표 12-12 감염병 확산 예측: 시공간 피쳐의 정보 가치 (시간 블록 검증)

피쳐 구성	R ²	MAE
시간 시차만(자기 과거)	0.694	1.483
+ 공간 시차(이웃 과거)	0.776	1.294
차이	+0.082	-0.189

- 공간 시차를 더하자 R²가 0.694에서 0.776으로 오르고 MAE는 1.483에서 1.294로 내려감. 피쳐 중요도에서는 이웃 발생의 직전 주 값 0.440과 당주 값 0.420이 자기 발생 0.074를 크게 앞섬
- 다음 주 발생을 예측하는 데 자기 격자의 과거보다 이웃 격자의 최근 발생이 더 큰 몫을 차지한다는 뜻이며, 시뮬레이터가 이웃 감염압으로 확산을 설계한 것과 대응함. 이 결과도 시뮬레이터의 내부 일관성 확인이므로 실제 감염병 자료의 결론으로 옮기지 않음

10.3 어떤 모델을 쓸까

- 이 장의 두 예측은 모두 트리 기반 방법을 썼지만, 자료 조건에 따라 다른 선택이 나올 수 있음

표 12-13 자료 조건에 따른 모델 선택

조건	선형 기준모형	트리 기반 머신러닝
단위 수	수백 이하에서도 안정	수천 이상에서 이점이 커짐
라벨 품질	편향이 커도 계수 해석이 가능	편향을 그대로 학습하므로 진단이 선행되어야 함
공간 상관	반영하지 못함	공간 시차 피처로 간접 반영
산출물의 성격	계수와 유의성	예측값과 중요도

- 기준모형을 먼저 적합하는 이유는 비교 대상 없이는 성능을 판정할 수 없기 때문임. 단위가 수백 개 수준이면 트리 기반 방법의 이점이 작아지고 과적합 위험이 커지므로, 이 규모에서는 정규화된 선형모형과 성능이 비슷하면 해석 가능한 쪽을 씀. 라벨 편향 진단(7.3절)에서 관심 프록시 상관이 높게 나온 자료라면, 어느 모형을 쓰든 예측값을 실재 수요로 읽지 않는다는 제한이 그대로 남음

11. 예측구간과 신뢰등급

11.1 정규화 conformal 예측구간

- 점예측만으로는 자원 배분을 판정할 수 없음. 예측 위험이 같은 16%로 나온 두 단위라도, 한 곳은 예상 오차가 $\pm 0.68\%p$ 이고 다른 곳은 $\pm 2.62\%p$ 이면 같은 조치를 적용할 근거가 없음
- 분포 가정 없이 목표 포함확률을 달성하는 예측구간이 **conformal 예측**이며(Lei et al., 2018), 단위마다 다른 불확실성을 반영하려면 잔차 크기로 정규화함(Romano et al., 2019 계열). 복지 자료에 적용하는 계산은 여섯 단계임
 1. 보정표본을 분리함(모형 학습에 쓰지 않은 단위)
 2. 잔차를 산출함 — $r_i = y_i - \hat{y}_i$
 3. 잔차 크기 모형을 적합함 — $|r_i|$ 를 목표로 같은 피처로 $\hat{\sigma}(x)$ 학습
 4. 정규화 점수를 계산함 — $s_i = |r_i| / \hat{\sigma}(x_i)$
 5. 목표 포함확률에 대응하는 분위값 q 를 보정표본에서 구함
 6. 반폭을 계산함 — 예측구간은 $\hat{y}_i \pm q \cdot \hat{\sigma}(x_i)$
- 한 단위에 숫자를 넣어 확인함. 보정표본에서 얻은 분위값이 $q = 1.65$ 이고 어느 단위의 $\hat{\sigma}(x_i) = 1.59\%p$ 라면 반폭은 $1.65 \times 1.59 = 2.62\%p$ 임. 예측 위험이 18.26%인 단위의 90% 예측구간은 [15.64, 20.88]%가 됨. 같은 q 라도 $\hat{\sigma}(x_i)$ 가 0.41%p인 단위에서는 반폭이 0.68%p로 줄어듦. 단위마다 폭이 달라지는 몫은 전부 $\hat{\sigma}(x_i)$ 에서 나옴

```
sigma = np.clip(GradientBoostingRegressor(...).fit(X, np.abs(resid)).predict(X), MIN_SIGMA, None)
scores = np.sort(resid / sigma) # 정규화 conformal 점수
q = scores[int(np.ceil((n + 1) * 0.90)) - 1] # 90% 목표 분위
half = q * sigma # 단위별 예측구간 반폭
```

전체 코드는 [lecture_practice/chapter12/code/12-1-welfare-blindspot-priority.py](#) 참고

- 합성자료 300개 읍면동에서 이 절차를 실행한 결과, 90% 예측구간의 경험적 포함률은 0.903으로 목표 0.90에 부합했고 구간 반폭은 중앙값 1.53%p, 범위 [0.59, 4.19]%p로 단위마다 갈림

주의. 이 구현은 학습·보정·시험을 세 갈래로 분리한 정식 분할이 아니라, 공간 블록 교차검증의 out-of-fold 잔차를 $\hat{\sigma}$ 적합과 분위 계산에 함께 쓴 근사임. 같은 잔차를 두 용도로 재사용하므로 포함률이 낙관적으로 나옴. 자료가 적어 3분할이 어려운 경우의 대응이며, 정식 절차라면 세 자료를 분리함.

11.2 신뢰등급을 조치로 바꾸기

- 구간 반폭은 연속값이므로 그대로는 조치와 연결되지 않음. 반폭을 3분위로 나눠 좁은 쪽부터 높음·중간·낮음의 세 등급으로 표기하면 예측값과 조합해 규칙을 만들 수 있음. 합성자료에서는 '낮음' 등급이 100개 읍면동에 배정됨

표 12-14 불확실성을 반영한 방문상담 우선순위 상위 8

순위	단위 ID	예측 위험(%)	반폭(%p)	신뢰등급
1	31	18.26	2.62	낮음
2	75	17.26	1.10	높음
3	44	16.73	2.03	낮음
4	104	16.68	2.31	낮음
5	30	16.61	0.68	높음
6	88	16.60	1.34	중간
7	78	16.42	1.84	낮음
8	107	15.74	0.98	높음

- 예측 위험이 가장 높은 31번 단위는 반폭이 2.62%p로 상위 8곳 가운데 가장 넓고 신뢰등급이 '낮음'임. 이 어긋남을 어떻게 다룰지가 이 절의 핵심
- 반폭이 넓어지는 원인을 따라가면 방향이 정해짐. 예측이 불확실한 단위는 대체로 위기정보 자체가 적게 수집된 단위임. 즉 낮은 신뢰등급은 "위험이 없다"가 아니라 "자료가 적다"를 가리킴

- 그래서 저신뢰 단위를 순위에서 제외하는 규칙을 쓰면 안 됨. 자료가 부족해 소외된 지역이 자료가 부족하다는 이유로 다시 배제되고, 7.2절에서 본 되먹임이 여기서 완성됨. 대신 저신뢰 단위를 **현장확인 우선 대상**으로 돌림

표 12-15 예측 위험과 신뢰등급에 따른 조치

예측 위험	신뢰등급	조치
높음	높음	방문상담 우선 배정으로 확정
높음	낮음	순위를 유지하되 방문 목적에 자료 보완을 포함
낮음	낮음	현장확인 대상으로 별도 편성. 자료 부족과 위험 부재를 구분 못 하는 구간
낮음	높음	일반 모니터링

12. 공간 군집을 탐지하기

12.1 탐지와 예측의 역할 구분

- 이 단계는 10절과 같은 자료를 쓰지만 다른 질문에 답함. 예측 모형은 과거 패턴이 이어진다고 보고 다음 시점의 규모를 추정하고, 스캔 통계는 미래를 추정하지 않는 대신 볼 위치와 크기를 사전에 정하지 않고 현재의 이상 집종을 찾음
- 두 산출물은 수신자와 조치가 다르므로 하나가 다른 하나를 대체하지 않음. 미국 뉴욕시 보건부는 2014~2015년 신고감염병에 일일 스캔 통계를 적용해 살모넬라-레지오넬라 군집을 조기 탐지한 운영 사례를 보고했고(Greene et al., 2016), 탐지 결과를 확진이 아니라 조사 착수의 근거로 씀

12.2 스캔 통계의 계산 절차

- 감염 신고가 어디에 몰렸는지 판정할 때 절대 건수로는 비교할 수 없음. 인구가 많은 지역에서 발생이 많은 것은 정상이기 때문
 - **공간 스캔 통계**는 인구비례 기대치를 기준으로 두고, 그 기준을 넘는 정도가 가장 큰 영역을 찾음 (Kulldorff, 1997). 계산은 다섯 단계임
1. 각 단위를 중심으로 반경을 넓혀 가며 원형 윈도우를 만듦(이 실행에서는 전체 인구의 50%를 반경 상한으로 씀)
 2. 윈도우마다 관측 발생 c 와 인구비례 기대 발생 e 를 구함
 3. 로그우도비를 계산함 — $LLR = c \cdot \ln(c/e) + (C-c) \cdot \ln((C-c)/(C-e))$
 4. $c > e$ 인 윈도우만 후보로 남김(고위험 군집만 찾는 것이 목적)
 5. 후보 가운데 LLR이 최대인 윈도우를 가장 가능성 높은 군집(MLC)으로 정함

```
def poisson_llr(c, e, C):
    # 포아송 우도비 로그통계(고위험 군집만 양수)
    mask = (c > e) & (c > 0) & (c < C)
    out[mask] = c[mask]*np.log(c[mask]/e[mask]) + (C-c[mask])*np.log((C-c[mask])/(C-e[mask]))
```

전체 코드는 `lecture_practice/chapter12/code/12-4-satscan-cluster.py` 참고

- 식의 두 항은 각각 윈도우 안과 밖의 설명력임. 첫 항 $c \cdot \ln(c/e)$ 는 윈도우 안에서 관측이 기대를 넘는 정도, 둘째 항은 윈도우 밖에서 관측이 기대에 못 미치는 정도임. $c = e$ 이면 두 항 모두 0이 되어 LLR도 0이 되고, 이 값이 "군집 없음"의 기준점임
- 실행값으로 확인함. 합성자료는 300개 격자에 총발생 $C = 10,371$ 건, 총인구 443,692명을 두고 중심 (6.0, 4.0)·반경 2.6 안의 21개 단위에 상대위험 3.0을 씌움. 탐지된 윈도우의 관측 발생은 $c = 2,245$ 건, 기대 발생은 $e = 892.6$ 건
- 첫 항 = $2,245 \times \ln(2,245/892.6) \approx 2,070.1$, 둘째 항 = $(10,371-2,245) \times \ln((10,371-2,245)/(10,371-892.6)) \approx -1,250.6$. 두 항을 더하면 $LLR \approx 819.5$ 로, 실행 로그의 819.57과 일치함

12.3 몬테카를로 순열검정

- LLR 값 하나만으로는 유의성을 판정할 수 없음. 모든 윈도우를 탐색해 최댓값을 골랐으므로 군집이 없는 자료에서도 어느 정도 큰 값이 나오기 때문
- 귀무가설은 "위험이 공간적으로 균일하다"임. 이 가설 아래에서 총발생 C 를 각 단위의 인구 비율에 따라 무작위로 재분배한 자료를 999개 만들고, 각 자료에서 12.2절의 다섯 단계를 그대로 수행해 최대 LLR을 구함. 999개의 최대 LLR이 "군집이 없을 때 우연히 나오는 최댓값의 분포"가 되고, 관측 LLR이 이 분포에서 어느 위치인지가 p값이 됨
- 최댓값의 분포를 쓰는 것이 핵심임. 개별 윈도우의 분포를 쓰면 다중비교 보정이 따로 필요하지만, 순열 자료에서도 같은 탐색을 반복해 최댓값을 뽑으면 탐색으로 인한 부풀림이 귀무분포에 이미 들어가므로 별도 보정이 필요 없음

표 12-16 공간 스캔 통계의 참 군집 회복

항목	값	읽는 법
MLC 구성단위	21개	설계한 참 군집의 21개와 같음
관측/기대 발생	2,245 / 892.6	관측 상대위험 2.52배
로그우도비 LLR	819.57	순열 최대 LLR의 95%분위 8.39를 크게 넘음
몬테카를로 p값	0.0010	999회 가운데 관측값 이상이 0회
recall / precision	1.00 / 1.00	설계한 21개 단위를 빠짐없이, 그 단위만 찾음

- 스캔 통계는 설계한 군집을 구성단위까지 회복했고 p값 0.0010으로 유의함. 이 결과가 확인하는 것은 "비정상 집중이 자료에 있을 때 스캔 통계가 위치와 크기를 지정하지 않고 그것을 찾는다"이며, 실제 감염병 자료의 성능은 아님. 실데이터에서는 신고 지연·인구 이동·검사 편중이 발생 분포를 바꾸므로, 탐지 결과는 역학조사의 가설로 쓰고 조사에서 확인된 뒤 대응 자원을 확정함

주의. 관측 상대위험 2.52는 설계값 3.0보다 낮게 나옴. 기대 발생 e 를 전체 평균 발생률로 계산하는데 심어 둔 군집 자체가 그 평균을 끌어올리므로, 군집이 클수록 상대위험이 실제보다 낮게 나옴(이 자료에서는 군집이 총발생의 21.6%를 차지). 군집의 위치와 존재는 그대로 쓰고, 상대위험 수치는 하한으로 읽음.

13. 개입효과를 인과로 추정하기

13.1 왜 통째로 비교하면 안 될까

- 이 단계는 이미 집행한 개입이 결과를 바꾸었는지 물음. 방문상담과 긴급복지 같은 선제 개입은 위기가 심각한 가구에 우선 배정되므로, 개입을 받은 가구와 받지 않은 가구의 결과를 그대로 비교하면 배정 규칙이 비교에 섞임
- 통상적인 대응은 회귀식에 위기지표를 선형으로 넣는 것이지만, 실제 위기지표는 선형으로 작동하지 않음. 체납은 일정 수준을 넘어야 위기 신호가 되고(임계), 어느 지점에서 급격히 나빠지며(꺾임), 아주 심각한 구간에서는 더 나빠질 여지가 없어 평평해짐(포화). 이런 굽은 구조가 결과와 처치확률 양쪽에 함께 작동하면, 직선으로 그은 통제선이 그 관계를 다 걷어내지 못하고 교란이 남음
- 검증 자료는 참 처치효과 $\theta = -2.0$ 을 심어 둔 합성자료임($N = 6,000$, 위기지표 20종). 실제 복지 미시데이터에서는 참 θ 를 알 수 없어 추정량의 타당성을 직접 검증할 수 없으므로, 참값을 아는 자료로 추정량의 거동을 먼저 확인함

13.2 이중기계학습의 세 장치

- **이중기계학습(DML)****은 세 장치로 이 문제를 다룸(Chernozhukov et al., 2018)
- 1. 유연한 머신러닝으로 보조 함수를 추정함.** 공변량 X 로 결과 Y 를 예측하는 함수 $\hat{g}(X)$ 와 처치 D 를 예측하는 함수(성향점수) $\hat{m}(X)$ 를 랜덤포레스트처럼 유연한 방법으로 학습해 임계·꺾임·포화 같은 굽은 관계를 근사함
- 2. 직교화로 교란을 뺀 나머지끼리 비교함.** 결과 잔차 $\tilde{Y} = Y - \hat{g}(X)$ 와 처치 잔차 $\tilde{D} = D - \hat{m}(X)$ 를 만들고, 두 잔차의 관계에서 처치효과를 뽑음($\hat{\theta} = \text{두 잔차의 곱의 평균} \div \tilde{D}$ 제곱의 평균)
- 3. 교차적합으로 학습 표본과 평가 표본을 분리함.** 같은 자료로 nuisance를 학습하고 그 자료에서 잔차를 구하면 모형이 과적합해 잔차를 실제보다 작게 만들고, 그 축소가 $\hat{\theta}$ 에 편향으로 남음. 자료를 K 조각으로 나눠 한 조각의 잔차를 나머지 조각으로 학습한 모형으로 계산하면 이 경로가 끊김

```
theta = float(resid_d @ resid_y) / (resid_d @ resid_d) # 잔차끼리 회귀
psi = resid_d * (resid_y - theta * resid_d) # 강건 표준오차 계산용
```

전체 코드는 [lecture_practice/chapter12/code/12-3-dml-highdim-confounding.py](#) 참고

- 한 표본에 숫자를 넣어 확인함. $Y = 3.1$, $\hat{g}(X) = 4.0$, $D = 1$, $\hat{m}(X) = 0.72$ 인 표본이라면 $\tilde{Y} = 3.1 - 4.0 = -0.90$, $\tilde{D} = 1 - 0.72 = 0.28$ 임. 성향점수가 0.72로 높은 표본(처치가 예상된 표본)은 $\tilde{D}$ 가 작아 추정에 작은 몫만 더하고, 예상과 어긋나게 처치된 표본일수록 $|\tilde{D}|$ 가 커져 추정에 더 큰 몫으로 들어감. 배정 규칙으로 설명되지 않는 변동만 골라 쓰는 구조가 여기에 있음

13.3 순진 비교와 DML의 차이

표 12-17 순진 OLS와 DML의 처치효과 추정 (참 $\theta = -2.0$)

추정량	$\hat{\theta}$	참값 대비 편향	SE
순진 OLS(선형 통제)	-0.579	+1.421	0.047
DML(교차적합 없음)	-1.754	+0.246	0.035
DML(교차적합 K=5)	-1.874	+0.126	0.036

- 순진 OLS의 $\hat{\theta}$ 는 -0.579로 참값 -2.0에서 +1.421만큼 벗어남. 비선형 교란이 선형 통제로 건히지 않고 남았고, 개입이 위기 심각 가구에 몰린 배정 구조가 그 교란과 얽혀 추정치를 0쪽으로 끌어올림. **개입 효과의 크기가 실제의 3분의 1 아래로 산출된 것**
- 같은 자료에서 DML 교차적합 K=5의 $\hat{\theta}$ 는 -1.874로 편향이 +0.126이며, 순진 OLS 편향의 9% 수준(95% 신뢰구간 [-1.945, -1.803])
- 교차적합의 몫도 표에서 드러남. 직교화는 하되 교차적합을 빼면 $\hat{\theta}$ 가 -1.754로, 교차적합을 넣은 -1.874보다 참값에서 멀. 같은 표본으로 nuisance를 학습하고 평가하면 잔차가 실제보다 작아지고 그 축소가 편향으로 남기 때문
- 이 대비가 정책 판단에 주는 함의는 **방법 선택이 결론을 바꾼다는 점**. 같은 자료에서 순진 비교는 개입 효과를 -0.58로, DML은 -1.87로 산출함. 전자를 근거로 삼으면 효과가 미미한 사업으로 판정되어 예산이 줄고, 후자를 근거로 삼으면 효과가 확인된 사업으로 판정됨

13.4 DML도 그대로 믿지 않는다

표 12-18 DML 추정의 진단 항목

진단	실행값	판정
nuisance 정확도	결과 $\hat{g}$ RMSE 0.31, 처치 $\hat{m}$ 0.29	보조 함수가 참 구조를 상당 부분 근사함
중첩(positivity)	성향점수 0.047~0.953	0과 1에서 떨어져 있어 두 군이 함께 관측되는 구간이 유지됨
표본분할 안정성	seed 0~4 평균 -1.869, SD 0.003	단일 분할의 우연으로 값이 정해지지 않음

- **중첩**은 극단 구간에서 특히 문제가 됨. 위기가 가장 심각한 가구가 항상 개입을 받으면 그 구간의 성향점수가 1에 붙고, 비교할 대조가 없으므로 그 영역의 효과는 식별되지 않음
- 95% 신뢰구간 [-1.945, -1.803]은 참값 -2.0을 포함하지 않음. 랜덤포레스트 nuisance에 남은 유한표본 편향 +0.126이 구간을 참값에서 밀어낸 결과이며, DML이 편향을 줄이되 유한표본에서 완전히 없애지는 못한다는 뜻임

주의. DML이 참값을 회복하는 것은 관측 공변량으로 처치배정이 조건부 무작위일 때임. 담당자 재량이나 비공식 정보처럼 자료에 없는 배정 동기가 있으면 성능 지표가 좋아도 추정치는 편향됨. 배정 규칙이 문서화되어 있는지 먼저 확인하고, 확인할 수 없으면 추정치를 효과의 크기가 아니라 방향의 참고값으로 씀.

14. 결과를 해석하고 처분과 분리하기

14.1 우선순위표 읽는 법

- 9단계의 첫 산출물은 단위별 우선순위표임. 열 구성은 단위 ID, 예측 위험, 구간 반폭, 신뢰등급, 취약계층 비율, 위기신호 강도의 여섯 열이 최소 구성
- 읽는 순서는 예측 위험 → 신뢰등급 → 근거 열임. 예측 위험으로 후보를 좁히고, 신뢰등급으로 그 예측을 배분 근거로 쓸지 확인 대상으로 돌릴지 가르고, 근거 열로 왜 높게 나왔는지 확인함
- 표 12-14의 1순위 31번과 2순위 75번이 이 판정이 갈리는 예임. 31번은 예측 위험이 가장 높지만 반폭이 넓어 신뢰등급 '낮음'이고, 75번은 예측 위험이 한 단계 낮지만 반폭이 좁아 '높음'임. 표 12-15의 규칙을 적용하면 두 단위 모두 방문 대상이지만 목적이 다름 — 31번은 자료 보완을 함께 하는 방문, 75번은 지원 연계를 목적으로 하는 방문
- 31번의 근거 열을 보면 인구 7,509명에 65세 이상 비율 0.284, 1인 가구 비율 0.511, 위기신호 강도 21.508, 의료 접근성 28.367로 확인됨. 고령·1인 가구 비중이 높고 의료시설이 먼 조건이 겹친 지역임
- 순위를 그대로 지원 확정으로 옮기지 않음. 실제 지원은 방문 확인과 자격 판정을 거치며, 우선순위표는 한정된 방문 인력을 어느 순서로 보낼지 정하는 배정 문서임

14.2 권역 단위로 모아 자원을 배분하기

- 격자·읍면동 예측은 그대로 예산 배정에 쓰이지 않음. 예산과 인력은 보건소 권역이나 자치단체 단위로 배정되므로, 예측값을 집행 단위로 집계하는 단계가 필요함(가중치는 7.4절 표 12-7에서 고름)

표 12-19 권역별 감염병 대응 자원 배분

권역	누적 발생(건)	누적 순위	다음 주 예측 발생(건)	예측 순위
0	4,083	1	255.50	2
1	3,613	2	273.68	1
6	3,055	3	252.62	3
7	1,782	4	150.04	4

- 누적 발생 순위와 예측 순위가 1·2위에서 어긋남. 권역 0은 40주 누적 4,083건으로 가장 많지만 다음 주 예측은 255.50건으로 권역 1의 273.68건에 뒤짐. 유행이 권역 0에서 꺾이고 권역 1에서 오르는 국면이면 두 순위가 갈릴 수 있음
- 자원 배분은 다음 기간에 필요한 양을 정하는 결정이므로 예측 순위를 따르되, 누적 순위도 함께 표에 남김. 두 순위가 크게 어긋날 때는 모형이 국면 전환을 잡은 것인지 최근 자료의 잡음을 확대한 것인지 확인해야 하고, 그 확인은 예측값만으로는 되지 않음

14.3 예측과 처분을 분리하기

- 예측 결과를 행정 행위로 연결하는 방식이 이 분야의 위험을 좌우함. 실패는 두 종류임 — 위험을 찾지 못하는 미발굴과, 위험이 없는 대상을 지목하는 오탐
- 두 실패의 비용은 대칭이 아님. 미발굴은 신청주의의 한계가 이어진 결과이므로 예측 체계가 없었을 때와 같은 상태에 머뭇. 오탐이 불이익 처분으로 직결되면 예측 체계가 없었으면 발생하지 않았을 피해가 새로 생기고, 그 피해를 입는 쪽은 대개 이익제기 자원이 가장 적은 집단임(자동화된 결정이 빈곤층에게 불리하게 작동하는 경로를 Eubanks(2018)가 미국 복지 자동화 사례로 기록)
- 미국 미시간주의 실업급여 자동판정 체계 MiDAS가 이 구조가 실제로 작동한 사례임. 2013~2015년 이 체계는 알고리즘 판정만으로 다수의 사기 판정을 산출했고, 이후 검토에서 상당수가 오판으로 확인됨. 판정을 받은 사람에게 임금 압류가 집행되었으며, 판정과 처분 사이에 사람의 검토가 없었음. 오판 비율과 피해 규모의 구체 수치는 출처에 따라 차이가 있어 여기서는 밝히지 않음(Bauserman v. Unemployment Insurance Agency, 미시간, 2022 합의로 종결)

표 12-20 자동 판정 실패의 지점과 설계 요건

실패 지점	MiDAS에서 일어난 일	설계 요건
처분 직결	자료 불일치라는 약한 신호가 사기 판정과 압류로 바로 이어짐	예측 점수를 불이익 처분의 근거로 쓰지 않음
설명 부재	판정 근거를 당사자가 확인할 수 없었음	어떤 요인으로 점수가 높게 산출됐는지 근거 열로 제시함
구제 부재	이의를 제기해도 실효적 시정 절차가 없었음	이의제기와 시정 절차를 처분 전에 둠

- 국내 사각지대 발굴 체계는 첫 행에서 다른 설계를 택함. 이 체계의 예측은 수급 중단이나 환수 같은 불이익 처분이 아니라 방문·상담이라는 지원 행위로 연결됨. 오탐이 발생해도 방문해 확인한 결과 위기가 아니었다는 기록으로 끝나며 처분으로 이어지지 않음. 예측 점수와 실제 지원 결정 사이에 담당자의 현장 확인이 있어 자동 처분 직결이 구조적으로 차단됨

주의. 예측 점수를 수급 중단·환수 같은 불이익 처분에 직접 연결하면, 잘못 지목된 사람이 곧바로 피해를 입고 그 사람은 대개 이의제기 자원이 가장 적음. 예측과 처분 사이에 현장 확인과 이의제기 절차를 두고, 오류의 방향이 지원 쪽으로만 열리도록 설계 단계에서 고정함.

14.4 배치 후에도 계속 확인할 것

표 12-21 정기 감사 항목(발체)

범주	지표	확인 주기
실행 연계	예측 상위 단위의 방문 실행률, 방문 후 지원 연계율	월
저정보 지역	위기정보 결측률 상위 단위의 발굴률 추이	분기
라벨 편향	관심 프록시와 라벨·예측의 상관 변화	반기

- 실행 연계 지표를 가장 먼저 확인함. 예측 상위 단위에 방문이 실제로 배정되지 않으면 나머지 지표는 모두 무의미해짐
- 저정보 지역 지표와 라벨 편향 지표는 짝을 이룸. 저정보 지역의 발굴률이 계속 낮게 유지되면 7.2절의 되먹임이 작동하고 있다는 신호이고, 그 지역의 현장확인 배정을 늘려 자료를 쌓는 개입이 필요함

15. 다른 자료에 적용하기

- 앞의 9단계는 복지 사각지대 예측을 기준으로 설명함. 같은 절차를 다른 자료에 적용하면 일부 단계가 달라짐. 세 사례로 어느 단계가 달라지는지 확인함

15.1 고립·고독사 위험

- 고독사 예방 및 관리에 관한 법률은 5년 주기 실태조사를 제도화함(2020 제정, 2021년 시행). 2022년 첫 실태조사에서 고독사 사망자 가운데 50대 남성이 26.6%, 60대 남성이 25.5%로 두 집단이 52.1%를 차지함(보건복지부, 2022)
- 이 구성이 뜻하는 바는 크다. 대상 집단을 초고령 독거노인으로 좁히면 실제 사망자의 절반을 놓침. 은퇴·이혼·실직으로 관계망이 끊긴 중·장년층을 피쳐 설계에 포함해야 하는 근거가 여기서 나옴
- **달라지는 단계는 2단계와 9단계임.** 2단계에서 예측 대상 y 와 관측 라벨 y^{obs} 의 시점이 어긋남. 고독사는 사후에만 관측되므로 사전 위험에 대응하는 라벨이 존재하지 않음. 사전 위험은 1인 가구 분포, 사회서비스 이용 이력, 건강보험 장기 미납, 안부 확인 공백 기간 같은 대리지표의 조합으로만 구성되고, 그 조합의 가중치를 정할 정답 자료가 없음. 대응은 가중치를 하나로 확정하지 않고 여러 조합에서 상위 단위가 유지되는지 보고하는 것임
- 9단계에서는 산출물 단위가 제한됨. 개인 단위 위험 점수로 당사자를 지목하면 수치심과 방어적 회피를 유발해 접촉을 더 어렵게 만들 수 있음. 그래서 산출물을 개인 점수가 아니라 읍면동·격자 단위 위험도로 고정하고, 지역 단위 서비스 배치(방문·안부 확인 인력, 생활 지원 거점)로 연결함
- **같은 단계는 3~6단계임.** 신호의 성격이 8절의 위기정보와 닮아 있음. 이 사례는 실습 코드와 실행 로그가 없으므로 절차와 제도 통계만 다루고 분석 결과 수치는 붙이지 않음

15.2 감염병 조기경보의 운영 배치

- 12절의 스캔 통계를 한 번 실행하는 것과 매일 실행하는 것은 다른 작업임
- **달라지는 단계는 7단계임.** 일회성 분석에서는 자료 하나에 대해 p 값 하나를 얻고 끝나지만, 매일 실행하면 같은 검정을 반복하는 만큼 우연히 유의한 결과가 나오는 횟수가 쌓임. 12.3절의 순열검정은 한 번의 실행 안에서 여러 윈도우를 탐색한 몫은 반영하지만, 날짜를 가로지르는 반복까지 반영하지는 않음
- 운영 체계에서는 경보 임계를 정할 때 이 누적을 함께 고려함. 순열 분포의 어느 분위를 임계로 쓸지, 며칠 연속 같은 지역이 임계를 넘을 때 경보로 확정할지, 경보를 발령한 지역을 며칠간 재경보에서 제외할지를 사전에 정해 문서로 남김
- 경보와 조사 착수의 연계 규칙도 여기 포함됨. 탐지된 군집은 조사의 가설이며 확진이 아니므로, 경보 발령이 곧 대응 자원 투입이 되지 않도록 두 단계를 분리함. 뉴욕시 보건부의 일일 스캔 운영에서도 탐지 결과는 역학조사 착수의 근거로 쓰였고, 조사에서 확인된 사례만 대응으로 이어짐(Greene et al., 2016)
- **같은 단계는 2단계임.** 진단·신고 기록이 검사량과 신고 체계에 좌우되는 구조는 7절과 같음. 이 사례의 국내외 운영 지표(탐지 건수, 오경보율)는 확인하지 못했으므로 방법 배치와 절차만 다룸

15.3 미충족 수요와 동물병원 입지 선택

- 앞의 두 사례는 공공 자원 배분이었음. 이 소절은 같은 접근성 계산을 민간 사업자가 쓰는 경우를 다룸. 공급이 수요를 못 따라가는 지역은 행정에게 확충 대상이고 사업자에게 진입 후보이며, 두 판단은 같은 지도에서 나옴
- **달라지는 단계는 1단계와 9단계임.** 1단계에서 결정 주체가 행정에서 사업자로 바뀌고 목적함수가 미충족 해소에서 기여이익 최대화로 바뀜. 9단계에는 자기잠식, 용량 제약, 원가 컷라인이 들어옴. 5~8단계는 수행하지 않음 — 접근성은 계산으로 확정되고 남은 물음이 예측이 아니라 배분이기 때문
- **같은 단계는 2~4단계임.** 분석 단위 정의, 수요 자료 구성, 2SFCA 접근성과 미충족 수요 계산은 9절의 절차를 그대로 씀

15.3.1 왜 동물병원인가

- 민간 의료 입지의 예로 약국을 쓰면 결론이 미리 정해짐. 약국 매출의 대부분이 처방 조제이므로 입지의 1순위 변수는 병원과의 근접성이고, 인구 피처로 분석해도 "병원 옆에 약국이 있다"는 사실을 재발견하는 데 그침
- 반려동물 의료는 다름. 수요가 처방 연계가 아니라 사육 가구의 거주지에서 나오고(인구·가구 피처가 직접 설명변수), 개설 자격은 의사사법 제17조가 의사·국가·법인으로 제한하지만 입지 자체를 제한하지 않으며, 2SFCA·서비스 권역·이동시간이 사람 의료와 같은 형태로 쓰임. 다만 건강보험이 없어 진료비가 전액 자기부담이므로, 접근성과 함께 지불 능력이 수요를 가름

15.3.2 자료와 가정을 세 갈래로 나누기

- 기존 동물병원 위치는 소상공인시장진흥공단 상가정보(2026년 6월판)에서 얻음. 서울 전체 점포 554,092개 가운데 동물병원은 905개이며 좌표 결측률은 0.000%. 자치구별로 강남구 92개·송파구 85개가 가장 많고 종로구 11개가 가장 적음
- 배후 수요는 서울 열린데이터광장 행정동 생활인구 중 **심야 0~5시 평균**을 씀. 동물병원 수요는 낮에 오는 사람이 아니라 그 지역에 사는 사람에게서 나오고, 심야에 그 지역에 있는 사람은 대체로 거주자이기 때문임. 대표점 매칭(97.2%) 이후 415개 동, 9,617,177명이 분석에 들어감. 후보지는 250m 격자 5,462곳
- 분석에 들어간 값은 출처가 확인된 값과 확인되지 않은 값이 섞여 있음. 섞인 채 두면 가정을 사실처럼 인용하게 되므로 갈라 적음

표 12-22 분석 입력값의 출처와 성격

값	설정	성격
마리당 월 병원비	37,000원	검증값 — 농림축산식품부 2025년 반려동물 양육현황조사
인구 1인당 반려동물 ρ	0.104	산출값 — 전국 사육률 $\times$ 서울/전국 양육가구비
지점 용량	서울 평균 담당 마리수 $\times$ 1.8	가정 — 배수를 1.4·1.0으로도 계산
거리 저항 β	2.0	가정 — 개인 방문 자료가 없어 1.5·2.5로 민감도를 봄
기여이익률	60%	가정 — 소매점 값을 업종을 가로질러 쓰지 않음

- 거리는 투영좌표(EPSG:5179)의 직선거리를 씀. 도로망 이동시간을 쓰려면 국내 도로의 표준 우회계수가 필요한데 확인하지 못해 적용하지 않았고, 이 근사는 접근성을 과대평가하는 방향으로 치우침(2절 10절의 우회비 논의와 같은 문제)
- 가정을 금액으로 환산해 실무 감각과 맞는지 먼저 확인함. 서울 동물병원 시장 규모는 월 370억원(연 4,441억원), 병원 한 곳의 평균 월 매출은 4,089만원으로 산출됨. 이 두 값이 실무 감각과 크게 어긋나면 최적화를 정교히 해도 교정되지 않으므로, 그 경우 사육률·기여이익률 가정을 먼저 고침

15.3.3 현행 접근성과 미충족 수요

- 추정 수요는 서울 전체 1,000,186마리, 병원 한 곳이 담당하는 평균은 1,105마리. 지점 용량을 그 1.8배 (1,989마리/월)로 두고 2SFCA 접근성 A_i 를 계산하면 최소 0.685, 중앙값 1.717, 최대 3.186으로 갈림
- 기준 접근성 A^* 는 9.3절의 정의대로 수요가중 평균으로 두었고 실행값은 1.8000으로 용량 배수와 일치함. 접근성 비율 A_i/A^* 는 최소 0.381, 중앙값 0.954, 최대 1.770
- 미충족 수요가 있는 행정동은 239개(57.6%)이고 합계는 108,080마리로 전체 수요의 10.8%

표 12-23 미충족 수요 상위 6 행정동

행정동	자치구	접근성비 A/A^*	미충족(마리)
진관동	은평구	0.469	3,197
세곡동	강남구	0.416	3,179
오류2동	구로구	0.669	1,930
강일동	강동구	0.683	1,799
가산동	금천구	0.545	1,766
대학동	관악구	0.454	1,718

- 상위에 오른 행정동은 대규모 택지와 산업단지처럼 인구가 뒤늦게 들어온 지역임. 시설 공급이 인구 유입을 따라가는 데 시차가 생기는 구조가 이 목록에 반영됨. 공공 분석이라면 이 표가 우선순위표가 되고 예산 배분으로 넘어감. 민간의 계산은 여기서 시작됨

15.3.4 순서대로 고르면 답이 달라진다

- 신규 체인이 서울에 10개 지점을 낸다고 하자. 표 12-23의 상위 10곳을 그대로 고르는 것이 자연스러워 보이지만 그렇게 되지 않음. 첫 선택이 둘째 선택의 조건을 바꾸기 때문이며, 두 경로로 그렇게 됨
- **자기잠식** — 이미 낸 지점과 가까운 자리에 새 지점을 내면, 새 지점이 끌어오는 수요의 일부가 자사 기존 지점에서 옮겨 온 몫임. 지점별 매출을 더하면 늘어난 것처럼 보이지만 회사 전체의 증가분은 그보다 작음
- **용량 제약** — 지점이 받을 수 있는 수요에는 상한이 있음. 상한을 넘긴 자리 근처에 남은 수요는 여전히 미충족으로 남음
- 두 경로 모두 이미 고른 것이 많아질수록 하나 더 고를 때의 이득이 줄어드는 구조를 만들. 이런 구조에서는 한계 이득이 가장 큰 후보를 차례로 고르고 이득이 소진되면 멈추는 **탐욕적 순차 선택**을 씀

표 12-24 제약 하 탐욕적 순차 선택 결과 ($\beta = 2.0$, 용량 배수 1.8)

순서	자치구	실현 포획	용량 소진
1	은평구	1,989	100.0%
2	금천구	1,989	100.0%
3	관악구	1,989	100.0%
...	...	...	...
10	은평구	1,989	100.0%

- 단독 배분(각 자리를 혼자 있다고 가정한 값) 합은 25,168마리였는데, 동시 배분(열 곳이 함께 있을 때의 값)은 24,801마리로 줄어듦. 이 차이가 자기잠식이며 손실률은 1.5%. 실현 포획이 19,893마리로 더 줄어든 것은 용량 상한 때문이며, 열 지점 모두 상한 1,989마리에 걸림
- 이 낮은 자기잠식률(1.5%)을 "자기잠식이 문제 되지 않는다"는 결론으로 읽으면 안 됨. 탐욕 절차의 선택 결과가 서로 겹치지 않는 자리에 놓였기 때문이며, 뒤에서 보듯 순위표를 그대로 따르면 같은 자료에서 자기잠식률이 18.3%로 올라감

15.3.5 손익분기와 원가 컷라인

- 월 매출은 실현 포획 $\times$ 37,000원, 월 기여이익은 매출 $\times$ 기여이익률이므로 손익분기 포획은 다음과 같이 역산됨

$$\begin{aligned}\text{손익분기 포획} &= \text{고정비} \div (\text{마리당 월 병원비} \times \text{기여이익률}) \\ &= 1,600\text{만원} \div (37,000 \times 0.60) = 721\text{마리/월}\end{aligned}$$

- 컷라인은 그 지점의 자기 매출이 아니라 자기잠식을 뺀 **한계 순증**에 적용함. 자기 매출로 판정하면 이미 낸 지점에서 옮겨 온 몫을 새로 생긴 이익으로 세게 되어, 회사 전체로는 손해인 지점을 열게 됨
- 이 기준으로 판정하면 열 지점의 한계 순증이 모두 1,989마리로 손익분기 721마리를 크게 넘어 10곳 전부가 통과함. 고정비를 1,600만원에서 4,400만원까지 올려도 10곳이 모두 남고, 4,800만원(손익분기 2,162마리)에서는 10곳이 한꺼번에 탈락함. 열 지점이 모두 같은 용량 상한에 걸려 한계 순증이 같으므로 탈락도 동시에 일어남

15.3.6 네 전략을 채점표로 비교하기

- 같은 후보 5,462곳에서 네 방식으로 10곳을 고르고 같은 평가자로 채점함

표 12-25 네 전략의 비교 (K = 10, 용량 배수 1.8)

전략	실현 포획	자기잠식률	총 월 영업이익(백만원)
N0 인구 상위 K	13,003	19.7%	128.7
N1 미충족 수요 상위 K	13,399	18.3%	137.5
N2 N1 + 이격 1km	14,051	9.0%	151.9
G 탐욕 순차	19,893	1.5%	281.6

- 탐욕 선택은 미충족 수요 순위 대비 실현 포획이 6,494마리(+48.5%) 많고 월 영업이익도 1억 4,410만원 많음. 선택된 격차는 두 순위표 어느 쪽과도 하나도 겹치지 않음
- 격차를 세 항으로 분해하면 자리 자체의 포획력 차이가 +8,770마리로 가장 크고, 자기잠식 손실의 차이가 +2,632마리, 용량 손실의 차이가 -4,908마리임. **격차의 주된 출처는 자기잠식이 아니라 자리 자체의 포획력임.** 미충족 수요가 큰 지역과 포획이 큰 지역이 서로 다르다는 뜻이며, 미충족 수요는 접근성 비율이 낮은 곳에서 커지는데 그런 지역은 배후 수요 자체가 얇은 경우가 많음. 진단 지표의 순위가 곧 좋은 입지는 아니라는 것
- 다만 자치구 수준에서는 크게 겹침. 탐욕 선택이 고른 곳은 강남·강동·관악·구로·금천·동작·영등포·은평구이고, 표 12-23의 상위 행정동이 속한 자치구와 상당 부분 같음. **진단은 어느 권역을 볼지 좁히고, 결정은 그 권역 안에서 배분·잠식·용량·원가가 정함**

15.3.7 가정이 흔들려도 결론이 버티는가

- 용량이 빠듯해질수록 탐욕 선택과 순위표 선택의 차이가 줄어듦. 용량 배수를 1.8 → 1.4 → 1.0으로 낮추면 차이는 +6,494 → +2,300 → +0으로 줄어들고, 배수 1.0에서는 완전히 같아짐. 용량이 낮으면 어지간한 자리는 모두 상한을 채우므로 입지의 우열이 사라지기 때문임

- β (거리 저항)를 1.5로 낮추면 선택 집합이 기준과 크게 달라짐(Jaccard 0.43). β 를 추정할 개인 방문 자료가 없으므로 이 소절의 좌표 목록을 확정된 후보지로 쓸 수 없음
- 다만 결론의 부호는 바뀌지 않음. 탐욕 선택이 순위표를 앞서는 정도는 모든 시나리오에서 0 이상이며 부호가 뒤집힌 적이 없음. 순위표를 그대로 결정으로 쓰면 손해라는 결론은 가정에 견고하고, 손해의 크기만 가정에 달려 있음
- 확인 못 한 사육률 ρ 는 선택 자체를 바꾸지 않음(ρ 를 $\pm 30\%$ 바꿔도 Jaccard 1.00). 9.3절에서 A^* 를 수요가중 평균으로 정의한 덕분에 접근성 비율이 ρ 에 불변이고, ρ 는 금액만 비례로 움직이기 때문임




그림 12-2 서울 동물병원의 미충족 수요와 제약 하 순차 입지 선택. 점 크기는 미충족 수요, 색은 접근성 비율이다.

주의. 기존 매장이 있는 지역에서만 이용 자료가 생성되므로, 그 자료로 학습한 수요 모형은 미진출 지역을 낮게 추정함. 자료가 없는 지역을 수요가 없는 지역으로 읽지 않고, 인구·가구처럼 매장 유무와 무관하게 관측되는 변수로 배후 수요를 별도 산출해 대조함(이 소절이 생활인구를 수요 기준으로 삼은

이유).

16. 방법 점검표

- 새 복지·보건 수요 분석 과제를 시작할 때 아래 표를 먼저 채움. 각 행은 6절의 아홉 단계에 대응하며, 채우지 못한 행이 있으면 그 단계의 결정 근거가 아직 없다는 뜻임

표 12-26 복지·보건 수요 분석 방법 점검표(축약)

단계	항목	기록할 내용
1	정책 질문	사각지대·접근성·위험 집중·자원 배분 가운데 무엇인가
2	관측 라벨	발굴·신청·수급·진단·신고 중 어떤 과정으로 기록되는가
2	라벨 편향 진단	차등 결측·관심 프록시 상관·감사 표본·준실험 중 무엇을 수행했는가
3	피처 가용성	각 피처를 예측 시점에 어디서 받아 오는가
4	접근성 지표	최근접 이동시간·2SFCA 중 무엇이며 용량 대리변수는 무엇인가
5	검증 설계	공간 블록·시간 블록 중 무엇이며 블록 크기는 얼마인가
6	등급 경계	신뢰등급의 경계를 어떤 기준으로 정했는가
7	탐지 설정	윈도우 인구 상한, 순열 횟수, 경보 임계 분위
8	식별 가정	배정 규칙이 문서화되어 있는가. 중첩이 성립하는가
9	처분 경로	예측에서 처분까지 사람의 판단 단계가 있는가

- 사각지대 분석에서는 2단계의 라벨 편향 진단과 9단계의 처분 경로가 중심이 됨. 감염병 분석에서는 3단계의 시차 구조와 7단계의 반복 실행 설정이 중심이 됨. 개입효과 분석에서는 8단계의 식별 가정이 중심이 되고, 그 가정을 확인할 수 없으면 추정치를 크기가 아니라 방향의 참고값으로 씀

체크 질문

1. y_i , y_i^{obs} , $\hat{y}_i$ 는 각각 무엇을 가리키며, 왜 셋을 구분해야 하는가?
2. 발굴·신청·수급 기록에 담긴 되먹임 구조는 어떤 방향으로 열려 있는가?
3. 신호 하나의 양성예측도가 낮아도 결합하면 올라가는 이유는 무엇인가?
4. 접근성 계산에는 왜 학습 모델을 쓰지 않는가?
5. 2SFCA의 A_i 가 재는 값은 무엇이며, 이동시간과 무엇이 다른가?
6. 공간 블록 교차검증과 랜덤 교차검증이 같은 R^2 를 낼 때, 이 값을 어떻게 해석해야 하는가?

7. 복지 분석에서 저신뢰 예측을 배제하지 않고 현장확인으로 돌리는 이유는 무엇인가?
8. 공간 스캔 통계에서 관측 상대위험이 설계값보다 낮게 나오는 이유는 무엇인가?
9. DML의 세 장치(유연한 학습, 직교화, 교차적합) 각각이 제거하는 것은 무엇인가?
10. 예측 점수를 처분과 분리해야 하는 이유를 MiDAS 사례로 설명하라
11. 미충족 수요 순위표를 그대로 입지 결정으로 쓰면 안 되는 이유는 무엇인가?

과제

```
python scripts/submit.py 12 --id 학번 --name 이름
```

- 실행하면 `submissions/` 폴더에 `제출_12장_학번.md` 가 생성되고 `12-5-unmet-demand-siting.py` 의 실행 결과가 붙어 있음
- **눈여겨볼 곳은 미충족 수요 상위 목록과 탐욕적 순차 선택 결과가 어긋나는 지점**
- 빈칸 세 개를 채움
 1. 미충족 수요 상위 10곳과 탐욕적 순차 선택 10곳이 얼마나 겹치는지 적고(Jaccard), 겹치지 않는 이유를 자기잠식·용량·자리 포획력 중 무엇이 가장 크게 기여하는지 표 12-25의 격차 분해로 설명하라
 2. "가장 부족한 곳 10군데"와 "순서대로 고른 10군데" 중 예산을 어느 쪽에 쓰겠는가? 그 근거를 한 문단으로 적으라
 3. 용량 배수를 1.0으로 낮추면 두 목록의 차이가 사라진다. 이 결과가 입지 분석 자체에 대해 무엇을 말하는지 적으라
- **2번과 3번이 핵심.** 1번은 표를 읽으면 나오지만 2:3번은 판단이 필요함

- **막혀도 제출함**
- 실행이 실패하면 오류 메시지가 파일에 담기고, 질문이 "어디서 막혔나"로 바뀜

- **이 장의 동물병원 실습은 실제 서울 자료를 씀**
- `12-0b-vetcare-data-prep.py` 를 먼저 실행해 원자료를 준비해야 함
(`lecture_practice/chapter12/data/raw/README.md` 참고)
- 사각지대·감염병·DML·SaTScan 네 실습은 합성자료이므로 결과가 항상 같지만, 동물병원 실습은 실데이터 갱신 시점에 따라 값이 달라질 수 있음

더 알아보기

- 복지 사각지대 발굴시스템의 실제 운영을 보기

- 보건복지부 사이트(<https://www.mohw.go.kr>)에서 위기정보 47종의 목록과 21개 연계 기관을 확인하면 8절의 표가 손에 잡힘

- 감염병 신고 자료의 구조를 보기

- 질병관리청 감염병포털(<https://dportal.kdca.go.kr>)에서 신고 통계의 갱신 주기와 공개 범위를 확인하면 12절의 스캔 통계가 어떤 자료 위에서 도는지 감이 잡힘

- 자동화된 행정 결정의 위험을 더 읽기

- Eubanks, *Automating Inequality*(2018)는 미국 복지 자동화 세 사례를 다루며, 14.3절의 처분 분리 논의가 이 책의 문제의식과 이어짐

- 공간 스캔 통계를 손으로 돌려 보기

- Kulldorff(1997)의 원 논문과 SaTScan 소프트웨어 문서를 보면 12절에서 다룬 다섯 단계 계산이 실제 소프트웨어에서 어떻게 구현되는지 확인할 수 있음

참고문헌

국가법령정보센터. *고독사 예방 및 관리에 관한 법률*(2020 제정, 2021.4.1 시행). <https://www.law.go.kr>

국가법령정보센터. *수의사법 제17조(개설)*. <https://www.law.go.kr>

보건복지부. *복지 사각지대 발굴시스템*(21개 기관 47종 위기정보). <https://www.mohw.go.kr>

보건복지부. (2022). *고독사 실태조사 결과*. <https://www.mohw.go.kr>

질병관리청. *감염병포털*. <https://dportal.kdca.go.kr>

소상공인시장진흥공단. *상가(상권)정보*(2026년 6월). <https://www.data.go.kr/data/15083033/fileData.do>

Chernozhukov, V., Chetverikov, D., Demirer, M., Duflo, E., Hansen, C., Newey, W., & Robins, J. (2018). Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*, 21(1), C1–C68.

Eubanks, V. (2018). *Automating Inequality: How High-Tech Tools Profile, Police, and Punish the Poor*. St. Martin's Press.

Greene, S. K., Peterson, E. R., Kapell, D., Fine, A. D., & Kulldorff, M. (2016). Daily reportable disease spatiotemporal cluster detection, New York City, New York, USA, 2014–2015. *American Journal of Epidemiology*, 184(7), 538–548.

Kulldorff, M. (1997). A spatial scan statistic. *Communications in Statistics: Theory and Methods*, 26(6), 1481–1496.

Lei, J., G'Sell, M., Rinaldo, A., Tibshirani, R. J., & Wasserman, L. (2018). Distribution-free predictive inference for regression. *Journal of the American Statistical Association*, 113(523), 1094–1111.

Luo, W., & Wang, F. (2003). Measures of spatial accessibility to health care in a GIS environment: Synthesis and a case study in the Chicago region. *Environment and Planning B: Planning and Design*, 30(6), 865–884.

Romano, Y., Patterson, E., & Candès, E. J. (2019). Conformalized quantile regression. *Advances in Neural Information Processing Systems* 32, 3538–3548.