

14장 입지 분석, 수요에서 자기잠식과 선택까지

- 이 장에 나오는 점포 수, 인구, 배분 수요, 전이율, 상관계수는 모두 `lecture_practice/chapter14/` 의 코드를 실제로 실행해 얻은 값
- 예시를 위해 지어낸 숫자는 없음(단, 계산 원리를 손으로 확인하는 단락은 "계산 예"로 표시하고 실행 결과와 구분함)

1. 이 장의 핵심 질문

□ 카페 프랜차이즈 본사가 "강남구에 매장을 하나 더 낸다"고 정했을 때, 실제로 답해야 하는 질문은 "어디가 좋아 보이는가"가 아님

1. **이 자리에 매장을 열면 회사 전체 매출이 얼마나 늘어나는가.** 새 매장이 끌어온 손님 중 일부가 원래 자사 매장에 가던 손님이라면, 새 매장의 매출은 늘었어도 회사 전체는 그만큼 늘지 않음. 이 현상이 **자기잠식(cannibalization)**임
2. **한 지역의 수요는 주변 매장들 사이에 어떻게 나뉘는가.** 매장이 하나 늘면 왜 나머지 전부의 몫이 함께 줄어드는가
3. **이 계산의 어디까지를 결정에 쓸 수 있는가.** 절대량과 순위 중 무엇이 가정에 건디는가

○ 임대차 계약은 보통 몇 년 단위로 묶임. **첫 자리를 잘못 고르면 그 손해가 계약 기간 내내 쌓임.** 그래서 "느낌이 좋다"가 아니라 계산으로 답해야 함

2. 도입 사례: 카페 2,123개 사이에 한 자리를 더 끼워 넣기

□ 4.4에서 직접 실행할 `14-0-data-prep.py` 의 출력에 다음이 나옴

- 상가정보 원본: 소상공인시장진흥공단 상가(상권)정보 서울 202606(302MB)
- **강남구 '카페' 점포: 2,123개**, 행정동 22개
- 상호명 상위 3곳: 스타벅스 102 / 투썸플레이스 12 / 매머드익스프레스 7
- 생활인구 원본: 서울 열린데이터광장 행정동 단위 생활인구(179MB), 424개 동, 11~15시 평균
- 두 자료의 행정동코드 결합률: 99.5%(2,113/2,123)

□ **이 숫자들만으로도 문제의 크기가 드러남.** 강남구 한 자치구의 카페가 원자료 기준 2,123개임

○ 이 가운데 생활인구와 결합된 2,113개가 분석 대상이고, 그 안에서 자사(스타벅스)가 102개, 경쟁 브랜드가 2,011개임

○ 빠진 10개는 점포의 행정동코드가 생활인구 자료에 없어 결합되지 않은 것임(결합률 99.5%)

○ 즉 "카페 하나를 더 연다"는 결정은 **이미 붐비는 시장에 한 자리를 더 끼워 넣는 일임**

□ 5절에서 직접 실행할 14-1-huff-location-cannibalization.py 의 출력에는 이 붐빔이 계산에 그대로 반영됨

○ 자사(스타벅스) 매장 점유율: **4.8%**(102 / 2,113)

○ 후보자: 250m 격자 540개, 자사 최근점 거리 중앙값 301m

○ 최선 후보 하나의 예상 배분: **1,228명**, 그중 자기잠식 **80명**(전이율 6.5%), 순증 **1,148명**

□ 배분받는 1,228명 가운데 자기잠식은 80명뿐이고 나머지는 순증임

○ 왜 자기잠식이 이렇게 작은지는 6절에서 계산으로 확인함. 결론을 미리 말하면, 자사 점유율(4.8%)이 낮을수록 신규 매장이 가져오는 수요의 대부분이 경쟁사에서 온다는 계산 구조 때문임

○ 이 결과가 어떻게 나왔는지 감을 잡기 위해 핵심 코드 몇 줄만 먼저 확인함

```
def huff_weights(dx, dy, sx, sy, attract, beta):  
    """수요 지점 x 매장의 '끌어당기는 점수'  $A/d^{\beta}$ ."""  
    d = np.hypot(dx[:, None] - sx[None, :], dy[:, None] - sy[None, :])  
    np.maximum(d, MIN_DIST_M, out=d)  
    return attract[None, :] / d ** beta
```

□ 세 가지를 먼저 확인함

○ 함수 이름부터 이 장의 핵심 계산이 *****끌어당기는 점수**(A/d^{β})**라는 것을 보여 줌

○ **attract** (매력도)는 분자에, 거리(**d**)는 분모의 지수(**beta**)로 들어감. **거리가 커지면 점수가 빠르게 작아짐**

○ `np.maximum(d, MIN_DIST_M, ...)` 은 거리가 0에 가까울 때 나눗셈이 터지는 것을 막는 하한선임. 이 한 줄이 없으면 바로 옆 칸을 후보로 셀 때 계산이 깨짐

○ 이 코드는 눈으로만 보고 넘기지 않음 — 5절 첫머리에서 같은 파일을 직접 실행하고, 위의 **4.8%·1,228명·80명이 화면에 그대로 찍히는 것을 확인함**

3. 어떤 결정인지, 어느 단위에서

3.1 결정 유형이 목적함수를 정한다

○ 같은 흡인 모형을 돌려도 "무엇을 최대화하는가"가 다르면 상위 후보가 뒤바뀜

결정 유형	후보 집합	목적함수
신규 출점	격자·필지·공실 목록	순증 최대화, 전이율 상한
이전	현 위치 + 대체 후보	이전 후 순증 - 이전 전 배분
철회	자사 기존점	손실 최소화 = 배분 - 회수분
권역 설계	매장 × 수요 지점 배정	커버리지 최대 또는 배송 원가 최소

○ 신규 출점과 이전은 계산 구조가 같음. 이전은 기존 매장을 없앤 상태에서 새 위치를 넣고 다시 계산하는 것이므로, 철회와 출점을 한 번씩 이어 붙인 형태임

○ 철회는 부호만 반대임. 매장을 빼고 다시 계산하면 남은 자사 매장이 흡수하는 몫이 나오고, 그 몫을 원래 배분에서 빼면 손실이 나옴(10절)

3.2 가장 거친 단위가 해상도를 정한다

○ 입지 분석에는 서로 다른 세 층위의 공간 단위가 동시에 들어감

층위	대상	흔히 쓰는 단위	정하는 것
수요 지점	인구가 집계된 위치	행정동, 격자	배분 계산의 해상도
후보지	신규 매장을 놓을 위치	250m 격자, 필지	결정의 세밀도
매장	기존 자사·경쟁 매장	점(좌표)	분모에 들어가는 경쟁 집합

□ 세 층위 가운데 가장 거친 단위가 분석 전체의 해상도를 정함

○ 강남구 사례에서 이 관계가 실제로 나타남. 후보지는 250m 격자로 촘촘히 깔았지만 수요는 행정동 (21개) 단위로만 있음. 그래서 같은 행정동 안의 후보지들은 거리에 따른 차이만 있고, 수요 자체는 거의 같은 값을 나눠 받음

○ 이 한계는 이 사례의 결과를 해석할 때 계속 따라다니는 조건이므로 여기서 미리 적어 둠

주의. 행정동 단위로 집계된 인구를 250m 격자에 그냥 균등하게 나눠 놓으면 안 됨. 카페가 많은 동일수록 배정되는 격자 수가 늘어 격자당 인구가 오히려 낮아지고, 정말 붐비는 상권이 인구 희박 지역처럼 계산됨. 실제 분포를 반영할 보조 자료(건물 연면적 등)가 없으면 거친 단위를 그대로 쓰는 편이 나옴.

3.3 상권을 어떻게 그을까

○ 상권은 한 매장이 고객을 끌어오는 지리적 범위임. 임의로 정하는 것이 아니라 누적 고객 비율로 정의함 — 고객을 거리순으로 세워 누적 비율이 일정 수준(보통 60~70%)에 이르는 지점까지가 1차 상권임

방법	필요한 자료	경쟁 반영	적용 대상
원형 버퍼	매장 좌표, 반경	없음	좌표만 있을 때
행정 경계	매장 좌표, 경계 파일	없음	통계 자료와 결합할 때
Thiessen 다각형	매장 좌표 전체	최근접만	매장 규모가 비슷할 때
고객점표법	고객 거주지 자료	실측에 포함	영업 중인 매장
Huff 확률 등고선	매장 좌표·매력도, β	분모에 포함	신규 후보지

□ **고객점표법**은 실제로 온 손님의 거주지를 지도에 찍어 침투율이 떨어지는 거리를 찾는 방법임 (Applebaum, 1966). 정확하지만 **이미 영업 중인 매장에만 쓸 수 있음** — 아직 열지 않은 후보지에는 손님이 없어서 쓸 자료가 없음

○ 그래서 **신규 후보지의 상권은 모형으로 그림**(Huff, 1964). 5절의 흡인 모형으로 각 지역에서 해당 매장을 고를 확률을 계산하고, 확률이 같은 지점을 이으면 확률 등고선이 나옴

3.4 집계 단위를 바꾸면 답이 달라진다

□ 같은 원자료에서 다른 결론이 나올 수 있는 현상을 **MAUP**라 부름(Openshaw, 1984). 두 가지 방식으로 나타남

○ **축척 효과**: 후보지 격자를 100m로 잘게 자르면 이웃 격자끼리 값이 거의 같아져 순위 차이가 흐려짐. 500m로 키우면 격자 안의 좋은 자리와 나쁜 자리가 평균에 섞임

○ **구획 효과**: 같은 지역을 행정동으로 자를 때와 지하철역 중심으로 자를 때, 어느 상권이 유망한지 답이 달라짐

○ **대응 방법은 하나로 확정하지 않는 것임**. 후보지 격자를 두세 가지 크기로 바꿔 상위 후보를 각각 산출하고, 최선 후보의 위치가 얼마나 이동하는지 재 봄. **이동이 격자 한 칸 이내면 단위 선택이 결론을 바꾸지 않은 것이고, 여러 칸을 넘으면 단위 선택이 결론을 만들고 있다는 뜻임**

4. 자료를 확보하고 점검한다

4.1 다섯 항목 점검

○ 자료를 계산에 넣기 전에 다섯 가지를 순서대로 확인함. **하나라도 답을 못 적으면 그 자료를 그대로 쓰지 않음**

#	항목	확인할 것
1	공간 단위	분석 단위와 맞는가(후보지 격자 대 수요 자료의 행정동)
2	갱신 주기·시점	두 자료의 기준 시점이 얼마나 떨어져 있는가
3	결측 구조	빈 칸이 최소 집계 규칙 때문인지, 애초에 수집 안 된 것인지
4	구조적 편향	관측값이 지역마다 다른 비율로 실제값을 담고 있지 않은가
5	라이선스	분석·결과공개·원자료배포 각각 허용되는가

□ 강남구 사례에 적용하면 **세 가지가 걸림**

- **공간 단위**: 수요가 행정동 단위인데 후보지는 250m 격자임(3.2)
- **매력도 대리변수 부재**: 상가정보에 매장 면적도 매출도 없어, 매력도는 상수(모두 같다)에서 출발함
- **방문 자료 부재**: β 를 실제 자료로 추정할 방법이 없어, 여러 값(1.5·2.0·2.5)을 비교해 결론이 흔들리는지 봄
- 나머지 두 항목(시점·라이선스)은 통과함. 두 자료 모두 2026년 6~7월 기준으로 시점이 맞고, 분석과 결과 공개는 허용하되 원자료 재배포는 허용하지 않음

4.2 정주 인구가 아니라 활동 인구를 쓴다

□ 반경 안에 인구가 많다고 해서 잠재 고객이 그만큼이라고 말할 수 없음. **그 인구가 그 시간에 그곳에 있는지가 더 중요함**

- **정주 인구**는 그 지역에 주소를 둔 사람의 수, **활동 인구**는 특정 시간에 그 지역에 있는 사람의 수임
- **오피스가 많은 지역은 정주 인구가 적어도 평일 낮 활동 인구는 매우 많음**. 점심 매출이 중심인 카페 업종에서는 정주 인구만 보면 이런 지역을 놓침
- 그래서 강남구 사례는 **평일 낮 11~15시 활동 인구**를 수요로 씀. 이 선택은 업종에 따라 바뀜 — 저녁 술집이면 평일 저녁, 주말 나들이 상권이면 주말 오후를 씀

4.3 배후 수요를 세는 세 가지 방법

- "후보지 반경 500m 안에 3,000명이 산다"는 사실만으로는 잠재 고객이 3,000명이라고 말할 수 없음
- ① **원형 버퍼 인구 합산**: 반경 r 안의 인구를 그냥 더함. 계산은 간단하지만 경쟁 매장을 반영하지 않고 하천·철로 같은 장벽도 무시하므로 **항상 과대 계산됨**
- ② **도로망 이동시간 권역**: 도로를 따라 실제로 몇 분 안에 닿는 범위를 계산함. 장벽이 자동으로 반영되지만 도로망 자료와 통행 속도 자료가 필요함
- ③ **확률적 배분**: 앞의 두 방법은 "권역 안이면 100%, 밖이면 0%"라는 이분법을 씀. **실제 소비자는 경계선에서 방문 여부를 딱 끊지 않으므로**, 각 지역의 인구를 여러 매장에 확률로 나누는 방법이 세 번째임

- 세 방법의 차이는 하나의 질문으로 요약됨 — "수요 지점 i 의 인구가 후보지 c 에 배정되는 비율을 어떻게 정하는가?" 원형 버퍼는 거리 임계로 0 또는 1을 주고, 이동시간 권역은 같은 이분법을 통행 시간으로 바꾸며, 확률적 배분은 연속값으로 두고 경쟁 매장의 존재까지 반영함
- 강남구 사례는 카페 밀도가 높은 지역이므로 **확률적 배분(흡인 모형)**을 씀

4.4 실습 준비

- 5절부터 9절까지는 설명과 실습을 나누지 않음 — 각 절 첫머리에 실행할 명령이 나오고 그 아래에 코드와 실제 실행 결과가 이어짐. 순서대로 따라가면 이 장의 모든 수치를 직접 만들게 됨
- 먼저 패키지를 설치함. GPU는 필요 없고 노트북에서 끝까지 돌아감

```
cd geoai_public # 저장소 루트 - 이 장의 명령은 모두 여기서 실행함
pip install -r lecture_practice/requirements-student.txt
```

- 14장이 쓰는 패키지만 따로 보려면 `lecture_practice/chapter14/code/requirements.txt` 에 적혀 있으나, 설치하는 위 공통 파일 하나로 끝남
- 원자료 두 개를 내려받음. 이 장은 시뮬레이션 자료가 아니라 국내 공개 자료를 쓰므로 이 단계를 건너뛸 수 없음
- 내려받기 안내: `lecture_practice/chapter14/data/raw/README.md`
- 원자료가 각각 **300MB·180MB**로 큰 편이라 **14-0 실행에 몇 분이 걸릴 수 있음**
- 두 포털 모두 로그인 없이 파일을 받을 수 있지만, 다운로드가 자바스크립트로 처리되어 있어 **자동 내려받기 스크립트로는 못 받음**. 한 번은 직접 페이지에서 눌러 받아야 함
- 저장소에는 `data/` 폴더를 넣지 않으므로 위 README도 내려받기 전에는 보이지 않음 — 같은 절차가 실습 폴더의 `lecture_practice/chapter14/README.md` 에도 적혀 있음
- 이 장에서 실행할 코드는 두 개이며 순서가 정해져 있음

순서	실행할 파일	하는 일	절
1	<code>14-0-data-prep.py</code>	원자료 두 개를 강남구 카페·행정동 수요 파일로 정리	4.4
2	<code>14-1-huff-location-cannibalization.py</code>	흡인 모형으로 배분·자기잠식·순증을 계산하고 제약·민감도를 검토	5~9

- 2번은 1번이 만든 `cafes.parquet` · `demand_dong.parquet` 을 입력으로 받으므로 **1번을 먼저 실행**해야 함
- GPU는 필요 없고, 인터넷도 원자료를 받을 때만 필요함 — 두 코드 자체는 로컬 파일만 읽음
- 산출 파일은 후보지 540개의 배분·자기잠식·순증을 담은 `location_candidates.csv` 이고, 실행 로그는 `lecture_practice/chapter14/results/*.log` 에 남음
- 본문에 인용한 출력은 모두 `lecture_practice/chapter14/results/` 의 실행 로그에서 그대로 가져온 것이며, 어느 파일에서 왔는지를 출력 블록 첫 줄에 적어 두었음

□ 첫 번째 코드를 실행함. 2절에서 미리 적은 점포 수와 결합률이 여기서 나옴

```
python lecture_practice/chapter14/code/14-0-data-prep.py
```

```
# 출처: lecture_practice/chapter14/results/14-0-data-prep.log
```

```
[1/2] 상가(상권)정보
```

```
원본: 소상공인시장진흥공단_상가(상권)정보_서울_202606.csv (302 MB, utf-8-sig)
```

```
강남구 '카페' 점포 2123개, 행정동 22개
```

```
상호명 상위: {'스타벅스': np.int64(102), '투썸플레이스': np.int64(12), '매머드익스프레스': np.int64(7)}
```

```
[2/2] 생활인구(행정동)
```

```
원본: 행정동 단위 서울 생활인구(내국인).csv (179 MB, cp949)
```

```
행정동 424개 | 기간 20260612~20260731 | 11~15시 평균
```

```
결합 점검: 점포의 행정동코드 중 생활인구와 매칭 99.5% (2113/2123)
```

```
저장: cafes.parquet(2123행), demand_dong.parquet(424행), SOURCES.txt
```

□ 화면에 나온 값에서 읽을 것

○ 강남구 한 자치구의 소분류 '카페' 점포가 2,123개이고 행정동 22개에 걸쳐 있음 — 2절에서 말한 붐빔의 근거가 이 한 줄임

○ 상호명 1위 스타벅스가 102개로, 점포 수가 가장 많은 브랜드조차 전체의 5%에 미치지 못함. 5절의 자사 점유율 4.8%가 여기서 나옴

○ 결합률 99.5%(2,113/2,123)는 4.1의 1번 항목(공간 단위)을 실제로 점검한 값이며, 행정동코드가 생활인구 자료에 없는 점포 10개는 뒤 계산에서 빠짐

○ 생활인구는 서울 424개 동 전체를 11~15시 평균으로 집계해 두고, 그중 강남구 동만 뒤에서 결합해 씬 (4.2)

○ 기준 시점은 상가정보 2026년 6월판, 생활인구 2026-06-12~07-31임. 공개 자료가 갱신되면 아래 수치가 달라지므로 본문 수치는 이 기준과 함께 인용함

5. 흡인 모형으로 배분을 계산한다

□ 두 번째 코드를 실행함. 5절부터 9절까지의 모든 표가 이 한 번의 실행에서 나옴

```
python lecture_practice/chapter14/code/14-1-huff-location-cannibalization.py
```

출처: lecture_practice/chapter14/results/14-1-huff-location-cannibalization.log

대상: 강남구 카페 2113개 | 자사 102개 / 경쟁 2011개 (자사 점포 점유율 4.8%)

수요 단위: 행정동 21개 | 낮 활동 인구 합계 993,215명

후보지: 250m 격자 540개 | 자사 최근접 거리 중앙값 301m

□ 화면에 나온 값에서 읽을 것

○ 2절에서 미리 적은 자사 점유율 4.8%가 여기서 나옴 — 생활인구와 결합된 2,113개 가운데 자사가 102개, 경쟁이 2,011개임

○ 4.4에서 22개였던 행정동이 여기서 21개임 — 코드가 맞지 않아 빠진 점포 10개가 모두 한 동에 몰려 있어 그 동이 통째로 빠졌기 때문임

○ 후보지 540개는 점포 분포 범위에 250m 격자를 깔고 가장 가까운 점포까지 375m(격자 1.5칸) 이내인 칸만 남긴 것임 — 점포가 없는 구역에는 후보를 놓지 않음

○ 수요 지점은 21개인데 후보지는 540개임. 3.2에서 미리 적은 해상도 제약이 이 두 숫자의 차이로 드러남 — 같은 동 안의 후보지들은 같은 인구를 거리만 달리해 나눠 받음

○ 이 실행의 출력은 여섯 덩어리로 이어짐 — 표 14.4·14.5(9절), 자기잠식 상한 판정(7.2), 표 14.6·14.7과 퇴화 검사(7.3)

5.1 거리와 매력도가 반대로 작용할 때

□ 두 카페 사이 한가운데에 있는 수요 지점을 생각함

○ 가까운 쪽이 좌석 네 개짜리 작은 매장이고 먼 쪽이 넓은 매장이면, 이 지역 수요가 어느 쪽으로 얼마나 가는지는 거리만으로도 매력도만으로도 정해지지 않음

□ 두 힘의 상대 크기를 하나의 확률로 바꾸는 계산이 **흡인 모형**(Huff, 1963, 1964)임

1. **매장별 점수 계산**: 수요 지점 i 에서 매장 j 로 향하는 점수를 $s_{ij} = A_j / d_{ij}^\beta$ 로 구함
2. **수요 지점별 합산**: 그 지점에서 갈 수 있는 모든 매장의 점수를 더해 s_i 를 구함
3. **정규화**: 각 매장 점수를 합으로 나눠 확률 p_{ij} 를 만들. 이 나눗셈이 경쟁을 계산에 넣는 지점임
4. **인구 곱**: 지점 i 의 인구에 확률을 곱해 모든 지점에 대해 더하면 매장별 배분 수요가 나옴

$$p_{ij} = (A_j / d_{ij}^\beta) / \sum_k (A_k / d_{ik}^\beta)$$

□ **분모($\sum_k$)에 자사 매장과 경쟁사 매장이 함께 들어감**. 이것이 계산 구조의 핵심임

○ 경쟁 매장을 별도 변수로 넣는 것이 아니라 **분모에 항을 하나 더하는 방식**이므로, 매장이 하나 늘면 그 매장의 점수만큼 분모가 커지고 나머지 매장의 확률이 자동으로 줄어듦

5.2 계산 예 — 매장 셋으로 손으로 확인하기

□ 분모가 경쟁을 담는 구조는 작은 숫자로 손을 대 보면 확인됨

○ **계산 예:** 수요 지점 하나에 인구 1,000명이 있고, 매장 A는 매력도 1에 거리 200m, 매장 B는 매력도 2에 거리 400m라고 함. $\beta = 2.0$ 으로 계산함(거리는 100m 단위로 바꿔 각각 2와 4로 둠)

– 매장 A 점수: $1 / 2^2 = 0.250$

– 매장 B 점수: $2 / 4^2 = 0.125$

– 합: 0.375 → 확률은 각각 0.667, 0.333 → 배분은 667명, 333명

○ **매력도가 두 배인 B가 거리도 두 배라서 확률의 절반밖에 못 가져감.** 매력도는 1차로 들어가지만 거리는 $\beta = 2$ 제곱으로 들어가므로, 거리 효과가 매력도 효과보다 세게 작용한 것임

○ 여기에 매장 C(매력도 1, 거리 200m, A와 조건이 같음)를 추가하면 분모가 0.375에서 0.625로 커짐

매장	매력도	거리(100m)	점수	C 추가 전 배분	C 추가 후 배분	감소분
A	1	2	0.250	667명	400명	267명
B	2	4	0.125	333명	200명	133명
C(신규)	1	2	0.250	—	400명	—

□ 신규 매장 C가 400명을 받고, 그 400명은 정확히 A(267명)와 B(133명)에서 옮겨 옴

○ 우연이 아님 — **확률의 합이 항상 1이므로, 신규 매장이 받는 몫은 반드시 다른 매장에서 나올 수밖에 없음**

5.3 매력도와 β 는 어디서 구할까

○ 매력도(A)는 원칙적으로 매장 면적·좌석수·품목수 같은 자료에서 잼. **그런 자료가 없으면 모든 매장을 같은 값(상수)으로 두고 시작함** — 강남구 사례가 이 경우임

○ β 는 원칙적으로 실제 방문 자료(회원 앱 위치, 카드 결제 기록 등)로 추정함(Nakanishi & Cooper, 1974). 이런 자료가 없으면 업종의 통행 성격에 맞춰 몇 개 값을 정해 비교함

○ 강남구 사례는 둘 다 자료가 없는 조건임. 그래서 매력도는 상수에서 출발해 집적으로 바꿔 보고, β 는 1.5·2.0·2.5 세 값으로 비교함(7.3)

주의. β 와 매력도를 관행값으로 고정한 채 배분 수요의 **절대량**을 그대로 보고하면 안 됨. 7.3에서 확인하듯 β 를 1.5에서 2.5로 바꾸면 최선 후보의 순증이 721명에서 1,478명으로 두 배가 됨. 방문 자료로 β 를 추정하지 못했다면 **순위만 인용하고 절대량은 결정 근거로 쓰지 않음.**

6. 자기잠식과 순증을 가른다

□ 이 절의 강남구 수치는 5절에서 실행한 그 명령의 출력임. 계산이 코드의 어디에서 이루어지는지 먼저 확인함

```
# 주식에 붙인 출력의 출처: lecture_practice/chapter14/results/14-1-huff-location-cannibalization.log
# [1] 개점 전 - 수요 지점별 분모 D와 그중 자사 몫 S
D = w.sum(axis=1)
S = w[:, own_mask].sum(axis=1)

# [2] 개점 후 - 분모에 신규점 항 a가 하나 늘어남
Dn = D[:, None] + a

# [3] 신규점 배분(gross)과 자사 기존점 감소분(loss)
gross = (pop[:, None] * a / Dn).sum(axis=0)
loss = (pop[:, None] * S[:, None] * (1.0 / D[:, None] - 1.0 / Dn)).sum(axis=0)
# 출력: 총배분 1위: 배분 1,228명, 전이율 6.5%, 순증 1,148명
#       전이율 분포: 중앙값 4.8%, 최대 6.6%
```

□ 화면에 나온 값에서 읽을 것

- `Dn = D + a` 한 줄이 6.2의 2단계를 그대로 옮긴 것임 — 신규점을 놓아도 전체를 다시 계산하지 않고 분모에 항 하나만 더함
- `loss`에는 `S`(자사 몫)만 곱해져 있음 — 경쟁사가 잃은 몫은 자기잠식에 넣지 않는다는 6.2의 3단계가 이 곱셈 하나로 표현됨
- 총배분 1위 후보의 전이율 6.5%는 후보 540개의 중앙값 4.8%보다 높음. 배분이 큰 후보일수록 전이율도 높게 나왔다는 뜻이며, 그래서 배분이 아니라 순증으로 다시 정렬함

6.1 전이율의 정의는 하나가 아니다

□ 전이율은 자사 기존점에서 옮겨 온 몫을 어떤 기준으로 나눈 비율임. 문제는 그 기준(분모)이 하나로 정해져 있지 않다는 점임

- 정의 A(신규점 배분 대비): 자사 기존점 감소분 합계 / 신규점 배분 수요. "신규점이 받은 수요 가운데 몇 퍼센트가 자기 것을 옮겨 온 것인가"
- 정의 B(기존점 개점 전 배분 대비): 자사 기존점 감소분 합계 / 자사 기존점의 개점 전 배분 수요. "기존 매장이 원래 받던 수요의 몇 퍼센트를 잃는가"

□ 5.2의 계산 예로 두 값을 비교함. 매장 A와 C가 자사라고 하면 **정의 A로는 $267 / 400 = 66.8\%$, 정의 B로는 $267 / 667 = 40.0\%$ **임

- 같은 상황을 두고 66.8%와 40.0%라는 서로 다른 숫자가 나옴. 이 장은 정의 A를 기준으로 씀

주의. 산출표에 전이율을 적을 때는 반드시 분모가 무엇인지 열 이름에 함께 적어야 함(예: "전이율 (신규점 배분 대비)"). 가맹계약 조항이나 회사 내부 기준이 다른 정의를 쓰고 있을 수 있음.

6.2 계산 절차 네 단계

1. **개점 전 배분 계산:** 신규점 없이 각 지점의 배분 확률을 계산하고 자사 기존점의 배분 수요를 기록함
2. **개점 후 배분 재계산:** 신규점을 후보지에 놓고 다시 계산함. **분모에 항이 하나 늘어 모든 기존 매장의 확률이 줄어듦**
3. **자사 감소분 합산:** 자사 기존점의 감소분만 더함. **경쟁사가 잃은 몫은 자기잠식이 아니므로 여기 넣지 않음**
4. **전이율과 순증 산출:** 전이율 = 자사 감소분 / 신규점 배분, 순증 = 신규점 배분 - 자사 감소분

□ **순증이 정렬의 기준이 되어야 함.** 두 후보의 신규점 배분이 같아도 자사 매장에 가까운 쪽은 감소분이 커서 순증이 작음

○ 배분 수요로만 순위를 매기면 자사 매장이 몰린 지역의 후보가 상위에 오르는데, **그 지역은 이미 자사가 수요를 받고 있어 회사 전체로는 늘어나는 양이 적음**

6.3 자사 점유율이 낮으면 잠식도 작다

□ 자사 감소분은 수요 지점마다 *****자사 매장의 원래 점유율 × 신규점의 새 점유율*****에 비례하는 값을 모두 더한 것임

○ 자사 매장의 원래 점유율이 낮으면(경쟁이 심하고 자사 매장 수가 적으면) 이 값도 작아지고, 더할 항의 개수도 적음. **그래서 전체 자기잠식이 작게 계산됨**

○ 이 관계가 강남구 사례에서 실제로 확인됨. **자사(스타벅스) 점유율이 4.8%로 낮으므로 신규 매장이 받는 수요의 대부분이 경쟁 브랜드에서 옴**

□ 실증 연구도 같은 방향을 보고함. Pancras, Sriram, Kumar(2012)는 한 체인의 출점 이력을 분석해 신규 매장 매출의 86.7%가 순증이고, **매장 사이 거리가 1마일 멀어질 때마다 잠식되는 매출이 28.1%씩 줄어 10마일에서는 거의 사라진다고 보고함**

○ 즉 **자기잠식은 거리가 멀수록, 자사 점유율이 낮을수록 작아짐.** 이 관계 때문에 이격 거리를 제약으로 걸어 잠식을 통제할 수 있음(7.2)

6.4 이 계산이 놓치는 것 — 고정 시장 가정

□ 5.2의 계산 예에서 **신규 매장 배분(400명)과 기존 매장 감소분 합계(400명)가 정확히 일치했음**

○ 이 항등식은 우연이 아니라 모형의 구조에서 나옴 — **확률의 합이 항상 1이므로, 시장 전체 크기가 고정되어 있다는 가정이 계산에 이미 새겨져 있음**

- 실제 시장에서는 세 가지가 함께 일어남: 자사 매장 수요를 가져가는 자기잠식, 경쟁사 수요를 가져가는 경쟁사 잠식, 그리고 **매장이 늘어 그 지역을 찾는 사람 자체가 늘어나는 시장 확대**
- 이 흡인 모형은 앞의 둘은 계산하지만 셋째는 계산에 담지 못함. 총수요가 상수로 고정되어 있어서, 매장 수가 늘어도 나눠 가지는 총량이 그대로이기 때문임
- 셋을 분리하려면 개점을 하나의 처치로 보고 개점 후 관측 자료에서 효과를 식별해야 함. **이 장은 개점 전에 모형이 가정한 재배분을 계산해 후보를 고르는 데까지 다루고, 개점 후 그 재배분이 실제로 일어났는지 확인하는 방법은 15장이 다름**

7. 점수를 만들고 제약으로 거른다

- 이 절에서 새로 실행할 명령은 없음 — 7.2의 제약 판정과 7.3의 민감도·퇴화 검사는 모두 5절에서 한 번 실행한 `14-1-huff-location-cannibalization.py`의 출력이며, 표마다 로그의 어느 구간에서 왔는지를 적어 둠

7.1 여러 변수를 하나의 점수로 합치기

- 실제 출점 검토는 배분·순증 외에 접근성·비용·규제도 함께 봄. 단위가 다른 여러 변수를 하나로 묶는 절차가 **입지 점수** 모형이며 네 단계로 이루어짐

1. **변수 선정**: 수요·경쟁·접근성·비용·규제 다섯 범주에서 고름. 결정에 실제로 영향을 주는 변수만 넣음
2. **방향 정렬**: 값이 클수록 좋은 변수(활동 인구)와 작을수록 좋은 변수(임대료)가 섞여 있으므로 정규화 전에 모두 "클수록 좋다"로 맞춤
3. **정규화**: 단위가 다른 변수를 같은 척도로 옮김
4. **가중합**: 정규화한 값에 가중치를 곱해 더함(가중치 합은 1)

- 규제처럼 "통과냐 아니냐"로만 걸리는 변수는 점수에 넣지 않고 7.2의 제약으로 처리함

주의. 상관이 높은 두 변수를 함께 가중합에 넣으면 그 축이 두 번 계산됨. "도보 10분 활동 인구"와 "지하철역까지 거리"가 상관 0.9인데 각각 가중치 0.3을 주면, 사실상 접근성이라는 하나의 축이 0.6의 비중을 갖게 됨. 가중치를 정하기 전에 변수 간 상관을 먼저 확인해야 함.

7.2 상한을 낮추면 무엇을 포기하는가

- 최소 조건이 있는 변수(임대료 상한, 전이율 상한)는 가중합이 아니라 **제약**으로 처리함. 임대료가 예산을 넘으면 다른 조건이 아무리 좋아도 계약할 수 없기 때문임
- **제약값을 정하는 일은 후보를 거르는 일이면서 동시에 순증을 포기하는 일이기도 함**
- 아래 표는 5절에서 실행한 로그의 "결정 — 자기잠식 상한은 언제 구속력을 갖는가" 구간을 옮긴 것임

상한	통과 후보	통과율	판정	대안 순증
30%	540/540	100.0%	구속하지 않음	1,148명(최선 후보 유지)
10%	540/540	100.0%	구속하지 않음	1,148명(최선 후보 유지)
6%	490/540	90.7%	구속함	872명(-24.0%)
5%	312/540	57.8%	구속함	872명(-24.0%)
4%	36/540	6.7%	구속함	872명(-24.0%)

□ 전이율 분포는 중앙값 4.8%, 최대 6.6%임. **그래서 30%와 10% 상한은 후보를 하나도 못 거름**

○ 6%에서 처음으로 순증 1위 후보가 탈락하고 대안 후보의 순증은 872명으로 24.0% 낮아짐. 상한을 더 낮춰도 통과 후보 수만 줄 뿐 대안 순증은 그대로 872명임

○ 이 표는 "상한을 몇 %로 하라"고 정해 주지 않음. 상한을 낮추는 일이 순증을 얼마나 포기하는 일인지 숫자로 보여 줄 뿐임. 실제 상한은 자기잠식을 허용했을 때의 비용(가맹점 매출 감소, 계약 분쟁)과 유망한 자리를 포기했을 때의 비용(순증 손실, 경쟁사 선점)을 비교해 정함

7.3 가정을 바꿔도 순위가 유지되는가

○ 강남구 사례에서 자료 없이 정한 값은 두 개, β 와 매력도(A)임

○ 아래 표는 같은 로그의 표 14.6(거리 저항 β)과 표 14.7(매력도 A)을 하나로 합친 것임

구분	설정	평균 전이율	최선 후보 순증	기준 대비 위치 이동
거리 저항 β	1.5	4.9%	721명	0m
	2.0(기준)	4.9%	1,148명	0m
	2.5	4.9%	1,478명	0m
매력도 A	상수(기준)	—	1,148명	0m
	집적도(50m 내 점포수)	—	1,501명	0m

□ 세 가지를 확인함

○ 순증의 절대량은 가정에 따라 크게 흔들림 — β 를 1.5에서 2.5로 바꾸면 721명에서 1,478명으로 두 배가 됨. 이 값을 매출 예측처럼 쓰면 안 됨

○ 최선 후보의 위치는 다섯 설정 모두에서 같음(이동 0m). 순위를 만드는 것은 β 나 A가 아니라 수요와 경쟁의 공간 배치임

○ 평균 전이율은 β 세 값에서 모두 4.9%로 같음. β 가 배분의 절대량은 바꾸지만 자사와 경쟁사가 나눠 갖는 비율 구조는 거의 그대로라는 뜻임

□ 마지막으로 ***이 결과가 그냥 인구 지도를 되풀이하는 것은 아닌가***도 확인함(퇴화 검사)

출처: lecture_practice/chapter14/results/14-1-huff-location-cannibalization.log

퇴화 검사 - 결과가 '사람 많은 곳'을 되풀이하는 데 그치는가

총배분 ~ 최근접 행정동 낮인구 상관: -0.051

순증 ~ 최근접 행정동 낮인구 상관: -0.052

순증 ~ 자사 최근접 거리 상관 : -0.046

□ 화면에 나온 값에서 읽을 것

○ 총배분과 최근접 행정동 낮 인구의 상관은 -0.051 , 순증과 낮 인구의 상관은 -0.052 , 순증과 자사 최근접 거리의 상관은 -0.046 임. 세 값 모두 0에 가까움

○ 인구가 많은 지역에는 카페도 많아서 큰 수요를 많은 매장이 나눠 가짐. 그래서 배분 수요가 인구 지도를 그대로 따라가지 않음. 만약 이 상관이 0.9처럼 높게 나왔다면 복잡한 흡인 모형을 계산할 필요 없이 인구 상위 지역을 고르는 것과 결과가 같았을 것임

8. 위치 자료를 써도 되는가

8.1 네 물음으로 판정한다

○ 위치 자료는 이름을 지워도 이동 궤적 자체가 개인을 특정하는 정보로 작동함. 그래서 "식별 정보를 지웠다"는 사실만으로는 써도 된다는 근거가 되지 않음

#	물음	"예"일 때 처리
1	이 해상도에서 개인의 하루 궤적이 복원되는가	시간·공간 해상도를 낮춘 뒤 다시 판정
2	다른 자료와 결합하면 해상도가 실질적으로 올라가는가	결합하지 않거나, 결합 후 자료로 1번을 다시 판정
3	산출물이 개인·가구 단위 처우로 내려가는가	산출 단위를 집계 단위로 올림
4	라이선스가 이 용도를 허용하는가	허용 범위 안으로 한정

□ 실제로 얼마나 조심해야 하는지는 정량 근거가 있음. de Montjoye 외(2013)는 150만 명의 이동 자료로 시공간 지점 네 개만 알면 95%의 개인이 유일하게 특정된다는 것을 보였음

○ 더 중요한 발견은 해상도를 낮춰도 유일성이 그에 비례해서는 줄지 않는다는 점임 — 거칠게 집계한 자료가 곧 안전한 자료라는 뜻은 아님

○ 강남구 사례의 산출물(후보지 순위표)은 개인이 아니라 격자를 대상으로 하므로 3번 물음은 통과함. 다만 같은 계산 결과가 나중에 지역별 배달 요금 차등 같은 개인 단위 처우로 이어진다면, 그 시점에 판정을 다시 해야 함

8.2 결과가 나온 뒤에도 감사가 필요하다

○ 계산이 맞았다고 해서 끝이 아님. 각각의 결정이 개별적으로는 합리적이어도, 그 결정들이 쌓이면 특정 지역에 몰릴 수 있음

범주	지표	판정 기준
점수 분포	지역별 입지 점수의 평균·분산	특정 지역이 계속 하위에 고정되는가
커버리지	인구 집단별 서비스 도달 비율	집단 간 차이가 벌어지는가
철수 누적	철수 결정이 발생한 지역의 분포	같은 지역에 철수가 반복되는가
자료 되먹임	산출물 적용 이후 그 지역 입력 자료의 변화	자료 악화가 산출물 때문인가

□ **되먹임은 특히 주의할 현상임.** 입지 점수가 낮게 나온 지역에서 상업 서비스가 하나씩 빠져나가면, 유동인구·매출이 줄어든 상태가 다음 분석의 입력 자료가 됨. 그러면 그 지역의 점수가 더 낮아지고 더 많은 서비스가 빠져나가는 순환이 생길 수 있음

○ 순환을 끊는 방법 하나는 **입력 자료의 시점을 이전 회차 결정이 적용되기 전으로 고정하는 것임**

9. 사례 전체: 강남구 카페

○ 앞 절에서 나온 숫자들을 결정의 흐름 순서로 다시 정리함. 여기서도 새로 실행할 명령은 없고, 5절에서 실행한 같은 로그를 결정 순서로 다시 늘어놓은 것임

단계별 값

- **결정·단위:** 신규 출점. 후보지는 점포 분포 범위에 칸 250m 격자 540개, 수요 지점은 행정동 21개, 매장은 점 단위. 자사 최근접 거리 중앙값 301m
- **자료:** 강남구 카페 원자료 2,123개 중 활동 인구와 결합된 2,113개(결합률 99.5%)가 분석 대상. 자사 102개, 경쟁 2,011개, 자사 점유율 4.8%. 21개 행정동 낮 활동 인구 합계 993,215명
- **수요:** 각 행정동의 대표점은 그 동에 있는 카페 좌표의 중심으로 잡음(상업 밀도 중심점)
- **배분·잠식:** $\beta = 2.0$, 매력도 상수로 계산
- 아래 두 표는 5절에서 실행한 로그의 표 14.4(상위 10곳)와 표 14.5(거리대별)를 그대로 옮긴 것임

총배분 순위	자사 최근접(m)	예상 배분(명)	자기잠식(명)	전이율	순증(명)
1	129	1,228	80	6.5%	1,148
2	180	1,221	80	6.6%	1,141
3	338	1,214	80	6.6%	1,134
4	416	1,213	80	6.6%	1,134
5	373	1,208	79	6.6%	1,129
6	144	1,203	79	6.6%	1,124
7	529	1,203	79	6.6%	1,123
8	385	1,199	79	6.6%	1,120
9	334	1,088	71	6.5%	1,017
10	633	1,070	71	6.6%	999

□ 총배분 순위와 순증 순위가 열 곳 모두에서 일치함. 자기잠식이 71~80명, 전이율이 6.5~6.6%로 좁은 범위에 머물러 순위를 뒤집을 만큼 크지 않기 때문임

○ 6.3에서 확인한 대로, 자사 점유율(4.8%)이 낮아서 신규 매장이 가져오는 수요의 대부분이 경쟁 브랜드에서 옴

거리와 전이율의 관계

거리대(m)	후보 수	평균 전이율	평균 순증(명)
~300	268	4.9%	430
300~500	129	5.0%	410
500~800	68	5.3%	355
800~1200	41	4.7%	335
1200~2000	34	3.7%	476

□ 거리와 전이율의 상관은 -0.333 임. 방향(멀수록 잠식이 작아짐)은 6.3의 이론과 맞지만, 구간별 평균이 단조롭게 줄지는 않음(500~800m 구간이 앞 두 구간보다 오히려 높음)

○ 이 불일치는 자료의 한계에서 나옴. 수요가 행정동 단위이므로 같은 동 안의 후보지들이 비슷한 값을 받고, 거리 차이가 행정동 경계에 흡수되기 때문임(3.2)

○ 그래서 이 사례에서는 거리를 제약(이격 거리 조건)으로는 쓰되 순증의 대리 지표로는 쓰지 않음

이 계산이 지지하는 것과 지지하지 않는 것

- **지지하는 것 셋**: 후보 사이의 상대 순위, 이 브랜드의 낮은 점유율 조건에서는 자기잠식 제약의 구속력이 약하다는 판정, 배분 수요가 인구를 그대로 따라가지 않는다는 사실(퇴화 검사)
- **지지하지 않는 것 셋**: 배분 수요의 절대량(β 에 따라 두 배까지 변함), 예상 매출(매출 자료가 없음), 개점 후 실제로 관측될 자기잠식의 크기(모형이 가정한 재배분일 뿐임)
- **이 사례에는 학습 모델이 하나도 쓰이지 않았음**. 학습 모델이 필요한 조건은 셋인데 — 개점 전이라 관측되지 않는 값을 추정해야 할 때, 변수 사이 관계가 심하게 휘어 있을 때, 이웃 지역의 상태가 이 지역 결과를 만들 때 — 이 사례는 어디에도 해당하지 않음. 반경 안 인구를 더하거나 거리를 재는 일은 답이 하나로 정해짐

10. 같은 계산의 다른 방향: 미진출 지역과 철수

단계	신규 출점	미진출 지역 진입	철수
대상·단위	후보 격자	후보 = 진출 대상 도시 목록	대상 = 자사 기존점 목록
배분	신규점 포함 재계산	좌동	대상점 제거 후 재계산
잠식	자사 감소분	해당 없음(자사 집합이 공집합)	남은 자사 매장의 회수분
선택	순증 최대, 전이율 상한	배분 최대, 임대료·용량 상한	손실 최소 = 배분 - 회수분

○ **미진출 지역 진입**: 자사 매장이 아예 없는 지역에 첫 매장을 낼 때는 잠식 계산이 통째로 빔. **계산 코드 자체는 바뀌지 않음** — 자사 매장 목록을 빈 목록으로 두면 같은 계산이 "순증 = 배분"을 만들어 냄. 다만 자사 기존점 실적과 비교할 대상이 없으므로 배분 수요의 절대량을 더욱 조심해서 다뤄야 함

□ **철수**: 자사 매장 하나를 없애고 배분을 다시 계산하면 분모에서 항이 하나 빠져 남은 모든 매장의 확률이 올라감. 올라간 몫 가운데 자사 매장이 회수하는 부분이 **회수분**이고, 철수 손실 = 제거된 매장의 배분 - 회수분임

○ 5.2의 계산 예를 거꾸로 돌리면 확인됨. 매장 A와 C가 자사일 때 C를 닫으면 분모가 다시 줄어 A는 667명으로 돌아감. **회수분은 $667 - 400 = 267$ 명, 회수율 66.8%, 철수 손실은 $400 - 267 = 133$ 명임**

○ **이 값이 6.1에서 본 전이율(66.8%)·순증(133명)과 똑같음**. 출점과 철수가 같은 계산의 두 방향이기 때문임 — **자사 점유율이 높을수록 출점 시 전이율이 크고, 철수 시 회수율도 큼**

○ 5.2의 계산 예를 양방향으로 놓으면 이 대칭이 한눈에 들어옴(A·C가 자사, B가 경쟁사, 인구 1,000명)




그림 14.1 같은 계산의 두 방향. **출점에서 자사가 잃는 267명과 철수에서 자사가 되찾는 267명이 같은 수임** — 확률의 분모에 항이 하나 늘고 주는 차이뿐이기 때문이며, 그래서 출점 시 전이율과 철수 시 회수율이 같은 값(66.8%)으로 나옴

- 회수분은 흡인 모형이 계산한 재배분일 뿐이며, 실제로 그만큼 회수되는지는 폐점 후 관측 자료로 확인해야 함. 폐점한 매장의 손님이 같은 브랜드가 아니라 경쟁사로 옮기면 실제 회수율은 계산보다 낮음. 이 확인은 15장의 영역임
- 이 절의 두 사례에는 실행 결과를 붙이지 않음. 이 장의 실습 코드가 강남구 신규 출점 사례만 다루기 때문이며, 위 서술은 계산 구조에서 그대로 도출한 것임

11. 핵심 요약

- 출점 결정은 배분 수요가 아니라 순증으로 정렬함. 자사 매장에 가까운 후보는 감소분이 커서, 배분이 같아도 회사 전체로 늘어나는 양이 적음 (6.2)
- 매장이 하나 늘면 나머지 전부의 확률이 함께 줄어듦. 경쟁을 별도 변수로 넣는 것이 아니라 분모에 항을 더하는 구조이기 때문임 (5.1)
- 신규 매장이 받는 몫은 반드시 다른 매장에서 옴. 계산 예에서 신규 400명이 정확히 A 267명 + B 133명이었음 (5.2)
- 전이율은 분모를 무엇으로 두느냐로 66.8%와 40.0%가 같림. 산출표 열 이름에 분모를 함께 적어야 함 (6.1)
- 자사 점유율이 낮으면 자기잠식도 작게 계산됨. 강남구 사례의 점유율 4.8%가 전이율 6.5%를 만들었고, 실증 연구도 같은 방향을 보고함 (6.3)
- 이 모형은 시장 확대를 계산하지 못함. 확률의 합이 1이라 총수요가 고정되어 있고, 개점 후 실제 재배분의 확인은 15장이 다름 (6.4)
- 가장 거친 단위가 분석 전체의 해상도를 정함. 후보지를 250m로 촘촘히 깔아도 수요가 행정동 단위면 같은 동 안의 후보는 거의 같은 값을 나눠 받음 (3.2, 9절)
- 절대량은 가정에 흔들리지만 순위는 흔들리지 않음. β 를 바꾸면 순증이 721명에서 1,478명으로 두 배가 되는데 최선 후보의 위치는 0m 이동이었음 (7.3)
- 퇴화 검사로 모형이 인구 지도의 되풀이가 아님을 확인함. 배분과 낮 인구의 상관이 -0.051로 0에 가까웠음 (7.3)
- 거칠게 집계한 자료가 곧 안전한 자료는 아님. 시공간 지점 네 개로 95%가 특정되고, 해상도를 낮춰도 유일성이 비례해 줄지 않음 (8.1)
- 이 사례에는 학습 모델이 하나도 쓰이지 않았음. 반경 안 인구를 더하고 거리를 재는 계산은 답이 하나로 정해지며, 학습이 필요한 세 조건 어디에도 해당하지 않았기 때문임 (9절)

12. 과제

```
python scripts/submit.py 14 --id 학번 --name 이름
```

□ 이 명령이 대신 처리하는 작업: `14-0-data-prep.py` 와 `14-1-huff-location-cannibalization.py` 실행, 제출용 파일 생성

○ 원자료 두 개를 먼저 받아야 하므로 `lecture_practice/chapter14/data/raw/README.md` 의 절차를 먼저 읽음

○ 끝나면 `submissions/` 폴더에 `제출_14장_학번.md` 파일이 생김

○ 눈여겨볼 곳은 후보지별 배후 수요와 기존 점포에서 옮겨 오는 몫(전이율)

○ 빈칸 세 개를 채움

1. 눈에 띈 숫자 하나를 그대로 옮겨 적고, 왜 눈에 띄었는지 한 문장으로
2. 그 숫자가 왜 그렇게 나왔는가 — 전이율이나 순증이라면 6.3의 논리로 설명하라
3. 순증이 가장 큰 후보가 곧 최선인가? 이 계산에 학습 모델이 하나도 쓰이지 않았다는 사실은 무엇을 말하는가?

○ 3번이 이 과제의 핵심. 1,2번은 로그를 보면 답이 나오지만 3번은 판단이 필요함

- **막혀도 제출함**

- 원자료 내려받기가 막혀 14-0을 못 돌렸다면, 어느 단계에서 막혔는지(포털 접속, 파일 형식, 인코딩 등)를 적은 제출도 온전한 제출임

- **이 장의 계산은 원자료가 갱신되면 수치가 달라짐**

- 그래서 옆 사람과 정확히 같은 숫자가 안 나올 수 있음
- 대신 구조(총배분 순위와 순증 순위가 거의 일치하는가, 거리~전이율 상관이 음수인가, β 를 바꿔도 최선 후보 위치가 고정되는가)가 같은지 확인함